第一讲：基本概念

April 11, 2026

大纲

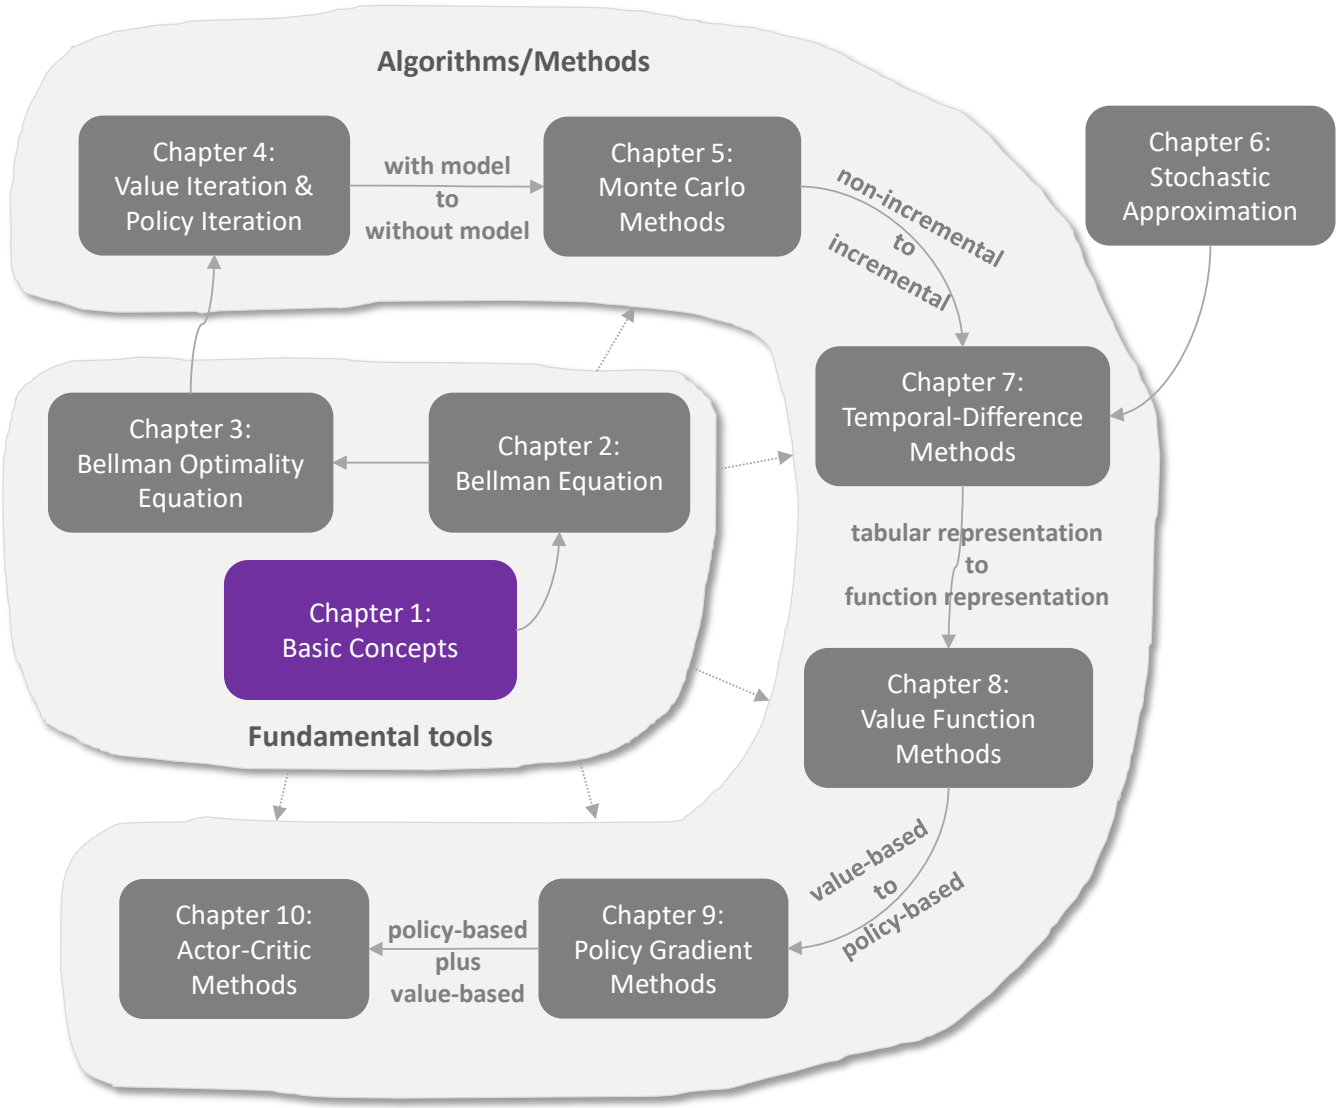
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

内容

- 首先，通过示例介绍强化学习（RL）中的基本概念。
- 其次，在马尔可夫决策过程的框架下对这些概念进行形式化。

网格世界示例

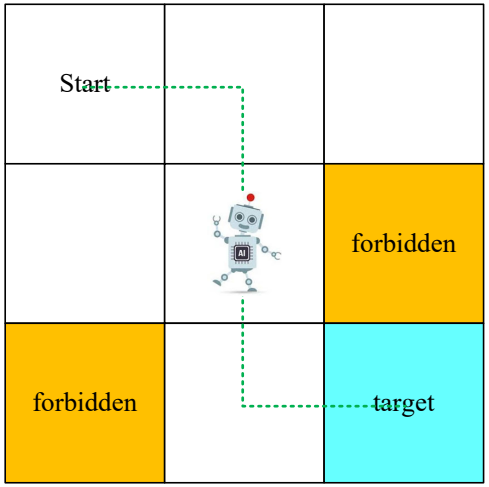

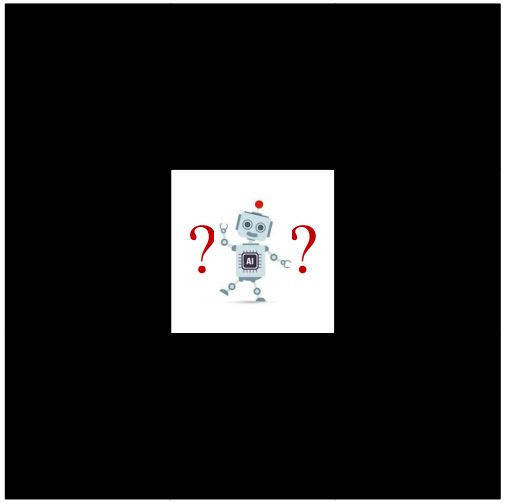

本课程中贯穿使用的一个示例：

- 由单元格组成的网格：可通行格/禁止格/目标格，以及边界。
- 非常直观，便于说明问题。

任务：

- 从任意起点出发，找到一条到达目标的"好"路径。
- 如何定义"好"？避开禁止格、绕路或越界。

网格世界示例

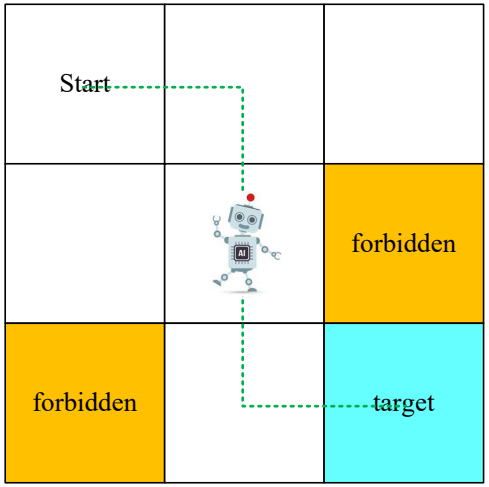

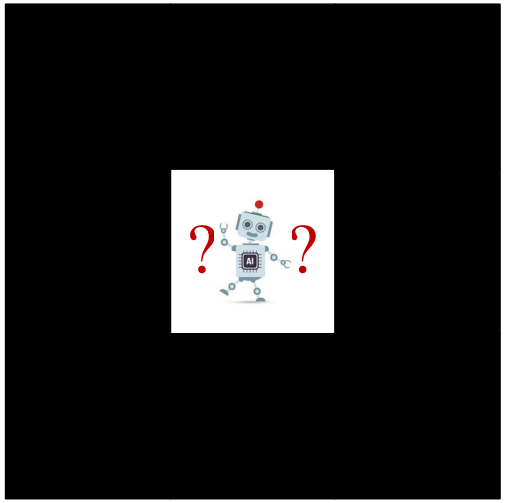

本课程中贯穿使用的一个示例：

- 由单元格组成的网格：可通行格/禁止格/目标格，以及边界。
- 非常直观，便于说明问题。

任务：

- 从任意起点出发，找到一条到达目标的"好"路径。
- 如何定义"好"？避开禁止格、绕路或越界。

状态

状态：智能体相对于环境的状态。

- 在网格世界示例中，智能体的位置即为状态。共有九个可能的位置，因此有九个状态：$s_1, s_2, \ldots, s_9$。

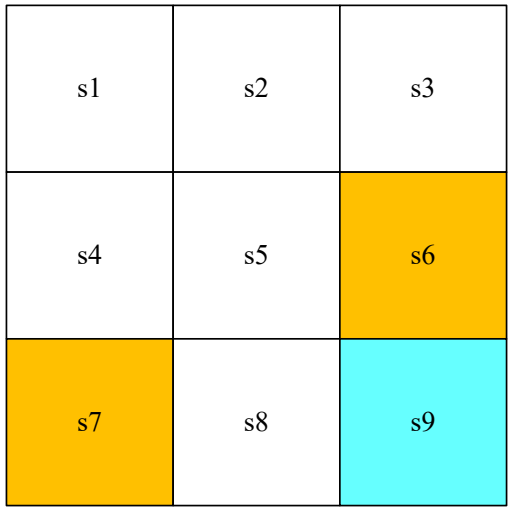

状态空间：所有状态的集合 $\mathcal{S} = \{s_i\}_{i=1}^{9}$。

状态

状态：智能体相对于环境的状态。

- 在网格世界示例中，智能体的位置即为状态。共有九个可能的位置，因此有九个状态：$s_1, s_2, \ldots, s_9$。

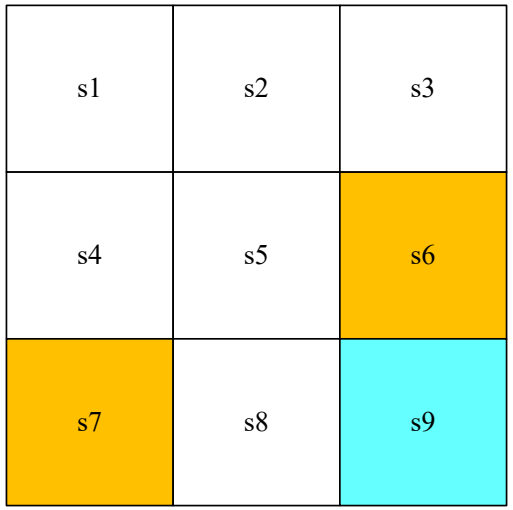

状态空间：所有状态的集合 $\mathcal{S} = \{s_i\}_{i=1}^{9}$。

动作

动作：在每个状态下，有五种可能的动作：$a_1, \ldots, a_5$

- a_1：向上移动；
- a_2：向右移动；
- a_3：向下移动；
- a_4：向左移动；
- a_5：保持不动；

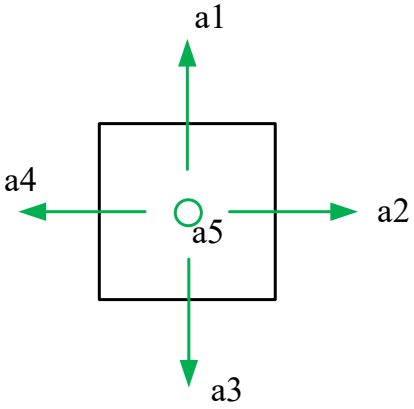

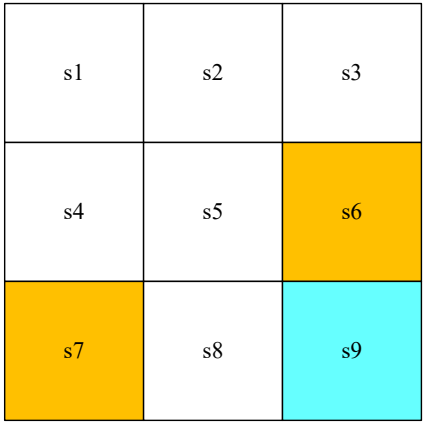

状态的动作空间：某状态下所有可能动作的集合。$\mathcal{A}(s_i) = \{a_k\}_{k=1}^{5}$。
问题：不同状态可以有不同的动作集合吗？

动作

动作：在每个状态下，有五种可能的动作：$a_1, \ldots, a_5$

- a_1：向上移动；
- a_2：向右移动；
- a_3：向下移动；
- a_4：向左移动；
- a_5：保持不动；

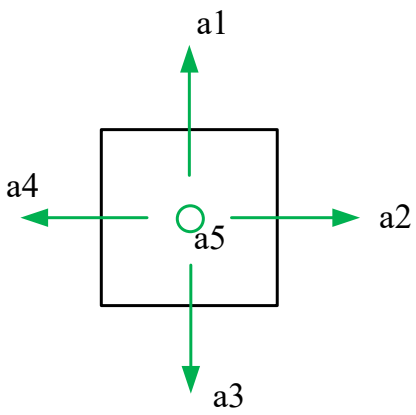

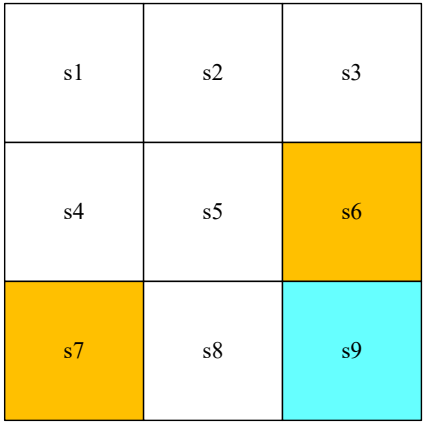

状态的动作空间：某状态下所有可能动作的集合。$\mathcal{A}(s_i) = \{a_k\}_{k=1}^{5}$。

问题：不同状态可以有不同的动作集合吗？

动作

动作：在每个状态下，有五种可能的动作：$a_1, \ldots, a_5$

- a_1：向上移动；
- a_2：向右移动；
- a_3：向下移动；
- a_4：向左移动；
- a_5：保持不动；

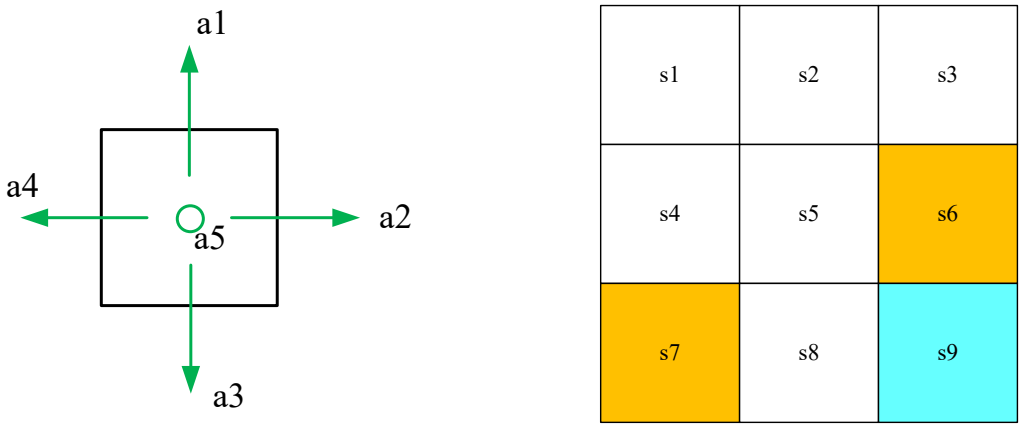

状态的动作空间：某状态下所有可能动作的集合。$\mathcal{A}(s_i) = \{a_k\}_{k=1}^{5}$。
问题：不同状态可以有不同的动作集合吗?

状态转移

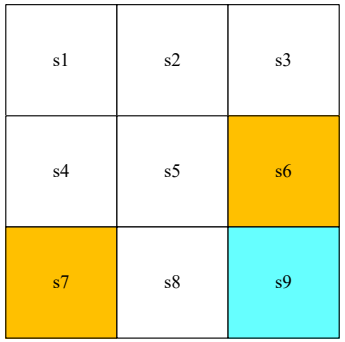

智能体执行动作后，可能从一个状态转移到另一个状态，这一过程称为状态转移。

- 示例：在状态 s_1 下，若选择动作 a_2，下一状态是什么？

$$s_1 \xrightarrow{a_2} s_2$$

- 示例：在状态 s_1 下，若选择动作 a_1，下一状态是什么？

$$s_1 \xrightarrow{a_1} s_1$$

- 状态转移描述了与环境的交互过程。
- 问题：能否以其他方式定义状态转移？仿真与物理的区别。

状态转移

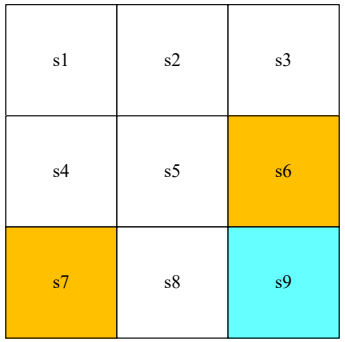

智能体执行动作后，可能从一个状态转移到另一个状态，这一过程称为状态转移。

- 示例：在状态 s_1 下，若选择动作 a_2，下一状态是什么？

$$s_1 \xrightarrow{a_2} s_2$$

- 示例：在状态 s_1 下，若选择动作 a_1，下一状态是什么？

$$s_1 \xrightarrow{a_1} s_1$$

- 状态转移描述了与环境的交互过程。
- 问题：能否以其他方式定义状态转移？仿真与物理的区别。

状态转移

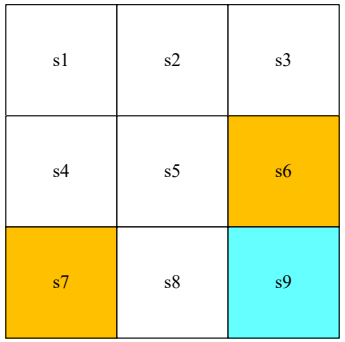

智能体执行动作后，可能从一个状态转移到另一个状态，这一过程称为状态转移。

- 示例：在状态 s_1 下，若选择动作 a_2，下一状态是什么？

$$s_1 \xrightarrow{a_2} s_2$$

- 示例：在状态 s_1 下，若选择动作 a_1，下一状态是什么？

$$s_1 \xrightarrow{a_1} s_1$$

- 状态转移描述了与环境的交互过程。
- 问题：能否以其他方式定义状态转移？仿真与物理的区别。

状态转移

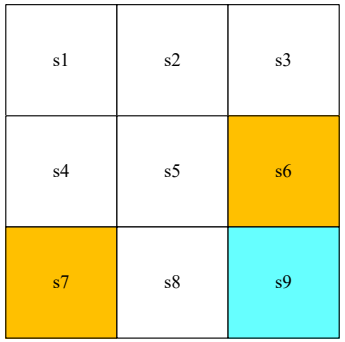

智能体执行动作后，可能从一个状态转移到另一个状态，这一过程称为状态转移。

- 示例：在状态 s_1 下，若选择动作 a_2，下一状态是什么？

$$s_1 \xrightarrow{a_2} s_2$$

- 示例：在状态 s_1 下，若选择动作 a_1，下一状态是什么？

$$s_1 \xrightarrow{a_1} s_1$$

- 状态转移描述了与环境的交互过程。
- 问题：能否以其他方式定义状态转移？仿真与物理的区别。

状态转移

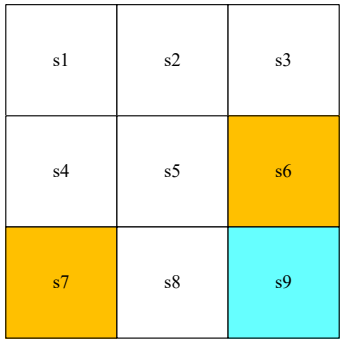

智能体执行动作后，可能从一个状态转移到另一个状态，这一过程称为状态转移。

- 示例：在状态 s_1 下，若选择动作 a_2，下一状态是什么？

$$s_1 \xrightarrow{a_2} s_2$$

- 示例：在状态 s_1 下，若选择动作 a_1，下一状态是什么？

$$s_1 \xrightarrow{a_1} s_1$$

- 状态转移描述了与环境的交互过程。
- 问题：能否以其他方式定义状态转移？仿真与物理的区别。

状态转移

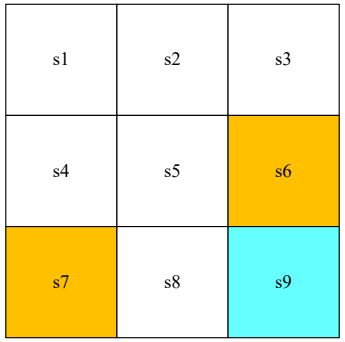

注意禁止区域：示例：在状态 s_5 下，若选择动作 a_2，下一状态是什么？

- 情形一：禁止区域可进入，但有惩罚。则

$$s_5 \xrightarrow{a_2} s_6$$

- 情形二：禁止区域不可进入（例如，被墙围住）

$$s_5 \xrightarrow{a_2} s_5$$

- 本课程讲授中考虑情形一，更具一般性和挑战性。
- 作业中考虑情形二！

状态转移

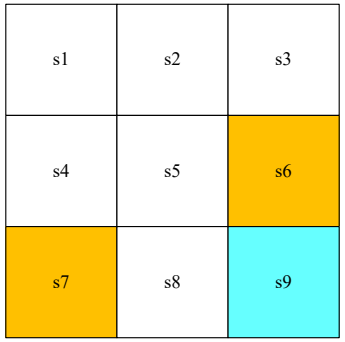

注意禁止区域：示例：在状态 s_5 下，若选择动作 a_2，下一状态是什么？

- 情形一：禁止区域可进入，但有惩罚。则

$$s_5 \xrightarrow{a_2} s_6$$

- 情形二：禁止区域不可进入（例如，被墙围住）

$$s_5 \xrightarrow{a_2} s_5$$

- 本课程讲授中考虑情形一，更具一般性和挑战性。
- 作业中考虑情形二！

状态转移

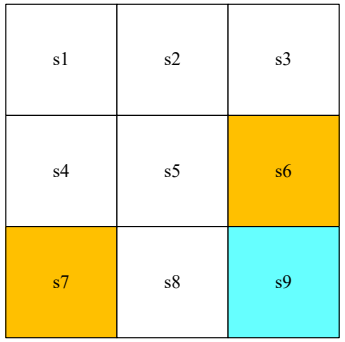

注意禁止区域：示例：在状态 s_5 下，若选择动作 a_2，下一状态是什么？

- 情形一：禁止区域可进入，但有惩罚。则

$$s_5 \xrightarrow{a_2} s_6$$

- 情形二：禁止区域不可进入（例如，被墙围住）

$$s_5 \xrightarrow{a_2} s_5$$

- 本课程讲授中考虑情形一，更具一般性和挑战性。
- 作业中考虑情形二！

状态转移

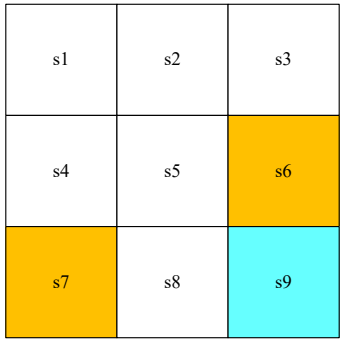

注意禁止区域：示例：在状态 s_5 下，若选择动作 a_2，下一状态是什么？

- 情形一：禁止区域可进入，但有惩罚。则

$$s_5 \xrightarrow{a_2} s_6$$

- 情形二：禁止区域不可进入（例如，被墙围住）

$$s_5 \xrightarrow{a_2} s_5$$

- 本课程讲授中考虑情形一，更具一般性和挑战性。
- 作业中考虑情形二！

状态转移

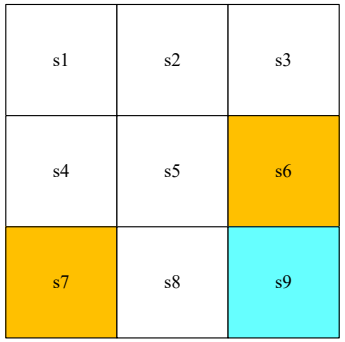

表格表示：可以用表格来描述状态转移：

	a_1（向上）	a_2（向右）	a_3（向下）	a_4（向左）	a_5（不动）
s_1	s_1	s_2	s_4	s_1	s_1
s_2	s_2	s_3	s_5	s_1	s_2
s_3	s_3	s_3	s_6	s_2	s_3
s_4	s_1	s_5	s_7	s_4	s_4
s_5	s_2	s_6	s_8	s_4	s_5
s_6	s_3	s_6	s_9	s_5	s_6
s_7	s_4	s_8	s_7	s_7	s_7
s_8	s_5	s_9	s_8	s_7	s_8
s_9	s_6	s_9	s_9	s_8	s_9

只能表示确定性情形。

状态转移

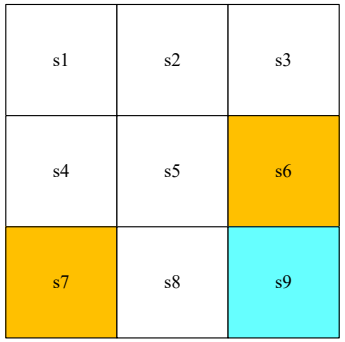

表格表示：可以用表格来描述状态转移：

	a_1（向上）	a_2（向右）	a_3（向下）	a_4（向左）	a_5（不动）
s_1	s_1	s_2	s_4	s_1	s_1
s_2	s_2	s_3	s_5	s_1	s_2
s_3	s_3	s_3	s_6	s_2	s_3
s_4	s_1	s_5	s_7	s_4	s_4
s_5	s_2	s_6	s_8	s_4	s_5
s_6	s_3	s_6	s_9	s_5	s_6
s_7	s_4	s_8	s_7	s_7	s_7
s_8	s_5	s_9	s_8	s_7	s_8
s_9	s_6	s_9	s_9	s_8	s_9

只能表示确定性情形。

状态转移

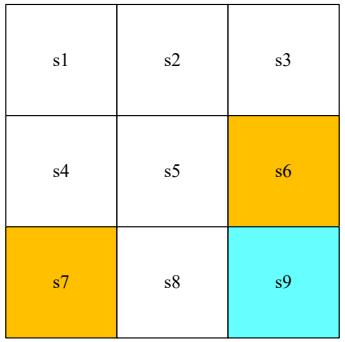

表格表示：可以用表格来描述状态转移：

	a_1（向上）	a_2（向右）	a_3（向下）	a_4（向左）	a_5（不动）
s_1	s_1	s_2	s_4	s_1	s_1
s_2	s_2	s_3	s_5	s_1	s_2
s_3	s_3	s_3	s_6	s_2	s_3
s_4	s_1	s_5	s_7	s_4	s_4
s_5	s_2	s_6	s_8	s_4	s_5
s_6	s_3	s_6	s_9	s_5	s_6
s_7	s_4	s_8	s_7	s_7	s_7
s_8	s_5	s_9	s_8	s_7	s_8
s_9	s_6	s_9	s_9	s_8	s_9

只能表示确定性情形。

状态转移

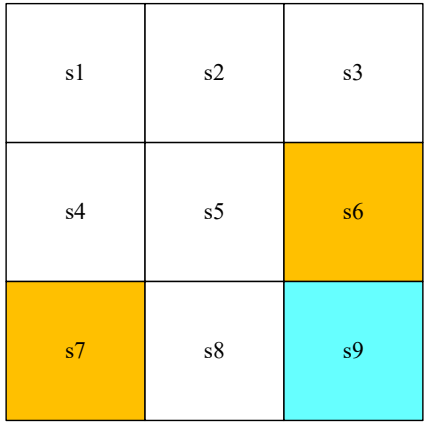

状态转移概率：用概率来描述状态转移！

- 直觉：在状态 s_1 下，若选择动作 a_2，下一状态为 s_2。
- 数学表达：

$$p(s_2|s_1, a_2) = 1$$
$$p(s_i|s_1, a_2) = 0 \quad \forall i \neq 2$$

这里是确定性情形。状态转移也可以是随机的（例如，阵风影响）。

状态转移

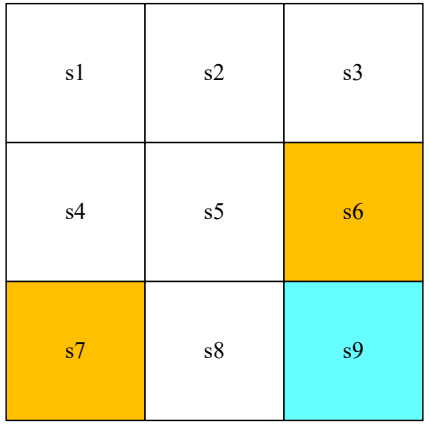

状态转移概率：用概率来描述状态转移！

- 直觉：在状态 s_1 下，若选择动作 a_2，下一状态为 s_2。
- 数学表达:

$$p(s_2|s_1, a_2) = 1$$
$$p(s_i|s_1, a_2) = 0 \quad \forall i \neq 2$$

这里是确定性情形。状态转移也可以是随机的（例如，阵风影响）。

状态转移

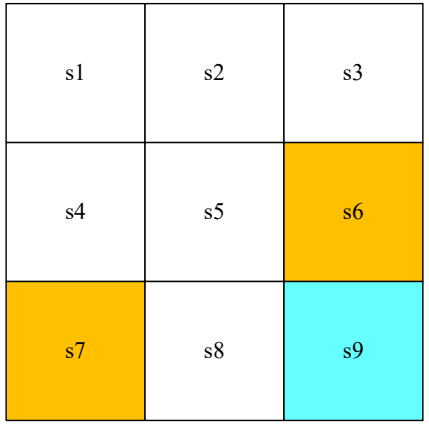

状态转移概率：用概率来描述状态转移！

- 直觉：在状态 s_1 下，若选择动作 a_2，下一状态为 s_2。
- 数学表达：

$$p(s_2|s_1, a_2) = 1$$
$$p(s_i|s_1, a_2) = 0 \quad \forall i \neq 2$$

这里是确定性情形。状态转移也可以是随机的（例如，阵风影响）。

状态转移

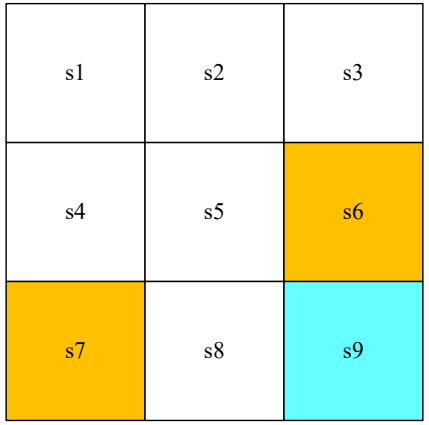

状态转移概率：用概率来描述状态转移！

- 直觉：在状态 s_1 下，若选择动作 a_2，下一状态为 s_2。
- 数学表达：

$$p(s_2|s_1, a_2) = 1$$
$$p(s_i|s_1, a_2) = 0 \quad \forall i \neq 2$$

这里是确定性情形。状态转移也可以是随机的（例如，阵风影响）。

策略

策略告诉智能体在某状态下应采取什么动作。

策略

策略告诉智能体在某状态下应采取什么动作。

直观表示：用箭头描述策略。

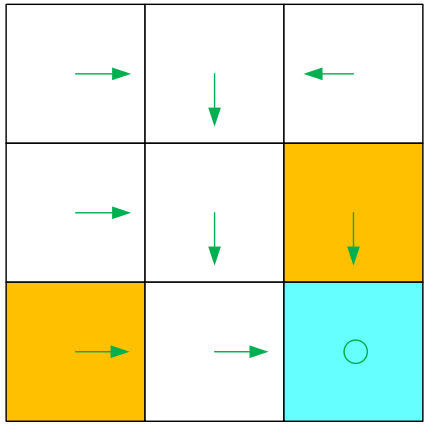

策略

策略告诉智能体在某状态下应采取什么动作。

直观表示：用箭头描述策略。

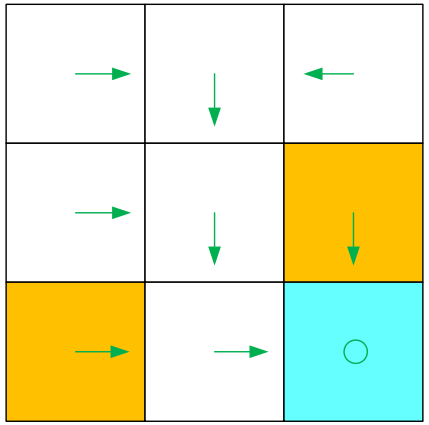

基于此策略，从不同起点出发可得到如下轨迹。

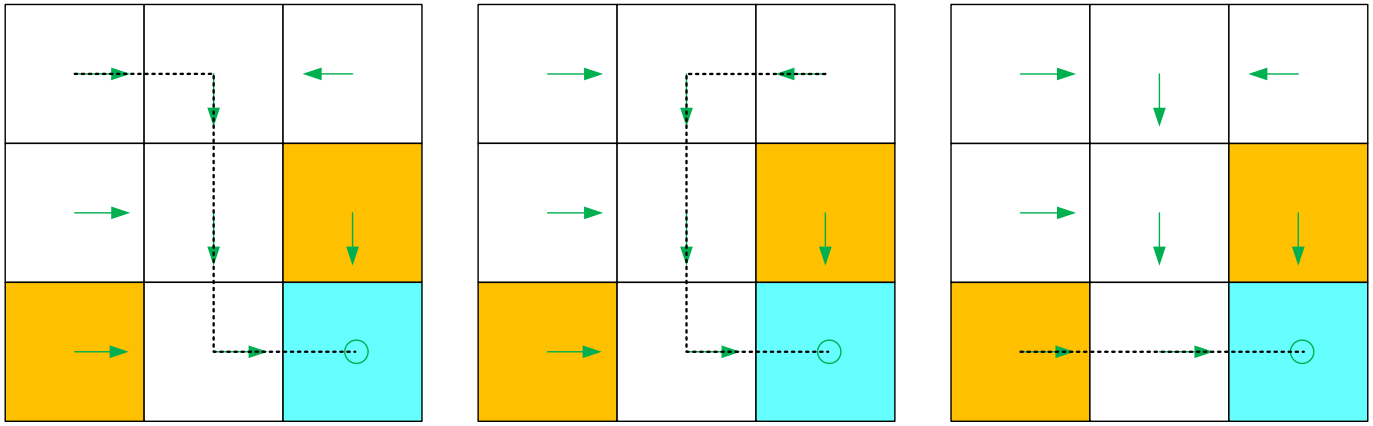

策略

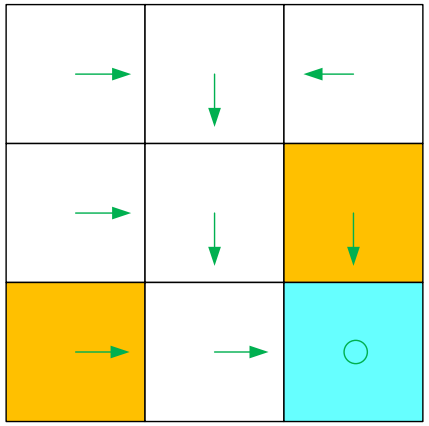

数学表示：用条件概率

例如，对状态 s_1：

$$\pi(a_1|s_1) = 0$$
$$\pi(a_2|s_1) = 1$$
$$\pi(a_3|s_1) = 0$$
$$\pi(a_4|s_1) = 0$$
$$\pi(a_5|s_1) = 0$$

这是一个确定性策略。

策略

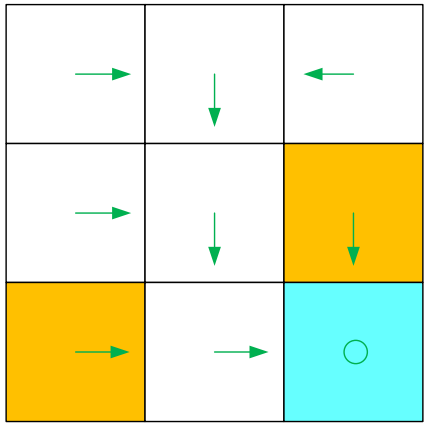

数学表示：用条件概率
例如，对状态 s_1：

$$\pi(a_1|s_1) = 0$$
$$\pi(a_2|s_1) = 1$$
$$\pi(a_3|s_1) = 0$$
$$\pi(a_4|s_1) = 0$$
$$\pi(a_5|s_1) = 0$$

这是一个确定性策略。

策略

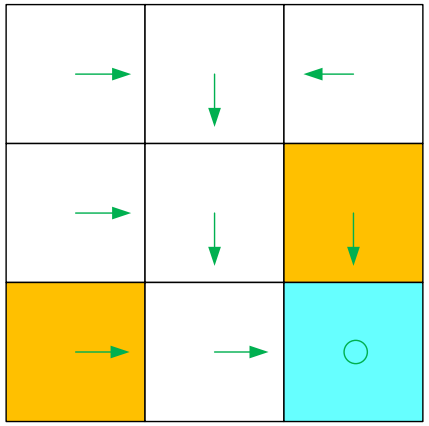

数学表示：用条件概率
例如，对状态 s_1：

$$\pi(a_1|s_1) = 0$$
$$\pi(a_2|s_1) = 1$$
$$\pi(a_3|s_1) = 0$$
$$\pi(a_4|s_1) = 0$$
$$\pi(a_5|s_1) = 0$$

这是一个确定性策略。

策略

也存在随机性策略。

策略

也存在随机性策略。

例如：

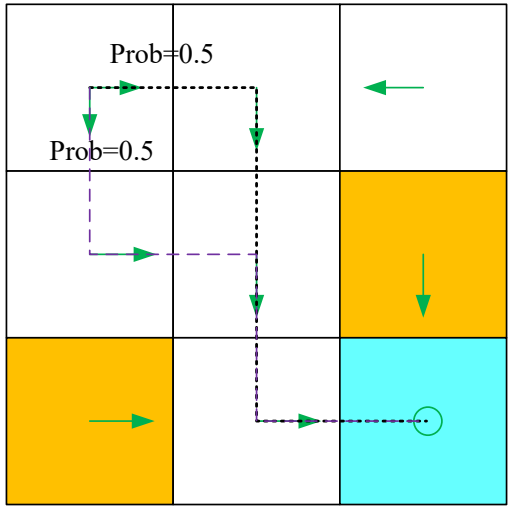

策略

也存在随机性策略。
例如：

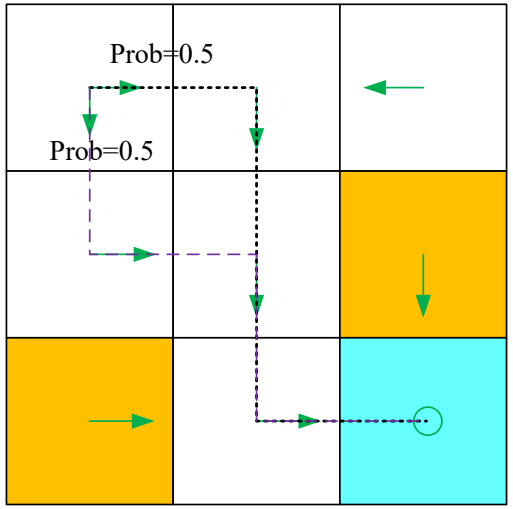

在此策略中，对 s_1：

$$\pi(a_1|s_1) = 0$$
$$\pi(a_2|s_1) = 0.5$$
$$\pi(a_3|s_1) = 0.5$$
$$\pi(a_4|s_1) = 0$$
$$\pi(a_5|s_1) = 0$$

策略

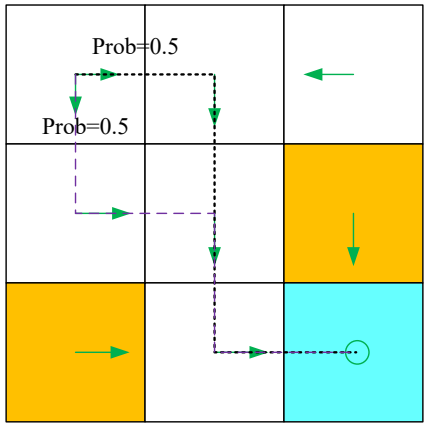

策略的**表格表示**：如何使用该表格。

	a_1（向上）	a_2（向右）	a_3（向下）	a_4（向左）	a_5（不动）
s_1	0	0.5	0.5	0	0
s_2	0	0	1	0	0
s_3	0	0	0	1	0
s_4	0	1	0	0	0
s_5	0	0	1	0	0
s_6	0	0	1	0	0
s_7	0	1	0	0	0
s_8	0	1	0	0	0
s_9	0	0	0	0	1

可以表示确定性或随机性情形。

奖励

奖励是强化学习中最独特的概念之一。
奖励：执行某动作后获得的实数值。

- 正奖励表示对该动作的鼓励。
- 负奖励表示对该动作的惩罚。

问题：

- 正值能表示惩罚、负值能表示鼓励吗？
  - 可以。
  - 在这种情形下，奖励可称为代价（cost）。
- 零奖励意味着什么？
  - 重要的是奖励的相对值，而非绝对值。
  - 例如：将 $r = \{+1, -1\}$ 改为 $r = \{+2, 0\}$ 不会改变最优策略，详见后续讲解。

奖励

奖励是强化学习中最独特的概念之一。
奖励：执行某动作后获得的实数值。

- 正奖励表示对该动作的鼓励。
- 负奖励表示对该动作的惩罚。

问题：

- 正值能表示惩罚、负值能表示鼓励吗?
  - 可以。
  - 在这种情形下，奖励可称为代价（cost）。
- 零奖励意味着什么?
  - 重要的是奖励的相对值，而非绝对值。
  - 例如：将 $r = \{+1, -1\}$ 改为 $r = \{+2, 0\}$ 不会改变最优策略，详见后续讲解。

奖励

奖励是强化学习中最独特的概念之一。
奖励：执行某动作后获得的实数值。

- 正奖励表示对该动作的鼓励。
- 负奖励表示对该动作的惩罚。

问题：

- 正值能表示惩罚、负值能表示鼓励吗?
  - 可以。
  - 在这种情形下，奖励可称为代价（cost）。
- 零奖励意味着什么?
  - 重要的是奖励的相对值，而非绝对值。
  - 例如：将 $r = \{+1, -1\}$ 改为 $r = \{+2, 0\}$ 不会改变最优策略，详见后续讲解。

奖励

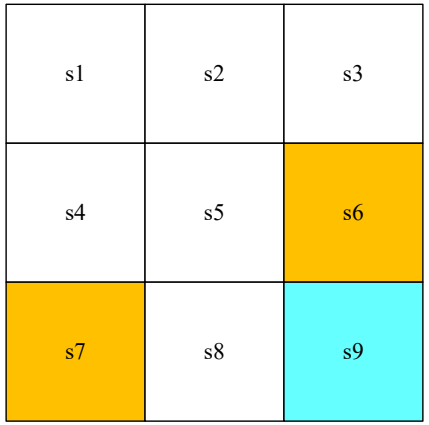

在网格世界示例中，奖励设计如下：

- 若智能体试图越出边界，令 $r_{\text{bound}} = -1$
- 若智能体试图进入禁止格，令 $r_{\text{forbid}} = -1$
- 若智能体到达目标格，令 $r_{\text{target}} = +1$
- 其他情况，奖励为 $r = 0$。

奖励可理解为一种**人机接口**，通过它可以引导智能体按照我们期望的方式行动。

- 例如，通过上述奖励设计，智能体会尽量避免越界或进入禁止格。

奖励

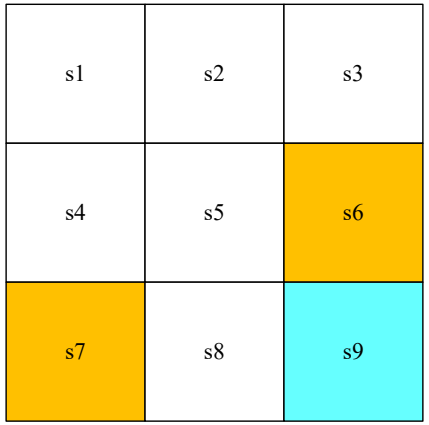

在网格世界示例中，奖励设计如下：

- 若智能体试图越出边界，令 $r_{\text{bound}} = -1$
- 若智能体试图进入禁止格，令 $r_{\text{forbid}} = -1$
- 若智能体到达目标格，令 $r_{\text{target}} = +1$
- 其他情况，奖励为 $r = 0$。

奖励可理解为一种**人机接口**，通过它可以引导智能体按照我们期望的方式行动。

- 例如，通过上述奖励设计，智能体会尽量避免越界或进入禁止格。

奖励

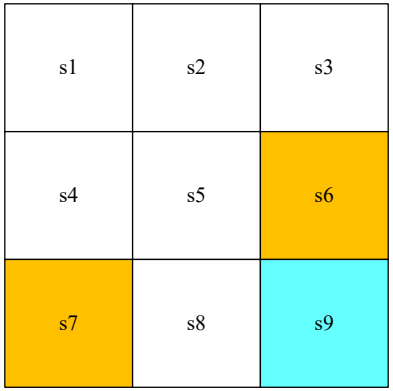

奖励转移的**表格表示**：如何使用该表格?

	a_1（向上）	a_2（向右）	a_3（向下）	a_4（向左）	a_5（不动）
s_1	r_{bound}	0	0	r_{bound}	0
s_2	r_{bound}	0	0	0	0
s_3	r_{bound}	r_{bound}	r_{forbid}	0	0
s_4	0	0	r_{forbid}	r_{bound}	0
s_5	0	r_{forbid}	0	0	0
s_6	0	r_{bound}	r_{target}	0	r_{forbid}
s_7	0	0	r_{bound}	r_{bound}	r_{forbid}
s_8	0	r_{target}	r_{bound}	r_{forbid}	0
s_9	r_{forbid}	r_{bound}	r_{bound}	0	r_{target}

只能表示确定性情形。

奖励

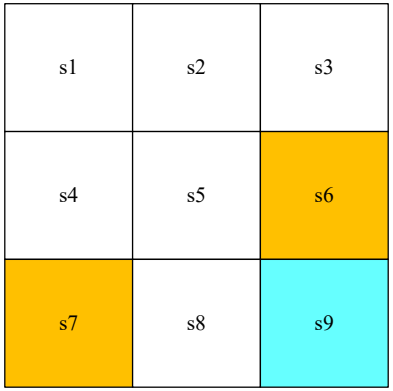

数学描述：条件概率

- 直觉：在状态 s_1 下，若选择动作 a_1，奖励为 -1。
- 数学：$p(r=-1|s_1,a_1)=1$，$p(r\neq -1|s_1,a_1)=0$

说明：

- 这里是确定性情形。奖励转移也可以是随机的。
  例如，若你努力学习，你会获得奖励，但具体多少是不确定的。

奖励

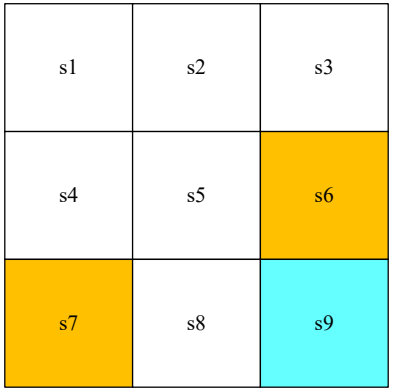

数学描述：条件概率

- 直觉：在状态 s_1 下，若选择动作 a_1，奖励为 -1。
- 数学：$p(r=-1|s_1,a_1)=1$，$p(r\neq -1|s_1,a_1)=0$

说明：

- 这里是确定性情形。奖励转移也可以是随机的。
  例如，若你努力学习，你会获得奖励，但具体多少是不确定的。

轨迹与回报

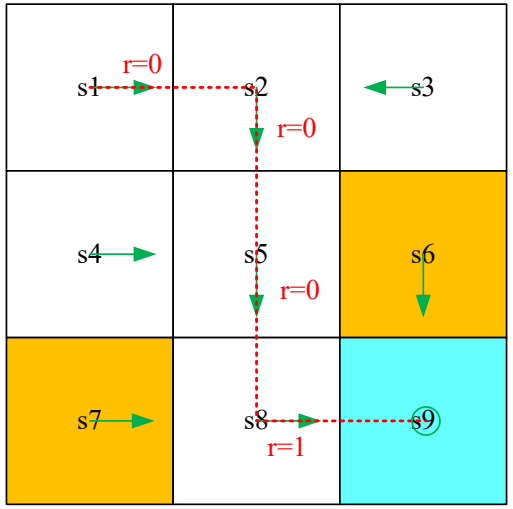

轨迹是状态-动作-奖励链：

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

该轨迹的回报是沿轨迹收集到的所有奖励之和：

$$= 0 + 0 + 0 + 1 = 1$$

轨迹与回报

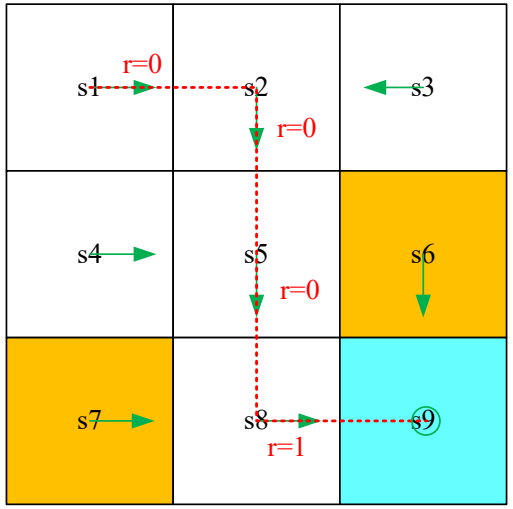

轨迹是状态-动作-奖励链：

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

该轨迹的回报是沿轨迹收集到的所有奖励之和：

$$= 0 + 0 + 0 + 1 = 1$$

轨迹与回报

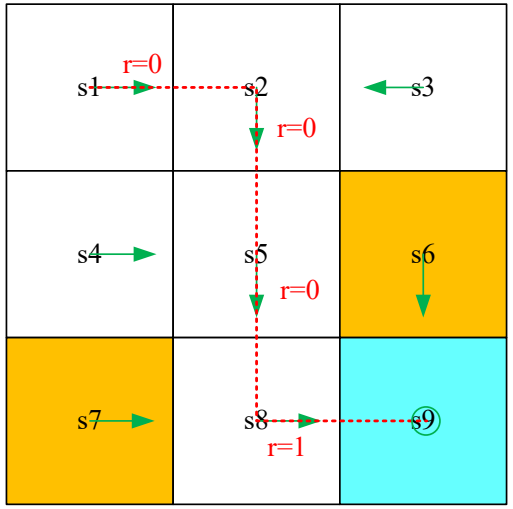

轨迹是状态-动作-奖励链:

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

该轨迹的回报是沿轨迹收集到的所有奖励之和:

$$= 0 + 0 + 0 + 1 = 1$$

轨迹与回报

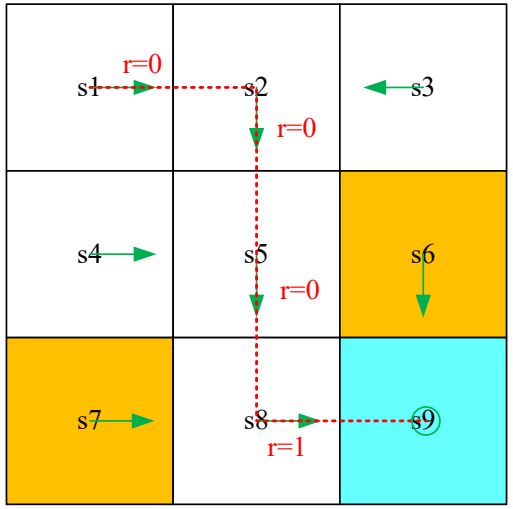

轨迹是状态-动作-奖励链:

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

该轨迹的回报是沿轨迹收集到的所有奖励之和:

$$= 0 + 0 + 0 + 1 = 1$$

轨迹与回报

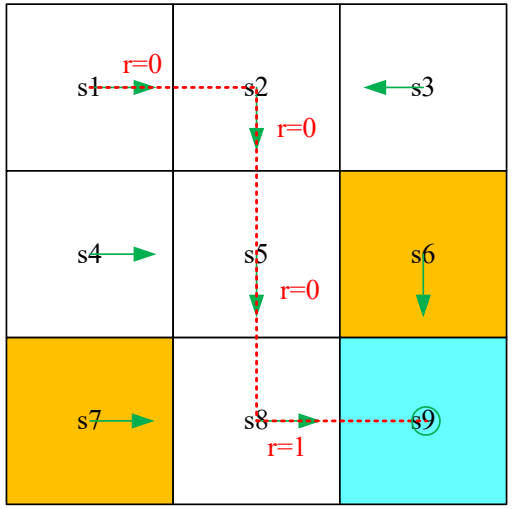

轨迹是状态-动作-奖励链：

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

该轨迹的回报是沿轨迹收集到的所有奖励之和：

$$= 0 + 0 + 0 + 1 = 1$$

轨迹与回报

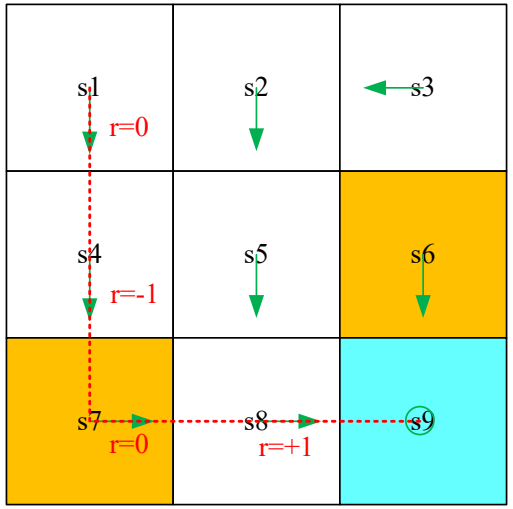

不同策略产生不同轨迹:

$$s_1 \xrightarrow[r=0]{a_3} s_4 \xrightarrow[r=-1]{a_3} s_7 \xrightarrow[r=0]{a_2} s_8 \xrightarrow[r=+1]{a_2} s_9$$

该路径的回报为:

$$= 0 - 1 + 0 + 1 = 0$$

轨迹与回报

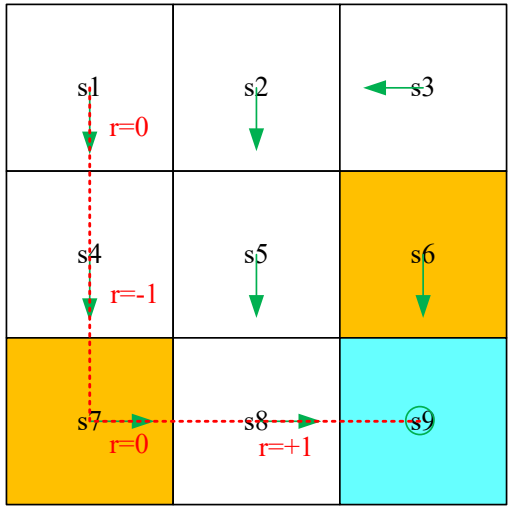

不同策略产生不同轨迹:

$$s_1 \xrightarrow[r=0]{a_3} s_4 \xrightarrow[r=-1]{a_3} s_7 \xrightarrow[r=0]{a_2} s_8 \xrightarrow[r=+1]{a_2} s_9$$

该路径的回报为:

$$= 0 - 1 + 0 + 1 = 0$$

轨迹与回报

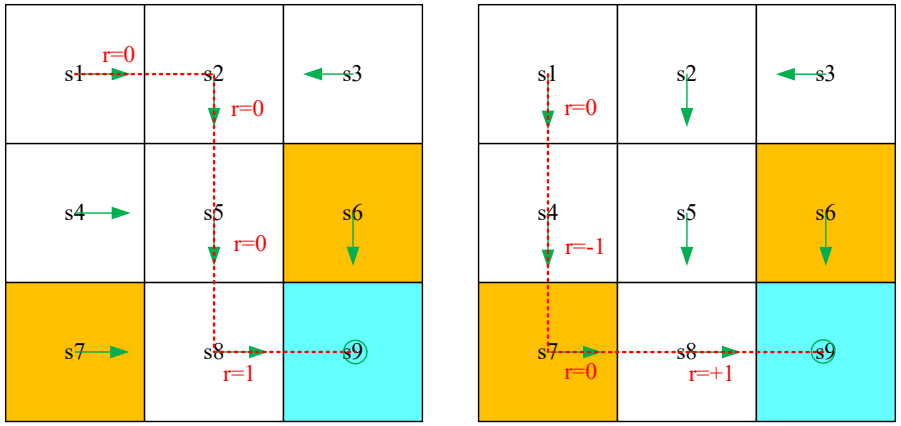

哪个策略更好?

- **直觉**：第一个更好，因为它避开了禁止区域。
- **数学**：第一个更好，因为它的回报更大！
- 回报可用于评估策略的优劣（详见下一讲）！

轨迹与回报

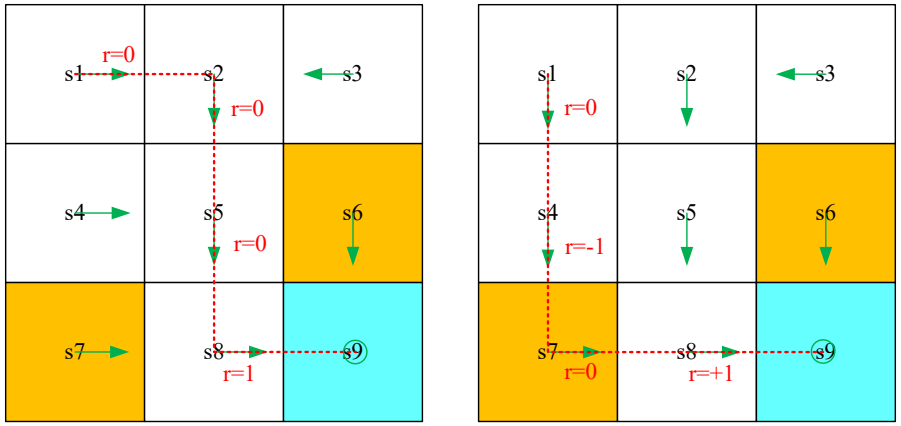

哪个策略更好?

- **直觉**：第一个更好，因为它避开了禁止区域。
- **数学**：第一个更好，因为它的回报更大！
- 回报可用于评估策略的优劣（详见下一讲）！

折扣回报

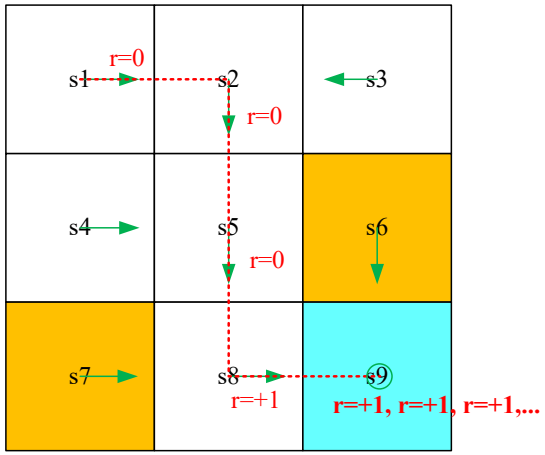

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

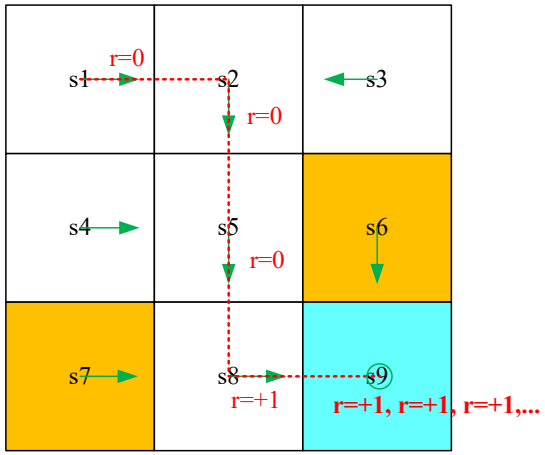

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

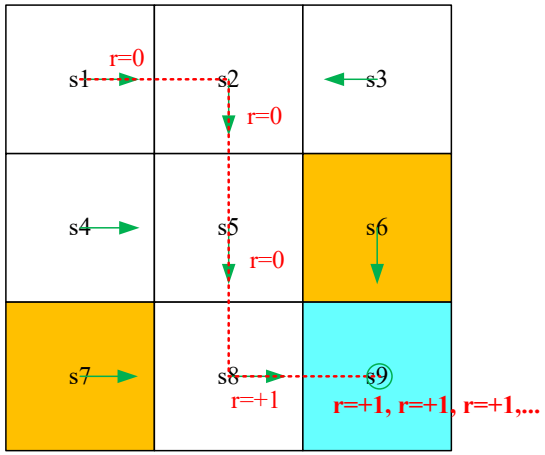

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

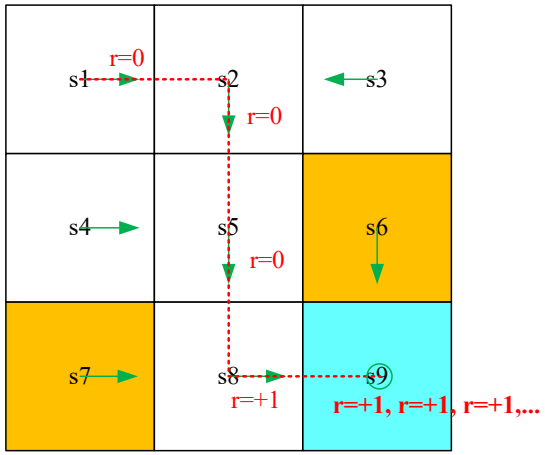

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

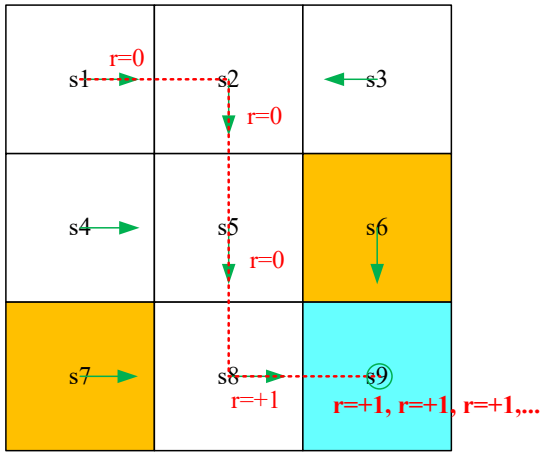

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

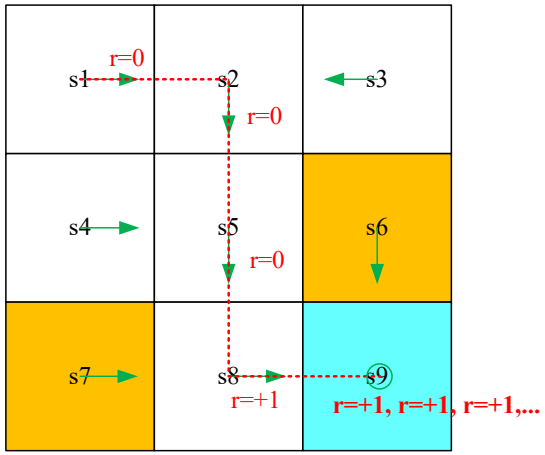

轨迹可能是无限长的:

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} s_8 \xrightarrow{a_2} s_9 \xrightarrow{a_5} s_9 \xrightarrow{a_5} s_9 \ldots$$

此时回报为

$$= 0 + 0 + 0 + 1 + 1 + 1 + \ldots = \infty$$

该定义无效，因为回报发散！

折扣回报

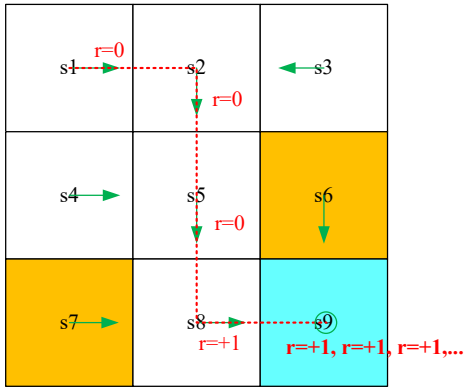

需要引入折扣因子 $\gamma \in (0,1)$:

$$
\begin{aligned}
\text{折扣回报} &= 0 + \gamma 0 + \gamma^2 0 + \gamma^3 1 + \gamma^4 1 + \gamma^5 1 + \dots \\
&= \gamma^3 (1 + \gamma + \gamma^2 + \dots) = \gamma^3 \frac{1}{1-\gamma}.
\end{aligned}
$$

作用：1) 使求和有限；2) 平衡远期与近期奖励:

- 若 γ 接近0，折扣回报的值主要由近期奖励决定。
- 若 γ 接近1，折扣回报的值主要由远期奖励决定。

回合

智能体按照某策略与环境交互时，可能会在某些终止状态处停止，所得轨迹称为一个回合（episode，也称试验）。

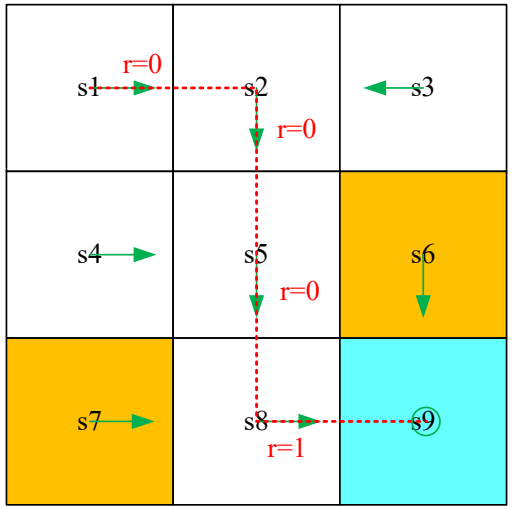

示例：回合

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

回合通常假定为有限长度的轨迹。含有回合的任务称为分幕式任务。

回合

智能体按照某策略与环境交互时，可能会在某些终止状态处停止，所得轨迹称为一个回合（episode，也称试验）。

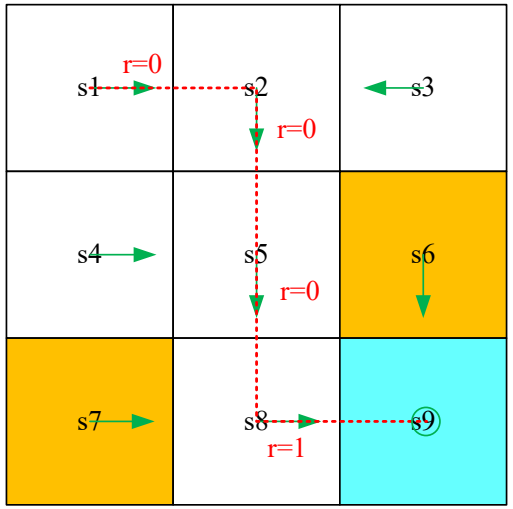

示例：回合

$$s_1 \xrightarrow[r=0]{a_2} s_2 \xrightarrow[r=0]{a_3} s_5 \xrightarrow[r=0]{a_3} s_8 \xrightarrow[r=1]{a_2} s_9$$

回合通常假定为有限长度的轨迹。含有回合的任务称为分幕式任务。

回合

某些任务可能没有终止状态，即与环境的交互永远不会结束。这类任务称为持续性任务。

在网格世界示例中，到达目标后是否应该停止?

- 分幕式任务 + 终止状态
- 持续性任务 + 吸收状态：将目标状态视为特殊的吸收状态，进入后将永远停留其中。
- 持续性任务 + 普通状态：无需区分目标状态与其他状态，将其视为普通状态。智能体仍可离开目标状态，并在每次进入目标状态时获得 $r = +1$。
  - 本课程采用此方式。

回合

某些任务可能没有终止状态，即与环境的交互永远不会结束。这类任务称为持续性任务。

在网格世界示例中，到达目标后是否应该停止?

- 分幕式任务 + 终止状态
- 持续性任务 + 吸收状态：将目标状态视为特殊的吸收状态，进入后将永远停留其中。
- 持续性任务 + 普通状态：无需区分目标状态与其他状态，将其视为普通状态。智能体仍可离开目标状态，并在每次进入目标状态时获得 $r = +1$。
  - 本课程采用此方式。

马尔可夫决策过程（MDP）

MDP的关键要素：

- 集合：
  - 状态：状态集合 $\mathcal{S}$
  - 动作：与状态 $s \in \mathcal{S}$ 关联的动作集合 $\mathcal{A}(s)$
  - 奖励：奖励集合 $\mathcal{R}(s, a)$
- 概率分布（也称系统模型）：
  - 状态转移概率：在状态 s 下执行动作 a，转移到状态 s' 的概率为 $p(s'|s, a)$
  - 奖励概率：在状态 s 下执行动作 a，获得奖励 r 的概率为 $p(r|s, a)$
- 策略：在状态 s 下，选择动作 a 的概率为 $\pi(a|s)$
- 马尔可夫性质：无记忆性

$$p(s_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(s_{t+1}|a_t, s_t),$$
$$p(r_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(r_{t+1}|a_t, s_t).$$

本讲介绍的所有概念均可纳入MDP框架。

马尔可夫决策过程（MDP）

MDP的关键要素：

- 集合：
  - 状态：状态集合 $\mathcal{S}$
  - 动作：与状态 $s \in \mathcal{S}$ 关联的动作集合 $\mathcal{A}(s)$
  - 奖励：奖励集合 $\mathcal{R}(s, a)$
- 概率分布（也称系统模型）：
  - 状态转移概率：在状态 s 下执行动作 a，转移到状态 s' 的概率为 $p(s'|s, a)$
  - 奖励概率：在状态 s 下执行动作 a，获得奖励 r 的概率为 $p(r|s, a)$
- 策略：在状态 s 下，选择动作 a 的概率为 $\pi(a|s)$
- 马尔可夫性质：无记忆性

$$p(s_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(s_{t+1}|a_t, s_t),$$
$$p(r_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(r_{t+1}|a_t, s_t).$$

本讲介绍的所有概念均可纳入MDP框架。

马尔可夫决策过程（MDP）

MDP的关键要素：

- 集合：
  - 状态：状态集合 $\mathcal{S}$
  - 动作：与状态 $s \in \mathcal{S}$ 关联的动作集合 $\mathcal{A}(s)$
  - 奖励：奖励集合 $\mathcal{R}(s, a)$
- 概率分布（也称系统模型）：
  - 状态转移概率：在状态 s 下执行动作 a，转移到状态 s' 的概率为 $p(s'|s, a)$
  - 奖励概率：在状态 s 下执行动作 a，获得奖励 r 的概率为 $p(r|s, a)$
- 策略：在状态 s 下，选择动作 a 的概率为 $\pi(a|s)$
- 马尔可夫性质：无记忆性

$$p(s_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(s_{t+1}|a_t, s_t),$$
$$p(r_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(r_{t+1}|a_t, s_t).$$

本讲介绍的所有概念均可纳入MDP框架。

马尔可夫决策过程（MDP）

MDP的关键要素：

- 集合：
  - 状态：状态集合 $\mathcal{S}$
  - 动作：与状态 $s \in \mathcal{S}$ 关联的动作集合 $\mathcal{A}(s)$
  - 奖励：奖励集合 $\mathcal{R}(s, a)$
- 概率分布（也称系统模型）：
  - 状态转移概率：在状态 s 下执行动作 a，转移到状态 s' 的概率为 $p(s'|s, a)$
  - 奖励概率：在状态 s 下执行动作 a，获得奖励 r 的概率为 $p(r|s, a)$
- 策略：在状态 s 下，选择动作 a 的概率为 $\pi(a|s)$
- 马尔可夫性质：无记忆性

$$p(s_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(s_{t+1}|a_t, s_t),$$
$$p(r_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(r_{t+1}|a_t, s_t).$$

本讲介绍的所有概念均可纳入MDP框架。

马尔可夫决策过程（MDP）

MDP的关键要素：

- 集合：
  - 状态：状态集合 $\mathcal{S}$
  - 动作：与状态 $s \in \mathcal{S}$ 关联的动作集合 $\mathcal{A}(s)$
  - 奖励：奖励集合 $\mathcal{R}(s, a)$
- 概率分布（也称系统模型）：
  - 状态转移概率：在状态 s 下执行动作 a，转移到状态 s' 的概率为 $p(s'|s, a)$
  - 奖励概率：在状态 s 下执行动作 a，获得奖励 r 的概率为 $p(r|s, a)$
- 策略：在状态 s 下，选择动作 a 的概率为 $\pi(a|s)$
- 马尔可夫性质：无记忆性

$$p(s_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(s_{t+1}|a_t, s_t),$$
$$p(r_{t+1}|a_t, s_t, \ldots, a_0, s_0) = p(r_{t+1}|a_t, s_t).$$

本讲介绍的所有概念均可纳入MDP框架。

马尔可夫决策过程（MDP）

网格世界可以抽象为更一般的模型——马尔可夫过程。

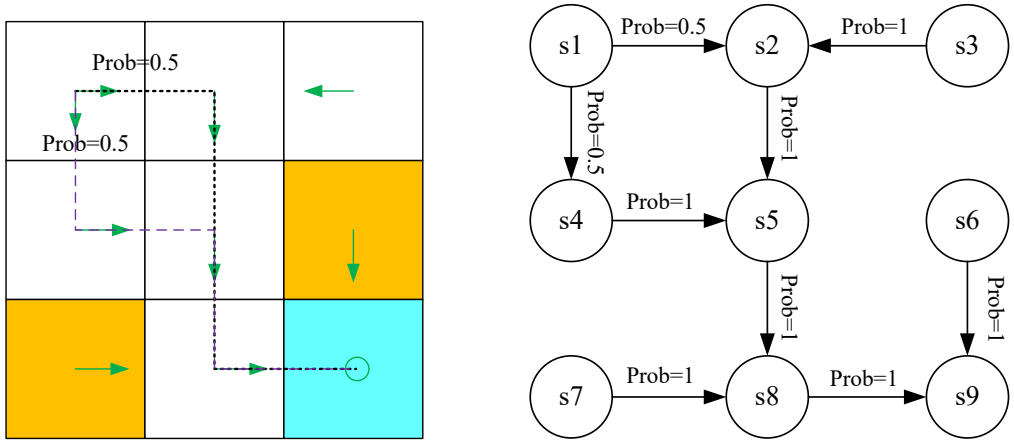

圆圈表示状态，带箭头的连线表示状态转移。

总结

通过网格世界示例，我们演示了以下关键概念：

- 状态
- 动作
- 状态转移，状态转移概率 $p(s'|s,a)$
- 奖励，奖励概率 $p(r|s,a)$
- 轨迹、回合、回报、折扣回报
- 马尔可夫决策过程