第二讲：状态值与贝尔曼方程

April 11, 2026

大纲

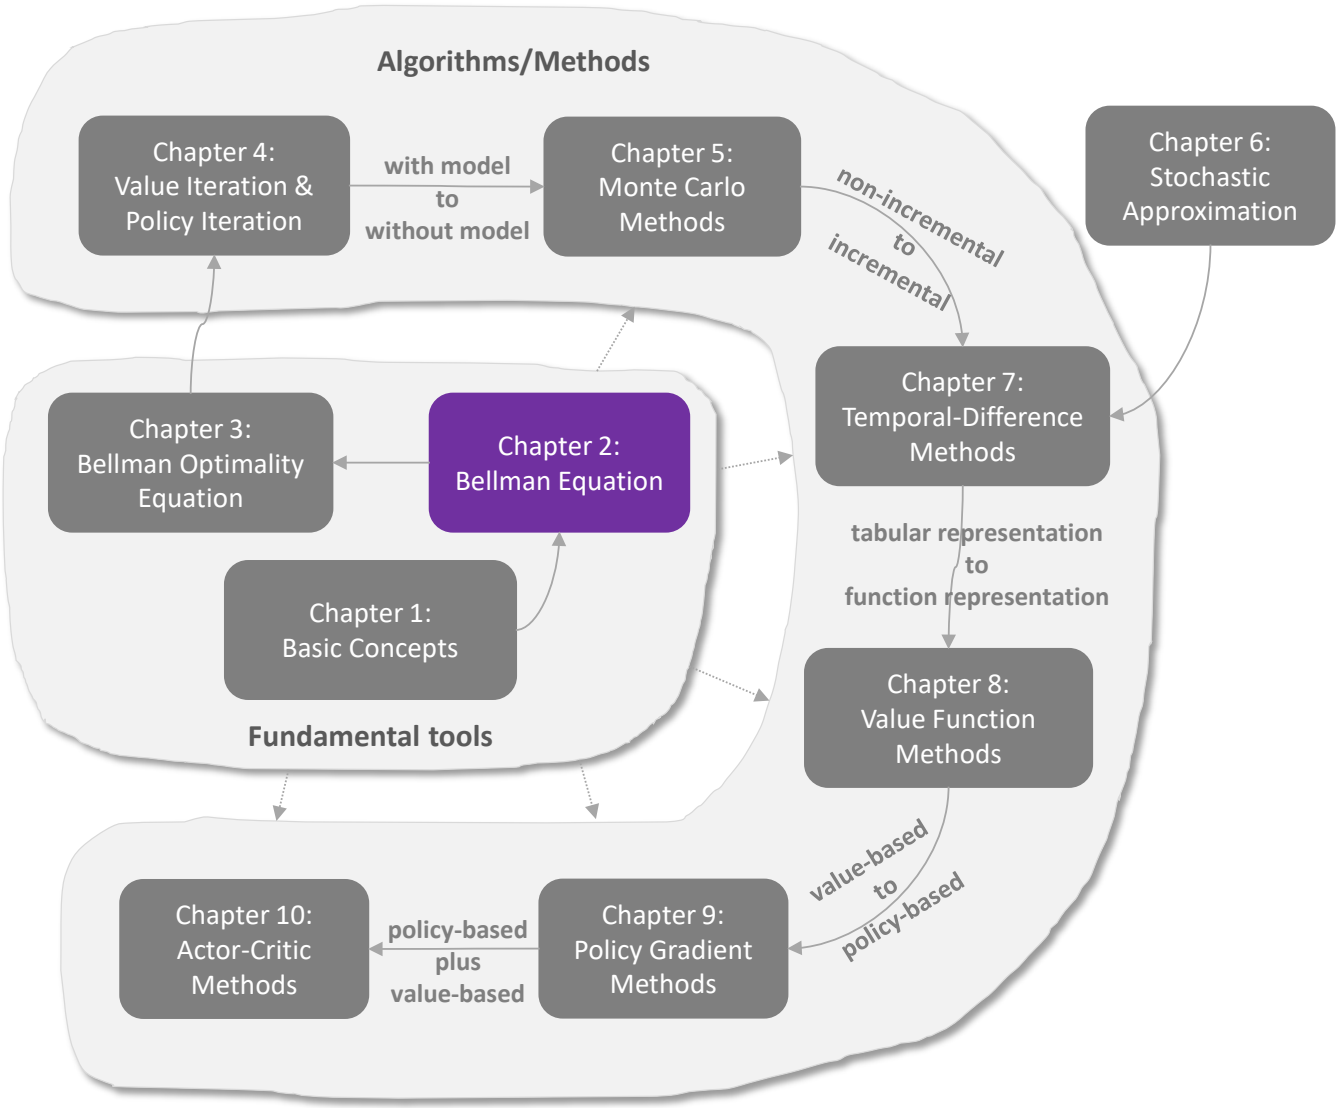
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

大纲

本讲内容：

- 一个核心概念：状态价值
- 一个基本工具：贝尔曼方程

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

动机示例一：为什么回报很重要?

- 什么是回报？沿轨迹获得的（折扣）奖励之和。
- 为什么回报很重要？见以下示例。

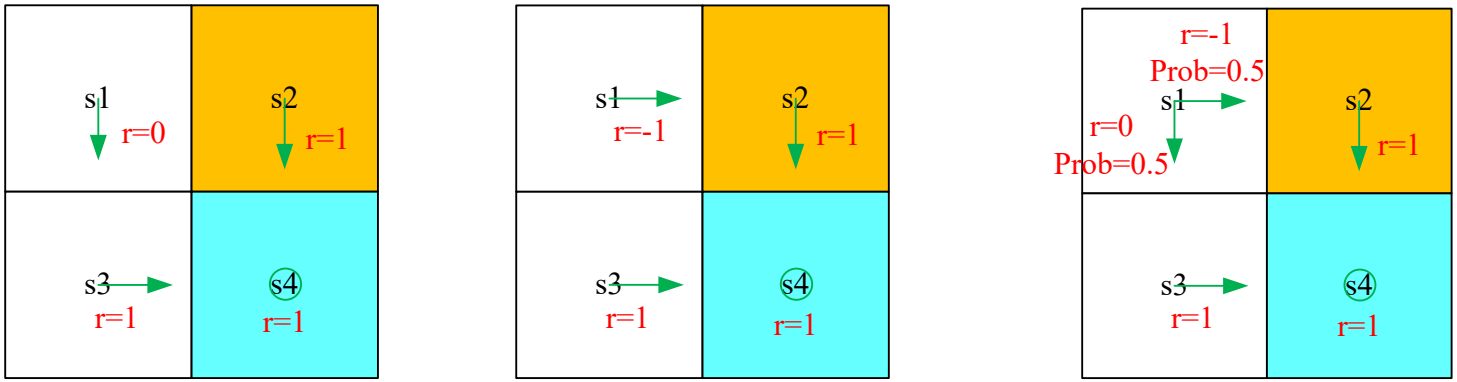

- 问题：哪个策略"最好"？哪个"最差"？
  - 直觉：第一个最好，第二个最差，因为涉及禁止区域。
  - 数学：能否用数学描述这种直觉？
    回报可用于评估策略，见下文。

动机示例一：为什么回报很重要?

- 什么是回报？沿轨迹获得的（折扣）奖励之和。
- 为什么回报很重要？见以下示例。

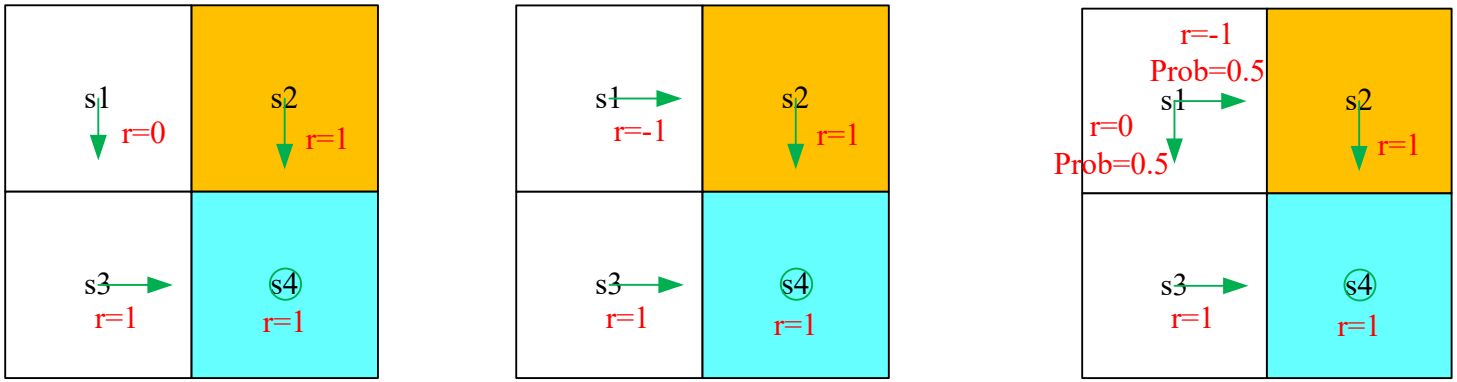

- 问题：哪个策略"最好"？哪个"最差"？
  - 直觉：第一个最好，第二个最差，因为涉及禁止区域。
  - 数学：能否用数学描述这种直觉？
    回报可用于评估策略，见下文。

动机示例一：为什么回报很重要?

- 什么是回报？沿轨迹获得的（折扣）奖励之和。
- 为什么回报很重要？见以下示例。

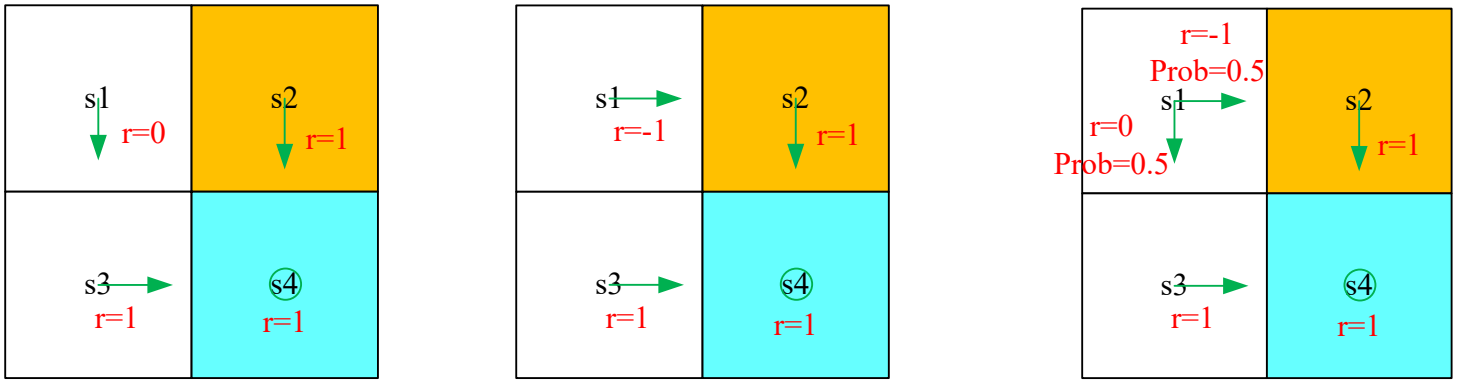

- 问题：哪个策略"最好"？哪个"最差"？
  - 直觉：第一个最好，第二个最差，因为涉及禁止区域。
  - 数学：能否用数学描述这种直觉？
    回报可用于评估策略，见下文。

动机示例一：为什么回报很重要?

- 什么是回报？沿轨迹获得的（折扣）奖励之和。
- 为什么回报很重要？见以下示例。

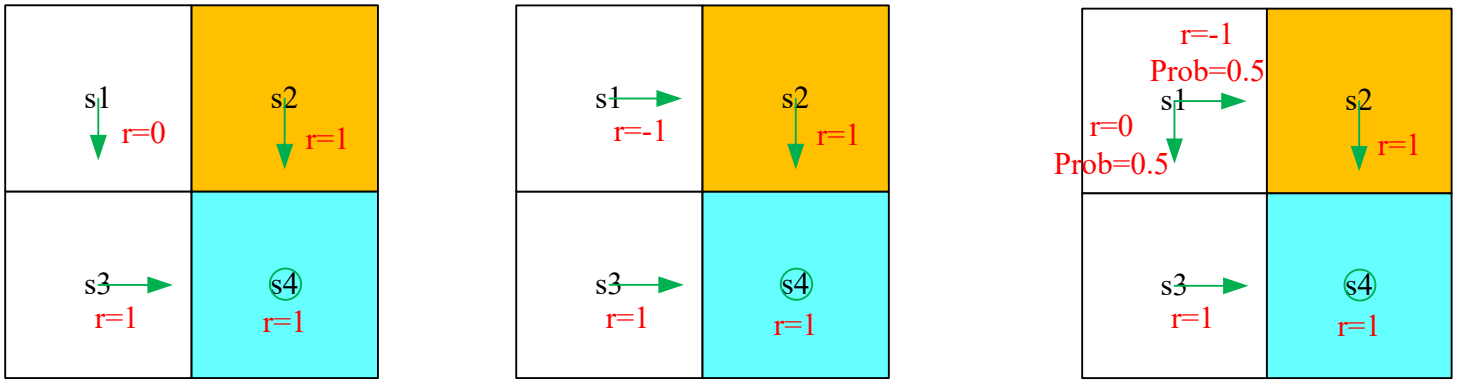

- 问题：哪个策略"最好"？哪个"最差"？
  - 直觉：第一个最好，第二个最差，因为涉及禁止区域。
  - 数学：能否用数学描述这种直觉?
    回报可用于评估策略，见下文。

动机示例一：为什么回报很重要?

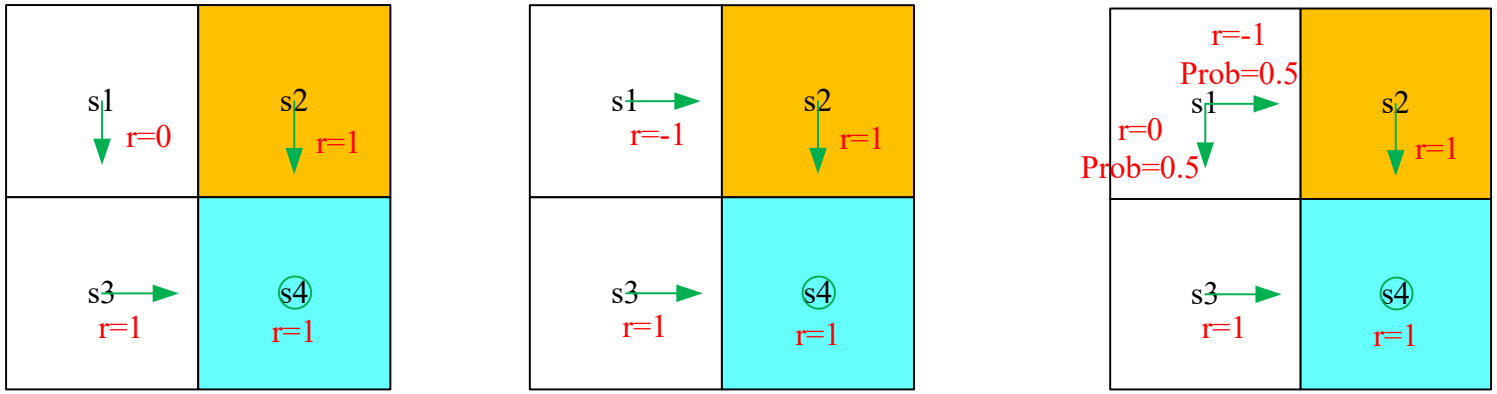

基于策略一（左图），从 s_1 出发，折扣回报为

$$
\begin{aligned}
\text{return}_1 &= 0 + \gamma 1 + \gamma^2 1 + \dots \\
&= \gamma(1 + \gamma + \gamma^2 + \dots) \\
&= \frac{\gamma}{1-\gamma}
\end{aligned}
$$

动机示例一：为什么回报很重要?

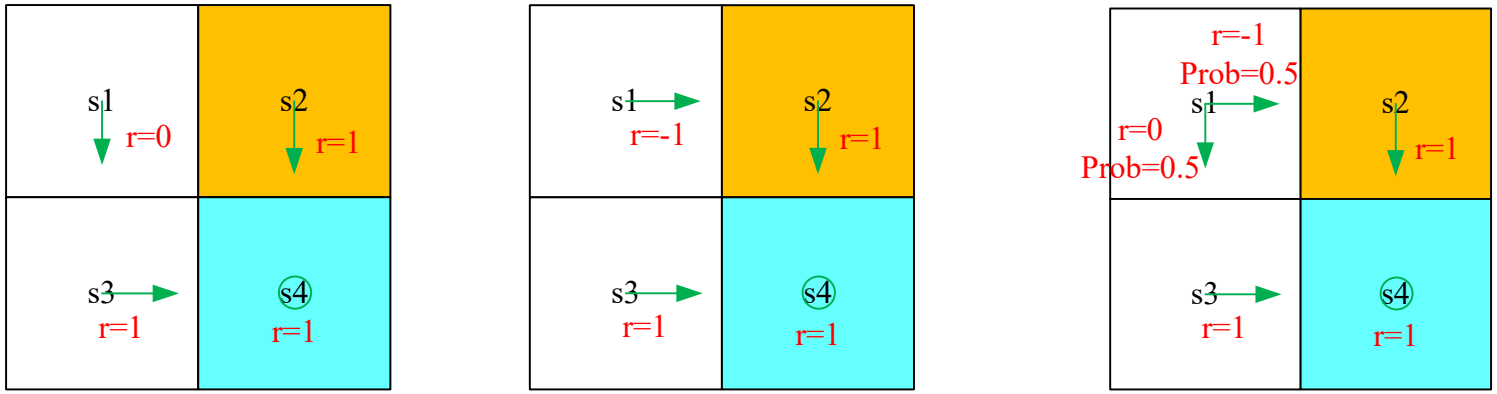

基于策略一（左图），从 s_1 出发，折扣回报为

$$
\begin{aligned}
\text{return}_1 &= 0 + \gamma 1 + \gamma^2 1 + \dots \\
&= \gamma(1 + \gamma + \gamma^2 + \dots) \\
&= \frac{\gamma}{1-\gamma}
\end{aligned}
$$

动机示例一：为什么回报很重要?

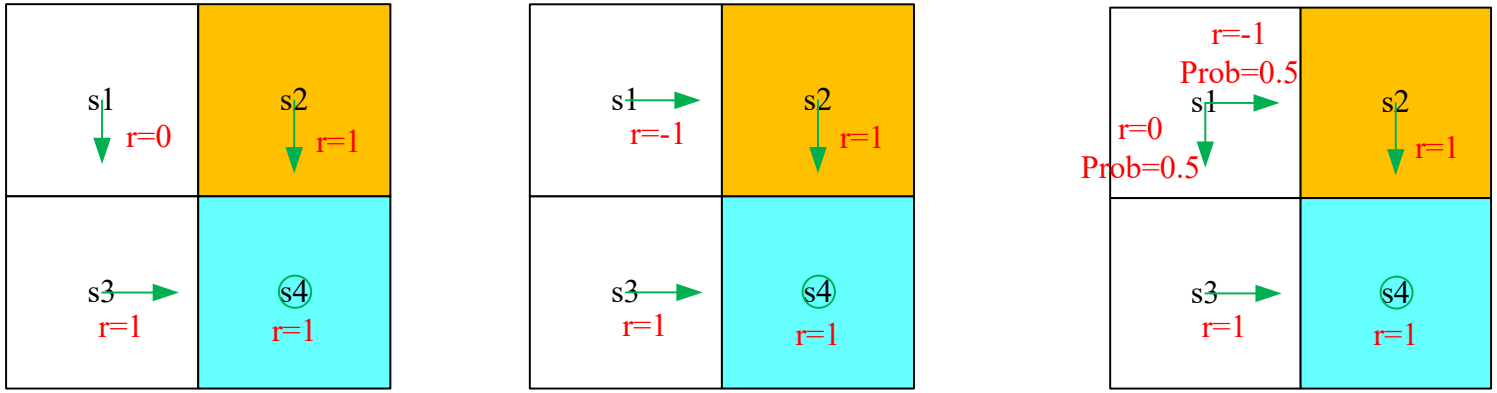

练习：基于策略二（中图），从 s_1 出发，折扣回报是多少?

答案:

$$
\begin{aligned}
\text{return}_2 &= -1 + \gamma 1 + \gamma^2 1 + \dots \\
&= -1 + \gamma(1 + \gamma + \gamma^2 + \dots) \\
&= -1 + \frac{\gamma}{1-\gamma}
\end{aligned}
$$

动机示例一：为什么回报很重要?

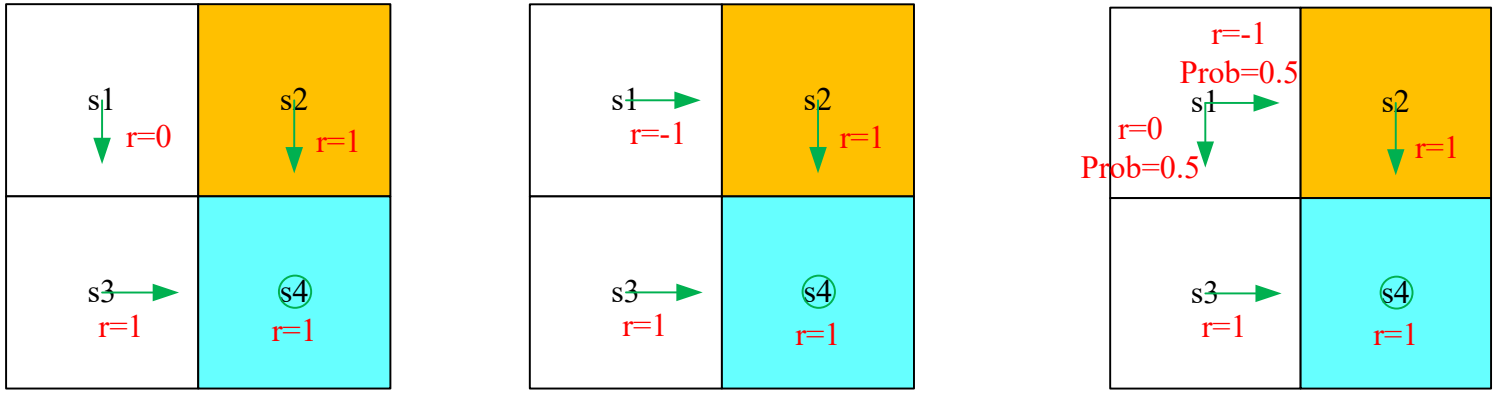

练习：基于策略二（中图），从 s_1 出发，折扣回报是多少?

答案:

$$
\begin{aligned}
\text{return}_2 &= -1 + \gamma 1 + \gamma^2 1 + \dots \\
&= -1 + \gamma(1 + \gamma + \gamma^2 + \dots) \\
&= -1 + \frac{\gamma}{1-\gamma}
\end{aligned}
$$

动机示例一：为什么回报很重要?

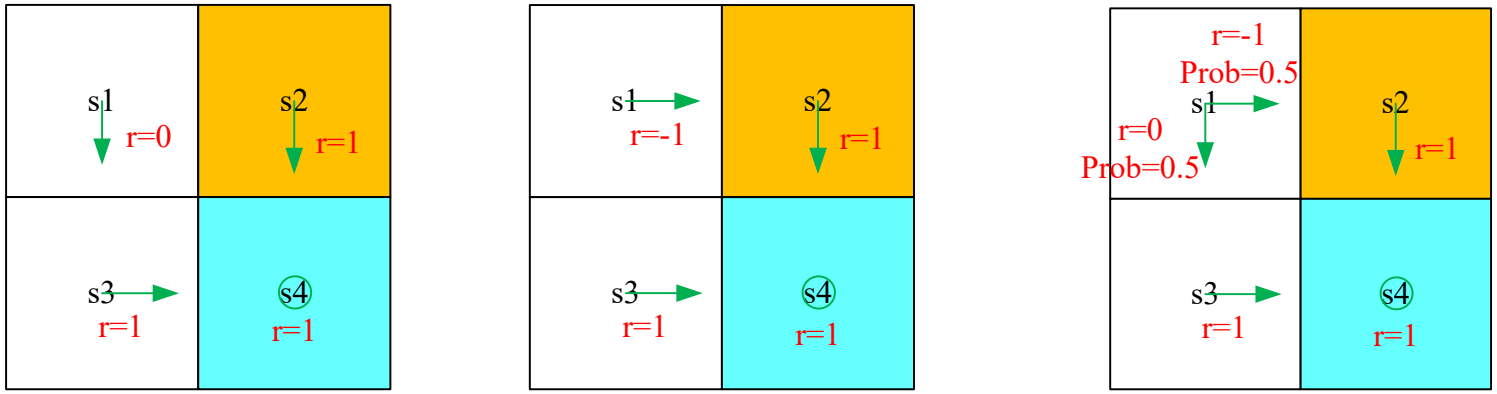

策略三是随机策略！

练习：基于策略三（右图），从 s_1 出发，折扣回报为

答案:

$$\begin{aligned}\text{return}_3 &= 0.5\left(-1+\frac{\gamma}{1-\gamma}\right)+0.5\left(\frac{\gamma}{1-\gamma}\right)\\ &= -0.5+\frac{\gamma}{1-\gamma}\end{aligned}$$

动机示例一：为什么回报很重要?

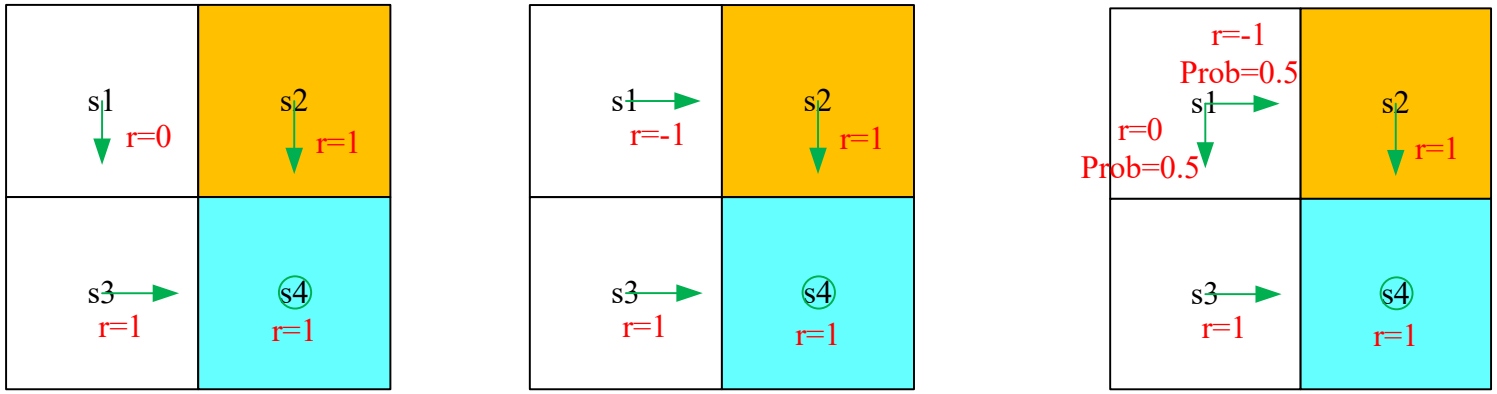

策略三是随机策略！

练习：基于策略三（右图），从 s_1 出发，折扣回报为

答案:

$$
\begin{aligned}
\text{return}_3 &= 0.5\left(-1+\frac{\gamma}{1-\gamma}\right)+0.5\left(\frac{\gamma}{1-\gamma}\right) \\
&= -0.5+\frac{\gamma}{1-\gamma}
\end{aligned}
$$

动机示例一：为什么回报很重要?

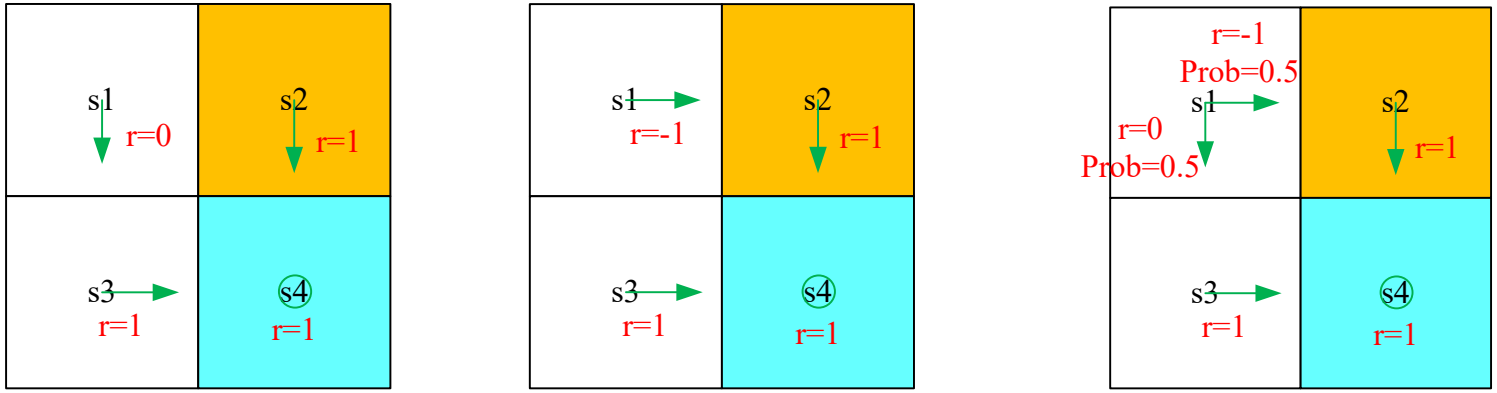

综上，从 s_1 出发，

$$\text{return}_1 > \text{return}_3 > \text{return}_2$$

- 上述不等式表明第一个策略最好，第二个策略最差，这与我们的直觉完全一致。
- 计算回报对于评估策略至关重要。

动机示例一：为什么回报很重要?

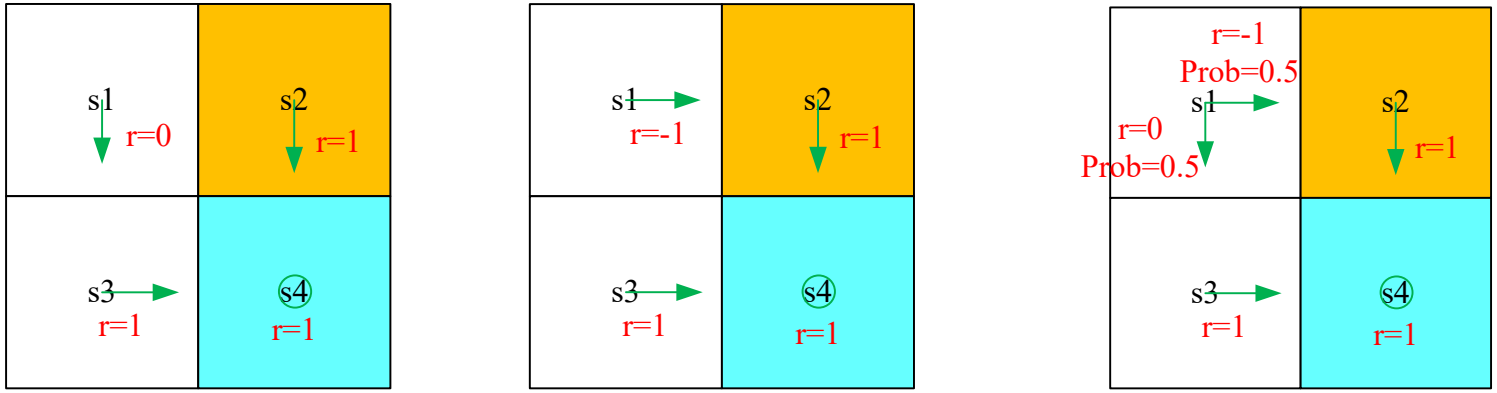

综上，从 s_1 出发，

$$\text{return}_1 > \text{return}_3 > \text{return}_2$$

- 上述不等式表明第一个策略最好，第二个策略最差，这与我们的直觉完全一致。
- 计算回报对于评估策略至关重要。

动机示例一：为什么回报很重要?

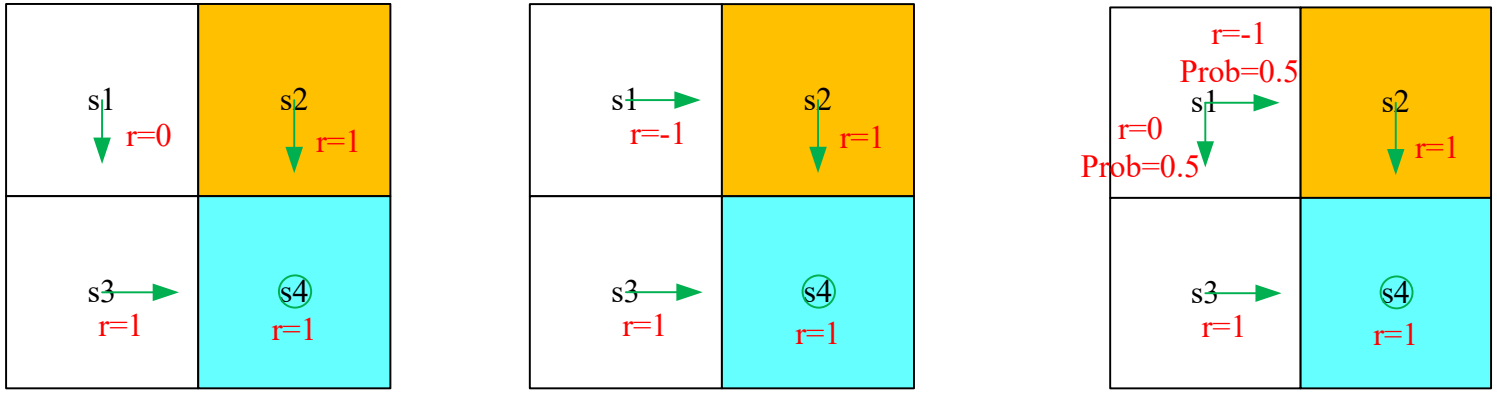

综上，从 s_1 出发，

$$\text{return}_1 > \text{return}_3 > \text{return}_2$$

- 上述不等式表明第一个策略最好，第二个策略最差，这与我们的直觉完全一致。
- 计算回报对于评估策略至关重要。

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

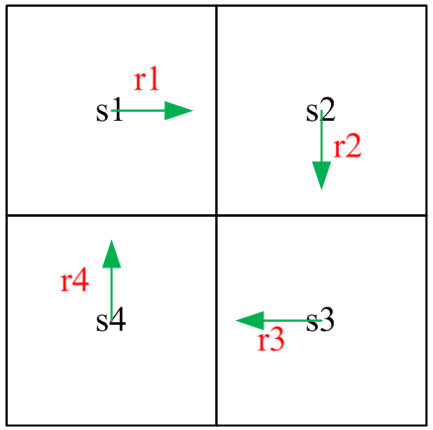

方法一：按定义计算

设 v_i 为从 s_i（$i = 1, 2, 3, 4$）出发所得的回报

$$v_1 = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

$$v_2 = r_2 + \gamma r_3 + \gamma^2 r_4 + \dots$$

$$v_3 = r_3 + \gamma r_4 + \gamma^2 r_1 + \dots$$

$$v_4 = r_4 + \gamma r_1 + \gamma^2 r_2 + \dots$$

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

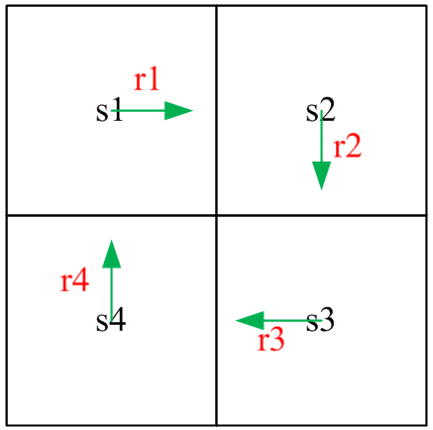

方法一：按定义计算

设 v_i 为从 s_i（$i = 1, 2, 3, 4$）出发所得的回报

$$v_1 = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

$$v_2 = r_2 + \gamma r_3 + \gamma^2 r_4 + \dots$$

$$v_3 = r_3 + \gamma r_4 + \gamma^2 r_1 + \dots$$

$$v_4 = r_4 + \gamma r_1 + \gamma^2 r_2 + \dots$$

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

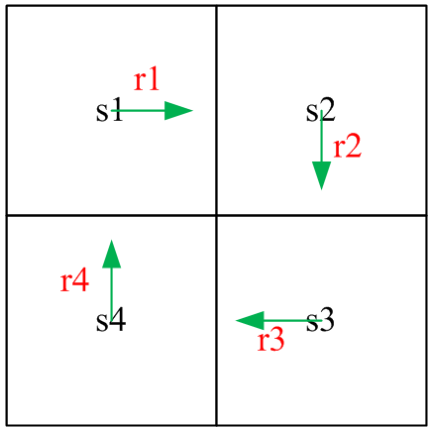

方法一：按定义计算

设 v_i 为从 s_i（$i = 1, 2, 3, 4$）出发所得的回报

$$v_1 = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

$$v_2 = r_2 + \gamma r_3 + \gamma^2 r_4 + \dots$$

$$v_3 = r_3 + \gamma r_4 + \gamma^2 r_1 + \dots$$

$$v_4 = r_4 + \gamma r_1 + \gamma^2 r_2 + \dots$$

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

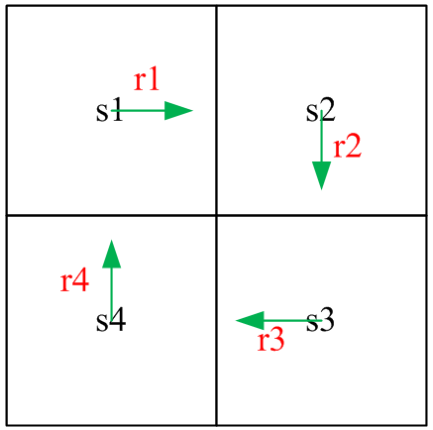

方法二：

$$v_1 = r_1 + \gamma(r_2 + \gamma r_3 + \dots) = r_1 + \gamma v_2$$

$$v_2 = r_2 + \gamma(r_3 + \gamma r_4 + \dots) = r_2 + \gamma v_3$$

$$v_3 = r_3 + \gamma(r_4 + \gamma r_1 + \dots) = r_3 + \gamma v_4$$

$$v_4 = r_4 + \gamma(r_1 + \gamma r_2 + \dots) = r_4 + \gamma v_1$$

- 各回报之间相互依赖：自举（Bootstrapping）

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

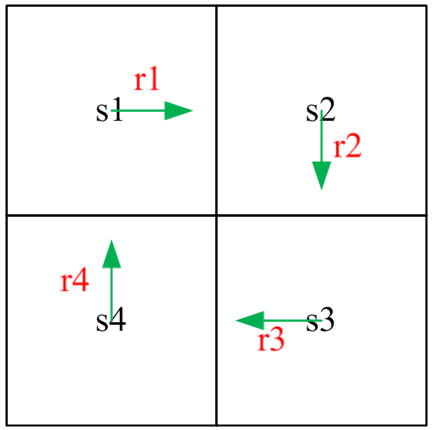

方法二：

$$v_1 = r_1 + \gamma(r_2 + \gamma r_3 + \dots) = r_1 + \gamma v_2$$

$$v_2 = r_2 + \gamma(r_3 + \gamma r_4 + \dots) = r_2 + \gamma v_3$$

$$v_3 = r_3 + \gamma(r_4 + \gamma r_1 + \dots) = r_3 + \gamma v_4$$

$$v_4 = r_4 + \gamma(r_1 + \gamma r_2 + \dots) = r_4 + \gamma v_1$$

- 各回报之间相互依赖：自举（Bootstrapping）

动机示例二：如何计算回报?

回报虽然重要，但如何计算呢?

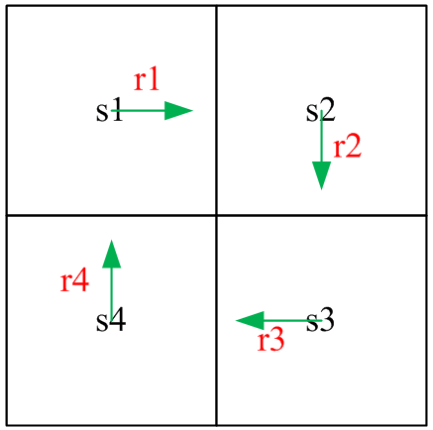

方法二：

$$v_1 = r_1 + \gamma(r_2 + \gamma r_3 + \dots) = r_1 + \gamma v_2$$

$$v_2 = r_2 + \gamma(r_3 + \gamma r_4 + \dots) = r_2 + \gamma v_3$$

$$v_3 = r_3 + \gamma(r_4 + \gamma r_1 + \dots) = r_3 + \gamma v_4$$

$$v_4 = r_4 + \gamma(r_1 + \gamma r_2 + \dots) = r_4 + \gamma v_1$$

- 各回报之间相互依赖：自举（Bootstrapping）

动机示例二：如何计算回报?

如何求解这些方程？写成如下矩阵-向量形式：

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} + \begin{bmatrix} \gamma v_2 \\ \gamma v_3 \\ \gamma v_4 \\ \gamma v_1 \end{bmatrix} = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_{\mathbf{r}} + \gamma \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}}$$

可改写为

$$\mathbf{v} = \mathbf{r} + \gamma \mathbf{P} \mathbf{v}$$

这就是贝尔曼方程（针对该特定确定性问题）！！

- 虽然简单，但它揭示了核心思想：一个状态的价值依赖于其他状态的价值。
- 矩阵-向量形式更清晰地展示了如何求解状态价值。

动机示例二：如何计算回报?

如何求解这些方程？写成如下矩阵-向量形式：

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} + \begin{bmatrix} \gamma v_2 \\ \gamma v_3 \\ \gamma v_4 \\ \gamma v_1 \end{bmatrix} = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_{\mathbf{r}} + \gamma \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}}$$

可改写为

$$\mathbf{v} = \mathbf{r} + \gamma \mathbf{P} \mathbf{v}$$

这就是贝尔曼方程（针对该特定确定性问题）！！

- 虽然简单，但它揭示了核心思想：一个状态的价值依赖于其他状态的价值。
- 矩阵-向量形式更清晰地展示了如何求解状态价值。

动机示例二：如何计算回报?

如何求解这些方程？写成如下矩阵-向量形式：

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} + \begin{bmatrix} \gamma v_2 \\ \gamma v_3 \\ \gamma v_4 \\ \gamma v_1 \end{bmatrix} = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_{\mathbf{r}} + \gamma \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}}$$

可改写为

$$\mathbf{v} = \mathbf{r} + \gamma \mathbf{P} \mathbf{v}$$

这就是贝尔曼方程（针对该特定确定性问题）！！

- 虽然简单，但它揭示了核心思想：一个状态的价值依赖于其他状态的价值。
- 矩阵-向量形式更清晰地展示了如何求解状态价值。

动机示例二：如何计算回报?

如何求解这些方程？写成如下矩阵-向量形式：

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix} + \begin{bmatrix} \gamma v_2 \\ \gamma v_3 \\ \gamma v_4 \\ \gamma v_1 \end{bmatrix} = \underbrace{\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \end{bmatrix}}_{\mathbf{r}} + \gamma \underbrace{\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}}_{\mathbf{P}} \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}}$$

可改写为

$$\mathbf{v} = \mathbf{r} + \gamma \mathbf{P} \mathbf{v}$$

这就是贝尔曼方程（针对该特定确定性问题）！！

- 虽然简单，但它揭示了核心思想：一个状态的价值依赖于其他状态的价值。
- 矩阵-向量形式更清晰地展示了如何求解状态价值。

动机示例二：如何计算回报?

练习：考虑图中所示策略，请写出各回报之间的关系（即写出贝尔曼方程）

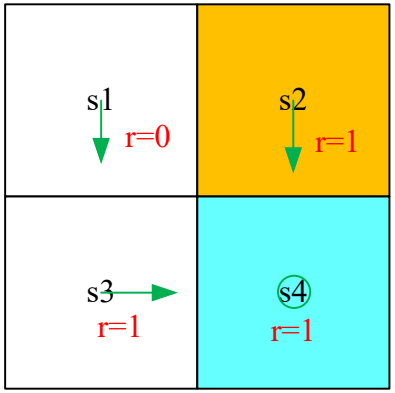

答案:

$$v_1 = 0 + \gamma v_3$$

$$v_2 = 1 + \gamma v_4$$

$$v_3 = 1 + \gamma v_4$$

$$v_4 = 1 + \gamma v_4$$

如何求解? 可先计算 v_4，再依次求 v_3, v_2, v_1。

动机示例二：如何计算回报?

练习：考虑图中所示策略，请写出各回报之间的关系（即写出贝尔曼方程）

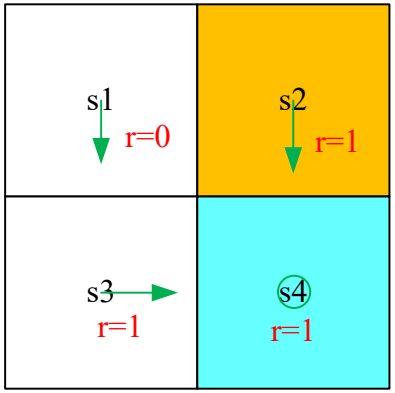

答案：

$$
\begin{aligned}
v_1 &= 0 + \gamma v_3 \\
v_2 &= 1 + \gamma v_4 \\
v_3 &= 1 + \gamma v_4 \\
v_4 &= 1 + \gamma v_4
\end{aligned}
$$

如何求解？可先计算 v_4，再依次求 v_3, v_2, v_1。

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

符号说明

考虑如下单步过程:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1}$$

- $t, t+1$: 离散时间步
- S_t: 时刻 t 的状态
- A_t: 在状态 S_t 下采取的动作
- R_{t+1}: 执行 A_t 后获得的奖励
- S_{t+1}: 执行 A_t 后转移到的状态

注意，S_t, A_t, R_{t+1} 均为随机变量。

符号说明

考虑如下单步过程:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1}$$

该步骤由以下概率分布控制:

- $S_t \to A_t$ 由 $\pi(A_t = a | S_t = s)$ 控制
- $S_t, A_t \to R_{t+1}$ 由 $p(R_{t+1} = r | S_t = s, A_t = a)$ 控制
- $S_t, A_t \to S_{t+1}$ 由 $p(S_{t+1} = s' | S_t = s, A_t = a)$ 控制

此时，我们假设模型（即概率分布）已知！

符号说明

考虑如下多步轨迹:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2} \xrightarrow{A_{t+2}} R_{t+3}, \ldots$$

折扣回报为

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots$$

- $\gamma \in (0, 1)$ 为折扣因子。
- 由于 $R_{t+1}, R_{t+2}, \ldots$ 均为随机变量，G_t 也是随机变量。

符号说明

考虑如下多步轨迹:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2} \xrightarrow{A_{t+2}} R_{t+3}, \ldots$$

折扣回报为

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots$$

- $\gamma \in (0, 1)$ 为折扣因子。
- 由于 $R_{t+1}, R_{t+2}, \ldots$ 均为随机变量，G_t 也是随机变量。

状态价值

G_t 的期望（也称期望值或均值）定义为状态价值函数，简称状态价值：

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s]$$

说明：

- 它是关于 s 的函数，是以状态从 s 出发为条件的条件期望。
- 它依赖于策略 π。不同策略对应不同的状态价值。

问：回报与状态价值之间有什么关系？
答：状态价值是从某状态出发所有可能回报的均值。若一切——$\pi(a|s)$、$p(r|s,a)$、$p(s'|s,a)$——均为确定性的，则状态价值与回报相同。

状态价值

G_t 的期望（也称期望值或均值）定义为状态价值函数，简称状态价值：

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s]$$

说明：

- 它是关于 s 的函数，是以状态从 s 出发为条件的条件期望。
- 它依赖于策略 π。不同策略对应不同的状态价值。

问： 回报与状态价值之间有什么关系？
答： 状态价值是从某状态出发所有可能回报的均值。若一切——$\pi(a|s)$、$p(r|s,a)$、$p(s'|s,a)$——均为确定性的，则状态价值与回报相同。

状态价值

G_t 的期望（也称期望值或均值）定义为状态价值函数，简称状态价值：

$$v_\pi(s) = \mathbb{E}[G_t|S_t = s]$$

说明：

- 它是关于 s 的函数，是以状态从 s 出发为条件的条件期望。
- 它依赖于策略 π。不同策略对应不同的状态价值。

问：回报与状态价值之间有什么关系？
答：状态价值是从某状态出发所有可能回报的均值。若一切——$\pi(a|s)$、$p(r|s,a)$、$p(s'|s,a)$——均为确定性的，则状态价值与回报相同。

状态价值

示例：哪个策略好，哪个策略差?

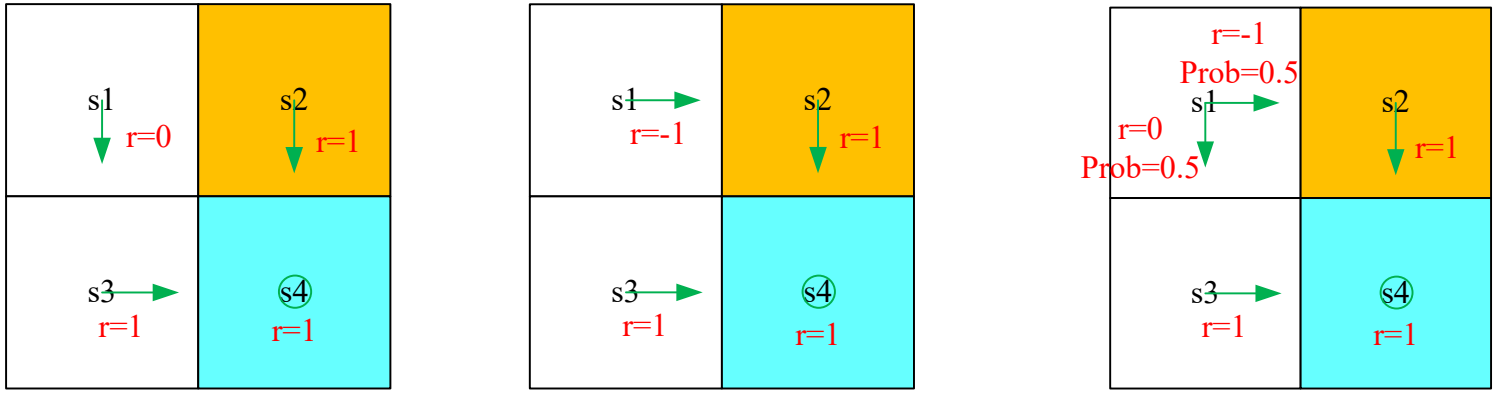

回顾三个示例中从 s_1 出发所得的回报：

状态价值

示例：哪个策略好，哪个策略差?

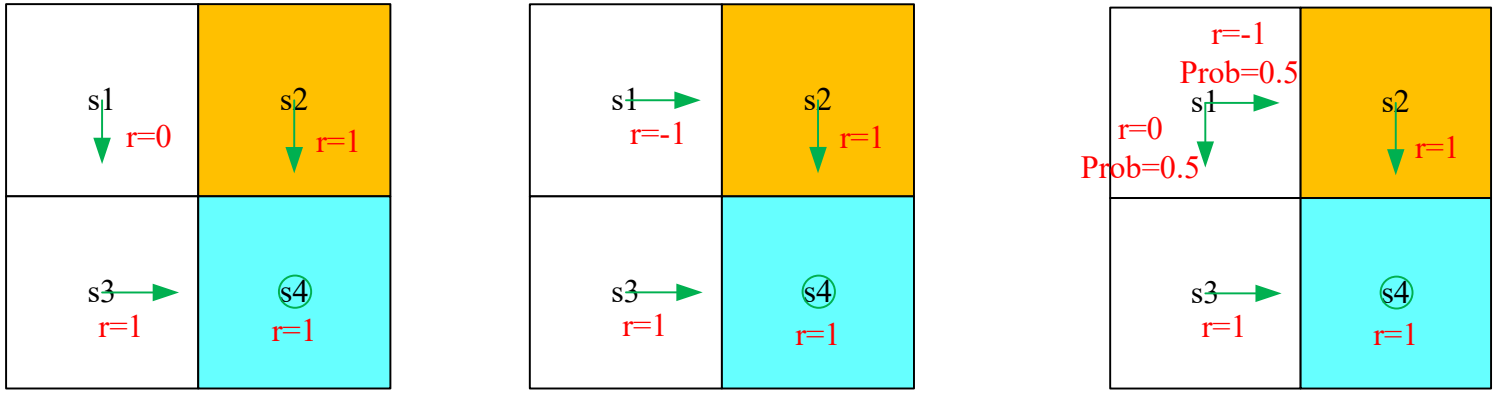

回顾三个示例中从 s_1 出发所得的回报：

$$v_{\pi_1}(s_1) = 0 + \gamma 1 + \gamma^2 1 + \cdots = \gamma(1 + \gamma + \gamma^2 + \ldots) = \frac{\gamma}{1-\gamma}$$

状态价值

示例：哪个策略好，哪个策略差?

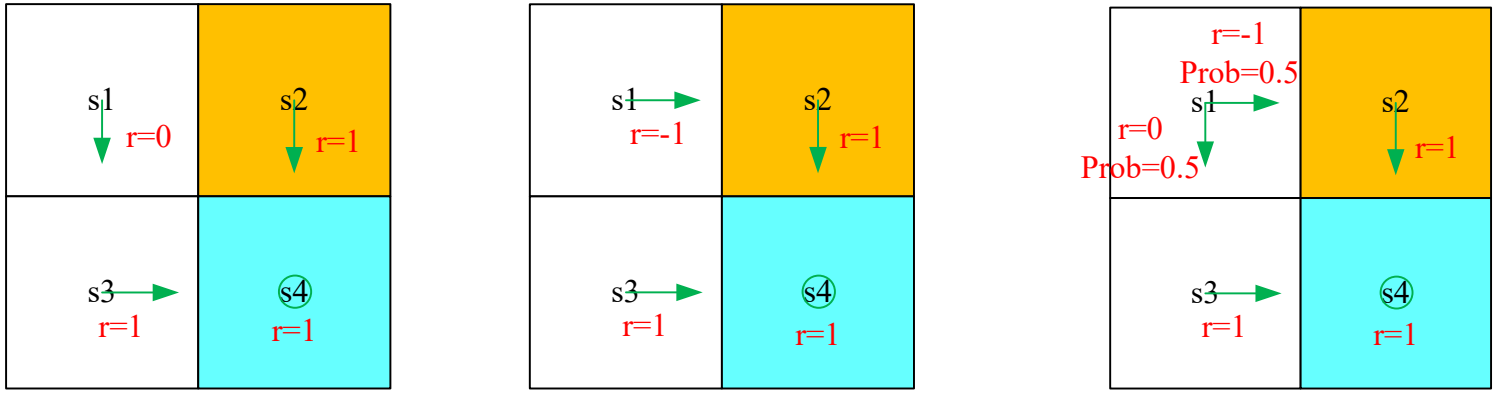

回顾三个示例中从 s_1 出发所得的回报：

$$v_{\pi_1}(s_1) = 0 + \gamma 1 + \gamma^2 1 + \cdots = \gamma(1 + \gamma + \gamma^2 + \ldots) = \frac{\gamma}{1-\gamma}$$

$$v_{\pi_2}(s_1) = -1 + \gamma 1 + \gamma^2 1 + \cdots = -1 + \gamma(1 + \gamma + \gamma^2 + \ldots) = -1 + \frac{\gamma}{1-\gamma}$$

状态价值

示例：哪个策略好，哪个策略差?

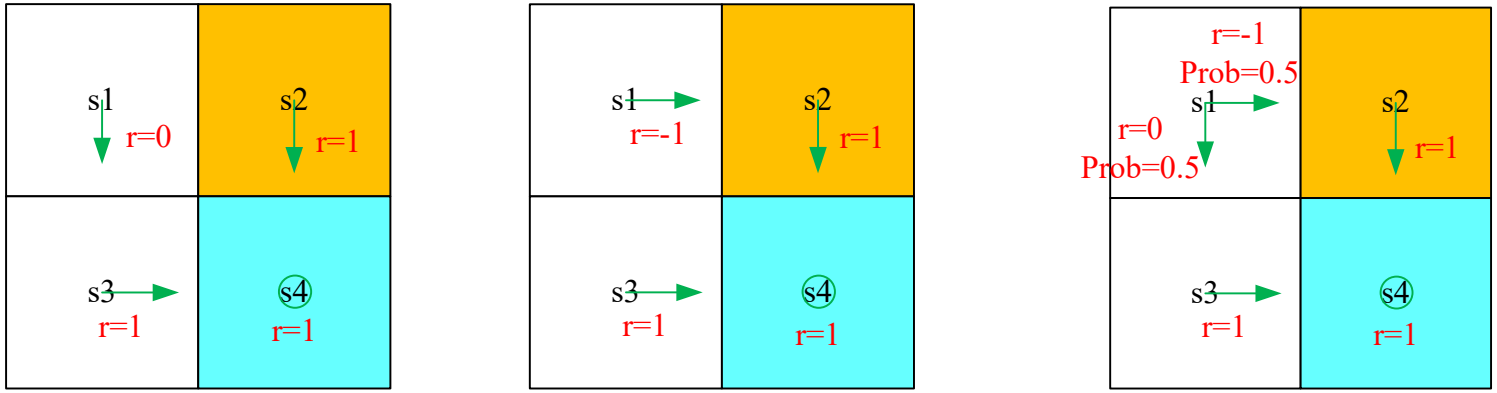

回顾三个示例中从 s_1 出发所得的回报：

$$v_{\pi_1}(s_1) = 0 + \gamma 1 + \gamma^2 1 + \cdots = \gamma(1 + \gamma + \gamma^2 + \ldots) = \frac{\gamma}{1-\gamma}$$

$$v_{\pi_2}(s_1) = -1 + \gamma 1 + \gamma^2 1 + \cdots = -1 + \gamma(1 + \gamma + \gamma^2 + \ldots) = -1 + \frac{\gamma}{1-\gamma}$$

$$v_{\pi_3}(s_1) = 0.5\left(-1 + \frac{\gamma}{1-\gamma}\right) + 0.5\left(\frac{\gamma}{1-\gamma}\right) = -0.5 + \frac{\gamma}{1-\gamma}$$

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

贝尔曼方程

- 状态价值固然重要，但如何计算？答案在于贝尔曼方程。
- 简而言之，贝尔曼方程描述了所有状态价值函数之间的关系。
- 接下来推导贝尔曼方程。
  - 涉及一些数学推导，但无需担心，因为我们已有直觉基础。

贝尔曼方程

- 状态价值固然重要，但如何计算？答案在于贝尔曼方程。
- 简而言之，贝尔曼方程描述了所有状态价值函数之间的关系。
- 接下来推导贝尔曼方程。
  - 涉及一些数学推导，但无需担心，因为我们已有直觉基础。

贝尔曼方程

- 状态价值固然重要，但如何计算？答案在于贝尔曼方程。
- 简而言之，贝尔曼方程描述了所有状态价值函数之间的关系。
- 接下来推导贝尔曼方程。
  - 涉及一些数学推导，但无需担心，因为我们已有直觉基础。

推导贝尔曼方程

考虑一条随机轨迹:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2} \xrightarrow{A_{t+2}} R_{t+3}, \ldots$$

回报 G_t 可以写成

$$\begin{aligned} G_t &= R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots, \\ &= R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \ldots), \\ &= R_{t+1} + \gamma G_{t+1} \end{aligned}$$

由状态价值的定义可得

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[G_t | S_t = s] \\ &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \mathbb{E}[R_{t+1} | S_t = s] + \gamma \mathbb{E}[G_{t+1} | S_t = s] \end{aligned}$$

接下来逐项计算。

推导贝尔曼方程

考虑一条随机轨迹:

$$S_t \xrightarrow{A_t} R_{t+1}, S_{t+1} \xrightarrow{A_{t+1}} R_{t+2}, S_{t+2} \xrightarrow{A_{t+2}} R_{t+3}, \ldots$$

回报 G_t 可以写成

$$\begin{aligned} G_t &= R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots, \\ &= R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \ldots), \\ &= R_{t+1} + \gamma G_{t+1} \end{aligned}$$

由状态价值的定义可得

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[G_t | S_t = s] \\ &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \mathbb{E}[R_{t+1} | S_t = s] + \gamma \mathbb{E}[G_{t+1} | S_t = s] \end{aligned}$$

接下来逐项计算。

推导贝尔曼方程

第一步，计算第一项 $\mathbb{E}[R_{t+1}|S_t = s]$:

$$\begin{aligned}\mathbb{E}[R_{t+1}|S_t = s] &= \sum_a \pi(a|s)\mathbb{E}[R_{t+1}|S_t = s, A_t = a] \\ &= \sum_a \pi(a|s) \sum_r p(r|s,a)r\end{aligned}$$

注意:

- 这是即时奖励的均值

推导贝尔曼方程

第一步，计算第一项 $\mathbb{E}[R_{t+1}|S_t = s]$:

$$\begin{aligned}\mathbb{E}[R_{t+1}|S_t = s] &= \sum_a \pi(a|s)\mathbb{E}[R_{t+1}|S_t = s, A_t = a] \\ &= \sum_a \pi(a|s) \sum_r p(r|s,a)r\end{aligned}$$

注意:

- 这是即时奖励的均值

推导贝尔曼方程

第二步，计算第二项 $\mathbb{E}[G_{t+1}|S_t = s]$:

$$
\begin{aligned}
\mathbb{E}[G_{t+1}|S_t = s] &= \sum_{s'} \mathbb{E}[G_{t+1}|S_t = s, S_{t+1} = s']p(s'|s) \\
&= \sum_{s'} \mathbb{E}[G_{t+1}|S_{t+1} = s']p(s'|s) \\
&= \sum_{s'} v_\pi(s')p(s'|s) \\
&= \sum_{s'} v_\pi(s') \sum_a p(s'|s,a)\pi(a|s)
\end{aligned}
$$

注意:

- 这是未来奖励的均值
- $\mathbb{E}[G_{t+1}|S_t = s, S_{t+1} = s'] = \mathbb{E}[G_{t+1}|S_{t+1} = s']$，这是由马尔可夫无记忆性保证的。

推导贝尔曼方程

第二步，计算第二项 $\mathbb{E}[G_{t+1}|S_t = s]$:

$$
\begin{aligned}
\mathbb{E}[G_{t+1}|S_t = s] &= \sum_{s'} \mathbb{E}[G_{t+1}|S_t = s, S_{t+1} = s']p(s'|s) \\
&= \sum_{s'} \mathbb{E}[G_{t+1}|S_{t+1} = s']p(s'|s) \\
&= \sum_{s'} v_\pi(s')p(s'|s) \\
&= \sum_{s'} v_\pi(s') \sum_a p(s'|s,a)\pi(a|s)
\end{aligned}
$$

注意:

- 这是未来奖励的均值
- $\mathbb{E}[G_{t+1}|S_t = s, S_{t+1} = s'] = \mathbb{E}[G_{t+1}|S_{t+1} = s']$，这是由马尔可夫无记忆性保证的。

推导贝尔曼方程

因此，我们得到

$$
\begin{aligned}
v_\pi(s) &= \mathbb{E}[R_{t+1}|S_t = s] + \gamma \mathbb{E}[G_{t+1}|S_t = s], \\
&= \underbrace{\sum_a \pi(a|s) \sum_r p(r|s,a) r}_{\text{即时奖励均值}} + \underbrace{\gamma \sum_a \pi(a|s) \sum_{s'} p(s'|s,a) v_\pi(s')}_{\text{未来奖励均值}}, \\
&= \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right], \quad \forall s \in \mathcal{S}.
\end{aligned}
$$

要点：

- 上式称为贝尔曼方程，它刻画了不同状态价值函数之间的关系。
- 由两项组成：即时奖励项和未来奖励项。
- 这是一组方程：每个状态都有一个这样的方程！！！

推导贝尔曼方程

因此，我们得到

$$
\begin{aligned}
v_\pi(s) &= \mathbb{E}[R_{t+1}|S_t = s] + \gamma \mathbb{E}[G_{t+1}|S_t = s], \\
&= \underbrace{\sum_a \pi(a|s) \sum_r p(r|s,a) r}_{\text{即时奖励均值}} + \underbrace{\gamma \sum_a \pi(a|s) \sum_{s'} p(s'|s,a) v_\pi(s')}_{\text{未来奖励均值}}, \\
&= \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right], \quad \forall s \in \mathcal{S}.
\end{aligned}
$$

要点：

- 上式称为贝尔曼方程，它刻画了不同状态价值函数之间的关系。
- 由两项组成：即时奖励项和未来奖励项。
- 这是一组方程：每个状态都有一个这样的方程！！！

推导贝尔曼方程

因此，我们得到

$$
\begin{aligned}
v_\pi(s) &= \mathbb{E}[R_{t+1}|S_t = s] + \gamma \mathbb{E}[G_{t+1}|S_t = s], \\
&= \underbrace{\sum_a \pi(a|s) \sum_r p(r|s,a) r}_{\text{即时奖励均值}} + \underbrace{\gamma \sum_a \pi(a|s) \sum_{s'} p(s'|s,a) v_\pi(s')}_{\text{未来奖励均值}}, \\
&= \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right], \quad \forall s \in \mathcal{S}.
\end{aligned}
$$

要点：方程中的符号说明

- $v_\pi(s)$ 和 $v_\pi(s')$ 是待求的状态价值。自举！
- $\pi(a|s)$ 是给定策略。求解该方程称为策略评估。
- $p(r|s,a)$ 和 $p(s'|s,a)$ 代表动态模型。若模型已知或未知，分别如何处理?

示例演示

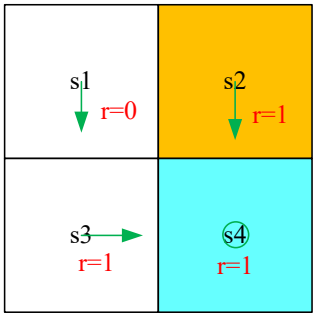

根据一般表达式写出贝尔曼方程:

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

该示例较为简单，因为策略是确定性的。

首先考虑 s_1 的状态价值:

- $\pi(a = a_3|s_1) = 1$，$\pi(a \neq a_3|s_1) = 0$。
- $p(r = 0|s_1, a_3) = 1$，$p(r \neq 0|s_1, a_3) = 0$。
- $p(s' = s_3|s_1, a_3) = 1$，$p(s' \neq s_3|s_1, a_3) = 0$。

代入贝尔曼方程得

$$v_\pi(s_1) = 0 + \gamma v_\pi(s_3)$$

示例演示

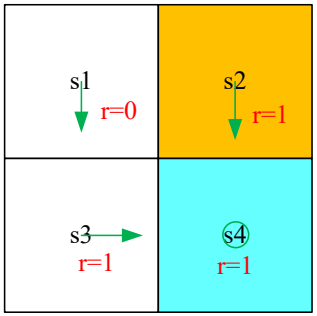

根据一般表达式写出贝尔曼方程:

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

该示例较为简单，因为策略是确定性的。
首先考虑 s_1 的状态价值:

- $\pi(a = a_3|s_1) = 1$，$\pi(a \neq a_3|s_1) = 0$。
- $p(r = 0|s_1, a_3) = 1$，$p(r \neq 0|s_1, a_3) = 0$。
- $p(s' = s_3|s_1, a_3) = 1$，$p(s' \neq s_3|s_1, a_3) = 0$。

代入贝尔曼方程得

$$v_\pi(s_1) = 0 + \gamma v_\pi(s_3)$$

示例演示

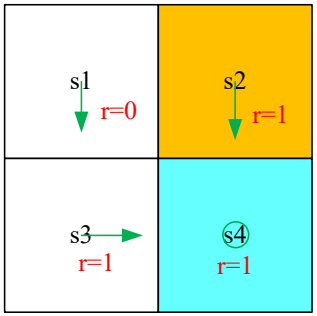

根据一般表达式写出贝尔曼方程:

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

该示例较为简单，因为策略是确定性的。
首先考虑 s_1 的状态价值:

- $\pi(a = a_3|s_1) = 1$，$\pi(a \neq a_3|s_1) = 0$。
- $p(r = 0|s_1, a_3) = 1$，$p(r \neq 0|s_1, a_3) = 0$。
- $p(s' = s_3|s_1, a_3) = 1$，$p(s' \neq s_3|s_1, a_3) = 0$。

代入贝尔曼方程得

$$v_\pi(s_1) = 0 + \gamma v_\pi(s_3)$$

示例演示

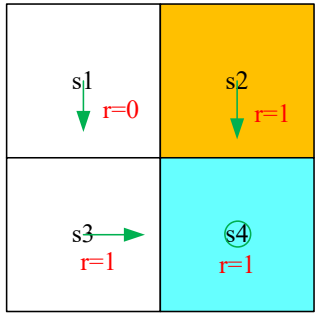

根据一般表达式写出贝尔曼方程:

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

类似地，可以得到

$$\begin{aligned}
v_\pi(s_1) &= 0 + \gamma v_\pi(s_3), \\
v_\pi(s_2) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_3) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_4) &= 1 + \gamma v_\pi(s_4).
\end{aligned}$$

示例演示

如何求解?

$$
\begin{aligned}
v_\pi(s_1) &= 0 + \gamma v_\pi(s_3), \\
v_\pi(s_2) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_3) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_4) &= 1 + \gamma v_\pi(s_4).
\end{aligned}
$$

从最后一个方程开始逐步求解:

$$
\begin{aligned}
v_\pi(s_4) &= \frac{1}{1-\gamma}, \\
v_\pi(s_3) &= \frac{1}{1-\gamma}, \\
v_\pi(s_2) &= \frac{1}{1-\gamma}, \\
v_\pi(s_1) &= \frac{\gamma}{1-\gamma}.
\end{aligned}
$$

示例演示

如何求解?

$$
\begin{aligned}
v_\pi(s_1) &= 0 + \gamma v_\pi(s_3), \\
v_\pi(s_2) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_3) &= 1 + \gamma v_\pi(s_4), \\
v_\pi(s_4) &= 1 + \gamma v_\pi(s_4).
\end{aligned}
$$

从最后一个方程开始逐步求解:

$$
\begin{aligned}
v_\pi(s_4) &= \frac{1}{1-\gamma}, \\
v_\pi(s_3) &= \frac{1}{1-\gamma}, \\
v_\pi(s_2) &= \frac{1}{1-\gamma}, \\
v_\pi(s_1) &= \frac{\gamma}{1-\gamma}.
\end{aligned}
$$

示例演示

若 $\gamma = 0.9$，则

$$
\begin{aligned}
v_\pi(s_4) &= \frac{1}{1-0.9} = 10, \\
v_\pi(s_3) &= \frac{1}{1-0.9} = 10, \\
v_\pi(s_2) &= \frac{1}{1-0.9} = 10, \\
v_\pi(s_1) &= \frac{0.9}{1-0.9} = 9.
\end{aligned}
$$

计算出状态价值后该做什么？请耐心等待（计算动作价值并改进策略）。

练习

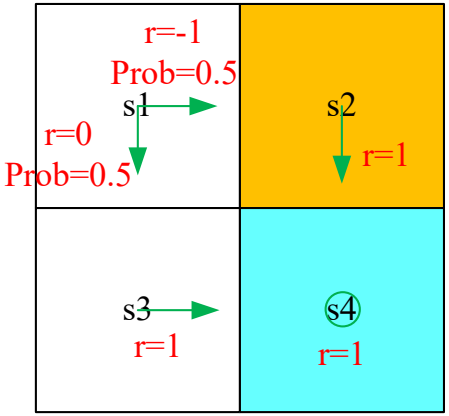

练习：

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

- 写出每个状态的贝尔曼方程。
- 从贝尔曼方程中求解状态价值。
- 与上一示例中的策略进行比较。

练习

答案:

$$
\begin{aligned}
v_\pi(s_1) &= 0.5[0+\gamma v_\pi(s_3)] + 0.5[-1+\gamma v_\pi(s_2)], \\
v_\pi(s_2) &= 1+\gamma v_\pi(s_4), \\
v_\pi(s_3) &= 1+\gamma v_\pi(s_4), \\
v_\pi(s_4) &= 1+\gamma v_\pi(s_4).
\end{aligned}
$$

从最后一个方程开始逐步求解:

$$
\begin{aligned}
v_\pi(s_4) &= \frac{1}{1-\gamma}, \quad v_\pi(s_3) = \frac{1}{1-\gamma}, \quad v_\pi(s_2) = \frac{1}{1-\gamma}, \\
v_\pi(s_1) &= 0.5[0+\gamma v_\pi(s_3)] + 0.5[-1+\gamma v_\pi(s_2)], \\
&= -0.5 + \frac{\gamma}{1-\gamma}.
\end{aligned}
$$

代入 $\gamma = 0.9$ 得

$$
v_\pi(s_4) = 10, \quad v_\pi(s_3) = 10, \quad v_\pi(s_2) = 10, \quad v_\pi(s_1) = -0.5 + 9 = 8.5.
$$

与上一策略相比，该策略更差。

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

贝尔曼方程的矩阵-向量形式

为何要考虑矩阵-向量形式？因为我们需要从中求解状态价值！

- 一个未知量依赖于另一个未知量，如何求解？

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

- 逐元素形式：上述逐元素形式对每个状态 $s \in \mathcal{S}$ 均成立，共有 $|\mathcal{S}|$ 个这样的方程！
- 矩阵-向量形式：将所有方程整合在一起，得到一组线性方程组，可简洁地写成矩阵-向量形式，既优雅又重要。

贝尔曼方程的矩阵-向量形式

为何要考虑矩阵-向量形式？因为我们需要从中求解状态价值！

- 一个未知量依赖于另一个未知量，如何求解？

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

- 逐元素形式：上述逐元素形式对每个状态 $s \in \mathcal{S}$ 均成立，共有 $|\mathcal{S}|$ 个这样的方程！
- 矩阵-向量形式：将所有方程整合在一起，得到一组线性方程组，可简洁地写成矩阵-向量形式，既优雅又重要。

贝尔曼方程的矩阵-向量形式

为何要考虑矩阵-向量形式？因为我们需要从中求解状态价值！

- 一个未知量依赖于另一个未知量，如何求解？

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

- 逐元素形式：上述逐元素形式对每个状态 $s \in \mathcal{S}$ 均成立，共有 $|\mathcal{S}|$ 个这样的方程！
- 矩阵-向量形式：将所有方程整合在一起，得到一组线性方程组，可简洁地写成矩阵-向量形式，既优雅又重要。

贝尔曼方程的矩阵-向量形式

为何要考虑矩阵-向量形式？因为我们需要从中求解状态价值！

- 一个未知量依赖于另一个未知量，如何求解？

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

- 逐元素形式：上述逐元素形式对每个状态 $s \in \mathcal{S}$ 均成立，共有 $|\mathcal{S}|$ 个这样的方程！
- 矩阵-向量形式：将所有方程整合在一起，得到一组线性方程组，可简洁地写成矩阵-向量形式，既优雅又重要。

贝尔曼方程的矩阵-向量形式

回顾:

$$v_\pi(s) = \sum_a \pi(a|s) \left[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \right]$$

将贝尔曼方程改写为

$$v_\pi(s) = r_\pi(s) + \gamma \sum_{s'} p_\pi(s'|s) v_\pi(s')$$

其中

$$r_\pi(s) \doteq \sum_a \pi(a|s) \sum_r p(r|s,a)r, \qquad p_\pi(s'|s) \doteq \sum_a \pi(a|s) p(s'|s,a)$$

贝尔曼方程的矩阵-向量形式

设状态可索引为 s_i（$i = 1, \ldots, n$）。
对状态 s_i，贝尔曼方程为

$$v_\pi(s_i) = r_\pi(s_i) + \gamma \sum_{s_j} p_\pi(s_j|s_i) v_\pi(s_j)$$

将所有状态的方程整合并改写为矩阵-向量形式:

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

其中

- $v_\pi = [v_\pi(s_1), \ldots, v_\pi(s_n)]^T \in \mathbb{R}^n$
- $r_\pi = [r_\pi(s_1), \ldots, r_\pi(s_n)]^T \in \mathbb{R}^n$
- $P_\pi \in \mathbb{R}^{n \times n}$，$[P_\pi]_{ij} = p_\pi(s_j|s_i)$，称为状态转移矩阵。

贝尔曼方程的矩阵-向量形式

设状态可索引为 s_i（$i = 1, \ldots, n$）。
对状态 s_i，贝尔曼方程为

$$v_\pi(s_i) = r_\pi(s_i) + \gamma \sum_{s_j} p_\pi(s_j|s_i) v_\pi(s_j)$$

将所有状态的方程整合并改写为矩阵-向量形式:

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

其中

- $v_\pi = [v_\pi(s_1), \ldots, v_\pi(s_n)]^T \in \mathbb{R}^n$
- $r_\pi = [r_\pi(s_1), \ldots, r_\pi(s_n)]^T \in \mathbb{R}^n$
- $P_\pi \in \mathbb{R}^{n \times n}$，$[P_\pi]_{ij} = p_\pi(s_j|s_i)$，称为状态转移矩阵。

示例演示

若共有四个状态，$v_\pi = r_\pi + \gamma P_\pi v_\pi$ 可展开为

$$\underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi} = \underbrace{\begin{bmatrix} r_\pi(s_1) \\ r_\pi(s_2) \\ r_\pi(s_3) \\ r_\pi(s_4) \end{bmatrix}}_{r_\pi} + \gamma \underbrace{\begin{bmatrix} p_\pi(s_1|s_1) & p_\pi(s_2|s_1) & p_\pi(s_3|s_1) & p_\pi(s_4|s_1) \\ p_\pi(s_1|s_2) & p_\pi(s_2|s_2) & p_\pi(s_3|s_2) & p_\pi(s_4|s_2) \\ p_\pi(s_1|s_3) & p_\pi(s_2|s_3) & p_\pi(s_3|s_3) & p_\pi(s_4|s_3) \\ p_\pi(s_1|s_4) & p_\pi(s_2|s_4) & p_\pi(s_3|s_4) & p_\pi(s_4|s_4) \end{bmatrix}}_{P_\pi} \underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi}$$

示例演示

若共有四个状态，$v_\pi = r_\pi + \gamma P_\pi v_\pi$ 可展开为

$$\underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi} = \underbrace{\begin{bmatrix} r_\pi(s_1) \\ r_\pi(s_2) \\ r_\pi(s_3) \\ r_\pi(s_4) \end{bmatrix}}_{r_\pi} + \gamma \underbrace{\begin{bmatrix} p_\pi(s_1|s_1) & p_\pi(s_2|s_1) & p_\pi(s_3|s_1) & p_\pi(s_4|s_1) \\ p_\pi(s_1|s_2) & p_\pi(s_2|s_2) & p_\pi(s_3|s_2) & p_\pi(s_4|s_2) \\ p_\pi(s_1|s_3) & p_\pi(s_2|s_3) & p_\pi(s_3|s_3) & p_\pi(s_4|s_3) \\ p_\pi(s_1|s_4) & p_\pi(s_2|s_4) & p_\pi(s_3|s_4) & p_\pi(s_4|s_4) \end{bmatrix}}_{P_\pi} \underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi}$$

对如下示例：

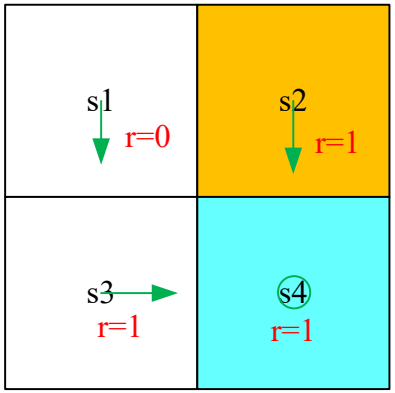

$$\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}$$

示例演示

若共有四个状态，$v_\pi = r_\pi + \gamma P_\pi v_\pi$ 可展开为

$$\underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi} = \underbrace{\begin{bmatrix} r_\pi(s_1) \\ r_\pi(s_2) \\ r_\pi(s_3) \\ r_\pi(s_4) \end{bmatrix}}_{r_\pi} + \gamma \underbrace{\begin{bmatrix} p_\pi(s_1|s_1) & p_\pi(s_2|s_1) & p_\pi(s_3|s_1) & p_\pi(s_4|s_1) \\ p_\pi(s_1|s_2) & p_\pi(s_2|s_2) & p_\pi(s_3|s_2) & p_\pi(s_4|s_2) \\ p_\pi(s_1|s_3) & p_\pi(s_2|s_3) & p_\pi(s_3|s_3) & p_\pi(s_4|s_3) \\ p_\pi(s_1|s_4) & p_\pi(s_2|s_4) & p_\pi(s_3|s_4) & p_\pi(s_4|s_4) \end{bmatrix}}_{P_\pi} \underbrace{\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}}_{v_\pi}.$$

对如下示例：

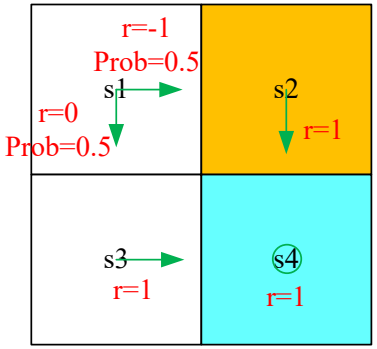

$$\begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix} = \begin{bmatrix} 0.5(0) + 0.5(-1) \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma \begin{bmatrix} 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v_\pi(s_1) \\ v_\pi(s_2) \\ v_\pi(s_3) \\ v_\pi(s_4) \end{bmatrix}.$$

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

求解状态价值

为何要求解状态价值?

- 给定策略，求解对应的状态价值称为策略评估！
- 这是强化学习中的基本问题，是寻找更优策略的基础。
- 因此，理解如何求解贝尔曼方程至关重要。

求解状态价值

矩阵-向量形式的贝尔曼方程为

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 闭合形式解为

$$v_\pi = (I - \gamma P_\pi)^{-1} r_\pi$$

  - 矩阵 $I - \gamma P_\pi$ 是可逆的，详见教材。
  - 仍需使用数值算法计算矩阵逆。
  - 能否避免矩阵求逆运算？可以，见下文。

- 迭代解为

$$v_{k+1} = r_\pi + \gamma P_\pi v_k$$

  该算法生成序列 $\{v_0, v_1, v_2, \ldots\}$。可以证明

$$v_k \to v_\pi = (I - \gamma P_\pi)^{-1} r_\pi, \quad k \to \infty$$

求解状态价值

矩阵-向量形式的贝尔曼方程为

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 闭合形式解为

$$v_\pi = (I - \gamma P_\pi)^{-1} r_\pi$$

  - 矩阵 $I - \gamma P_\pi$ 是可逆的，详见教材。
  - 仍需使用数值算法计算矩阵逆。
  - 能否避免矩阵求逆运算？可以，见下文。

- 迭代解为

$$v_{k+1} = r_\pi + \gamma P_\pi v_k$$

  该算法生成序列 $\{v_0, v_1, v_2, \ldots\}$。可以证明

$$v_k \to v_\pi = (I - \gamma P_\pi)^{-1} r_\pi, \quad k \to \infty$$

求解状态价值

矩阵-向量形式的贝尔曼方程为

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 闭合形式解为

$$v_\pi = (I - \gamma P_\pi)^{-1} r_\pi$$

  - 矩阵 $I - \gamma P_\pi$ 是可逆的，详见教材。
  - 仍需使用数值算法计算矩阵逆。
  - 能否避免矩阵求逆运算？可以，见下文。

- 迭代解为

$$v_{k+1} = r_\pi + \gamma P_\pi v_k$$

  该算法生成序列 $\{v_0, v_1, v_2, \dots\}$。可以证明

$$v_k \to v_\pi = (I - \gamma P_\pi)^{-1} r_\pi, \quad k \to \infty$$

求解状态价值（选读）

Proof.

定义误差为

$$\delta_k = v_k - v_\pi.$$

只需证明 $\delta_k \to 0$。将 $v_{k+1} = \delta_{k+1} + v_\pi$ 和 $v_k = \delta_k + v_\pi$ 代入 $v_{k+1} = r_\pi + \gamma P_\pi v_k$，得

$$\delta_{k+1} + v_\pi = r_\pi + \gamma P_\pi(\delta_k + v_\pi),$$

整理为

$$\delta_{k+1} = -v_\pi + r_\pi + \gamma P_\pi \delta_k + \gamma P_\pi v_\pi = \gamma P_\pi \delta_k.$$

因此，

$$\delta_{k+1} = \gamma P_\pi \delta_k = \gamma^2 P_\pi^2 \delta_{k-1} = \cdots = \gamma^{k+1} P_\pi^{k+1} \delta_0.$$

注意 $0 \le P_\pi^k \le 1$，即对任意 $k = 0, 1, 2, \ldots$，P_π^k 的每个元素均不超过$\mathbf{1}$，这是因为 $P_\pi^k \mathbf{1} = \mathbf{1}$，其中 $\mathbf{1} = [1, \ldots, 1]^T$。另一方面，由于 $\gamma < 1$，$\gamma^k \to 0$，从而当 $k \to \infty$ 时 $\delta_{k+1} = \gamma^{k+1} P_\pi^{k+1} \delta_0 \to 0$。 □

求解状态价值

示例：$r_{\text{boundary}} = r_{\text{forbidden}} = -1$，$r_{\text{target}} = +1$，$\gamma = 0.9$

- 以下是两个"好"策略及其状态价值。两个策略在第四列顶部两个状态处有所不同。

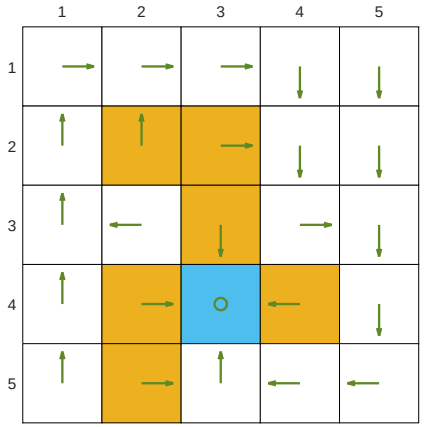

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

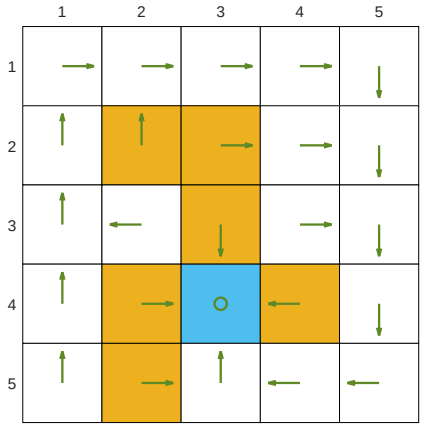

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

求解状态价值

示例：$r_{\text{boundary}} = r_{\text{forbidden}} = -1$，$r_{\text{target}} = +1$，$\gamma = 0.9$

- 以下是两个"差"策略及其状态价值。其状态价值低于好策略。

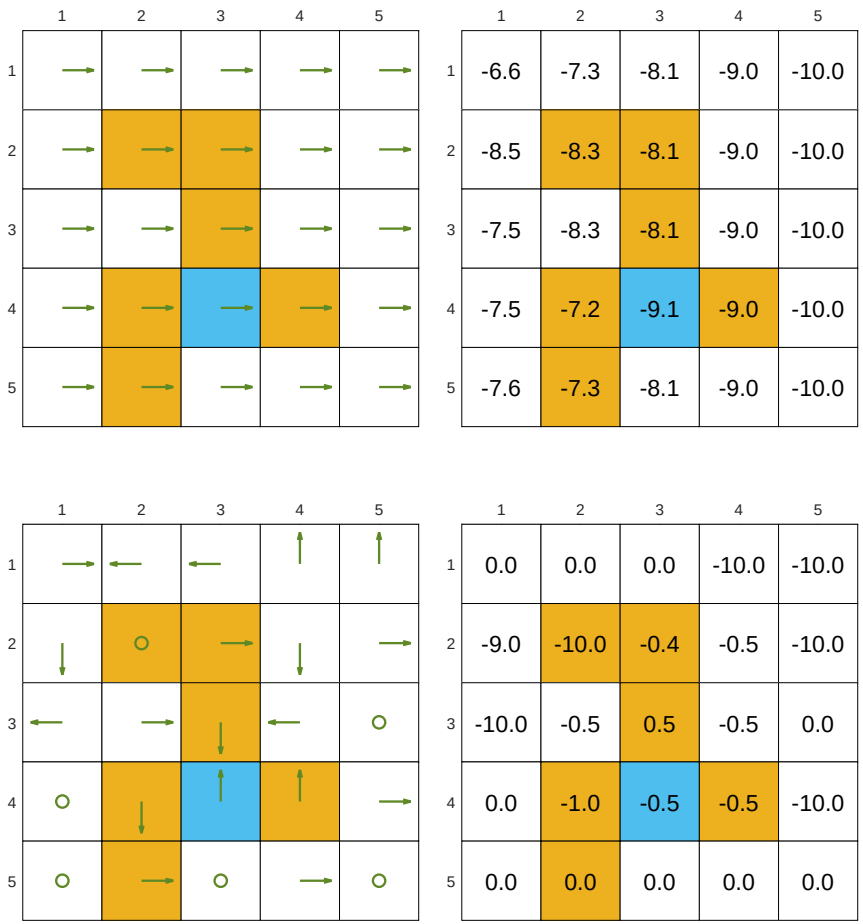

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

动作价值

从状态价值到动作价值：

- 状态价值：智能体从某状态出发能获得的平均回报。
- 动作价值：智能体从某状态出发并采取某动作后能获得的平均回报。

为何关注动作价值？因为我们想知道哪个动作更好。这一点在后续讲解中会更加清晰，我们将频繁使用动作价值。

动作价值

从状态价值到动作价值：

- 状态价值：智能体从某状态出发能获得的平均回报。
- 动作价值：智能体从某状态出发并采取某动作后能获得的平均回报。

为何关注动作价值？因为我们想知道哪个动作更好。这一点在后续讲解中会更加清晰，我们将频繁使用动作价值。

动作价值

从状态价值到动作价值：

- 状态价值：智能体从某状态出发能获得的平均回报。
- 动作价值：智能体从某状态出发并采取某动作后能获得的平均回报。

为何关注动作价值？因为我们想知道哪个动作更好。这一点在后续讲解中会更加清晰，我们将频繁使用动作价值。

动作价值

定义:

$$q_\pi(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a]$$

- $q_\pi(s,a)$ 是状态-动作对 (s,a) 的函数
- $q_\pi(s,a)$ 依赖于策略 π

由条件期望的性质可得

$$\underbrace{\mathbb{E}[G_t | S_t = s]}_{v_\pi(s)} = \sum_a \underbrace{\mathbb{E}[G_t | S_t = s, A_t = a]}_{q_\pi(s,a)} \pi(a|s)$$

因此,

$$v_\pi(s) = \sum_a \pi(a|s) q_\pi(s,a) \tag{1}$$

动作价值

定义:

$$q_\pi(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$$

- $q_\pi(s,a)$ 是状态-动作对 (s,a) 的函数
- $q_\pi(s,a)$ 依赖于策略 π

由条件期望的性质可得

$$\underbrace{\mathbb{E}[G_t|S_t = s]}_{v_\pi(s)} = \sum_a \underbrace{\mathbb{E}[G_t|S_t = s, A_t = a]}_{q_\pi(s,a)} \pi(a|s)$$

因此,

$$v_\pi(s) = \sum_a \pi(a|s) q_\pi(s,a) \tag{1}$$

动作价值

回顾状态价值的表达式:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)} \tag{2}$$

比较 (1) 和 (2)，得**动作价值函数**为

$$q_\pi(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \tag{3}$$

(1) 和 (3) 是一枚硬币的两面:

- (1) 展示了如何从动作价值得到状态价值。
- (3) 展示了如何从状态价值得到动作价值。

动作价值

回顾状态价值的表达式:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)} \tag{2}$$

比较 (1) 和 (2)，得**动作价值函数**为

$$q_\pi(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \tag{3}$$

(1) 和 (3) 是一枚硬币的两面:

- (1) 展示了如何从动作价值得到状态价值。
- (3) 展示了如何从状态价值得到动作价值。

动作价值

回顾状态价值的表达式:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)} \tag{2}$$

比较 (1) 和 (2)，得**动作价值函数**为

$$q_\pi(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \tag{3}$$

(1) 和 (3) 是一枚硬币的两面:

- (1) 展示了如何从动作价值得到状态价值。
- (3) 展示了如何从状态价值得到动作价值。

动作价值示例

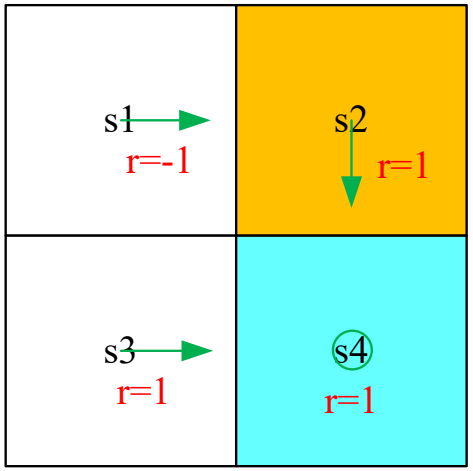

写出状态 s_1 的动作价值:

$$q_\pi(s_1, a_2) = -1 + \gamma v_\pi(s_2),$$

问题:

- $q_\pi(s_1, a_1), q_\pi(s_1, a_3), q_\pi(s_1, a_4), q_\pi(s_1, a_5) =?$ 请注意!

动作价值示例

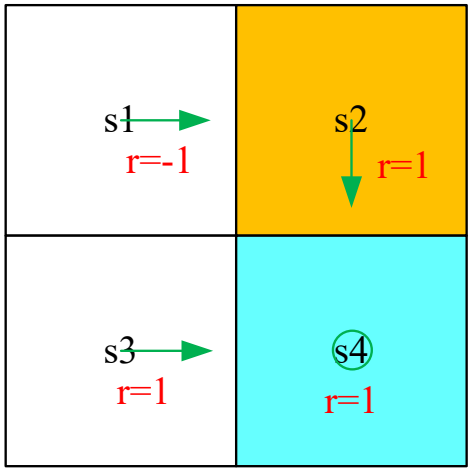

写出状态 s_1 的动作价值:

$$q_\pi(s_1, a_2) = -1 + \gamma v_\pi(s_2),$$

问题:

- $q_\pi(s_1, a_1), q_\pi(s_1, a_3), q_\pi(s_1, a_4), q_\pi(s_1, a_5) =?$ 请注意!

动作价值示例

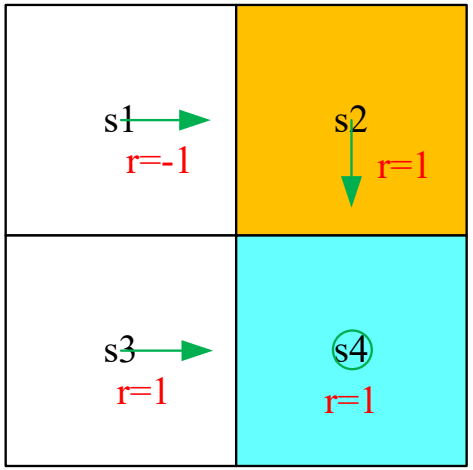

其他动作的动作价值:

$$
\begin{aligned}
q_\pi(s_1, a_1) &= -1 + \gamma v_\pi(s_1), \\
q_\pi(s_1, a_3) &= 0 + \gamma v_\pi(s_3), \\
q_\pi(s_1, a_4) &= -1 + \gamma v_\pi(s_1), \\
q_\pi(s_1, a_5) &= 0 + \gamma v_\pi(s_1).
\end{aligned}
$$

动作价值示例

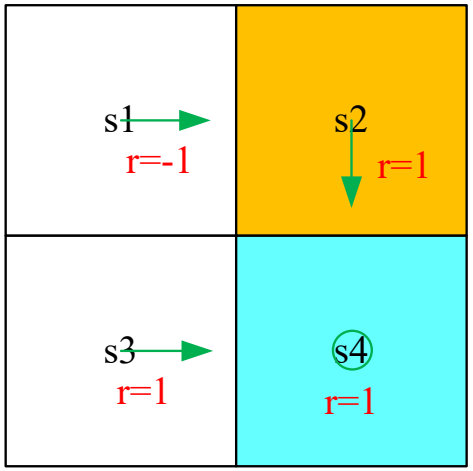

要点:

- 动作价值很重要，因为我们关心应该采取哪个动作。
- 可以先计算所有状态价值，再计算动作价值。
- 也可以在有模型或无模型的情况下直接计算动作价值。

大纲

1 动机示例

2 状态价值

3 贝尔曼方程：推导

4 贝尔曼方程：矩阵-向量形式

5 贝尔曼方程：求解状态价值

6 动作价值

7 总结

总结

关键概念与结论：

- 状态价值：$v_\pi(s) = \mathbb{E}[G_t | S_t = s]$
- 动作价值：$q_\pi(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a]$
- 贝尔曼方程（逐元素形式）：

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)}$$

$$= \sum_a \pi(a|s) q_\pi(s,a)$$

- 贝尔曼方程（矩阵-向量形式）：

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 如何求解贝尔曼方程：闭合形式解、迭代解

总结

关键概念与结论:

- 状态价值: $v_\pi(s) = \mathbb{E}[G_t|S_t = s]$
- 动作价值: $q_\pi(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$
- 贝尔曼方程（逐元素形式）:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)}$$

$$= \sum_a \pi(a|s) q_\pi(s,a)$$

- 贝尔曼方程（矩阵-向量形式）:

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 如何求解贝尔曼方程: 闭合形式解、迭代解

总结

关键概念与结论:

- 状态价值: $v_\pi(s) = \mathbb{E}[G_t|S_t = s]$
- 动作价值: $q_\pi(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$
- 贝尔曼方程（逐元素形式）:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)}$$

$$= \sum_a \pi(a|s) q_\pi(s,a)$$

- 贝尔曼方程（矩阵-向量形式）:

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 如何求解贝尔曼方程: 闭合形式解、迭代解

总结

关键概念与结论:

- 状态价值: $v_\pi(s) = \mathbb{E}[G_t|S_t = s]$
- 动作价值: $q_\pi(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$
- 贝尔曼方程（逐元素形式）:

$$v_\pi(s) = \sum_a \pi(a|s) \underbrace{\Big[\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v_\pi(s') \Big]}_{q_\pi(s,a)}$$

$$= \sum_a \pi(a|s) q_\pi(s,a)$$

- 贝尔曼方程（矩阵-向量形式）:

$$v_\pi = r_\pi + \gamma P_\pi v_\pi$$

- 如何求解贝尔曼方程: 闭合形式解、迭代解