第三讲：最优状态值与贝尔曼最优方程

April 11, 2026

大纲

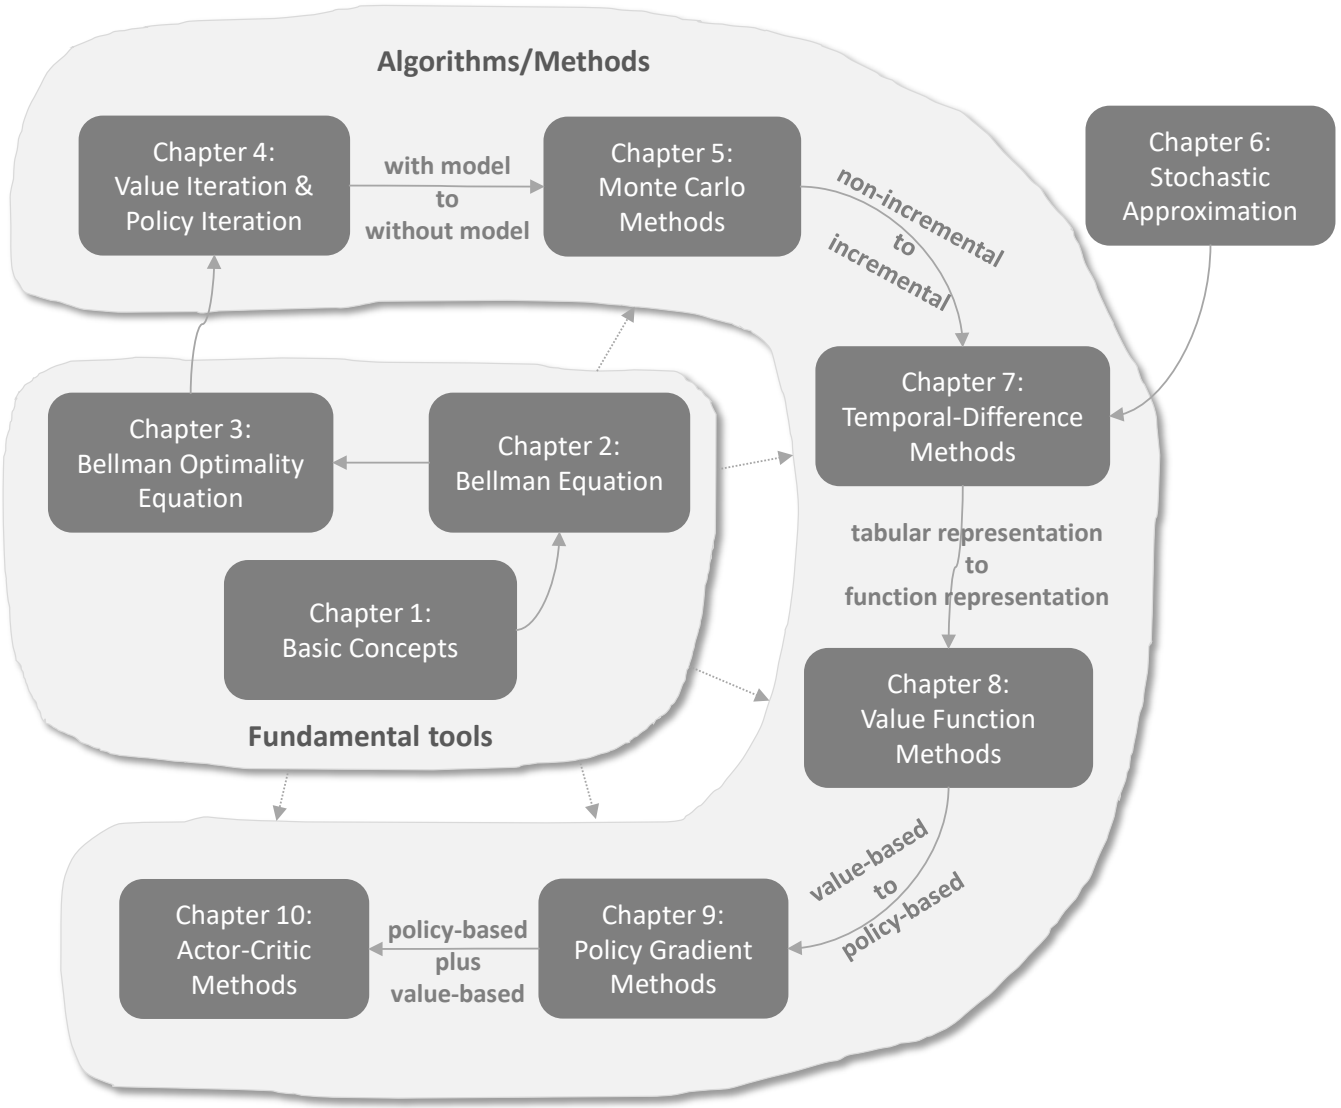
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

大纲

本讲内容：

- 核心概念：最优状态价值与最优策略
- 基本工具：贝尔曼最优方程（BOE）

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

动机示例

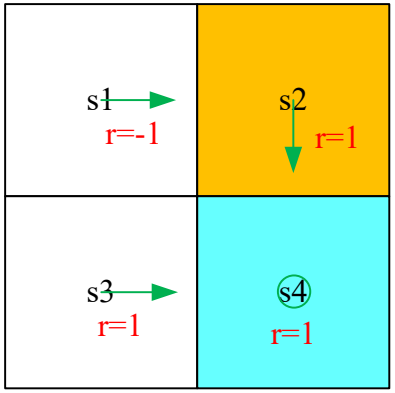

练习：写出贝尔曼方程并求解状态价值（令 $\gamma = 0.9$）

答案：贝尔曼方程：

$$
\begin{aligned}
v_\pi(s_1) &= -1 + \gamma v_\pi(s_2), \\
v_\pi(s_2) &= +1 + \gamma v_\pi(s_4), \\
v_\pi(s_3) &= +1 + \gamma v_\pi(s_4), \\
v_\pi(s_4) &= +1 + \gamma v_\pi(s_4).
\end{aligned}
$$

状态价值：$v_\pi(s_4) = v_\pi(s_3) = v_\pi(s_2) = 10, \quad v_\pi(s_1) = 8$

动机示例

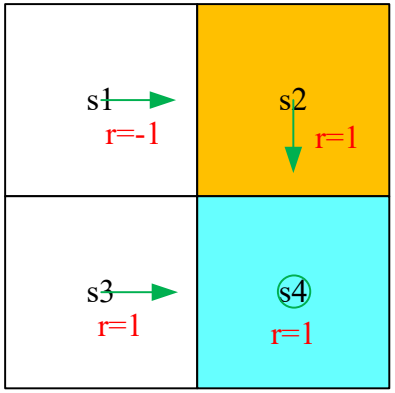

练习：写出贝尔曼方程并求解状态价值（令 $\gamma = 0.9$）

答案：贝尔曼方程：

$$
\begin{aligned}
v_\pi(s_1) &= -1 + \gamma v_\pi(s_2), \\
v_\pi(s_2) &= +1 + \gamma v_\pi(s_4), \\
v_\pi(s_3) &= +1 + \gamma v_\pi(s_4), \\
v_\pi(s_4) &= +1 + \gamma v_\pi(s_4).
\end{aligned}
$$

状态价值：$v_\pi(s_4) = v_\pi(s_3) = v_\pi(s_2) = 10, \quad v_\pi(s_1) = 8$

动机示例

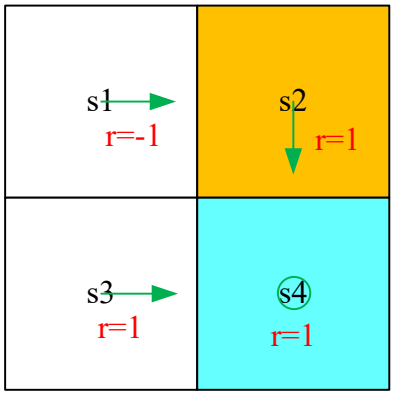

练习：计算 s_1 处五个动作的动作价值

答案： 动作价值:

$$q_\pi(s_1, a_1) = -1 + \gamma v_\pi(s_1) = 6.2,$$
$$q_\pi(s_1, a_2) = -1 + \gamma v_\pi(s_2) = 8,$$
$$q_\pi(s_1, a_3) = 0 + \gamma v_\pi(s_3) = 9,$$
$$q_\pi(s_1, a_4) = -1 + \gamma v_\pi(s_1) = 6.2,$$
$$q_\pi(s_1, a_5) = 0 + \gamma v_\pi(s_1) = 7.2.$$

动机示例

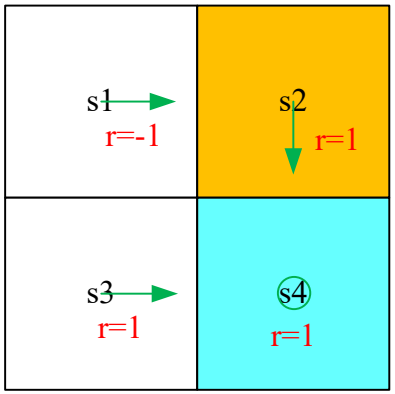

练习：计算 s_1 处五个动作的动作价值

答案： 动作价值:

$$q_\pi(s_1, a_1) = -1 + \gamma v_\pi(s_1) = 6.2,$$

$$q_\pi(s_1, a_2) = -1 + \gamma v_\pi(s_2) = 8,$$

$$q_\pi(s_1, a_3) = 0 + \gamma v_\pi(s_3) = 9,$$

$$q_\pi(s_1, a_4) = -1 + \gamma v_\pi(s_1) = 6.2,$$

$$q_\pi(s_1, a_5) = 0 + \gamma v_\pi(s_1) = 7.2.$$

动机示例

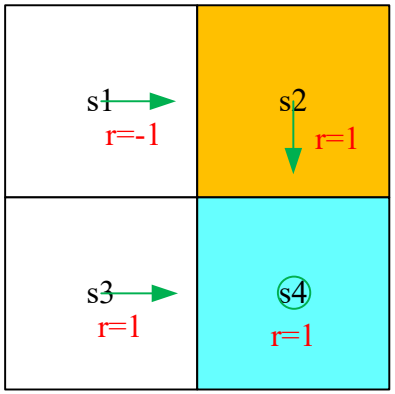

问题：当前策略不够好，如何改进?

答案：可以基于动作价值来改进策略。

具体而言，当前策略 $\pi(a|s_1)$ 为

$$\pi(a|s_1) = \begin{cases} 1 & a = a_2 \\ 0 & a \neq a_2 \end{cases}$$

动机示例

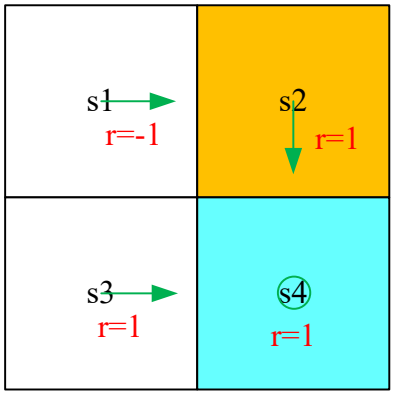

问题：当前策略不够好，如何改进?

答案：可以基于动作价值来改进策略。

具体而言，当前策略 $\pi(a|s_1)$ 为

$$\pi(a|s_1) = \begin{cases} 1 & a = a_2 \\ 0 & a \neq a_2 \end{cases}$$

动机示例

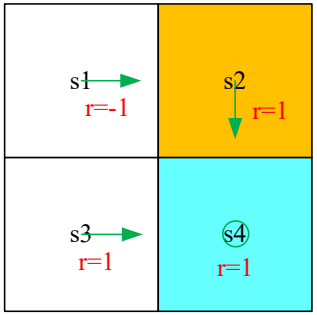

观察刚才得到的动作价值:

$$q_\pi(s_1, a_1) = 6.2, \quad q_\pi(s_1, a_2) = 8, \quad q_\pi(s_1, a_3) = 9,$$
$$q_\pi(s_1, a_4) = 6.2, \quad q_\pi(s_1, a_5) = 7.2.$$

若选择最大动作价值对应的动作，则新策略为

$$\pi_{\text{new}}(a|s_1) = \begin{cases} 1 & a = a_3 \\ 0 & a \neq a_3 \end{cases}$$

新策略可以避开禁止区域，看起来更好。

动机示例

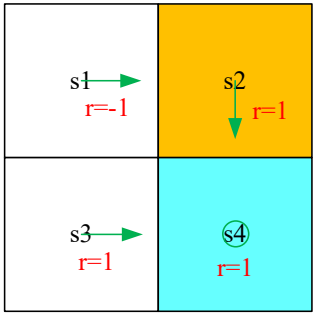

观察刚才得到的动作价值:

$$q_\pi(s_1, a_1) = 6.2, \quad q_\pi(s_1, a_2) = 8, \quad q_\pi(s_1, a_3) = 9,$$
$$q_\pi(s_1, a_4) = 6.2, \quad q_\pi(s_1, a_5) = 7.2.$$

若选择最大动作价值对应的动作，则新策略为

$$\pi_{\text{new}}(a|s_1) = \begin{cases} 1 & a = a_3 \\ 0 & a \neq a_3 \end{cases}$$

新策略可以避开禁止区域，看起来更好。

动机示例

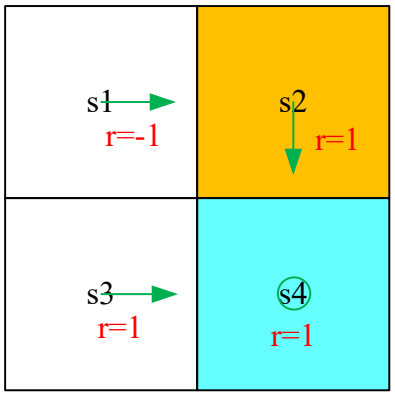

问题：为什么这样做可以改进策略?

- 直觉：很简单！价值更大的动作更好。
- 数学：并不显然！将在本讲及下一讲中介绍！

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

最优策略

状态价值可用于评估策略的优劣：若

$$v_{\pi_1}(s) \geq v_{\pi_2}(s) \quad \text{对所有 } s \in \mathcal{S}$$

则 π_1 优于 π_2。

该定义引出许多**问题**：

- 最优策略是否存在?
- 最优策略是否唯一?
- 最优策略是随机的还是确定性的?
- 如何获得最优策略?

要回答这些问题，需要用到贝尔曼最优方程。

最优策略

状态价值可用于评估策略的优劣：若

$$v_{\pi_1}(s) \geq v_{\pi_2}(s) \quad \text{对所有 } s \in \mathcal{S}$$

则 π_1 优于 π_2。

Definition

若对任意其他策略 π 和所有 $s \in \mathcal{S}$，均有 $v_{\pi^*}(s) \geq v_\pi(s)$，则策略 π^* 为最优策略。

该定义引出许多问题：

- 最优策略是否存在?
- 最优策略是否唯一?
- 最优策略是随机的还是确定性的?
- 如何获得最优策略?

要回答这些问题，需要用到贝尔曼最优方程。

最优策略

状态价值可用于评估策略的优劣：若

$$v_{\pi_1}(s) \geq v_{\pi_2}(s) \quad \text{对所有 } s \in \mathcal{S}$$

则 π_1 优于 π_2。

Definition

若对任意其他策略 π 和所有 $s \in \mathcal{S}$，均有 $v_{\pi^*}(s) \geq v_\pi(s)$，则策略 π^* 为最优策略。

该定义引出许多**问题**：

- 最优策略是否存在?
- 最优策略是否唯一?
- 最优策略是随机的还是确定性的?
- 如何获得最优策略?

要回答这些问题，需要用到贝尔曼最优方程。

最优策略

状态价值可用于评估策略的优劣：若

$$v_{\pi_1}(s) \geq v_{\pi_2}(s) \quad \text{对所有 } s \in \mathcal{S}$$

则 π_1 优于 π_2。

Definition

若对任意其他策略 π 和所有 $s \in \mathcal{S}$，均有 $v_{\pi^*}(s) \geq v_\pi(s)$，则策略 π^* 为最优策略。

该定义引出许多**问题**：

- 最优策略是否存在?
- 最优策略是否唯一?
- 最优策略是随机的还是确定性的?
- 如何获得最优策略?

要回答这些问题，需要用到贝尔曼最优方程。

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

贝尔曼最优方程（BOE）

贝尔曼最优方程（逐元素形式）：

$$v(s) = \sum_a \pi(a|s) \left(\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right), \quad s \in \mathcal{S}$$

贝尔曼最优方程（BOE）

贝尔曼最优方程（逐元素形式）：

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right), \quad s \in \mathcal{S}$$

贝尔曼最优方程（BOE）

贝尔曼最优方程（逐元素形式）：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a), \quad s \in \mathcal{S}
\end{aligned}
$$

贝尔曼最优方程（BOE）

贝尔曼最优方程（逐元素形式）：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a), \quad s \in \mathcal{S}
\end{aligned}
$$

说明:

- $p(r|s,a), p(s'|s,a)$，r，γ 均为已知量。
- $v(s), v(s')$ 为未知量，待求解。
- $\pi(s)$ 是已知还是未知？未知，待求解！

贝尔曼最优方程（BOE）

贝尔曼最优方程（矩阵-向量形式）：

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

其中对应状态 s 或 s' 的元素为

$$[r_\pi]_s \triangleq \sum_a \pi(a|s) \sum_r p(r|s,a) r,$$
$$[P_\pi]_{s,s'} = p(s'|s) \triangleq \sum_a \pi(a|s) \sum_{s'} p(s'|s,a)$$

其中 $\max_\pi$ 按元素执行：

$$\max_{\pi} \begin{bmatrix} * \\ \vdots \\ * \end{bmatrix} = \begin{bmatrix} \max_{\pi(s_1)} * \\ \vdots \\ \max_{\pi(s_n)} * \end{bmatrix}$$

贝尔曼最优方程（BOE）

贝尔曼最优方程（矩阵-向量形式）：

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

- BOE 精妙而优雅！
  - 优雅在哪里？它以简洁的方式描述了最优策略和最优状态价值。
  - 精妙在哪里？右侧含有最大化操作，如何计算并不显然。
- 本讲将回答以下所有问题：
  - **算法**：如何求解该方程？
  - **存在性**：该方程是否有解？
  - **唯一性**：该方程的解是否唯一？
  - **最优性**：它与最优策略有何关系？

贝尔曼最优方程（BOE）

贝尔曼最优方程（矩阵-向量形式）：

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

- BOE 精妙而优雅！
  - 优雅在哪里？它以简洁的方式描述了最优策略和最优状态价值。
  - 精妙在哪里？右侧含有最大化操作，如何计算并不显然。
- 本讲将回答以下所有问题：
  - **算法**：如何求解该方程？
  - **存在性**：该方程是否有解？
  - **唯一性**：该方程的解是否唯一？
  - **最优性**：它与最优策略有何关系？

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

BOE 右侧的最大化操作

BOE 逐元素形式:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right), \quad \forall s \in \mathcal{S}$$

BOE 矩阵-向量形式:

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

BOE 右侧的最大化操作

BOE 逐元素形式:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right), \quad \forall s \in \mathcal{S}$$

BOE 矩阵-向量形式:

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

Example (如何从一个方程求解两个未知量)

从以下方程中求解两个未知变量 $x, a \in \mathbb{R}$:

$$x = \max_{a}(2x - 1 - a^2).$$

求解过程：首先考虑右侧，无论 x 取何值，$\max_a(2x-1-a^2) = 2x-1$，最大值在 $a=0$ 时取得。其次，当 $a=0$ 时，方程变为 $x = 2x-1$，解得 $x=1$。因此，方程的解为 $a=0$，$x=1$。

BOE 右侧的最大化操作

先固定 $v'(s)$，再求解 π：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a) = \max_{\pi} \left[\pi(a_1|s) q(s,a_1) + \cdots + \pi(a_5|s) q(s,a_5) \right] \\
&\doteq \max_{c_1,\ldots,c_5} \left[c_1 q(s,a_1) + \cdots + c_5 q(s,a_5) \right], \qquad c_1 + \cdots + c_5 = 1
\end{aligned}
$$

BOE 右侧的最大化操作

先固定 $v'(s)$，再求解 π：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a) = \max_{\pi} \left[\pi(a_1|s) q(s,a_1) + \cdots + \pi(a_5|s) q(s,a_5) \right] \\
&\doteq \max_{c_1,\ldots,c_5} \left[c_1 q(s,a_1) + \cdots + c_5 q(s,a_5) \right], \qquad c_1 + \cdots + c_5 = 1
\end{aligned}
$$

BOE 右侧的最大化操作

先固定 $v'(s)$，再求解 π：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a) = \max_{\pi} \left[\pi(a_1|s) q(s,a_1) + \cdots + \pi(a_5|s) q(s,a_5) \right] \\
&\doteq \max_{c_1,\ldots,c_5} \left[c_1 q(s,a_1) + \cdots + c_5 q(s,a_5) \right], \qquad c_1 + \cdots + c_5 = 1
\end{aligned}
$$

Example (如何求解 $\max_\pi \sum_a \pi(a|s) q(s,a)$)

设 $q_1, q_2, q_3 \in \mathbb{R}$ 已知，求 c_1^*, c_2^*, c_3^* 使得

$$
\max_{c_1,c_2,c_3} \; c_1 q_1 + c_2 q_2 + c_3 q_3
$$

满足 $c_1 + c_2 + c_3 = 1$ 且 $c_1, c_2, c_3 \geq 0$。

BOE 右侧的最大化操作

先固定 $v'(s)$，再求解 π：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a) = \max_{\pi} \left[\pi(a_1|s) q(s,a_1) + \cdots + \pi(a_5|s) q(s,a_5) \right] \\
&\doteq \max_{c_1,\ldots,c_5} \left[c_1 q(s,a_1) + \cdots + c_5 q(s,a_5) \right], \qquad c_1 + \cdots + c_5 = 1
\end{aligned}
$$

Example (如何求解 $\max_\pi \sum_a \pi(a|s) q(s,a)$)

设 $q_1, q_2, q_3 \in \mathbb{R}$ 已知，求 c_1^*, c_2^*, c_3^* 使得

$$\max_{c_1,c_2,c_3} \; c_1 q_1 + c_2 q_2 + c_3 q_3$$

满足 $c_1 + c_2 + c_3 = 1$ 且 $c_1, c_2, c_3 \geq 0$。

答案：设 $q_3 \geq q_1, q_2$，则最优解为 $c_3^* = 1$，$c_1^* = c_2^* = 0$。因为对任意 c_1, c_2, c_3，有

$$q_3 = (c_1 + c_2 + c_3) q_3 = c_1 q_3 + c_2 q_3 + c_3 q_3 \geq c_1 q_1 + c_2 q_2 + c_3 q_3$$

BOE 右侧的最大化操作

先固定 $v'(s)$，再求解 π：

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_{a} \pi(a|s) q(s,a) = \max_{\pi} \left[\pi(a_1|s) q(s,a_1) + \cdots + \pi(a_5|s) q(s,a_5) \right] \\
&\doteq \max_{c_1,\ldots,c_5} \left[c_1 q(s,a_1) + \cdots + c_5 q(s,a_5) \right], \qquad c_1 + \cdots + c_5 = 1
\end{aligned}
$$

Example (如何求解 $\max_\pi \sum_a \pi(a|s) q(s,a)$)

设 $q_1, q_2, q_3 \in \mathbb{R}$ 已知，求 c_1^*, c_2^*, c_3^* 使得

$$\max_{c_1,c_2,c_3} c_1 q_1 + c_2 q_2 + c_3 q_3$$

满足 $c_1 + c_2 + c_3 = 1$ 且 $c_1, c_2, c_3 \geq 0$。

答案：设 $q_3 \geq q_1, q_2$，则最优解为 $c_3^* = 1$，$c_1^* = c_2^* = 0$。因为对任意 c_1, c_2, c_3，有

$$q_3 = (c_1 + c_2 + c_3) q_3 = c_1 q_3 + c_2 q_3 + c_3 q_3 \geq c_1 q_1 + c_2 q_2 + c_3 q_3$$

BOE 右侧的最大化操作

受上述示例启发，考虑到 $\sum_a \pi(a|s) = 1$，我们有

$$
\begin{aligned}
v(s) &= \max_{\pi} \sum_a \pi(a|s) \left(\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v(s') \right), \quad \forall s \in \mathcal{S} \\
&= \max_{\pi} \sum_a \pi(a|s) q(s,a) \\
&= \max_{a \in \mathcal{A}(s)} q(s,a)
\end{aligned}
$$

最优解在以下情形取得:

$$
\pi(a|s) = \begin{cases} 1 & a = a^* \\ 0 & a \neq a^* \end{cases}
$$

其中 $a^* = \arg\max_a q(s,a)$。

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

求解贝尔曼最优方程

BOE 为 $v = \max_\pi(r_\pi + \gamma P_\pi v)$。令

$$f(v) := \max_\pi(r_\pi + \gamma P_\pi v)$$

则贝尔曼最优方程变为

$$v = f(v)$$

其中

$$[f(v)]_s = \max_\pi \sum_a \pi(a|s)q(s,a), \quad s \in \mathcal{S}$$

该方程形式非常简洁，如何求解?

求解贝尔曼最优方程

BOE 为 $v = \max_\pi(r_\pi + \gamma P_\pi v)$。令

$$f(v) := \max_\pi(r_\pi + \gamma P_\pi v)$$

则贝尔曼最优方程变为

$$v = f(v)$$

其中

$$[f(v)]_s = \max_\pi \sum_a \pi(a|s)q(s,a), \quad s \in \mathcal{S}$$

该方程形式非常简洁，如何求解?

求解贝尔曼最优方程

BOE 为 $v = \max_\pi(r_\pi + \gamma P_\pi v)$。令

$$f(v) := \max_\pi(r_\pi + \gamma P_\pi v)$$

则贝尔曼最优方程变为

$$v = f(v)$$

其中

$$[f(v)]_s = \max_\pi \sum_a \pi(a|s)q(s,a), \quad s \in \mathcal{S}$$

该方程形式非常简洁，如何求解?

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

预备知识：压缩映射定理

一些概念：

- 不动点：若 $f : X \to X$ 满足

$$f(x) = x$$

，则称 $x \in X$ 为 f 的不动点。

- 压缩映射（或收缩函数）：若

$$\|f(x_1) - f(x_2)\| \leq \gamma \|x_1 - x_2\|$$

其中 $\gamma \in (0, 1)$，则称 f 为压缩映射。

- γ 必须严格小于 1，以保证诸如 $\gamma^k \to 0$（$k \to \infty$）等极限成立。
- 此处 $\|\cdot\|$ 可以是任意向量范数。

预备知识：压缩映射定理

一些概念：

- 不动点：若 $f: X \to X$ 满足

$$f(x) = x$$

，则称 $x \in X$ 为 f 的不动点。

- 压缩映射（或收缩函数）：若

$$\|f(x_1) - f(x_2)\| \leq \gamma \|x_1 - x_2\|$$

其中 $\gamma \in (0, 1)$，则称 f 为压缩映射。

- γ 必须严格小于 1，以保证诸如 $\gamma^k \to 0$（$k \to \infty$）等极限成立。
- 此处 $\|\cdot\|$ 可以是任意向量范数。

预备知识：压缩映射定理

示例说明相关概念。

Example

- $x = f(x) = 0.5x$，$x \in \mathbb{R}$。
  容易验证 $x = 0$ 是不动点，因为 $0 = 0.5 \times 0$。此外，$\|0.5x_1 - 0.5x_2\| = 0.5\|x_1 - x_2\| \leq \gamma\|x_1 - x_2\|$（对任意 $\gamma \in [0.5, 1)$ 成立），故 $f(x) = 0.5x$ 是压缩映射。

预备知识：压缩映射定理

示例说明相关概念。

Example

- $x = f(x) = 0.5x$，$x \in \mathbb{R}$。
  容易验证 $x = 0$ 是不动点，因为 $0 = 0.5 \times 0$。此外，$\|0.5x_1 - 0.5x_2\| = 0.5\|x_1 - x_2\| \leq \gamma\|x_1 - x_2\|$（对任意 $\gamma \in [0.5, 1)$ 成立），故 $f(x) = 0.5x$ 是压缩映射。
- $x = f(x) = Ax$，其中 $x \in \mathbb{R}^n$，$A \in \mathbb{R}^{n\times n}$，$\|A\| \leq \gamma < 1$。
  容易验证 $x = 0$ 是不动点，因为 $0 = A0$。关于压缩性，$\|Ax_1 - Ax_2\| = \|A(x_1 - x_2)\| \leq \|A\|\|x_1 - x_2\| \leq \gamma\|x_1 - x_2\|$，故 $f(x) = Ax$ 是压缩映射。

预备知识：压缩映射定理

Theorem (压缩映射定理)

对于形如 $x = f(x)$ 的方程，若 f 是压缩映射，则

- **存在性**：存在不动点 x^* 满足 $f(x^*) = x^*$。
- **唯一性**：不动点 x^* 唯一。
- **算法**：考虑由

$$x_{k+1} = f(x_k)$$

  生成的序列 $\{x_k\}$，则当 $k \to \infty$ 时 $x_k \to x^*$，且收敛速度为指数级。

定理的证明详见教材。

预备知识：压缩映射定理

示例：

- $x = 0.5x$，其中 $f(x) = 0.5x$，$x \in \mathbb{R}$
  $x^* = 0$ 是唯一不动点，可通过以下迭代求解：

$$x_{k+1} = 0.5x_k$$

- $x = Ax$，其中 $f(x) = Ax$，$x \in \mathbb{R}^n$，$A \in \mathbb{R}^{n \times n}$，$\|A\| < 1$
  $x^* = 0$ 是唯一不动点，可通过以下迭代求解：

$$x_{k+1} = Ax_k$$

预备知识：压缩映射定理

示例：

- $x = 0.5x$，其中 $f(x) = 0.5x$，$x \in \mathbb{R}$
  $x^* = 0$ 是唯一不动点，可通过以下迭代求解：

$$x_{k+1} = 0.5x_k$$

- $x = Ax$，其中 $f(x) = Ax$，$x \in \mathbb{R}^n$，$A \in \mathbb{R}^{n\times n}$，$\|A\| < 1$
  $x^* = 0$ 是唯一不动点，可通过以下迭代求解：

$$x_{k+1} = Ax_k$$

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

BOE 的压缩性

回到贝尔曼最优方程:

$$v = f(v) = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

证明略，详见教材。

BOE 的压缩性

回到贝尔曼最优方程:

$$v = f(v) = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

Theorem (压缩性)

$f(v)$ 是压缩映射，满足

$$\|f(v_1) - f(v_2)\| \leq \gamma \|v_1 - v_2\|$$

其中 γ 为折扣因子！

证明略，详见教材。

求解贝尔曼最优方程

应用压缩映射定理，得到如下结论。

Theorem (存在性、唯一性与算法)

对于 *BOE* $v = f(v) = \max_\pi(r_\pi + \gamma P_\pi v)$，解 v^* 总是存在且唯一。可通过以下迭代算法求解:

$$v_{k+1} = f(v_k) = \max_\pi(r_\pi + \gamma P_\pi v_k) \tag{1}$$

从任意初始值 v_0 出发，序列 $\{v_k\}$ 指数速度收敛到 v^*，收敛速率由 γ 决定。

重要: (1) 中的算法即称为值迭代算法，将在下一讲中详细分析！本讲重点介绍基本性质。

求解贝尔曼最优方程

应用压缩映射定理，得到如下结论。

Theorem (存在性、唯一性与算法)

对于 *BOE* $v = f(v) = \max_\pi(r_\pi + \gamma P_\pi v)$，解 v^* 总是存在且唯一。可通过以下迭代算法求解:

$$v_{k+1} = f(v_k) = \max_\pi(r_\pi + \gamma P_\pi v_k) \tag{1}$$

从任意初始值 v_0 出发，序列 $\{v_k\}$ 指数速度收敛到 v^*，收敛速率由 γ 决定。

重要：(1) 中的算法即称为值迭代算法，将在下一讲中详细分析！本讲重点介绍基本性质。

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

策略最优性

设 v^* 是贝尔曼最优方程的解，满足

$$v^* = \max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

设

$$\pi^* = \arg\max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

则

$$v^* = r_{\pi^*} + \gamma P_{\pi^*} v^*$$

因此，π^* 是一个策略，$v^* = v_{\pi^*}$ 是对应的状态价值。

π^* 是最优策略吗？v^* 是所有可能中最大的状态价值吗？

策略最优性

设 v^* 是贝尔曼最优方程的解，满足

$$v^* = \max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

设

$$\pi^* = \arg\max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

则

$$v^* = r_{\pi^*} + \gamma P_{\pi^*} v^*$$

因此，π^* 是一个策略，$v^* = v_{\pi^*}$ 是对应的状态价值。

π^* 是最优策略吗？v^* 是所有可能中最大的状态价值吗？

策略最优性

设 v^* 是贝尔曼最优方程的解，满足

$$v^* = \max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

设

$$\pi^* = \arg\max_{\pi}(r_\pi + \gamma P_\pi v^*)$$

则

$$v^* = r_{\pi^*} + \gamma P_{\pi^*} v^*$$

因此，π^* 是一个策略，$v^* = v_{\pi^*}$ 是对应的状态价值。

π^* 是最优策略吗？v^* 是所有可能中最大的状态价值吗？

策略最优性

设 v^* 是贝尔曼最优方程的解，满足

$$v^* = \max_\pi (r_\pi + \gamma P_\pi v^*)$$

设

$$\pi^* = \arg\max_\pi (r_\pi + \gamma P_\pi v^*)$$

则

$$v^* = r_{\pi^*} + \gamma P_{\pi^*} v^*$$

因此，π^* 是一个策略，$v^* = v_{\pi^*}$ 是对应的状态价值。

π^* 是最优策略吗？v^* 是所有可能中最大的状态价值吗？

策略最优性

Theorem (策略最优性)

设 v^* 是方程 $v = \max_\pi(r_\pi + \gamma P_\pi v)$ 的唯一解，v_π 是对任意给定策略 π 满足 $v_\pi = r_\pi + \gamma P_\pi v_\pi$ 的状态价值函数，则

$$v^* \geq v_\pi, \quad \forall \pi$$

证明详见教材。

现在我们理解了为何要研究BOE：因为它描述了**最优状态价值**和**最优策略**。

策略最优性

Theorem (策略最优性)

设 v^* 是方程 $v = \max_\pi(r_\pi + \gamma P_\pi v)$ 的唯一解，v_π 是对任意给定策略 π 满足 $v_\pi = r_\pi + \gamma P_\pi v_\pi$ 的状态价值函数，则

$$v^* \geq v_\pi, \quad \forall \pi$$

证明详见教材。

现在我们理解了为何要研究BOE：因为它描述了**最优状态价值**和**最优策略**。

最优策略

最优策略 π^* 是什么样的?

$$\pi^*(s) = \arg\max_{\pi} \sum_a \pi(a|s) \underbrace{\left(\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v^*(s') \right)}_{q^*(s,a)}$$

最优策略

最优策略 π^* 是什么样的?

$$\pi^*(s) = \arg\max_{\pi} \sum_a \pi(a|s) \underbrace{\left(\sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a) v^*(s') \right)}_{q^*(s,a)}$$

Theorem (贪婪最优策略)

对任意 $s \in \mathcal{S}$，确定性贪婪策略

$$\pi^*(a|s) = \begin{cases} 1 & a = a^*(s) \\ 0 & a \neq a^*(s) \end{cases}$$

是求解*BOE*的最优策略。其中，

$$a^*(s) = \arg\max_a q^*(a,s),$$

$q^*(s,a) \doteq \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v^*(s')$。

大纲

1 动机示例

2 最优策略的定义

3 BOE：引入

4 BOE：预备知识
- BOE：右侧的最大化操作
- BOE：改写为 $v = f(v)$
- 压缩映射定理

5 BOE：求解

6 BOE：最优性

7 最优策略分析

最优策略分析

哪些因素决定最优状态价值和最优策略?

从BOE中可以清楚地看出:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right)$$

有三个决定因素:

- 系统模型: $p(s'|s,a)$, $p(r|s,a)$
- 奖励设计: r
- 折扣因子: γ

下面展示 r 和 γ 如何影响最优策略。

最优策略分析

哪些因素决定最优状态价值和最优策略?

从BOE中可以清楚地看出:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right)$$

有三个决定因素:

- 系统模型: $p(s'|s,a)$, $p(r|s,a)$
- 奖励设计: r
- 折扣因子: γ

下面展示 r 和 γ 如何影响最优策略。

最优策略分析

哪些因素决定最优状态价值和最优策略?

从BOE中可以清楚地看出:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right)$$

有三个决定因素:

- 系统模型: $p(s'|s,a)$, $p(r|s,a)$
- 奖励设计: r
- 折扣因子: γ

下面展示 r 和 γ 如何影响最优策略。

最优策略分析

通过求解BOE得到最优策略及对应的最优状态价值。

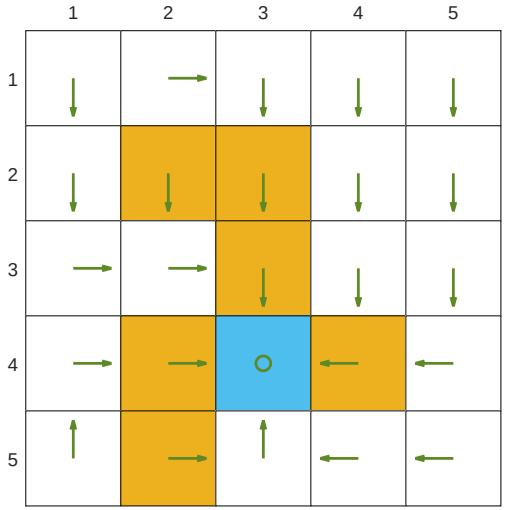

	1	2	3	4	5
1	5.8	5.6	6.2	6.5	5.8
2	6.5	7.2	8.0	7.2	6.5
3	7.2	8.0	10.0	8.0	7.2
4	8.0	10.0	10.0	10.0	8.0
5	7.2	9.0	10.0	9.0	8.1

(a) $r_{\text{boundary}} = r_{\text{forbidden}} = -1$, $r_{\text{target}} = 1$, $\gamma = 0.9$

最优策略**敢于冒险**：进入禁止区域！！

最优策略分析

若将$\gamma = 0.9$ 改为 $\gamma = 0.5$:

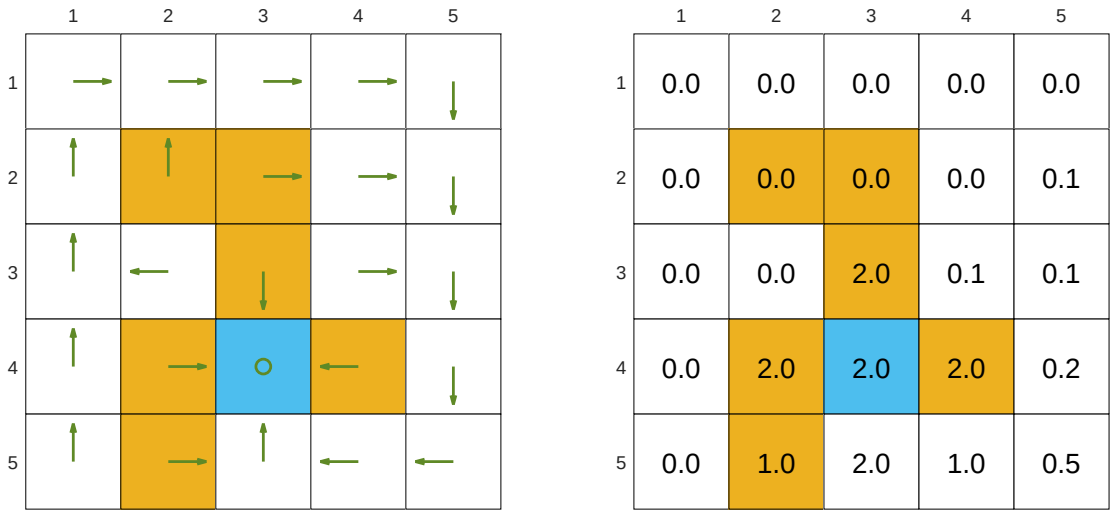

(b) 折扣因子 $\gamma = 0.5$，其余与上图相同。

最优策略**变得更加短视**！回避所有禁止区域！

最优策略分析

若将γ 改为 0:

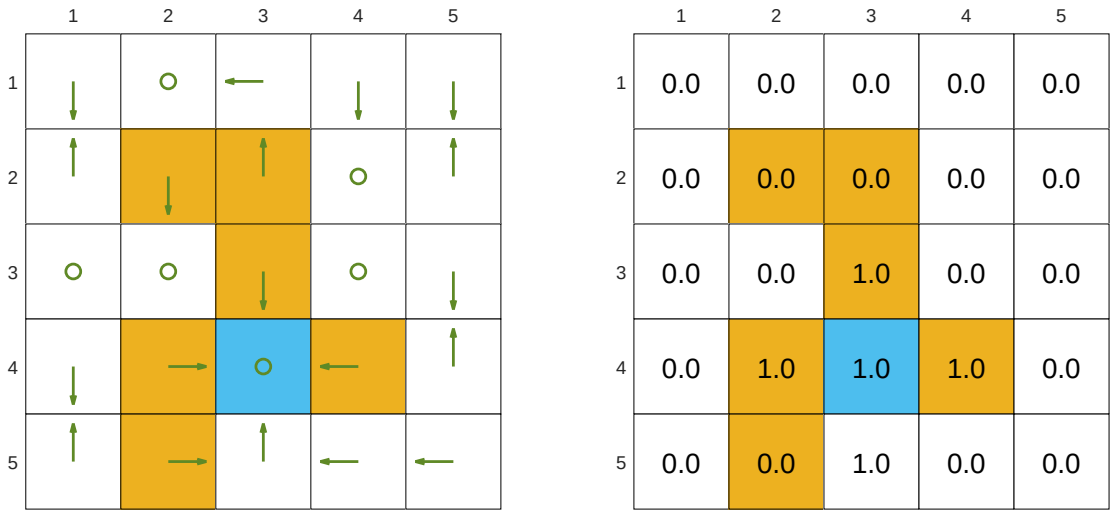

(c) 折扣因子 $\gamma = 0$，其余与上图相同。

最优策略**变得极度短视**！只选择**即时奖励最大**的动作！无法到达目标！

最优策略分析

若增大进入禁止区域的惩罚：将 $r_{\text{forbidden}} = -1$ 改为 $r_{\text{forbidden}} = -10$：

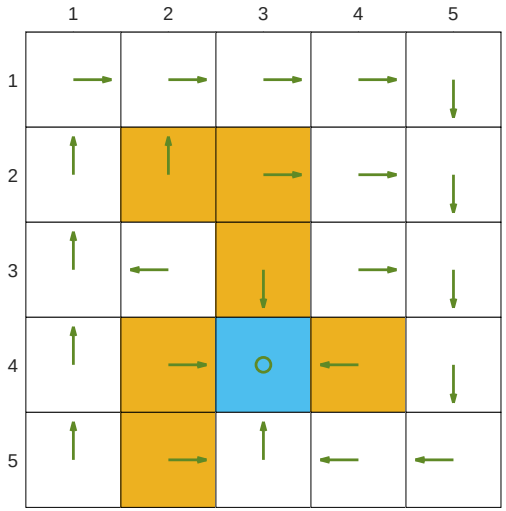

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

(d) $r_{\text{forbidden}} = -10$，其余与上图相同。

最优策略也会回避禁止区域。

最优策略分析

若将奖励变换为 $r \to ar + b$（$a > 0$），会怎样?

例如，将

$$r_{\text{boundary}} = r_{\text{forbidden}} = -1, \quad r_{\text{target}} = 1, \quad r_{\text{otherstep}} = 0$$

改为

$$r_{\text{boundary}} = r_{\text{forbidden}} = 0, \quad r_{\text{target}} = 2, \quad r_{\text{otherstep}} = 1$$

- **最优策略保持不变！**
- **重要的不是奖励的绝对值，而是它们的相对值！**

最优策略分析（选读）

Theorem (最优策略不变性)

考虑一个马尔可夫决策过程，设 $v^* \in \mathbb{R}^{|\mathcal{S}|}$ 为满足 $v^* = \max_\pi(r_\pi + \gamma P_\pi v^*)$ 的最优状态价值。若每个奖励 r 经仿射变换变为 $ar + b$（其中 $a, b \in \mathbb{R}$，$a > 0$），则对应的最优状态价值 v' 也是 v^* 的仿射变换：

$$v' = av^* + \frac{b}{1-\gamma}\mathbf{1},$$

其中 $\gamma \in (0,1)$ 为折扣因子，$\mathbf{1} = [1, \ldots, 1]^T$。因此，最优策略对奖励信号的仿射变换具有不变性。

证明详见教材。

最优策略分析

毫无意义的绕路?

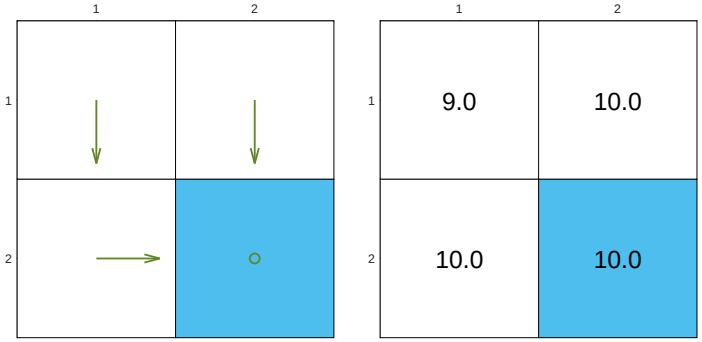

(a) 最优策略

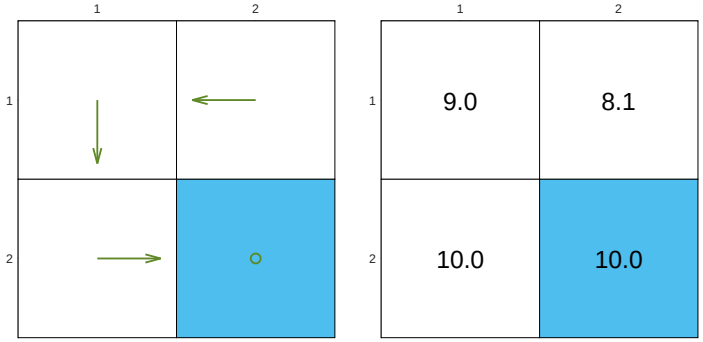

(b) 非最优

问题：为什么最优策略不走毫无意义的弯路？我们并没有惩罚绕路行为，因为 $r_{\text{otherstep}} = 0$。

答案：我们通过折扣因子来隐性惩罚！

策略(a)：$\text{return} = 1 + \gamma 1 + \gamma^2 1 + \cdots = 1/(1-\gamma) = 10$

策略(b)：$\text{return} = 0 + \gamma 0 + \gamma^2 1 + \gamma^3 1 + \cdots = \gamma^2/(1-\gamma) = 8.1$

最优策略分析

毫无意义的绕路?

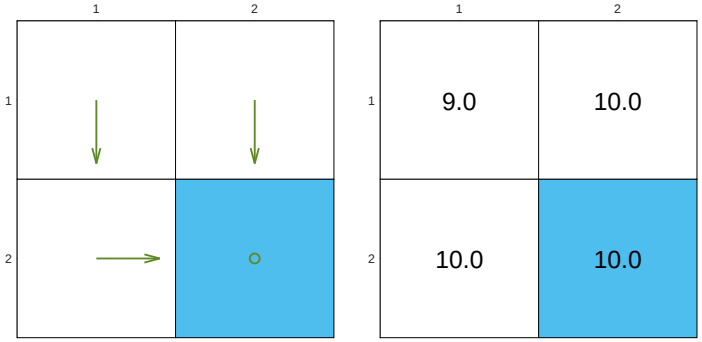

(a) 最优策略

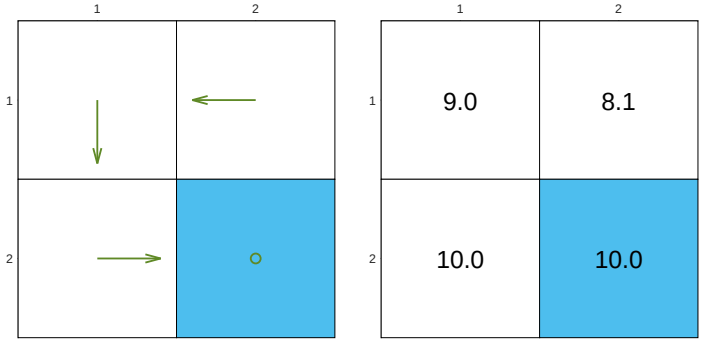

(b) 非最优

问题：为什么最优策略不走毫无意义的弯路？我们并没有惩罚绕路行为，因为 $r_{\text{otherstep}} = 0$。

答案：我们通过折扣因子来隐性惩罚！

策略(a)：$\text{return} = 1 + \gamma 1 + \gamma^2 1 + \cdots = 1/(1-\gamma) = 10$

策略(b)：$\text{return} = 0 + \gamma 0 + \gamma^2 1 + \gamma^3 1 + \cdots = \gamma^2/(1-\gamma) = 8.1$

最优策略分析

毫无意义的绕路?

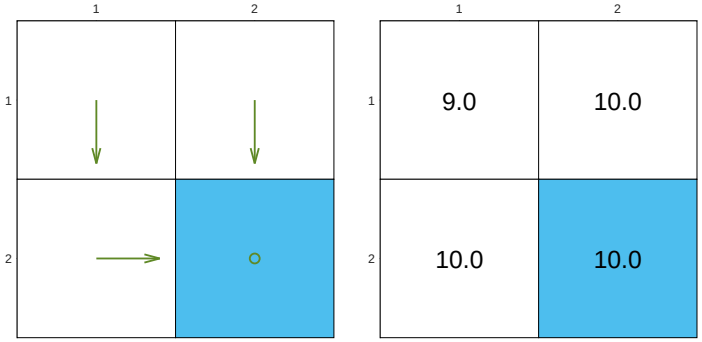

(a) 最优策略

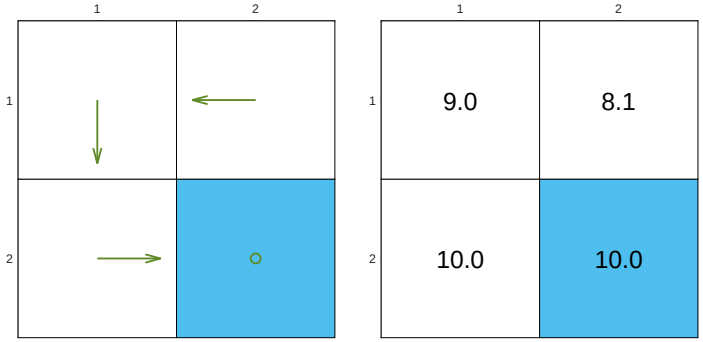

(b) 非最优

问题：为什么最优策略不走毫无意义的弯路？我们并没有惩罚绕路行为，因为 $r_{\text{otherstep}} = 0$。

答案：我们通过折扣因子来隐性惩罚！

策略(a)：$\text{return} = 1 + \gamma 1 + \gamma^2 1 + \cdots = 1/(1-\gamma) = 10$

策略(b)：$\text{return} = 0 + \gamma 0 + \gamma^2 1 + \gamma^3 1 + \cdots = \gamma^2/(1-\gamma) = 8.1$

最优策略分析

毫无意义的绕路?

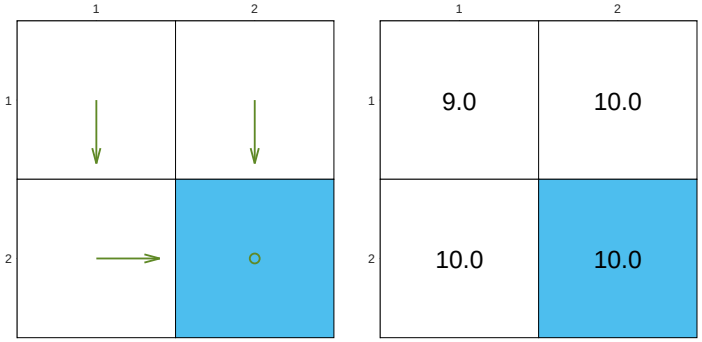

(a) 最优策略

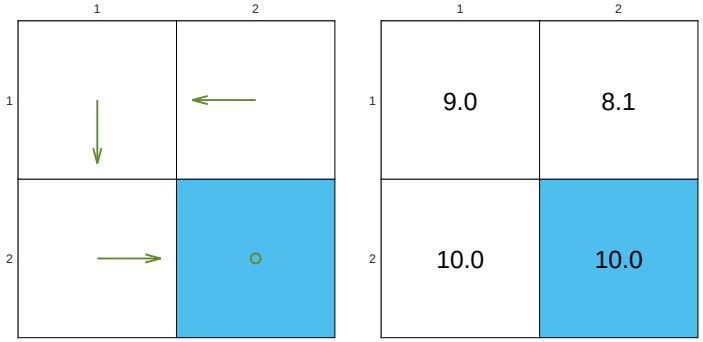

(b) 非最优

问题：为什么最优策略不走毫无意义的弯路？我们并没有惩罚绕路行为，因为 $r_{\text{otherstep}} = 0$。

答案：我们通过折扣因子来隐性惩罚！

策略(a)：$\text{return} = 1 + \gamma 1 + \gamma^2 1 + \cdots = 1/(1-\gamma) = 10$

策略(b)：$\text{return} = 0 + \gamma 0 + \gamma^2 1 + \gamma^3 1 + \cdots = \gamma^2/(1-\gamma) = 8.1$

总结

贝尔曼最优方程:

- 逐元素形式:

$$v(s) = \max_{\pi} \sum_{a} \pi(a|s) \underbrace{\left(\sum_{r} p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v(s') \right)}_{q(s,a)}, \quad \forall s \in \mathcal{S}$$

- 矩阵-向量形式:

$$v = \max_{\pi}(r_\pi + \gamma P_\pi v)$$

总结

关于贝尔曼最优方程的问题：

- **存在性**：该方程是否有解?
  - 有，由压缩映射定理保证
- **唯一性**：该方程的解是否唯一?
  - 唯一，由压缩映射定理保证
- **算法**：如何求解该方程?
  - 压缩映射定理提示的迭代算法
- **最优性**：为什么研究该方程?
  - 因为其解对应最优状态价值和最优策略。

至此，我们终于理解了为何研究BOE如此重要！

总结

关于贝尔曼最优方程的问题：

- **存在性**：该方程是否有解?
  - 有，由压缩映射定理保证
- **唯一性**：该方程的解是否唯一?
  - 唯一，由压缩映射定理保证
- **算法**：如何求解该方程?
  - 压缩映射定理提示的迭代算法
- **最优性**：为什么研究该方程?
  - 因为其解对应最优状态价值和最优策略。

至此，我们终于理解了为何研究BOE如此重要！

总结

关于贝尔曼最优方程的问题：

- **存在性**：该方程是否有解?
  - 有，由压缩映射定理保证
- **唯一性**：该方程的解是否唯一?
  - 唯一，由压缩映射定理保证
- **算法**：如何求解该方程?
  - 压缩映射定理提示的迭代算法
- **最优性**：为什么研究该方程?
  - 因为其解对应最优状态价值和最优策略。

至此，我们终于理解了为何研究BOE如此重要！

总结

关于贝尔曼最优方程的问题：

- **存在性**：该方程是否有解?
  - 有，由压缩映射定理保证
- **唯一性**：该方程的解是否唯一?
  - 唯一，由压缩映射定理保证
- **算法**：如何求解该方程?
  - 压缩映射定理提示的迭代算法
- **最优性**：为什么研究该方程?
  - 因为其解对应最优状态价值和最优策略。

至此，我们终于理解了为何研究BOE如此重要！

总结

关于贝尔曼最优方程的问题：

- **存在性**：该方程是否有解?
  - 有，由压缩映射定理保证
- **唯一性**：该方程的解是否唯一?
  - 唯一，由压缩映射定理保证
- **算法**：如何求解该方程?
  - 压缩映射定理提示的迭代算法
- **最优性**：为什么研究该方程?
  - 因为其解对应最优状态价值和最优策略。

至此，我们终于理解了为何研究BOE如此重要！