第五讲：蒙特卡罗方法

April 11, 2026

大纲

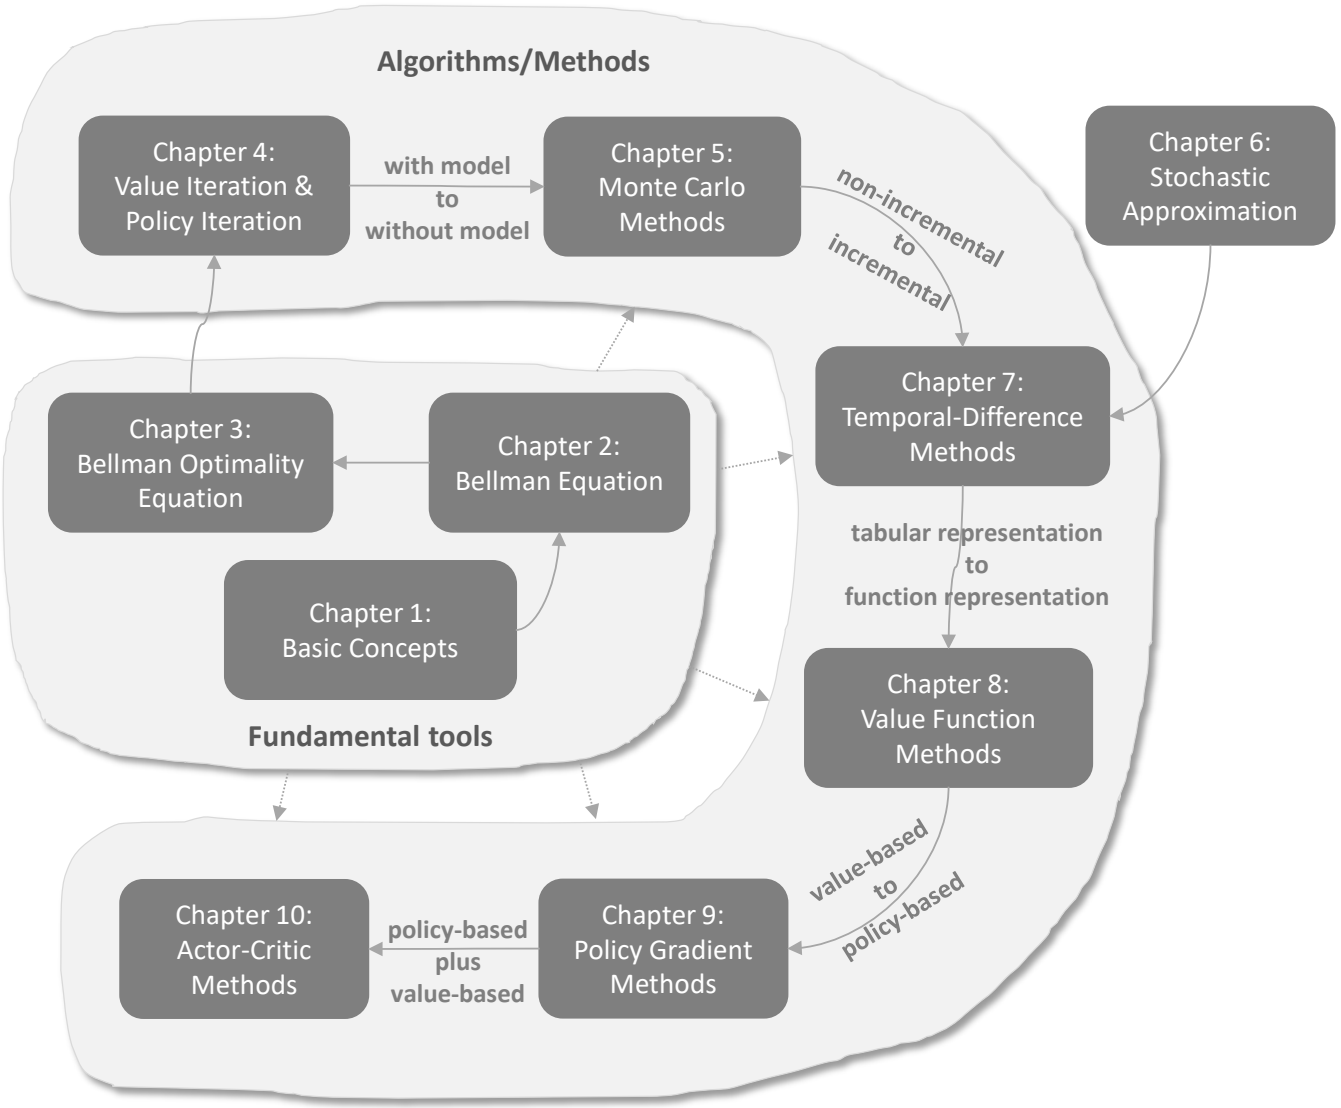
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

大纲

1 动机示例

2 最简单的基于蒙特卡洛的强化学习算法
- 算法：MC Basic

3 更高效地利用数据
- 算法：MC Exploring Starts

4 无需探索性起始的蒙特卡洛方法
- 算法：MC ϵ-贪婪

大纲

1 动机示例

2 最简单的基于蒙特卡洛的强化学习算法
- 算法：MC Basic

3 更高效地利用数据
- 算法：MC Exploring Starts

4 无需探索性起始的蒙特卡洛方法
- 算法：MC ϵ-贪婪

动机示例：蒙特卡洛估计

▷ 如何在**没有模型**的情况下估计某些量?

- 最简单的想法：蒙特卡洛估计。

▷ **示例：抛硬币**

结果（正面或反面）记为随机变量 X

- 若结果为正面，则 $X = +1$
- 若结果为反面，则 $X = -1$

目标是计算 $\mathbb{E}[X]$。

动机示例：蒙特卡洛估计

▷ 如何在**没有模型**的情况下估计某些量?

- 最简单的想法：蒙特卡洛估计。

▷ **示例：抛硬币**

结果（正面或反面）记为随机变量 X

- 若结果为正面，则 $X = +1$
- 若结果为反面，则 $X = -1$

目标是计算 $\mathbb{E}[X]$。

动机示例：蒙特卡洛估计

▷ **方法一：基于模型**

- 假设概率模型已知为

$$p(X=1)=0.5, \quad p(X=-1)=0.5$$

则由定义

$$\mathbb{E}[X]=\sum_{x} xp(x)=1\times 0.5+(-1)\times 0.5=0$$

- 问题：实际中可能无法知道精确的分布！

动机示例：蒙特卡洛估计

▷ **方法一：基于模型**

- 假设概率模型已知为

$$p(X=1)=0.5, \quad p(X=-1)=0.5$$

则由定义

$$\mathbb{E}[X]=\sum_{x} xp(x)=1\times 0.5+(-1)\times 0.5=0$$

- **问题：实际中可能无法知道精确的分布！**

动机示例：蒙特卡洛估计

▷ **方法二：不依赖模型（无模型方法）**

- 思路：多次抛硬币，然后计算结果的平均值。
- 假设我们得到样本序列 $\{x_1, x_2, \ldots, x_N\}$。
  则均值可近似为

$$\mathbb{E}[X] \approx \bar{x} = \frac{1}{N} \sum_{j=1}^{N} x_j.$$

  这就是蒙特卡洛估计的思想！

动机示例：蒙特卡洛估计

▷ **方法二：不依赖模型（无模型方法）**

- 思路：多次抛硬币，然后计算结果的平均值。
- 假设我们得到样本序列 $\{x_1, x_2, \ldots, x_N\}$。
  则均值可近似为

$$\mathbb{E}[X] \approx \bar{x} = \frac{1}{N}\sum_{j=1}^{N} x_j.$$

这就是蒙特卡洛估计的思想！

动机示例：蒙特卡洛估计

▷ **问题**：蒙特卡洛估计准确吗?

- 当 N 较小时，近似不准确。
- 当 N 较大时，近似更准确。

动机示例：蒙特卡洛估计

▷ **问题**：蒙特卡洛估计准确吗?

- 当 N 较小时，近似不准确。
- 当 N 较大时，近似更准确。

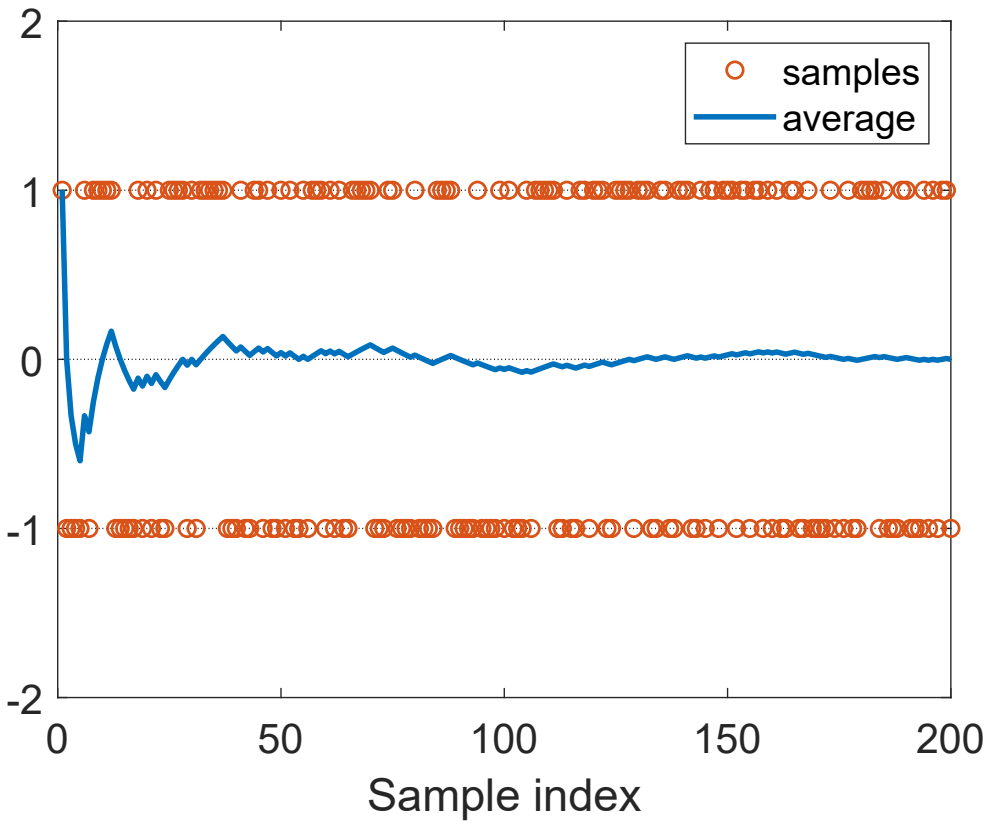

动机示例：蒙特卡洛估计

Theorem (大数定律)

对于随机变量 X，假设 $\{x_j\}_{j=1}^N$ 是一组独立同分布的样本。令 $\bar{x} = \frac{1}{N}\sum_{j=1}^N x_j$ 为样本均值。则

$$\mathbb{E}[\bar{x}] = \mathbb{E}[X],$$
$$\mathrm{Var}[\bar{x}] = \frac{1}{N}\mathrm{Var}[X].$$

因此，$\bar{x}$ 是 $\mathbb{E}[X]$ 的无偏估计，且其方差随 N 趋于无穷而趋于零。

- ▷ 样本必须是独立同分布（iid）的
- ▷ 证明详见教材。

动机示例：蒙特卡洛估计

▷ 小结：

- 蒙特卡洛估计是指一大类依赖重复随机采样来求解近似问题的技术。
- 为什么关注蒙特卡洛估计？因为它不需要模型！
- 为什么关注均值估计？因为状态价值和动作价值均定义为随机变量的期望！

动机示例：蒙特卡洛估计

▷ 小结：

- 蒙特卡洛估计是指一大类依赖重复随机采样来求解近似问题的技术。
- 为什么关注蒙特卡洛估计？因为它不需要模型！
- 为什么关注均值估计？因为状态价值和动作价值均定义为随机变量的期望！

动机示例：蒙特卡洛估计

▷ 小结：

- 蒙特卡洛估计是指一大类依赖重复随机采样来求解近似问题的技术。
- 为什么关注蒙特卡洛估计？因为它不需要模型！
- 为什么关注均值估计？因为状态价值和动作价值均定义为随机变量的期望！

大纲

1 动机示例

2 最简单的基于蒙特卡洛的强化学习算法
- 算法：MC Basic

3 更高效地利用数据
- 算法：MC Exploring Starts

4 无需探索性起始的蒙特卡洛方法
- 算法：MC ϵ-贪婪

将策略迭代转化为无模型算法

核心思想是将策略迭代算法转化为无模型算法。

若能

- 深入理解策略迭代算法，以及
- 理解蒙特卡洛均值估计的思想，

则该转化过程便不难理解。

将策略迭代转化为无模型算法

策略迭代每次迭代包含两个步骤:

$$\begin{cases} \textbf{策略评估:} & v_{\pi_k} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k} \\ \textbf{策略改进:} & \pi_{k+1} = \arg\max_\pi (r_\pi + \gamma P_\pi v_{\pi_k}) \end{cases}$$

策略改进步骤的逐元素形式为:

$$\begin{aligned} \pi_{k+1}(s) &= \arg\max_\pi \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_{\pi_k}(s') \right] \\ &= \arg\max_\pi \sum_a \pi(a|s) q_{\pi_k}(s,a), \quad s \in \mathcal{S} \end{aligned}$$

关键在于计算 $q_{\pi_k}(s,a)$!

将策略迭代转化为无模型算法

策略迭代每次迭代包含两个步骤:

$$\begin{cases} \textbf{策略评估:} & v_{\pi_k} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k} \\ \textbf{策略改进:} & \pi_{k+1} = \arg\max_\pi (r_\pi + \gamma P_\pi v_{\pi_k}) \end{cases}$$

策略改进步骤的逐元素形式为:

$$\begin{aligned} \pi_{k+1}(s) &= \arg\max_\pi \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_{\pi_k}(s') \right] \\ &= \arg\max_\pi \sum_a \pi(a|s) q_{\pi_k}(s,a), \quad s \in \mathcal{S} \end{aligned}$$

关键在于计算 $q_{\pi_k}(s,a)$!

将策略迭代转化为无模型算法

策略迭代每次迭代包含两个步骤:

$$\begin{cases} \textbf{策略评估:} & v_{\pi_k} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k} \\ \textbf{策略改进:} & \pi_{k+1} = \arg\max_\pi (r_\pi + \gamma P_\pi v_{\pi_k}) \end{cases}$$

策略改进步骤的逐元素形式为:

$$\begin{aligned} \pi_{k+1}(s) &= \arg\max_\pi \sum_a \pi(a|s) \left[\sum_r p(r|s,a) r + \gamma \sum_{s'} p(s'|s,a) v_{\pi_k}(s') \right] \\ &= \arg\max_\pi \sum_a \pi(a|s) q_{\pi_k}(s,a), \quad s \in \mathcal{S} \end{aligned}$$

关键在于计算 $q_{\pi_k}(s,a)$!

将策略迭代转化为无模型算法

动作价值的两种表达形式:

- **形式一：需要模型**

$$q_{\pi_k}(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v_{\pi_k}(s')$$

- **形式二：不需要模型**

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$$

实现无模型强化学习的思路：我们可以利用形式二，基于数据（样本或经验）来获得 $q_{\pi_k}(s,a)$！

将策略迭代转化为无模型算法

动作价值的两种表达形式:

- **形式一：需要模型**

$$q_{\pi_k}(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v_{\pi_k}(s')$$

- **形式二：不需要模型**

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$$

实现无模型强化学习的思路：我们可以利用形式二，基于数据（样本或经验）来获得 $q_{\pi_k}(s,a)$！

将策略迭代转化为无模型算法

动作价值的两种表达形式:

- **形式一：需要模型**

$$q_{\pi_k}(s,a) = \sum_r p(r|s,a)r + \gamma \sum_{s'} p(s'|s,a)v_{\pi_k}(s')$$

- **形式二：不需要模型**

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$$

实现无模型强化学习的思路：我们可以利用形式二，基于数据（样本或经验）来获得 $q_{\pi_k}(s,a)$！

将策略迭代转化为无模型算法

如何基于数据获得 $q_{\pi_k}(s,a)$?

- 从 (s,a) 出发，按照策略 π_k 生成一条轨迹（episode）。
- 该轨迹的回报为 $g(s,a)$，是

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a]$$

中 G_t 的一个样本。

- 假设我们有一组轨迹，从而得到 $\{g^{(j)}(s,a)\}$。则

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a] \approx \frac{1}{N}\sum_{i=1}^{N} g^{(i)}(s,a).$$

根本思想：当模型不可用时，我们可以用数据代替。

将策略迭代转化为无模型算法

如何基于数据获得 $q_{\pi_k}(s,a)$?

- 从 (s,a) 出发，按照策略 π_k 生成一条轨迹（episode）。
- 该轨迹的回报为 $g(s,a)$，是

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a]$$

  中 G_t 的一个样本。
- 假设我们有一组轨迹，从而得到 $\{g^{(j)}(s,a)\}$。则

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a] \approx \frac{1}{N}\sum_{i=1}^{N} g^{(i)}(s,a).$$

根本思想：当模型不可用时，我们可以用数据代替。

将策略迭代转化为无模型算法

如何基于数据获得 $q_{\pi_k}(s,a)$?

- 从 (s,a) 出发，按照策略 π_k 生成一条轨迹（episode）。
- 该轨迹的回报为 $g(s,a)$，是

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a]$$

  中 G_t 的一个样本。
- 假设我们有一组轨迹，从而得到 $\{g^{(j)}(s,a)\}$。则

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a] \approx \frac{1}{N}\sum_{i=1}^{N} g^{(i)}(s,a).$$

根本思想：当模型不可用时，我们可以用数据代替。

将策略迭代转化为无模型算法

如何基于数据获得 $q_{\pi_k}(s,a)$?

- 从 (s,a) 出发，按照策略 π_k 生成一条轨迹（episode）。
- 该轨迹的回报为 $g(s,a)$，是

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a]$$

  中 G_t 的一个样本。
- 假设我们有一组轨迹，从而得到 $\{g^{(j)}(s,a)\}$。则

$$q_{\pi_k}(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a] \approx \frac{1}{N}\sum_{i=1}^{N} g^{(i)}(s,a).$$

根本思想：当模型不可用时，我们可以用数据代替。

MC Basic 算法

给定初始策略 π_0，第 k 次迭代包含两个步骤。

- **步骤一：策略评估。** 该步骤的目标是对所有 (s,a) 估计 $q_{\pi_k}(s,a)$。具体地，对每个 (s,a)，运行足够多条轨迹，将其回报的平均值记为 $q_k(s,a)$，用于近似 $q_{\pi_k}(s,a)$。
  - 策略迭代算法的第一步通过求解贝尔曼方程得到状态价值 v_{π_k}，进而计算 $q_{\pi_k}(s,a)$，这需要模型。
  - *MC Basic* 算法的第一步直接从经验样本中估计 $q_k(s,a)$，不需要模型。
- **步骤二：策略改进。** 该步骤对所有 $s \in \mathcal{S}$ 求解 $\pi_{k+1}(s) = \arg\max_\pi \sum_a \pi(a|s) q_k(s,a)$。贪婪最优策略为 $\pi_{k+1}(a_k^*|s) = 1$，其中 $a_k^* = \arg\max_a q_k(s,a)$。
  - 该步骤与策略迭代算法的第二步完全相同。

MC Basic 算法

给定初始策略 π_0，第 k 次迭代包含两个步骤。

- **步骤一：策略评估。** 该步骤的目标是对所有 (s,a) 估计 $q_{\pi_k}(s,a)$。具体地，对每个 (s,a)，运行足够多条轨迹，将其回报的平均值记为 $q_k(s,a)$，用于近似 $q_{\pi_k}(s,a)$。
  - 策略迭代算法的第一步通过求解贝尔曼方程得到状态价值 v_{π_k}，进而计算 $q_{\pi_k}(s,a)$，这需要模型。
  - *MC Basic* 算法的第一步直接从经验样本中估计 $q_k(s,a)$，不需要模型。
- **步骤二：策略改进。** 该步骤对所有 $s \in \mathcal{S}$ 求解 $\pi_{k+1}(s) = \arg\max_\pi \sum_a \pi(a|s) q_k(s,a)$。贪婪最优策略为 $\pi_{k+1}(a_k^*|s) = 1$，其中 $a_k^* = \arg\max_a q_k(s,a)$。
  - 该步骤与策略迭代算法的第二步完全相同。

MC Basic 算法

给定初始策略 π_0，第 k 次迭代包含两个步骤。

- **步骤一：策略评估。** 该步骤的目标是对所有 (s,a) 估计 $q_{\pi_k}(s,a)$。具体地，对每个 (s,a)，运行足够多条轨迹，将其回报的平均值记为 $q_k(s,a)$，用于近似 $q_{\pi_k}(s,a)$。
  - 策略迭代算法的第一步通过求解贝尔曼方程得到状态价值 v_{π_k}，进而计算 $q_{\pi_k}(s,a)$，这需要模型。
  - *MC Basic* 算法的第一步直接从经验样本中估计 $q_k(s,a)$，不需要模型。
- **步骤二：策略改进。** 该步骤对所有 $s \in \mathcal{S}$ 求解 $\pi_{k+1}(s) = \arg\max_\pi \sum_a \pi(a|s) q_k(s,a)$。贪婪最优策略为 $\pi_{k+1}(a_k^*|s) = 1$，其中 $a_k^* = \arg\max_a q_k(s,a)$。
  - 该步骤与策略迭代算法的第二步完全相同。

MC Basic 算法

▷ 算法描述：

伪代码：MC Basic 算法（策略迭代的无模型变体）

初始化： 初始策略 π_0。
目标： 搜索最优策略。

第 k 次迭代（$k = 0, 1, 2, \ldots$），执行：
对每个状态 $s \in \mathcal{S}$，执行：
对每个动作 $a \in \mathcal{A}(s)$，执行：
从 (s, a) 出发，按照 π_k 收集足够多条轨迹
策略评估：
$q_{\pi_k}(s, a) \approx q_k(s, a) =$ 所有从 (s, a) 出发的轨迹的平均回报
策略改进：
$a_k^*(s) = \arg\max_a q_k(s, a)$
若 $a = a_k^*$ 则 $\pi_{k+1}(a|s) = 1$，否则 $\pi_{k+1}(a|s) = 0$

MC Basic 算法

- MC Basic 是策略迭代算法的一个变体。
- 无模型算法建立在有模型算法的基础之上。因此，在学习无模型算法之前，有必要先深入理解有模型算法。
- MC Basic 有助于揭示基于蒙特卡洛的无模型强化学习的核心思想，但由于效率较低，在实际中并不实用。
- 为什么 MC Basic 估计的是动作价值而非状态价值？因为在没有模型的情况下，状态价值无法直接用于改进策略，应当直接估计动作价值。
- 由于策略迭代算法是收敛的，在轨迹数量足够的情况下，MC Basic 的收敛性同样得到保证。

MC Basic 算法

- MC Basic 是策略迭代算法的一个变体。
- 无模型算法建立在有模型算法的基础之上。因此，在学习无模型算法之前，有必要先深入理解有模型算法。
- MC Basic 有助于揭示基于蒙特卡洛的无模型强化学习的核心思想，但由于效率较低，在实际中并不实用。
- 为什么 MC Basic 估计的是动作价值而非状态价值？因为在没有模型的情况下，状态价值无法直接用于改进策略，应当直接估计动作价值。
- 由于策略迭代算法是收敛的，在轨迹数量足够的情况下，MC Basic 的收敛性同样得到保证。

MC Basic 算法

- MC Basic 是策略迭代算法的一个变体。
- 无模型算法建立在有模型算法的基础之上。因此，在学习无模型算法之前，有必要先深入理解有模型算法。
- MC Basic 有助于揭示基于蒙特卡洛的无模型强化学习的核心思想，但由于效率较低，在实际中并不实用。
- 为什么 MC Basic 估计的是动作价值而非状态价值？因为在没有模型的情况下，状态价值无法直接用于改进策略，应当直接估计动作价值。
- 由于策略迭代算法是收敛的，在轨迹数量足够的情况下，MC Basic 的收敛性同样得到保证。

MC Basic 算法

- MC Basic 是策略迭代算法的一个变体。
- 无模型算法建立在有模型算法的基础之上。因此，在学习无模型算法之前，有必要先深入理解有模型算法。
- MC Basic 有助于揭示基于蒙特卡洛的无模型强化学习的核心思想，但由于效率较低，在实际中并不实用。
- 为什么 MC Basic 估计的是动作价值而非状态价值？因为在没有模型的情况下，状态价值无法直接用于改进策略，应当直接估计动作价值。
- 由于策略迭代算法是收敛的，在轨迹数量足够的情况下，MC Basic 的收敛性同样得到保证。

MC Basic 算法

- MC Basic 是策略迭代算法的一个变体。
- 无模型算法建立在有模型算法的基础之上。因此，在学习无模型算法之前，有必要先深入理解有模型算法。
- MC Basic 有助于揭示基于蒙特卡洛的无模型强化学习的核心思想，但由于效率较低，在实际中并不实用。
- 为什么 MC Basic 估计的是动作价值而非状态价值？因为在没有模型的情况下，状态价值无法直接用于改进策略，应当直接估计动作价值。
- 由于策略迭代算法是收敛的，在轨迹数量足够的情况下，MC Basic 的收敛性同样得到保证。

示例一：逐步演示

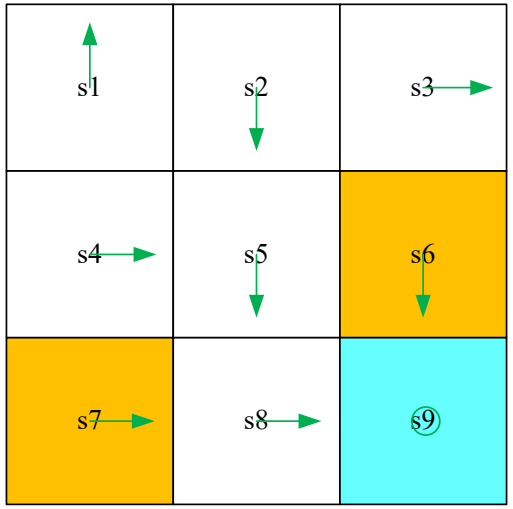

任务：

- 初始策略如图所示。
- 使用 MC Basic 寻找最优策略。
- $r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -1$，$r_{\text{target}} = 1$，$\gamma = 0.9$。

示例一：逐步演示

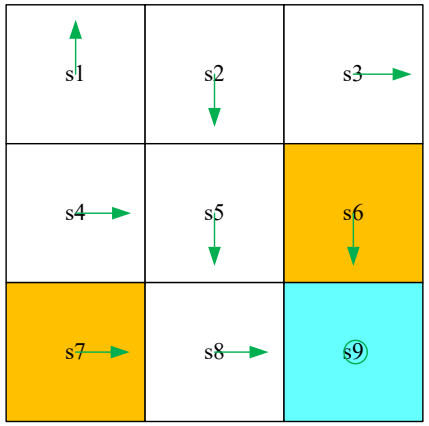

流程：给定当前策略 π_k

- 步骤一——策略评估：计算 $q_{\pi_k}(s,a)$
  共有多少状态-动作对？9个状态 $\times$ 5个动作 $=$ 45个状态-动作对！
- 步骤二——策略改进：选择贪婪动作 $a^*(s) = \arg\max_a q_{\pi_k}(s,a)$

示例一：逐步演示

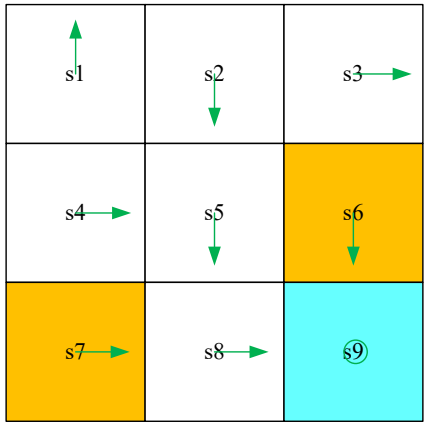

▷ 由于篇幅限制，仅展示 $q_{\pi_k}(s_1, a)$

▷ **步骤一——策略评估：**

- 由于当前策略是确定性的，一条轨迹就足以得到动作价值！否则，若策略或模型是随机的，则需要许多条轨迹！

示例一：逐步演示

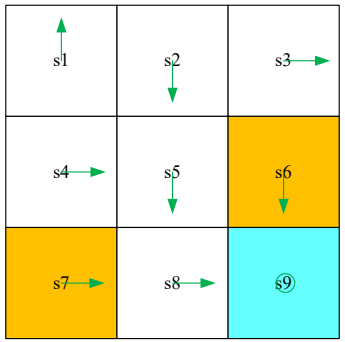

- 从 (s_1, a_1) 出发，轨迹为 $s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_1) = -1 + \gamma(-1) + \gamma^2(-1) + \ldots$$

- 从 (s_1, a_2) 出发，轨迹为 $s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_2) = 0 + \gamma 0 + \gamma^2 0 + \gamma^3(1) + \gamma^4(1) + \ldots$$

- 从 (s_1, a_3) 出发，轨迹为 $s_1 \xrightarrow{a_3} s_4 \xrightarrow{a_2} s_5 \xrightarrow{a_3} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_3) = 0 + \gamma 0 + \gamma^2 0 + \gamma^3(1) + \gamma^4(1) + \ldots$$

示例一：逐步演示

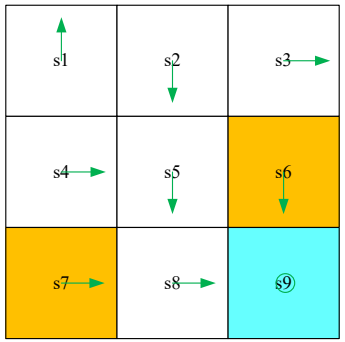

- 从 (s_1, a_1) 出发，轨迹为 $s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_1) = -1 + \gamma(-1) + \gamma^2(-1) + \ldots$$

- 从 (s_1, a_2) 出发，轨迹为 $s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_3} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_2) = 0 + \gamma 0 + \gamma^2 0 + \gamma^3(1) + \gamma^4(1) + \ldots$$

- 从 (s_1, a_3) 出发，轨迹为 $s_1 \xrightarrow{a_3} s_4 \xrightarrow{a_2} s_5 \xrightarrow{a_3} \ldots$。故动作价值为

$$q_{\pi_0}(s_1, a_3) = 0 + \gamma 0 + \gamma^2 0 + \gamma^3(1) + \gamma^4(1) + \ldots$$

示例一：逐步演示

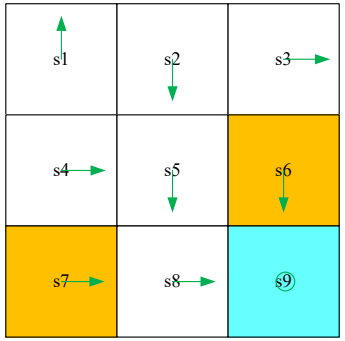

- 从 (s_1, a_4) 出发，轨迹为 $s_1 \xrightarrow{a_4} s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} \ldots$。 故动作价值为

$$q_{\pi_0}(s_1, a_4) = -1 + \gamma(-1) + \gamma^2(-1) + \ldots$$

- 从 (s_1, a_5) 出发，轨迹为 $s_1 \xrightarrow{a_5} s_1 \xrightarrow{a_1} s_1 \xrightarrow{a_1} \ldots$。 故动作价值为

$$q_{\pi_0}(s_1, a_5) = 0 + \gamma(-1) + \gamma^2(-1) + \ldots$$

示例一：逐步演示

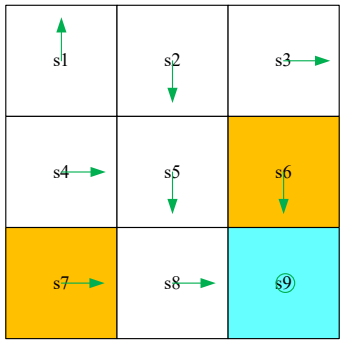

▷ **步骤二——策略改进：**

- 观察动作价值，可以发现

$$q_{\pi_0}(s_1, a_2) = q_{\pi_0}(s_1, a_3)$$

  取得最大值。

- 因此，策略可改进为

$$\pi_1(a_2|s_1) = 1 \quad \text{或} \quad \pi_1(a_3|s_1) = 1$$

  无论哪种选择，s_1 的新策略都达到最优。

对此简单示例，仅需一次迭代即可！

示例一：逐步演示

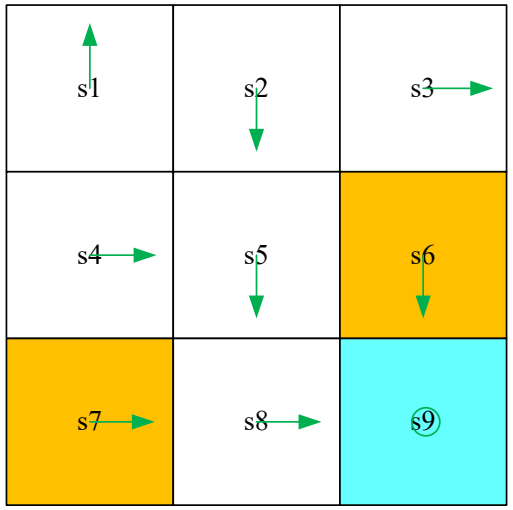

练习：现在使用 MC Basic 更新 s_3 的策略！

大纲

1 动机示例

2 最简单的基于蒙特卡洛的强化学习算法
- 算法：MC Basic

3 更高效地利用数据
- 算法：MC Exploring Starts

4 无需探索性起始的蒙特卡洛方法
- 算法：MC ϵ-贪婪

更高效地利用数据

MC Basic 算法:

- **优点**：核心思想清晰易懂！
- **缺点**：过于简单，缺乏实用性。

然而，MC Basic 可以被扩展得更加高效。

更高效地利用数据

▷ 考虑一个网格世界示例，按照策略 π 生成如下轨迹：

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$$

▷ **访问（Visit）**：每当一个状态-动作对出现在轨迹中，称为对该状态-动作对的一次访问。

▷ 利用数据的方法：**初始访问法（Initial-visit method）**

- 仅计算并近似 $q_\pi(s_1, a_2)$ 的回报。
- 这正是 MC Basic 算法所采用的方式。
- 缺点：未能充分利用数据。

更高效地利用数据

▷ 考虑一个网格世界示例，按照策略 π 生成如下轨迹：

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$$

▷ **访问（Visit）**：每当一个状态-动作对出现在轨迹中，称为对该状态-动作对的一次访问。

▷ 利用数据的方法：**初始访问法（Initial-visit method）**

- 仅计算并近似 $q_\pi(s_1, a_2)$ 的回报。
- 这正是 MC Basic 算法所采用的方式。
- 缺点：未能充分利用数据。

更高效地利用数据

▷ 考虑一个网格世界示例，按照策略 π 生成如下轨迹：

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$$

▷ **访问（Visit）**：每当一个状态-动作对出现在轨迹中，称为对该状态-动作对的一次访问。

▷ 利用数据的方法：**初始访问法（Initial-visit method）**

- 仅计算并近似 $q_\pi(s_1, a_2)$ 的回报。
- 这正是 MC Basic 算法所采用的方式。
- 缺点：未能充分利用数据。

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad \text{[原始轨迹]}$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad \text{[原始轨迹]}$$

$$s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad \text{[从 } (s_2, a_4) \text{ 出发的轨迹]}$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$
\begin{aligned}
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad & [\text{原始轨迹}] \\
s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad & [\text{从 } (s_2, a_4) \text{ 出发的轨迹}] \\
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots \quad & [\text{从 } (s_1, a_2) \text{ 出发的轨迹}]
\end{aligned}
$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$
\begin{aligned}
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[原始轨迹]} \\
s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_4) \text{ 出发的轨迹]} \\
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_1, a_2) \text{ 出发的轨迹]} \\
s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_3) \text{ 出发的轨迹]}
\end{aligned}
$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$
\begin{aligned}
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[原始轨迹]} \\
s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_4) \text{ 出发的轨迹]} \\
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_1, a_2) \text{ 出发的轨迹]} \\
s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_3) \text{ 出发的轨迹]} \\
s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_5, a_1) \text{ 出发的轨迹]}
\end{aligned}
$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$
\begin{aligned}
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[原始轨迹]} \\
s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_4) \text{ 出发的轨迹]} \\
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_1, a_2) \text{ 出发的轨迹]} \\
s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_2, a_3) \text{ 出发的轨迹]} \\
s_5 \xrightarrow{a_1} \dots & \quad \text{[从 } (s_5, a_1) \text{ 出发的轨迹]}
\end{aligned}
$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地利用数据

▷ 该轨迹还访问了其他状态-动作对。

$$
\begin{aligned}
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad [\text{原始轨迹}] \\
s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad [\text{从 } (s_2, a_4) \text{ 出发的轨迹}] \\
s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad [\text{从 } (s_1, a_2) \text{ 出发的轨迹}] \\
s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots & \quad [\text{从 } (s_2, a_3) \text{ 出发的轨迹}] \\
s_5 \xrightarrow{a_1} \dots & \quad [\text{从 } (s_5, a_1) \text{ 出发的轨迹}]
\end{aligned}
$$

可用于估计 $q_\pi(s_1, a_2)$、$q_\pi(s_2, a_4)$、$q_\pi(s_2, a_3)$、$q_\pi(s_5, a_1)$.....

高效利用数据的方法:

- 首次访问法（first-visit method）
- 每次访问法（every-visit method）

更高效地更新价值估计

▷ 基于蒙特卡洛的强化学习中，另一个方面是何时更新策略。有两种方法。

- **方法一**：在策略评估步骤中，收集从某一状态-动作对出发的所有轨迹，再用平均回报来近似动作价值。
  - 这是 MC Basic 算法所采用的方式。
  - 该方法的问题在于，智能体必须等待所有轨迹收集完毕。
- **方法二**：用单条轨迹的回报来近似动作价值。
  - 这样可以逐条轨迹地改进策略。

更高效地更新价值估计

▷ 基于蒙特卡洛的强化学习中，另一个方面是何时更新策略。有两种方法。

- **方法一**：在策略评估步骤中，收集从某一状态-动作对出发的所有轨迹，再用平均回报来近似动作价值。
  - 这是 MC Basic 算法所采用的方式。
  - 该方法的问题在于，智能体必须等待所有轨迹收集完毕。
- **方法二**：用单条轨迹的回报来近似动作价值。
  - 这样可以逐条轨迹地改进策略。

更高效地更新价值估计

▷ 基于蒙特卡洛的强化学习中，另一个方面是何时更新策略。有两种方法。

- **方法一**：在策略评估步骤中，收集从某一状态-动作对出发的所有轨迹，再用平均回报来近似动作价值。
  - 这是 MC Basic 算法所采用的方式。
  - 该方法的问题在于，智能体必须等待所有轨迹收集完毕。
- **方法二**：用单条轨迹的回报来近似动作价值。
  - 这样可以逐条轨迹地改进策略。

更高效地更新价值估计

▷ 方法二会带来问题吗?

- 有人可能认为，单条轨迹的回报不能准确近似对应的动作价值。
- 实际上，我们在上一章介绍的截断策略迭代算法中已经这样做过了！

▷ **广义策略迭代（Generalized Policy Iteration）：**

- 并非一个具体算法。
- 指在策略评估与策略改进过程之间交替进行的通用思想或框架。
- 许多强化学习算法都属于这一框架。

更高效地更新价值估计

▷ 方法二会带来问题吗?

- 有人可能认为，单条轨迹的回报不能准确近似对应的动作价值。
- 实际上，我们在上一章介绍的截断策略迭代算法中已经这样做过了！

▷ **广义策略迭代（Generalized Policy Iteration）：**

- 并非一个具体算法。
- 指在策略评估与策略改进过程之间交替进行的通用思想或框架。
- 许多强化学习算法都属于这一框架。

MC Exploring Starts（探索性起始）

▷ 若我们更高效地利用数据并更新估计，可得到一种新算法——MC Exploring Starts：

算法：MC Exploring Starts（MC Basic 的高效变体）

初始化： 初始策略 $\pi_0(a|s)$ 和所有 (s,a) 的初始价值 $q(s,a)$。对所有 (s,a)，令 $\text{Returns}(s,a) = 0$，$\text{Num}(s,a) = 0$。
目标： 搜索最优策略。

对每条轨迹，执行：
生成轨迹：选择起始状态-动作对 (s_0, a_0)，并确保所有状态-动作对均有可能被选中（即探索性起始条件）。按当前策略生成长度为 T 的轨迹：$s_0, a_0, r_1, \ldots, s_{T-1}, a_{T-1}, r_T$。
每条轨迹的初始化：$g \leftarrow 0$
对轨迹的每个时间步 $t = T-1, T-2, \ldots, 0$，执行：
$g \leftarrow \gamma g + r_{t+1}$
$\text{Returns}(s_t, a_t) \leftarrow \text{Returns}(s_t, a_t) + g$
$\text{Num}(s_t, a_t) \leftarrow \text{Num}(s_t, a_t) + 1$
策略评估：
$q(s_t, a_t) \leftarrow \text{Returns}(s_t, a_t)/\text{Num}(s_t, a_t)$
策略改进：
若 $a = \arg\max_a q(s_t, a)$ 则 $\pi(a|s_t) = 1$，否则 $\pi(a|s_t) = 0$

MC Exploring Starts

▷ **什么是探索性起始（Exploring Starts）？**

- 探索性起始是指需要生成足够多的轨迹，使每个状态-动作对都作为起始点被覆盖到。
- 例如，需要从 $\{(s_1, a_j)\}_{j=1}^5$、$\{(s_2, a_j)\}_{j=1}^5$、$\ldots$、$\{(s_9, a_j)\}_{j=1}^5$ 各自出发的轨迹。
  否则，若没有从 (s_i, a_j) 出发的轨迹，则 (s_i, a_j) 可能不会被任何轨迹访问到，从而无法估计 $q_\pi(s_i, a_j)$。
- MC Basic 和 MC Exploring Starts 均需要该假设。

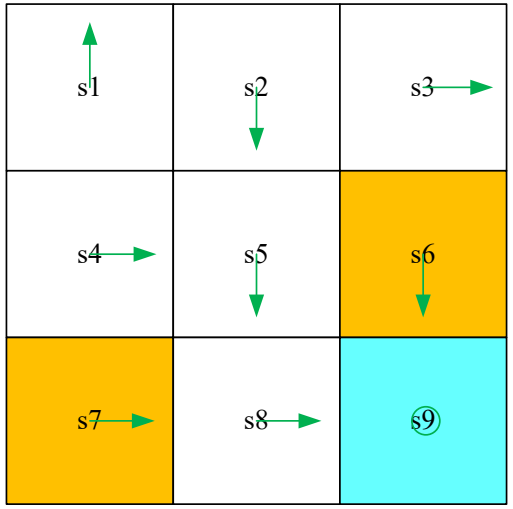

MC Exploring Starts

▷ **为什么需要探索性起始?**

- 理论上，只有每个状态的每个动作价值都被充分探索，才能正确选择最优动作。
  否则，若某个动作从未被探索过，而它恰好是最优动作，则会被遗漏。
- 实践中，探索性起始难以实现。对于许多应用（尤其是与环境发生物理交互的场景），很难收集从每个状态-动作对出发的轨迹。

能否去掉探索性起始的要求? 下面将说明，通过使用软策略可以做到这一点。

MC Exploring Starts

▷ **为什么需要探索性起始?**

- 理论上，只有每个状态的每个动作价值都被充分探索，才能正确选择最优动作。

  否则，若某个动作从未被探索过，而它恰好是最优动作，则会被遗漏。
- 实践中，探索性起始难以实现。对于许多应用（尤其是与环境发生物理交互的场景），很难收集从每个状态-动作对出发的轨迹。

能否去掉探索性起始的要求？下面将说明，通过使用软策略可以做到这一点。

▷ **为什么需要探索性起始?**

- 理论上，只有每个状态的每个动作价值都被充分探索，才能正确选择最优动作。
  否则，若某个动作从未被探索过，而它恰好是最优动作，则会被遗漏。
- 实践中，探索性起始难以实现。对于许多应用（尤其是与环境发生物理交互的场景），很难收集从每个状态-动作对出发的轨迹。

能否去掉探索性起始的要求? 下面将说明，通过使用软策略可以做到这一点。

大纲

1 动机示例

2 最简单的基于蒙特卡洛的强化学习算法
- 算法：MC Basic

3 更高效地利用数据
- 算法：MC Exploring Starts

4 无需探索性起始的蒙特卡洛方法
- 算法：MC ϵ-贪婪

软策略

▷ 什么是软策略（Soft Policy）？

- 若采取任何动作的概率均为正，则该策略为软策略。
  - 确定性策略：例如，贪婪策略
  - 随机策略：例如，软策略

▷ 为什么引入软策略?

- 采用软策略时，若轨迹足够长，少量轨迹便可访问每个状态-动作对。
- 因此，无需从每个状态-动作对出发收集大量轨迹，从而可以去掉探索性起始的要求。

软策略

▷ 什么是软策略（Soft Policy）？

- 若采取任何动作的概率均为正，则该策略为软策略。
  - 确定性策略：例如，贪婪策略
  - 随机策略：例如，软策略

▷ 为什么引入软策略?

- 采用软策略时，若轨迹足够长，少量轨迹便可访问每个状态-动作对。
- 因此，无需从每个状态-动作对出发收集大量轨迹，从而可以去掉探索性起始的要求。

软策略

▷ 什么是软策略（Soft Policy）？

- 若采取任何动作的概率均为正，则该策略为软策略。
  - 确定性策略：例如，贪婪策略
  - 随机策略：例如，软策略

▷ 为什么引入软策略?

- 采用软策略时，若轨迹足够长，少量轨迹便可访问每个状态-动作对。
- 因此，无需从每个状态-动作对出发收集大量轨迹，从而可以去掉探索性起始的要求。

ϵ-贪婪策略

- 我们将使用哪种软策略？答：ϵ-贪婪策略（ϵ-greedy policy）
- 什么是 ϵ-贪婪策略？

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1), & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

其中 $\epsilon \in [0, 1]$，$|\mathcal{A}(s)|$ 是状态 s 的动作数量。

- 示例：若 $\epsilon = 0.2$，则

$$\frac{\epsilon}{|\mathcal{A}(s)|} = \frac{0.2}{5} = 0.04, \qquad 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - 0.04 \times 4 = 0.84$$

- 选择贪婪动作的概率始终大于其他动作，因为

$$1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \geq \frac{\epsilon}{|\mathcal{A}(s)|}$$

ϵ-贪婪策略

- 我们将使用哪种软策略？答：ϵ-贪婪策略（ϵ-greedy policy）
- 什么是 ϵ-贪婪策略？

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1), & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

其中 $\epsilon \in [0, 1]$，$|\mathcal{A}(s)|$ 是状态 s 的动作数量。

- 示例：若 $\epsilon = 0.2$，则

$$\frac{\epsilon}{|\mathcal{A}(s)|} = \frac{0.2}{5} = 0.04, \qquad 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - 0.04 \times 4 = 0.84$$

- 选择贪婪动作的概率始终大于其他动作，因为

$$1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \geq \frac{\epsilon}{|\mathcal{A}(s)|}$$

ϵ-贪婪策略

- 我们将使用哪种软策略？答：ϵ-贪婪策略（ϵ-greedy policy）
- 什么是 ϵ-贪婪策略？

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1), & \text{对贪婪动作，} \\ \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

其中 $\epsilon \in [0, 1]$，$|\mathcal{A}(s)|$ 是状态 s 的动作数量。

- 示例：若 $\epsilon = 0.2$，则

$$\frac{\epsilon}{|\mathcal{A}(s)|} = \frac{0.2}{5} = 0.04, \qquad 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - 0.04 \times 4 = 0.84$$

- 选择贪婪动作的概率始终大于其他动作，因为

$$1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \geq \frac{\epsilon}{|\mathcal{A}(s)|}$$

ϵ-贪婪策略

- 我们将使用哪种软策略？答：ϵ-贪婪策略（ϵ-greedy policy）
- 什么是 ϵ-贪婪策略？

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1), & \text{对贪婪动作，} \\ \frac{\epsilon}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

其中 $\epsilon \in [0, 1]$，$|\mathcal{A}(s)|$ 是状态 s 的动作数量。

- 示例：若 $\epsilon = 0.2$，则

$$\frac{\epsilon}{|\mathcal{A}(s)|} = \frac{0.2}{5} = 0.04, \qquad 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - 0.04 \times 4 = 0.84$$

- 选择贪婪动作的概率始终大于其他动作，因为

$$1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \geq \frac{\epsilon}{|\mathcal{A}(s)|}$$

ϵ-贪婪策略

ϵ-贪婪策略能够平衡利用与探索。

- 当 $\epsilon \to 0$ 时，退化为贪婪策略！

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = 0, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多利用，更少探索。

- 当 $\epsilon \to 1$ 时，退化为均匀分布。

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = \frac{1}{|\mathcal{A}(s)|}, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = \frac{1}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多探索，更少利用。

ϵ-贪婪策略

ϵ-贪婪策略能够平衡利用与探索。

- 当 $\epsilon \to 0$ 时，退化为贪婪策略！

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = 0, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多利用，更少探索。

- 当 $\epsilon \to 1$ 时，退化为均匀分布。

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = \frac{1}{|\mathcal{A}(s)|}, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = \frac{1}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多探索，更少利用。

ϵ-贪婪策略

ϵ-贪婪策略能够平衡利用与探索。

- 当 $\epsilon \to 0$ 时，退化为贪婪策略！

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = 0, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多利用，更少探索。

- 当 $\epsilon \to 1$ 时，退化为均匀分布。

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = \frac{1}{|\mathcal{A}(s)|}, & \text{对贪婪动作}, \\ \frac{\epsilon}{|\mathcal{A}(s)|} = \frac{1}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多探索，更少利用。

ϵ-贪婪策略

ϵ-贪婪策略能够平衡利用与探索。

- 当 $\epsilon \to 0$ 时，退化为贪婪策略！

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1, & \text{对贪婪动作,} \\ \frac{\epsilon}{|\mathcal{A}(s)|} = 0, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多利用，更少探索。

- 当 $\epsilon \to 1$ 时，退化为均匀分布。

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = \frac{1}{|\mathcal{A}(s)|}, & \text{对贪婪动作,} \\ \frac{\epsilon}{|\mathcal{A}(s)|} = \frac{1}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多探索，更少利用。

ϵ-贪婪策略

ϵ-贪婪策略能够平衡利用与探索。

- 当 $\epsilon \to 0$ 时，退化为贪婪策略！

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = 1, & \text{对贪婪动作,} \\ \frac{\epsilon}{|\mathcal{A}(s)|} = 0, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多利用，更少探索。

- 当 $\epsilon \to 1$ 时，退化为均匀分布。

$$\pi(a|s) = \begin{cases} 1 - \frac{\epsilon}{|\mathcal{A}(s)|}(|\mathcal{A}(s)| - 1) = \frac{1}{|\mathcal{A}(s)|}, & \text{对贪婪动作,} \\ \frac{\epsilon}{|\mathcal{A}(s)|} = \frac{1}{|\mathcal{A}(s)|}, & \text{对其余 } |\mathcal{A}(s)| - 1 \text{ 个动作。} \end{cases}$$

更多探索，更少利用。

探索能力演示示例

▷ **单条轨迹能否访问所有状态-动作对?**

当 $\epsilon = 1$ 时，策略（均匀分布）具有最强的探索能力。

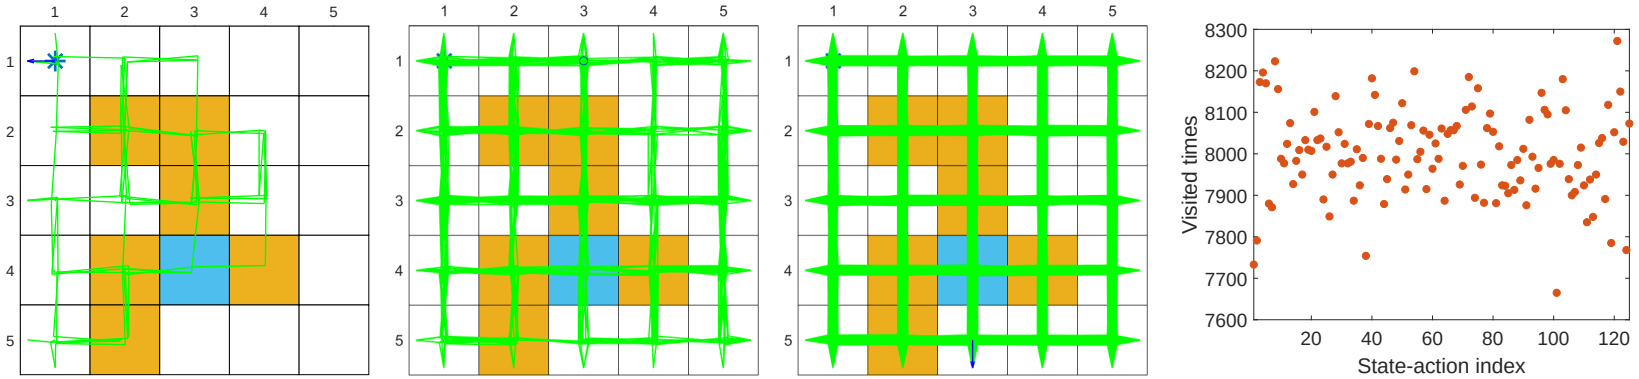

(a) 100步　(b) 1000步　(c) 10000步　(d)

点击此处播放视频（视频仅在本机上）

探索能力演示示例

▷ **单条轨迹能否访问所有状态-动作对?**

当 ϵ 较小时，策略的探索能力也较弱。

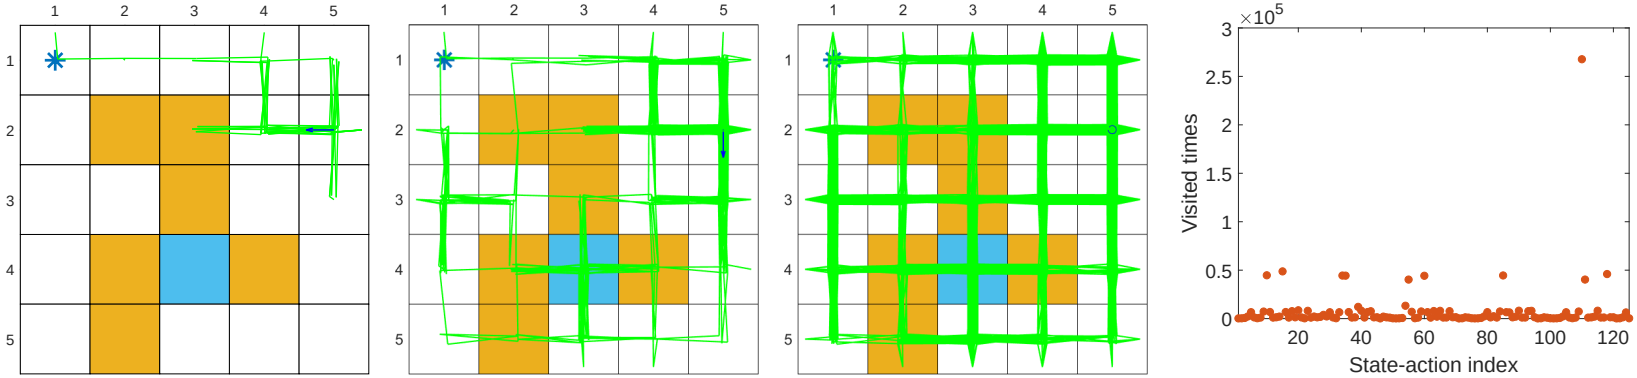

(a) 100步 (b) 1000步 (c) 10000步 (d)

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

原来， MC Basic 和 MC Exploring Starts 中策略改进步骤的目标是求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π 表示所有可能策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1, & a = a_k^*, \\ 0, & a \neq a_k^*, \end{cases}$$

其中 $a_k^* = \arg\max_a q_{\pi_k}(s,a)$。

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

原来， MC Basic 和 MC Exploring Starts 中策略改进步骤的目标是求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π 表示所有可能策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1, & a = a_k^*, \\ 0, & a \neq a_k^*, \end{cases}$$

其中 $a_k^* = \arg\max_a q_{\pi_k}(s,a)$。

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

原来， MC Basic 和 MC Exploring Starts 中策略改进步骤的目标是求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π 表示所有可能策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1, & a = a_k^*, \\ 0, & a \neq a_k^*, \end{cases}$$

其中 $a_k^* = \arg\max_a q_{\pi_k}(s,a)$。

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

现在，策略改进步骤改为求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi_\epsilon} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π_ϵ 表示固定 ϵ 值的所有 ϵ-贪婪策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1 - \frac{|\mathcal{A}(s)|-1}{|\mathcal{A}(s)|}\epsilon, & a = a_k^*, \\ \frac{1}{|\mathcal{A}(s)|}\epsilon, & a \neq a_k^*. \end{cases}$$

小结:

- MC ϵ-贪婪与 MC Exploring Starts 相同，区别仅在于前者使用 ϵ-贪婪策略。
- MC ϵ-贪婪不要求探索性起始条件，但仍以另一种形式要求访问所有状态-动作对。

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

现在，策略改进步骤改为求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi_\epsilon} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π_ϵ 表示固定 ϵ 值的所有 ϵ-贪婪策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1 - \frac{|\mathcal{A}(s)|-1}{|\mathcal{A}(s)|}\epsilon, & a = a_k^*, \\ \frac{1}{|\mathcal{A}(s)|}\epsilon, & a \neq a_k^*. \end{cases}$$

小结:

- MC ϵ-贪婪与 MC Exploring Starts 相同，区别仅在于前者使用 ϵ-贪婪策略。
- MC ϵ-贪婪不要求探索性起始条件，但仍以另一种形式要求访问所有状态-动作对。

MC ϵ-贪婪算法

▷ **如何将 ϵ-贪婪策略嵌入基于蒙特卡洛的强化学习算法?**

现在，策略改进步骤改为求解

$$\pi_{k+1}(s) = \arg\max_{\pi \in \Pi_\epsilon} \sum_a \pi(a|s) q_{\pi_k}(s,a),$$

其中Π_ϵ 表示固定 ϵ 值的所有 ϵ-贪婪策略的集合。 此时的最优策略为

$$\pi_{k+1}(a|s) = \begin{cases} 1 - \frac{|\mathcal{A}(s)|-1}{|\mathcal{A}(s)|}\epsilon, & a = a_k^*, \\ \frac{1}{|\mathcal{A}(s)|}\epsilon, & a \neq a_k^*. \end{cases}$$

小结:

- MC ϵ-贪婪与 MC Exploring Starts 相同，区别仅在于前者使用 ϵ-贪婪策略。
- MC ϵ-贪婪不要求探索性起始条件，但仍以另一种形式要求访问所有状态-动作对。

MC ϵ-贪婪算法

算法：MC ϵ-贪婪（MC Exploring Starts 的变体）

初始化： 初始策略 $\pi_0(a|s)$ 和所有 (s,a) 的初始价值 $q(s,a)$。对所有 (s,a)，令 $\text{Returns}(s,a) = 0$，$\text{Num}(s,a) = 0$。$\epsilon \in (0,1]$

目标： 搜索最优策略。

对每条轨迹，执行：

生成轨迹：选择起始状态-动作对 (s_0, a_0)（无需满足探索性起始条件）。按当前策略生成长度为 T 的轨迹：$s_0, a_0, r_1, \ldots, s_{T-1}, a_{T-1}, r_T$。

每条轨迹的初始化：$g \leftarrow 0$

对轨迹的每个时间步 $t = T-1, T-2, \ldots, 0$，执行：

$g \leftarrow \gamma g + r_{t+1}$

$\text{Returns}(s_t, a_t) \leftarrow \text{Returns}(s_t, a_t) + g$

$\text{Num}(s_t, a_t) \leftarrow \text{Num}(s_t, a_t) + 1$

策略评估：

$q(s_t, a_t) \leftarrow \text{Returns}(s_t, a_t)/\text{Num}(s_t, a_t)$

策略改进：

令 $a^* = \arg\max_a q(s_t, a)$，且

$$\pi(a|s_t) = \begin{cases} 1 - \frac{|\mathcal{A}(s_t)|-1}{|\mathcal{A}(s_t)|}\epsilon, & a = a^* \\ \frac{1}{|\mathcal{A}(s_t)|}\epsilon, & a \neq a^* \end{cases}$$

示例

▷ 演示 MC ϵ-贪婪算法。

每次迭代中，执行以下步骤:

- 在轨迹生成步骤中，使用前一策略生成一条长达100万步的轨迹！
- 在后续步骤中，用该单条轨迹更新策略。
- 两次迭代即可得到最优 ϵ-贪婪策略。

此处，$r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -10$，$r_{\text{target}} = 1$，$\gamma = 0.9$。

示例

▷ 演示 MC ϵ-贪婪算法。

每次迭代中，执行以下步骤:

- 在轨迹生成步骤中，使用前一策略生成一条长达100万步的轨迹！
- 在后续步骤中，用该单条轨迹更新策略。
- 两次迭代即可得到最优 ϵ-贪婪策略。

此处，$r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -10$，$r_{\text{target}} = 1$，$\gamma = 0.9$。

示例

▷ 演示 MC ϵ-贪婪算法。

每次迭代中，执行以下步骤:

- 在轨迹生成步骤中，使用前一策略生成一条长达100万步的轨迹！
- 在后续步骤中，用该单条轨迹更新策略。
- 两次迭代即可得到最优 ϵ-贪婪策略。

此处，$r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -10$，$r_{\text{target}} = 1$，$\gamma = 0.9$。

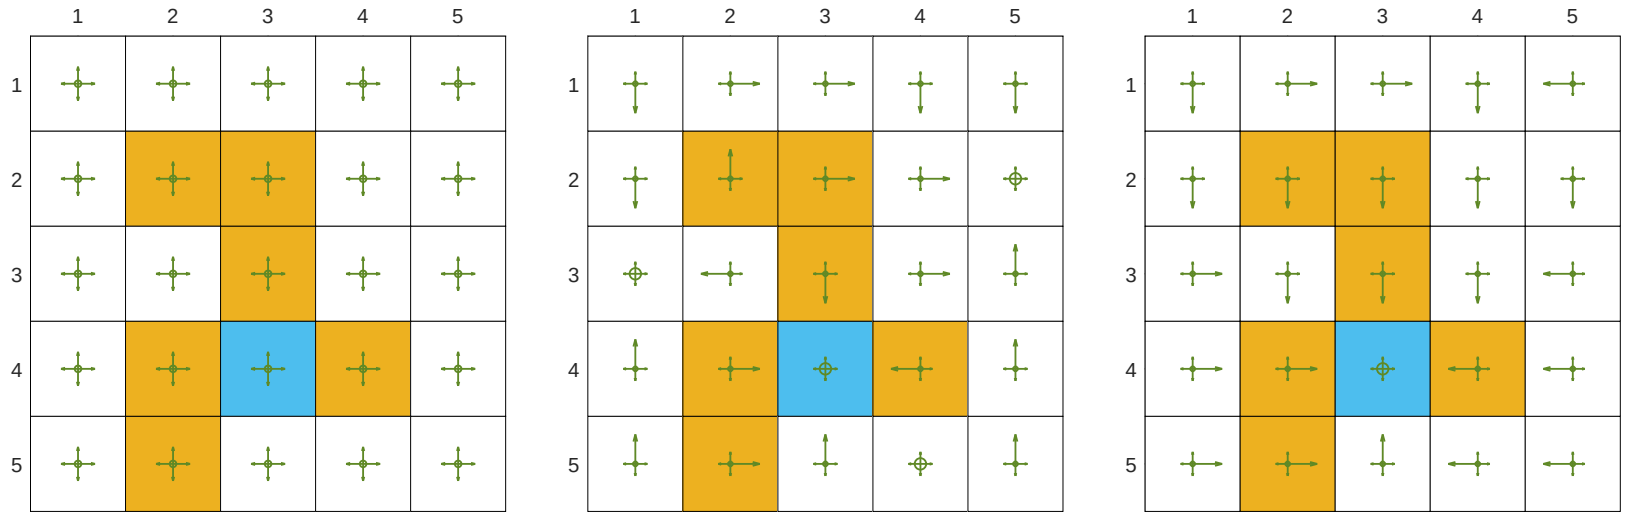

(a) 初始策略　(b) 第一次迭代后　(c) 第二次迭代后

最优性与探索性

▷ 与贪婪策略相比，

- ϵ-贪婪策略的**优点**在于，当 ϵ 较大时具有较强的探索能力。
  - 因此无需满足探索性起始条件。
- **缺点**是 ϵ-贪婪策略通常并不最优。
  - 它仅在所有 ϵ-贪婪策略的集合 Π_ϵ 中最优。
  - 因此 ϵ 不应过大，也可以使用衰减的 ϵ。

▷ 接下来，通过示例进行演示。设置为

$r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -10$，$r_{\text{target}} = 1$，$\gamma = 0.9$

最优性与探索性

▷ 与贪婪策略相比，

- ϵ-贪婪策略的**优点**在于，当 ϵ 较大时具有较强的探索能力。
  - 因此无需满足探索性起始条件。
- **缺点**是 ϵ-贪婪策略通常并不最优。
  - 它仅在所有 ϵ-贪婪策略的集合 Π_ϵ 中最优。
  - 因此 ϵ 不应过大，也可以使用衰减的 ϵ。

▷ 接下来，通过示例进行演示。设置为

$r_{\text{boundary}} = -1$，$r_{\text{forbidden}} = -10$，$r_{\text{target}} = 1$，$\gamma = 0.9$

最优性

▷ 示例：给定 ϵ-贪婪策略，其状态价值是多少?

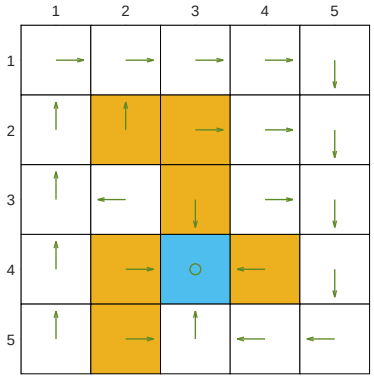

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

▷ 当 ϵ 增大时，策略的最优性变差！

▷ 为什么目标状态的状态价值为负?

最优性

▷ 示例：给定 ϵ-贪婪策略，其状态价值是多少?

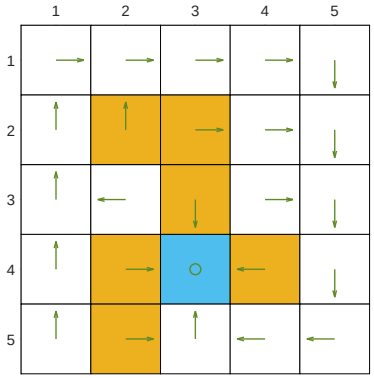

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

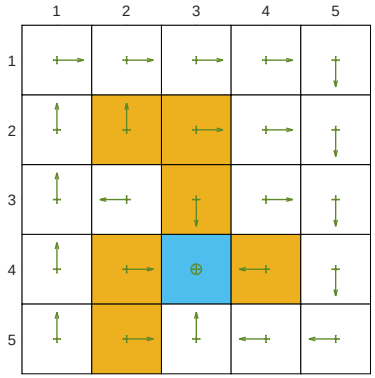

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

▷ 当 ϵ 增大时，策略的最优性变差！

▷ 为什么目标状态的状态价值为负?

最优性

▷ 示例：给定 ϵ-贪婪策略，其状态价值是多少?

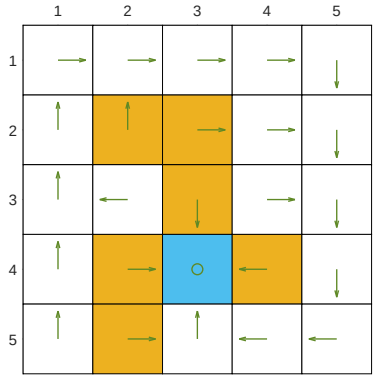

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

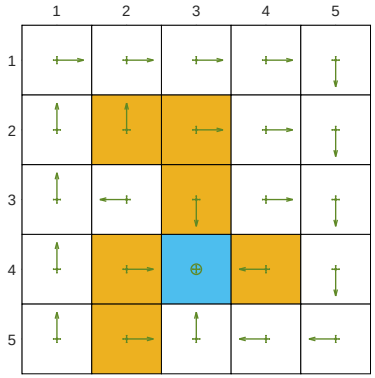

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

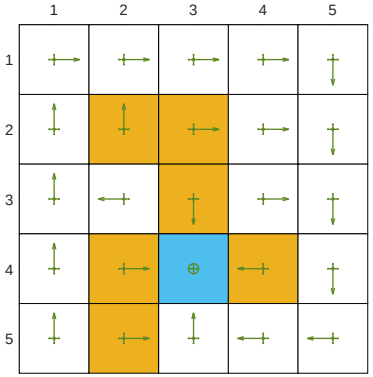

	1	2	3	4	5
1	-2.2	-2.4	-2.1	-1.7	-1.8
2	-2.5	-3.0	-3.3	-2.3	-2.0
3	-2.3	-3.3	-2.5	-2.8	-2.2
4	-2.5	-2.5	-2.8	-2.0	-2.4
5	-2.8	-3.2	-2.1	-2.3	-2.2

$\epsilon = 0.2$

▷ 当 ϵ 增大时，策略的最优性变差！

▷ 为什么目标状态的状态价值为负?

最优性

▷ 示例：给定 ϵ-贪婪策略，其状态价值是多少?

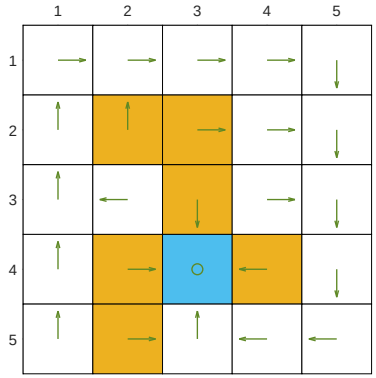

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

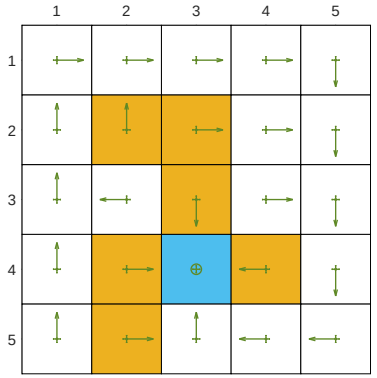

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

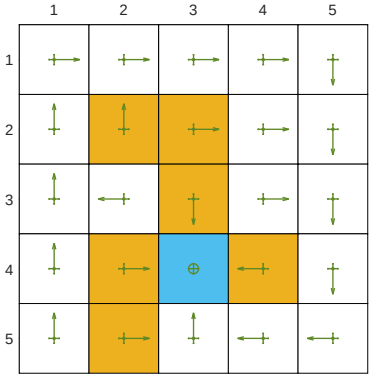

	1	2	3	4	5
1	-2.2	-2.4	-2.1	-1.7	-1.8
2	-2.5	-3.0	-3.3	-2.3	-2.0
3	-2.3	-3.3	-2.5	-2.8	-2.2
4	-2.5	-2.5	-2.8	-2.0	-2.4
5	-2.8	-3.2	-2.1	-2.3	-2.2

$\epsilon = 0.2$

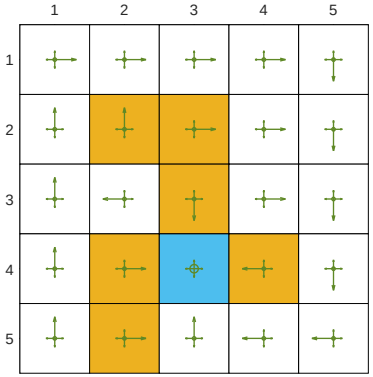

	1	2	3	4	5
1	-8.0	-9.0	-8.4	-7.2	-7.8
2	-8.7	-10.8	-12.4	-9.6	-8.9
3	-8.3	-12.3	-15.3	-12.3	-10.5
4	-9.7	-15.5	-17.0	-14.4	-12.2
5	-10.9	-16.7	-15.2	-14.3	-12.4

$\epsilon = 0.5$

▷ 当 ϵ 增大时，策略的最优性变差！

▷ 为什么目标状态的状态价值为负?

最优性

▷ 示例：给定 ϵ-贪婪策略，其状态价值是多少?

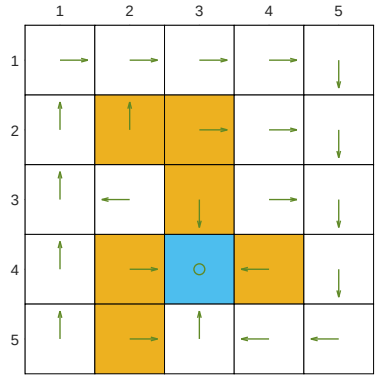

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

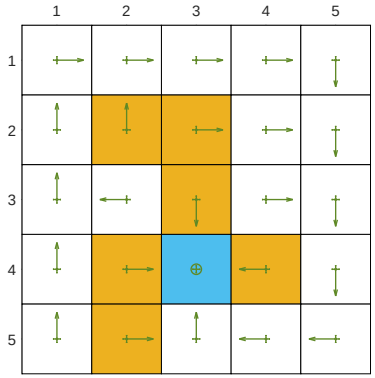

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

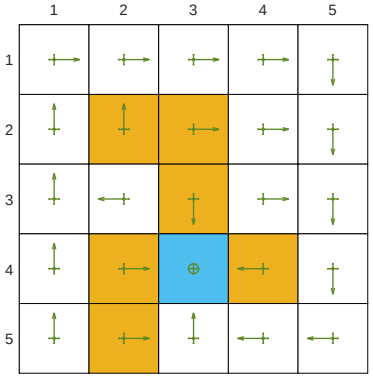

	1	2	3	4	5
1	-2.2	-2.4	-2.1	-1.7	-1.8
2	-2.5	-3.0	-3.3	-2.3	-2.0
3	-2.3	-3.3	-2.5	-2.8	-2.2
4	-2.5	-2.5	-2.8	-2.0	-2.4
5	-2.8	-3.2	-2.1	-2.3	-2.2

$\epsilon = 0.2$

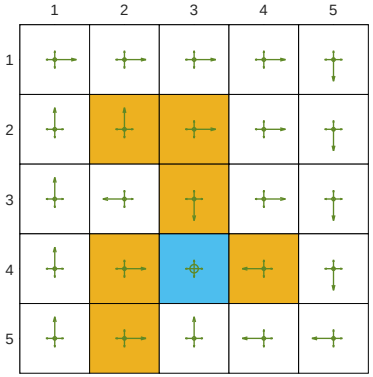

	1	2	3	4	5
1	-8.0	-9.0	-8.4	-7.2	-7.8
2	-8.7	-10.8	-12.4	-9.6	-8.9
3	-8.3	-12.3	-15.3	-12.3	-10.5
4	-9.7	-15.5	-17.0	-14.4	-12.2
5	-10.9	-16.7	-15.2	-14.3	-12.4

$\epsilon = 0.5$

▷ 当 ϵ 增大时，策略的最优性变差！

▷ 为什么目标状态的状态价值为负?

一致性

▷ 示例：找到最优 ϵ-贪婪策略及其状态价值。

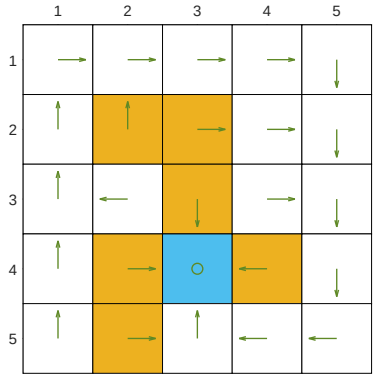

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

▷ 最优 ϵ-贪婪策略与贪婪最优策略并不一致！ 为什么？以目标状态为例思考。

一致性

▷ 示例：找到最优 ϵ-贪婪策略及其状态价值。

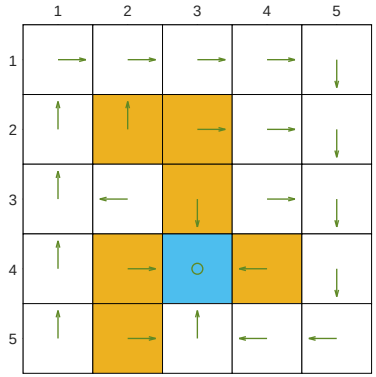

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

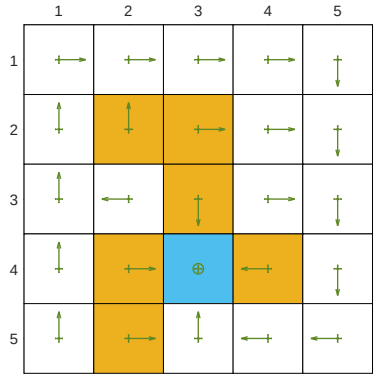

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

▷ 最优 ϵ-贪婪策略与贪婪最优策略并不一致！ 为什么？以目标状态为例思考。

一致性

▷ 示例：找到最优 ϵ-贪婪策略及其状态价值。

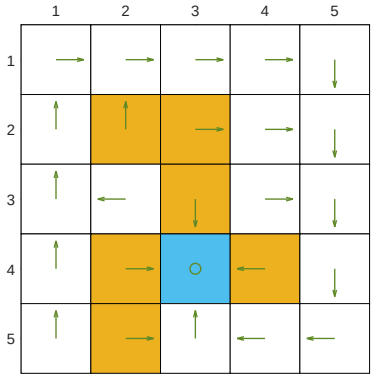

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

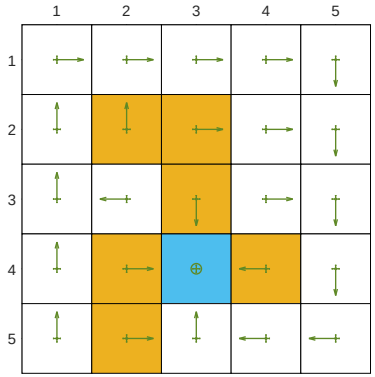

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

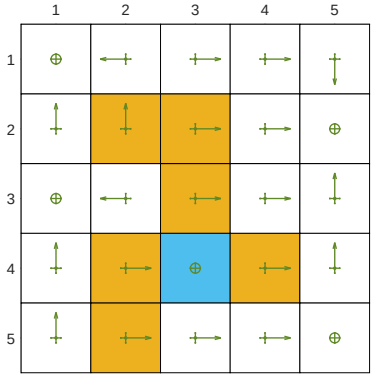

	1	2	3	4	5
1	-1.1	-1.5	-1.1	-0.6	-0.6
2	-1.5	-2.2	-2.3	-1.0	-0.6
3	-1.2	-2.4	-2.2	-1.5	-0.6
4	-1.6	-2.3	-2.6	-1.4	-1.1
5	-2.0	-3.0	-1.8	-1.4	-1.0

$\epsilon = 0.2$

▷ 最优 ϵ-贪婪策略与贪婪最优策略并不一致！ 为什么？以目标状态为例思考。

一致性

▷ 示例：找到最优 ϵ-贪婪策略及其状态价值。

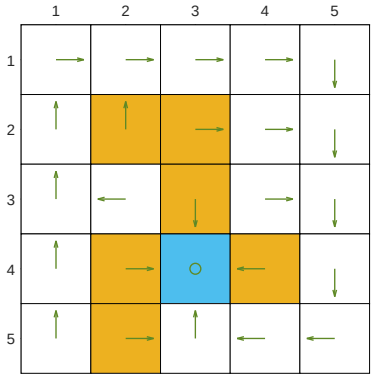

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

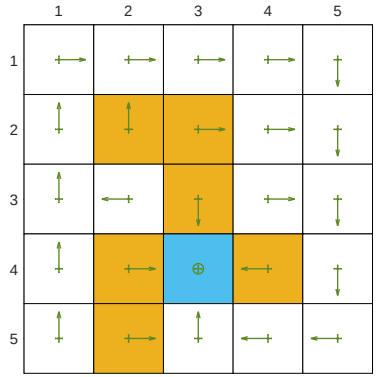

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

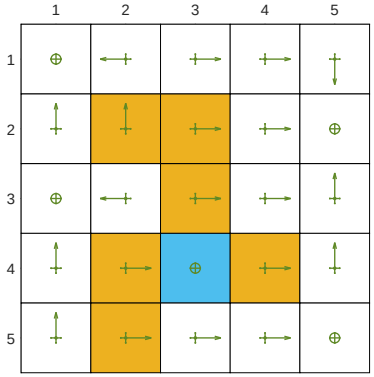

	1	2	3	4	5
1	-1.1	-1.5	-1.1	-0.6	-0.6
2	-1.5	-2.2	-2.3	-1.0	-0.6
3	-1.2	-2.4	-2.2	-1.5	-0.6
4	-1.6	-2.3	-2.6	-1.4	-1.1
5	-2.0	-3.0	-1.8	-1.4	-1.0

$\epsilon = 0.2$

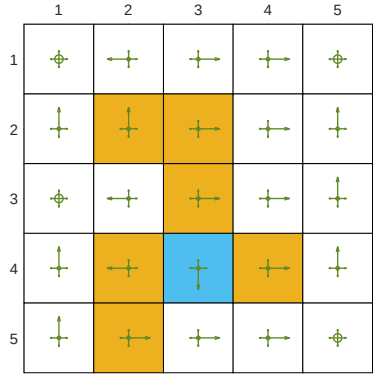

	1	2	3	4	5
1	-4.3	-5.5	-4.5	-2.6	-2.3
2	-5.6	-7.7	-7.7	-4.1	-2.4
3	-5.5	-9.0	-8.0	-5.6	-2.8
4	-6.8	-8.9	-9.4	-5.5	-4.2
5	-7.9	-10.1	-6.7	-5.1	-3.7

$\epsilon = 0.5$

▷ 最优 ϵ-贪婪策略与贪婪最优策略并不一致！ 为什么？以目标状态为例思考。

一致性

▷ 示例：找到最优 ϵ-贪婪策略及其状态价值。

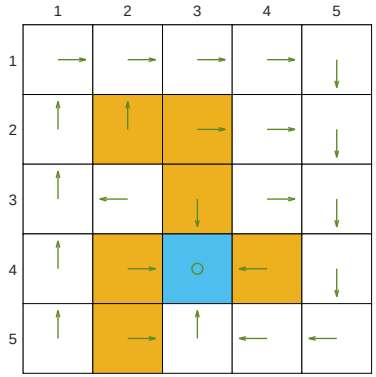

	1	2	3	4	5
1	3.5	3.9	4.3	4.8	5.3
2	3.1	3.5	4.8	5.3	5.9
3	2.8	2.5	10.0	5.9	6.6
4	2.5	10.0	10.0	10.0	7.3
5	2.3	9.0	10.0	9.0	8.1

$\epsilon = 0$

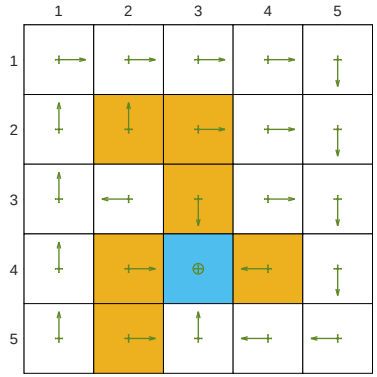

	1	2	3	4	5
1	0.4	0.5	0.9	1.3	1.4
2	0.1	0.0	0.5	1.3	1.7
3	0.1	-0.4	3.4	1.4	1.9
4	-0.1	3.4	3.3	3.7	2.2
5	-0.3	2.6	3.7	3.1	2.7

$\epsilon = 0.1$

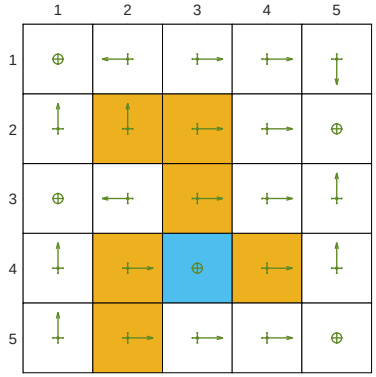

	1	2	3	4	5
1	-1.1	-1.5	-1.1	-0.6	-0.6
2	-1.5	-2.2	-2.3	-1.0	-0.6
3	-1.2	-2.4	-2.2	-1.5	-0.6
4	-1.6	-2.3	-2.6	-1.4	-1.1
5	-2.0	-3.0	-1.8	-1.4	-1.0

$\epsilon = 0.2$

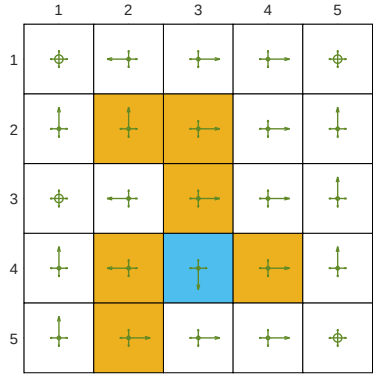

	1	2	3	4	5
1	-4.3	-5.5	-4.5	-2.6	-2.3
2	-5.6	-7.7	-7.7	-4.1	-2.4
3	-5.5	-9.0	-8.0	-5.6	-2.8
4	-6.8	-8.9	-9.4	-5.5	-4.2
5	-7.9	-10.1	-6.7	-5.1	-3.7

$\epsilon = 0.5$

▷ 最优 ϵ-贪婪策略与贪婪最优策略并不一致！ 为什么？以目标状态为例思考。

总结

关键要点:

- 蒙特卡洛方法进行均值估计
- 三种算法:
  - MC Basic
  - MC ES（探索性起始）
  - MC ϵ-贪婪
- 三种算法之间的关系
- ϵ-贪婪策略的最优性与探索性