第六讲：随机近似算法

April 11, 2026

大纲

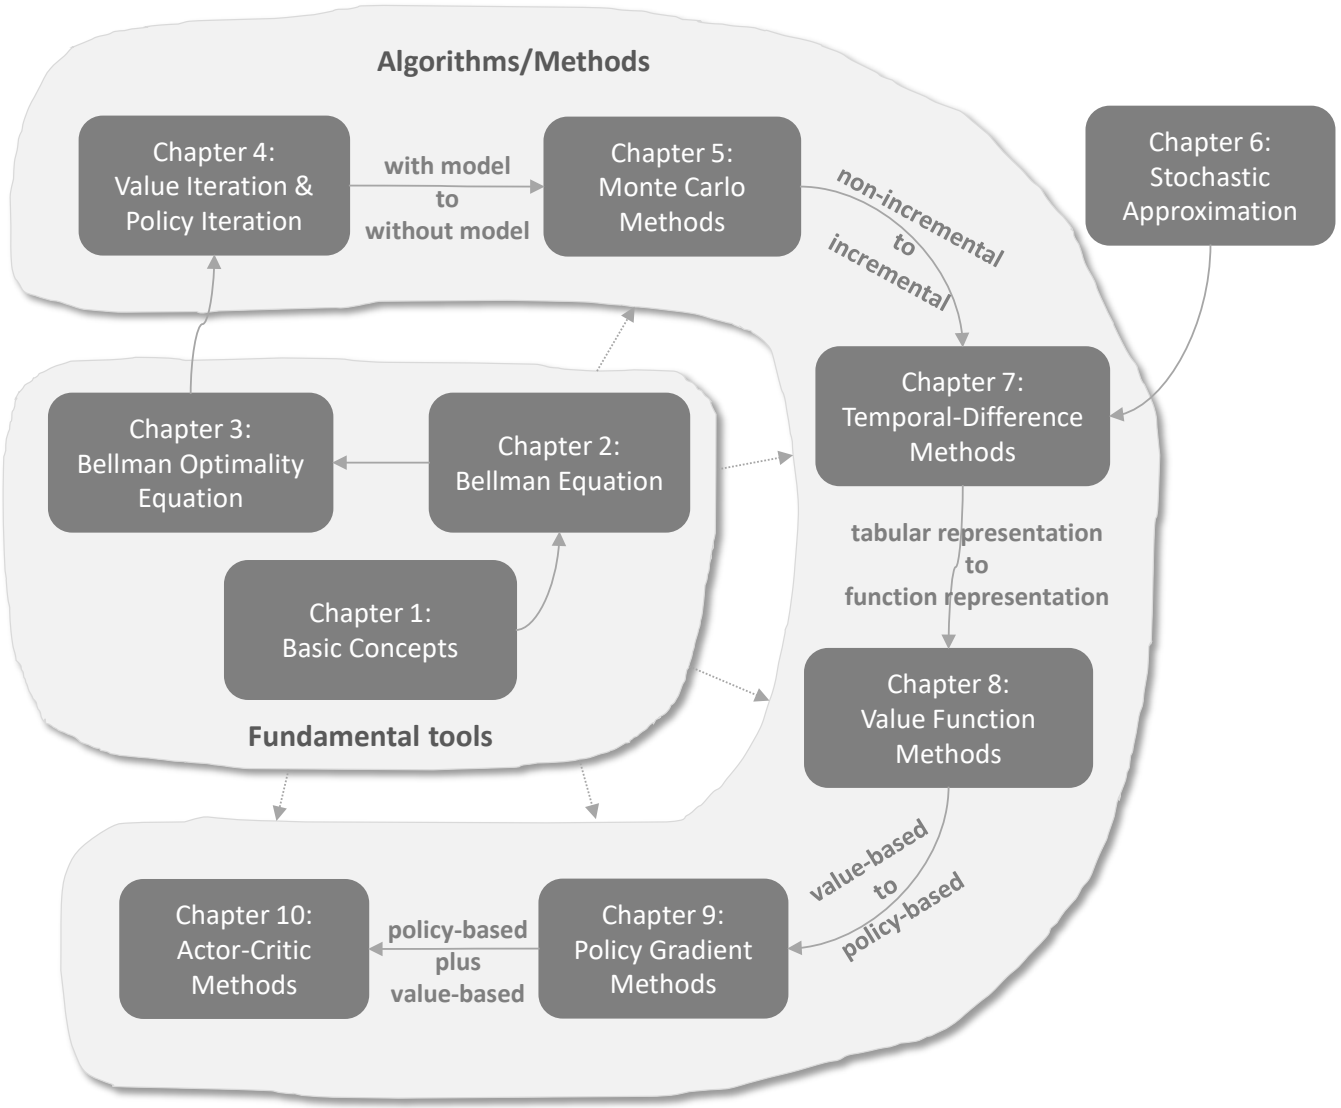
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

引言

- 在上一讲中，我们介绍了蒙特卡洛学习。
- 在下一讲中，我们将介绍时序差分（TD）学习。
- 本讲我们暂停一下，做好更充分的准备。
  为什么?
  - 存在一个知识缺口！
  - TD算法的思想和表达方式与我们目前所学的算法非常不同。
  - 许多第一次接触TD算法的学生可能会疑惑：这些算法最初为什么会被这样设计？它们为何能有效工作?

引言

- 在上一讲中，我们介绍了蒙特卡洛学习。
- 在下一讲中，我们将介绍时序差分（TD）学习。
- 本讲我们暂停一下，做好更充分的准备。
  为什么?
  - 存在一个知识缺口！
  - TD算法的思想和表达方式与我们目前所学的算法非常不同。
  - 许多第一次接触TD算法的学生可能会疑惑：这些算法最初为什么会被这样设计？它们为何能有效工作?

引言

本讲中，

- 我们通过介绍基本的随机逼近（SA）算法，填补前后两讲之间的知识缺口。
- 在下一讲中，我们将看到时序差分算法是特殊的SA算法，从而使这些算法更易于理解。
- 我们还将学习重要的随机梯度下降（SGD）算法。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计？

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：再谈均值估计

回顾均值估计问题：

- 考虑随机变量 X。
- 假设我们收集了一组独立同分布的样本 $\{x_i\}_{i=1}^N$。
- 我们的目标是估计 $\mathbb{E}[X]$。
- X 的期望可以近似为

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- 这一近似就是蒙特卡洛估计的基本思想。
- 我们知道，当 $N \to \infty$ 时，$\bar{x} \to \mathbb{E}[X]$。

为什么我们如此关注均值估计?

- 强化学习中的许多量，如动作价值和梯度，都被定义为期望！

动机示例：均值估计

新问题：如何计算均值 $\bar{x}$?

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

我们有两种方式。

- **第一种方式**比较直接，即收集所有样本后再计算平均值。
  - 这种方式的缺点是：若样本是随时间逐一收集的，则必须等待所有样本都收集完毕。
- **第二种方式**可以避免这一缺点，因为它以增量方式计算平均值。

动机示例：均值估计

新问题：如何计算均值 $\bar{x}$?

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

我们有两种方式。

- **第一种方式**比较直接，即收集所有样本后再计算平均值。
  - 这种方式的缺点是：若样本是随时间逐一收集的，则必须等待所有样本都收集完毕。
- **第二种方式**可以避免这一缺点，因为它以增量方式计算平均值。

动机示例：均值估计

新问题：如何计算均值 $\bar{x}$?

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

我们有两种方式。

- **第一种方式**比较直接，即收集所有样本后再计算平均值。
  - 这种方式的缺点是：若样本是随时间逐一收集的，则必须等待所有样本都收集完毕。
- **第二种方式**可以避免这一缺点，因为它以增量方式计算平均值。

动机示例：均值估计

新问题：如何计算均值 $\bar{x}$?

$$\mathbb{E}[X] \approx \bar{x} := \frac{1}{N}\sum_{i=1}^{N} x_i.$$

我们有两种方式。

- **第一种方式**比较直接，即收集所有样本后再计算平均值。
  - 这种方式的缺点是：若样本是随时间逐一收集的，则必须等待所有样本都收集完毕。
- **第二种方式**可以避免这一缺点，因为它以增量方式计算平均值。

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i$$

因此，我们得到如下迭代算法:

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i$$

因此，我们得到如下迭代算法:

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i$$

因此，我们得到如下迭代算法:

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i = \frac{1}{k}\left(\sum_{i=1}^{k-1} x_i + x_k\right)$$

因此，我们得到如下迭代算法：

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$\begin{aligned} w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i &= \frac{1}{k}\left(\sum_{i=1}^{k-1} x_i + x_k\right) \\ &= \frac{1}{k}((k-1)w_k + x_k) \end{aligned}$$

因此，我们得到如下迭代算法：

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$\begin{aligned} w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i &= \frac{1}{k}\left(\sum_{i=1}^{k-1} x_i + x_k\right) \\ &= \frac{1}{k}((k-1)w_k + x_k) = w_k - \frac{1}{k}(w_k - x_k). \end{aligned}$$

因此，我们得到如下迭代算法：

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

具体地，假设

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i \quad k = 1, 2, \ldots$$

从而

$$w_k = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i, \quad k = 2, 3, \ldots$$

则 w_{k+1} 可以用 w_k 表示为

$$\begin{aligned} w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i &= \frac{1}{k}\left(\sum_{i=1}^{k-1} x_i + x_k\right) \\ &= \frac{1}{k}((k-1)w_k + x_k) = w_k - \frac{1}{k}(w_k - x_k). \end{aligned}$$

因此，我们得到如下迭代算法:

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$w_1 = x_1,$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$w_1 = x_1,$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$\begin{aligned} w_1 &= x_1, \\ w_2 &= w_1 - \frac{1}{1}(w_1 - x_1) = x_1, \end{aligned}$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$\begin{aligned}
w_1 &= x_1, \\
w_2 &= w_1 - \frac{1}{1}(w_1 - x_1) = x_1, \\
w_3 &= w_2 - \frac{1}{2}(w_2 - x_2) = x_1 - \frac{1}{2}(x_1 - x_2) = \frac{1}{2}(x_1 + x_2),
\end{aligned}$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$\begin{aligned}
w_1 &= x_1, \\
w_2 &= w_1 - \frac{1}{1}(w_1 - x_1) = x_1, \\
w_3 &= w_2 - \frac{1}{2}(w_2 - x_2) = x_1 - \frac{1}{2}(x_1 - x_2) = \frac{1}{2}(x_1 + x_2), \\
w_4 &= w_3 - \frac{1}{3}(w_3 - x_3) = \frac{1}{3}(x_1 + x_2 + x_3),
\end{aligned}$$

动机示例：均值估计

验证：我们可以用

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k)$$

来增量式地计算均值 $\bar{x}$：

$$\begin{aligned}
w_1 &= x_1, \\
w_2 &= w_1 - \frac{1}{1}(w_1 - x_1) = x_1, \\
w_3 &= w_2 - \frac{1}{2}(w_2 - x_2) = x_1 - \frac{1}{2}(x_1 - x_2) = \frac{1}{2}(x_1 + x_2), \\
w_4 &= w_3 - \frac{1}{3}(w_3 - x_3) = \frac{1}{3}(x_1 + x_2 + x_3), \\
&\vdots \\
w_{k+1} &= \frac{1}{k}\sum_{i=1}^{k} x_i.
\end{aligned}$$

动机示例：均值估计

关于该算法的说明：

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

- 该算法的一个优点是它是增量式的。每收到一个样本，便可立即得到一个均值估计，并可立即用于其他目的。
- 由于初期样本不足，均值估计并不准确。但聊胜于无。随着样本增多，估计会逐渐改善（即当 $k \to \infty$ 时，$w_k \to \mathbb{E}[X]$）。

动机示例：均值估计

进一步地，考虑一个更一般形式的算法：

$$w_{k+1} = w_k - \alpha_k(w_k - x_k),$$

其中 $1/k$ 被替换为 $\alpha_k > 0$。

- 该算法是否仍然收敛到均值 $\mathbb{E}[X]$？我们将证明，若 $\{\alpha_k\}$ 满足某些温和条件，答案是肯定的。
- 我们还将证明，该算法是一种特殊的随机逼近算法，也是一种特殊的随机梯度下降算法。
- 在下一讲中，我们将看到时序差分算法具有类似（但更复杂）的表达形式。

动机示例：均值估计

进一步地，考虑一个更一般形式的算法：

$$w_{k+1} = w_k - \alpha_k(w_k - x_k),$$

其中 $1/k$ 被替换为 $\alpha_k > 0$。

- 该算法是否仍然收敛到均值 $\mathbb{E}[X]$？我们将证明，若 $\{\alpha_k\}$ 满足某些温和条件，答案是肯定的。
- 我们还将证明，该算法是一种特殊的随机逼近算法，也是一种特殊的随机梯度下降算法。
- 在下一讲中，我们将看到时序差分算法具有类似（但更复杂）的表达形式。

动机示例：均值估计

进一步地，考虑一个更一般形式的算法：

$$w_{k+1} = w_k - \alpha_k(w_k - x_k),$$

其中 $1/k$ 被替换为 $\alpha_k > 0$。

- 该算法是否仍然收敛到均值 $\mathbb{E}[X]$？我们将证明，若 $\{\alpha_k\}$ 满足某些温和条件，答案是肯定的。
- 我们还将证明，该算法是一种特殊的随机逼近算法，也是一种特殊的随机梯度下降算法。
- 在下一讲中，我们将看到时序差分算法具有类似（但更复杂）的表达形式。

动机示例：均值估计

进一步地，考虑一个更一般形式的算法：

$$w_{k+1} = w_k - \alpha_k(w_k - x_k),$$

其中 $1/k$ 被替换为 $\alpha_k > 0$。

- 该算法是否仍然收敛到均值 $\mathbb{E}[X]$？我们将证明，若 $\{\alpha_k\}$ 满足某些温和条件，答案是肯定的。
- 我们还将证明，该算法是一种特殊的随机逼近算法，也是一种特殊的随机梯度下降算法。
- 在下一讲中，我们将看到时序差分算法具有类似（但更复杂）的表达形式。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

Robbins-Monro 算法

随机逼近（SA）：

- SA 是一大类用于求解求根问题或优化问题的随机迭代算法。
- 与许多其他求根算法（如基于梯度的方法）相比，SA 的强大之处在于它不需要知道目标函数的表达式及其导数。

Robbins-Monro（RM）算法:

- 这是随机逼近领域的一项开创性工作。
- 著名的随机梯度下降算法是RM算法的特殊形式。
- 它可用于分析本讲开头介绍的均值估计算法。

Robbins-Monro 算法

随机逼近（SA）：

- SA 是一大类用于求解求根问题或优化问题的随机迭代算法。
- 与许多其他求根算法（如基于梯度的方法）相比，SA 的强大之处在于它不需要知道目标函数的表达式及其导数。

Robbins-Monro（RM）算法:

- 这是随机逼近领域的一项开创性工作。
- 著名的随机梯度下降算法是RM算法的特殊形式。
- 它可用于分析本讲开头介绍的均值估计算法。

Robbins-Monro 算法

随机逼近（SA）：

- SA 是一大类用于求解求根问题或优化问题的随机迭代算法。
- 与许多其他求根算法（如基于梯度的方法）相比，SA 的强大之处在于它不需要知道目标函数的表达式及其导数。

Robbins-Monro（RM）算法:

- 这是随机逼近领域的一项开创性工作。
- 著名的随机梯度下降算法是RM算法的特殊形式。
- 它可用于分析本讲开头介绍的均值估计算法。

Robbins-Monro 算法——问题描述

问题描述：假设我们希望求解方程

$$g(w) = 0,$$

其中 $w \in \mathbb{R}$ 是待求变量，$g : \mathbb{R} \to \mathbb{R}$ 是一个函数。

- 许多问题最终可以转化为这一求根问题。例如，设 $J(w)$ 是待最小化的目标函数，则优化问题可转化为

$$g(w) = \nabla_w J(w) = 0$$

- 注意，形如 $g(w) = c$（c 为常数）的方程也可以转化为上述形式，只需将 $g(w) - c$ 视为一个新函数即可。

Robbins-Monro 算法——问题描述

问题描述：假设我们希望求解方程

$$g(w) = 0,$$

其中 $w \in \mathbb{R}$ 是待求变量，$g : \mathbb{R} \to \mathbb{R}$ 是一个函数。

- 许多问题最终可以转化为这一求根问题。例如，设 $J(w)$ 是待最小化的目标函数，则优化问题可转化为

$$g(w) = \nabla_w J(w) = 0$$

- 注意，形如 $g(w) = c$（c 为常数）的方程也可以转化为上述形式，只需将 $g(w) - c$ 视为一个新函数即可。

Robbins-Monro 算法——问题描述

问题描述：假设我们希望求解方程

$$g(w) = 0,$$

其中 $w \in \mathbb{R}$ 是待求变量，$g : \mathbb{R} \to \mathbb{R}$ 是一个函数。

- 许多问题最终可以转化为这一求根问题。例如，设 $J(w)$ 是待最小化的目标函数，则优化问题可转化为

$$g(w) = \nabla_w J(w) = 0$$

- 注意，形如 $g(w) = c$（c 为常数）的方程也可以转化为上述形式，只需将 $g(w) - c$ 视为一个新函数即可。

Robbins-Monro 算法——问题描述

如何计算 $g(w) = 0$ 的根?

- 基于模型：若 g 的表达式已知，有许多数值算法可以求解此问题。
- 无模型：若函数 g 的表达式未知（例如，函数由人工神经网络表示），该如何处理?

Robbins-Monro 算法——问题描述

如何计算 $g(w) = 0$ 的根?

- 基于模型：若 g 的表达式已知，有许多数值算法可以求解此问题。
- 无模型：若函数 g 的表达式未知（例如，函数由人工神经网络表示），该如何处理?

Robbins-Monro 算法——问题描述

如何计算 $g(w) = 0$ 的根?

- 基于模型：若 g 的表达式已知，有许多数值算法可以求解此问题。
- 无模型：若函数 g 的表达式未知（例如，函数由人工神经网络表示），该如何处理?

Robbins-Monro 算法——算法本身

能够求解该问题的 Robbins-Monro（RM）算法如下：

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k), \qquad k = 1, 2, 3, \ldots$$

其中

- w_k 是第 k 次对根的估计
- $\tilde{g}(w_k, \eta_k) = g(w_k) + \eta_k$ 是第 k 次含噪观测
  - 为何引入噪声？例如，考虑对 X 的随机采样 x。
- a_k 是一个正系数。

Robbins-Monro 算法——算法本身

该算法依赖数据而非模型:

- 输入序列: $\{w_k\}$
- 输出序列（含噪）: $\{\tilde{g}(w_k, \eta_k)\}$

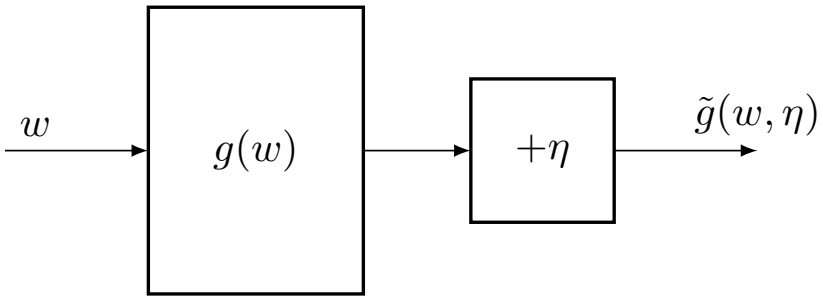

核心理念: 没有模型，我们需要数据！

- 函数 $g(w)$ 被视为一个黑盒。
- 这里的"模型"指的是函数的表达式。

Robbins-Monro 算法——算法本身

该算法依赖数据而非模型：

- 输入序列：$\{w_k\}$
- 输出序列（含噪）：$\{\tilde{g}(w_k, \eta_k)\}$

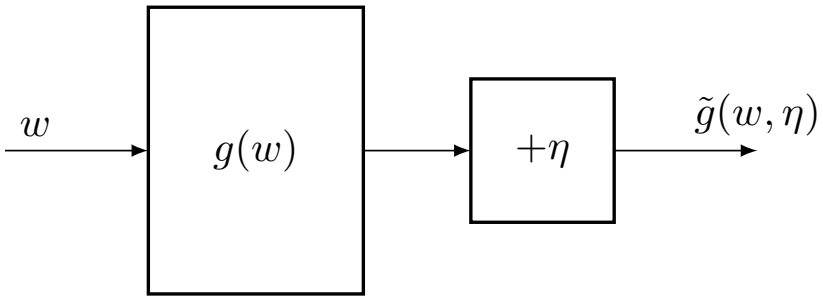

核心理念：没有模型，我们需要数据！

- 函数 $g(w)$ 被视为一个黑盒。
- 这里的"模型"指的是函数的表达式。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20 \Longrightarrow g(w_1) = 10$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20 \Longrightarrow g(w_1) = 10$$

$$w_2 = w_1 - a_1 g(w_1) = 20 - 0.5 * 10 = 15$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20 \Longrightarrow g(w_1) = 10$$

$$w_2 = w_1 - a_1 g(w_1) = 20 - 0.5 * 10 = 15 \Longrightarrow g(w_2) = 5$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20 \Longrightarrow g(w_1) = 10$$

$$w_2 = w_1 - a_1 g(w_1) = 20 - 0.5 * 10 = 15 \Longrightarrow g(w_2) = 5$$

$$w_3 = w_2 - a_2 g(w_2) = 15 - 0.5 * 5 = 12.5$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$w_1 = 20 \Longrightarrow g(w_1) = 10$$

$$w_2 = w_1 - a_1 g(w_1) = 20 - 0.5 * 10 = 15 \Longrightarrow g(w_2) = 5$$

$$w_3 = w_2 - a_2 g(w_2) = 15 - 0.5 * 5 = 12.5 \Longrightarrow g(w_3) = 2.5$$

Robbins-Monro 算法——示例演示

简单示例：用RM算法手动求解 $g(w) = w - 10$。

设：$w_1 = 20$，$a_k \equiv 0.5$，$\eta_k = 0$（即无观测误差）

$$
\begin{aligned}
&w_1 = 20 \Longrightarrow g(w_1) = 10 \\
&w_2 = w_1 - a_1 g(w_1) = 20 - 0.5 * 10 = 15 \Longrightarrow g(w_2) = 5 \\
&w_3 = w_2 - a_2 g(w_2) = 15 - 0.5 * 5 = 12.5 \Longrightarrow g(w_3) = 2.5 \\
&\vdots \\
&w_k \to 10
\end{aligned}
$$

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

Robbins-Monro 算法——收敛性

为什么RM算法能找到 $g(w) = 0$ 的根?

- 首先给出一个直观示例。
- 然后给出严格的收敛性分析。

Robbins-Monro 算法——收敛性

直观示例:

- $g(w) = \tanh(w - 1)$
- $g(w) = 0$ 的真实根为 $w^* = 1$。
- 参数设置：$w_1 = 3$，$a_k = 1/k$，$\eta_k \equiv 0$（为简便起见，不含噪声）

此情形下RM算法为

$$w_{k+1} = w_k - a_k g(w_k)$$

因为当 $\eta_k = 0$ 时，$\tilde{g}(w_k, \eta_k) = g(w_k)$。

Robbins-Monro 算法——收敛性

直观示例:

- $g(w) = \tanh(w-1)$
- $g(w) = 0$ 的真实根为 $w^* = 1$。
- 参数设置：$w_1 = 3$，$a_k = 1/k$，$\eta_k \equiv 0$（为简便起见，不含噪声）

此情形下RM算法为

$$w_{k+1} = w_k - a_k g(w_k)$$

因为当 $\eta_k = 0$ 时，$\tilde{g}(w_k, \eta_k) = g(w_k)$。

Robbins-Monro 算法——收敛性

仿真结果：w_k 收敛到真实根 $w^* = 1$。

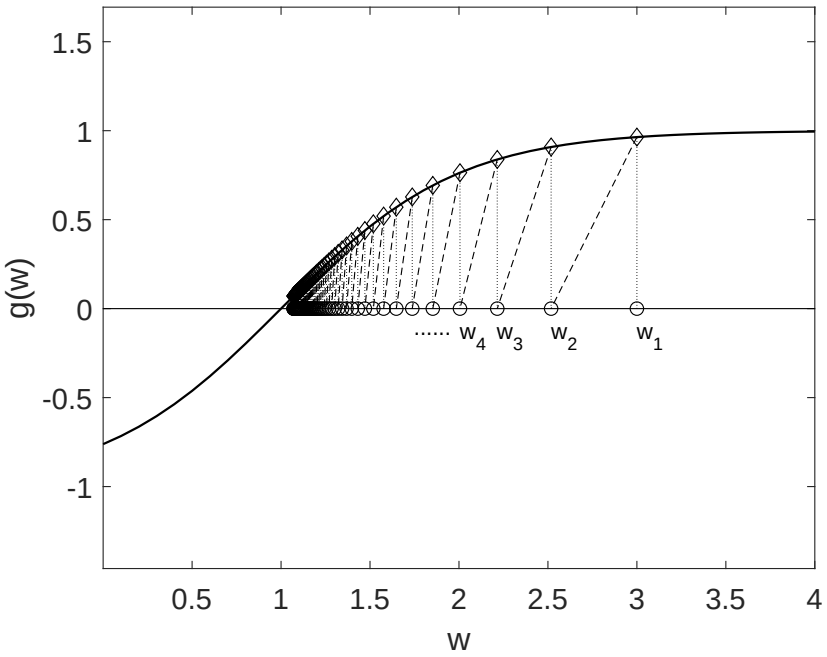

直觉：w_{k+1} 比 w_k 更接近 w^*。

- 当$w_k > w^*$时，$g(w_k) > 0$，则$w_{k+1} = w_k - a_k g(w_k) < w_k$，故 w_{k+1} 比 w_k 更接近 w^*。
- 当$w_k < w^*$时，$g(w_k) < 0$，则$w_{k+1} = w_k - a_k g(w_k) > w_k$，故 w_{k+1} 比 w_k 更接近 w^*。

Robbins-Monro 算法——收敛性

仿真结果：w_k 收敛到真实根 $w^* = 1$。

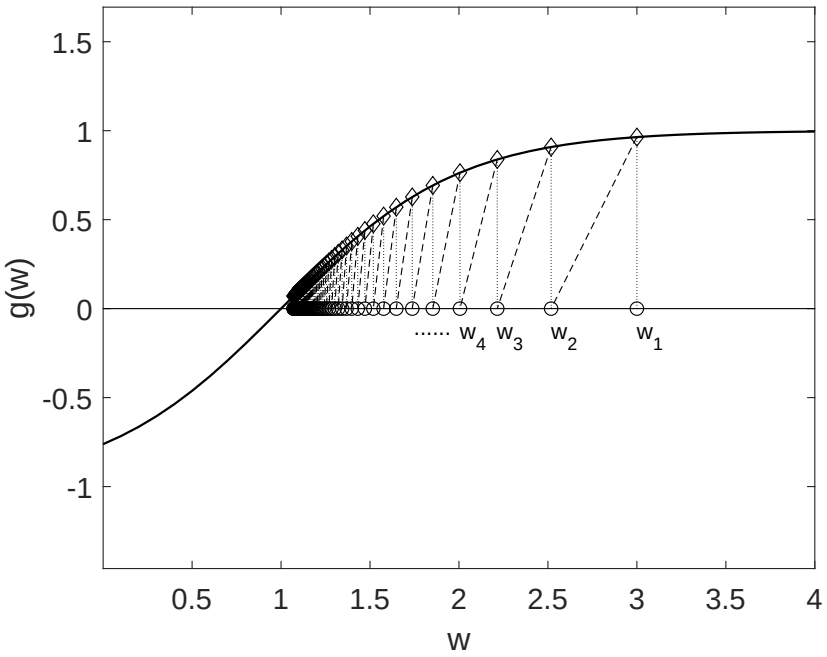

直觉：w_{k+1} 比 w_k 更接近 w^*。

- 当$w_k > w^*$时，$g(w_k) > 0$，则$w_{k+1} = w_k - a_k g(w_k) < w_k$，故 w_{k+1} 比 w_k 更接近 w^*。
- 当$w_k < w^*$时，$g(w_k) < 0$，则$w_{k+1} = w_k - a_k g(w_k) > w_k$，故 w_{k+1} 比 w_k 更接近 w^*。

Robbins-Monro 算法——收敛性

仿真结果：w_k 收敛到真实根 $w^* = 1$。

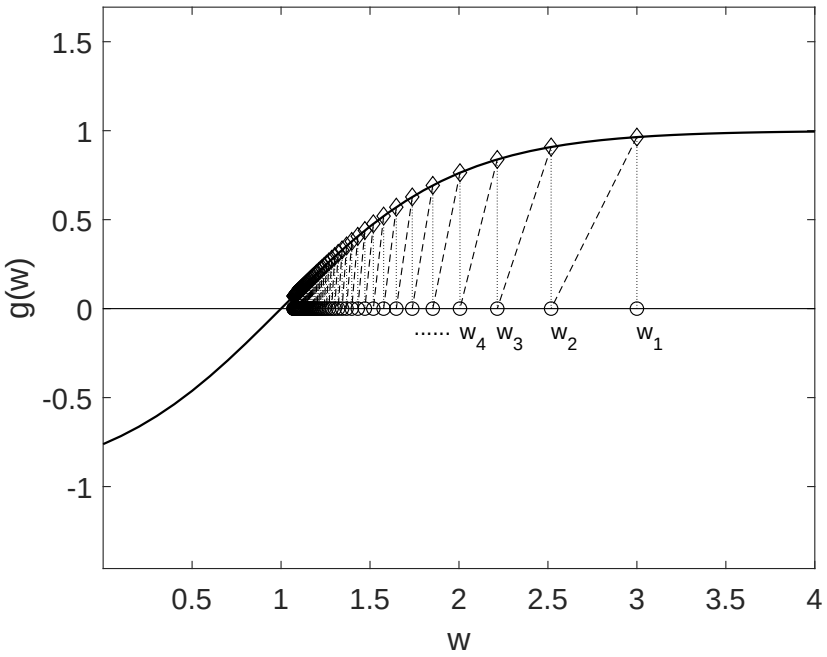

直觉：w_{k+1} 比 w_k 更接近 w^*。

- 当$w_k > w^*$时，$g(w_k) > 0$，则$w_{k+1} = w_k - a_k g(w_k) < w_k$，故 w_{k+1} 比 w_k 更接近 w^*。
- 当$w_k < w^*$时，$g(w_k) < 0$，则$w_{k+1} = w_k - a_k g(w_k) > w_k$，故 w_{k+1} 比 w_k 更接近 w^*。

Robbins-Monro 算法——收敛性

仿真结果：w_k 收敛到真实根 $w^* = 1$。

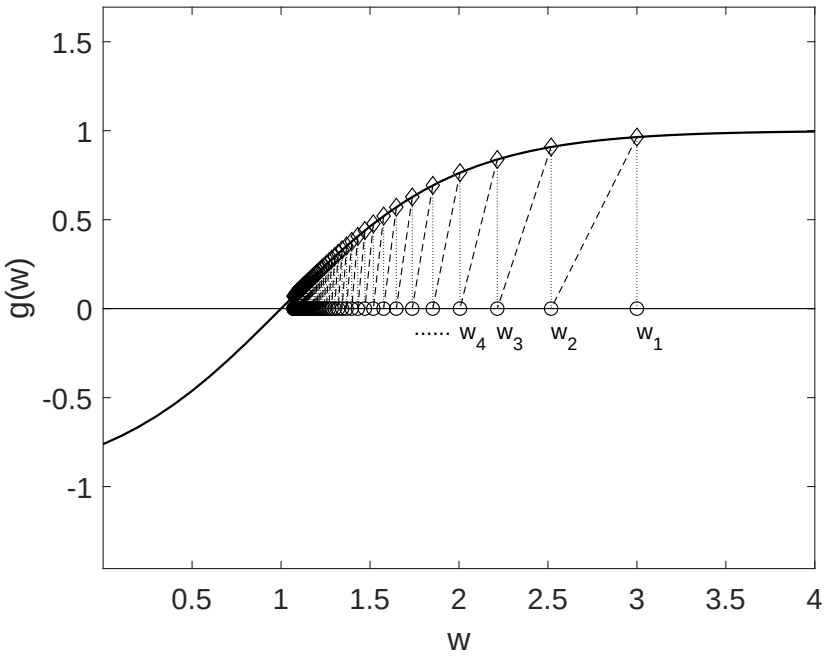

直觉：w_{k+1} 比 w_k 更接近 w^*。

- 当$w_k > w^*$时，$g(w_k) > 0$，则$w_{k+1} = w_k - a_k g(w_k) < w_k$，故 w_{k+1} 比 w_k 更接近 w^*。
- 当$w_k < w^*$时，$g(w_k) < 0$，则$w_{k+1} = w_k - a_k g(w_k) > w_k$，故 w_{k+1} 比 w_k 更接近 w^*。

Robbins-Monro 算法——收敛性

上述分析较为直观，但不够严格。下面给出严格的收敛性结论。

Theorem (Robbins-Monro 定理)

在 *Robbins-Monro* 算法中，若

1) 对所有 w，$0 < c_1 \leq \nabla_w g(w) \leq c_2$；

2) $\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$；

3) $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$；

其中 $\mathcal{H}_k = \{w_k, w_{k-1}, \ldots\}$，则 w_k 以概率*1*（*w.p.1*）收敛到满足 $g(w^*) = 0$ 的根 w^*。

Robbins-Monro 算法——收敛性

对三个条件的解释:

- **条件一**: 对所有 w, $0 < c_1 \leq \nabla_w g(w) \leq c_2$
  - g 应当单调递增, 这保证了 $g(w) = 0$ 的根存在且唯一。
  - 梯度有上界。
  - 该条件并不苛刻。考虑 $g(w) = \nabla_w J(w) = 0$ 的情形, 该条件要求 $J(w)$ 是凸函数。

- **条件二**: $\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$
  - $\sum_{k=1}^{\infty} a_k^2 < \infty$ 保证当 $k \to \infty$ 时 a_k 收敛到零。
  - $\sum_{k=1}^{\infty} a_k = \infty$ 保证a_k 收敛到零的速度不能太快。

- **条件三**: $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$
  - 一种特殊但常见的情形是, $\{\eta_k\}$ 是满足 $\mathbb{E}[\eta_k] = 0$ 和 $\mathbb{E}[\eta_k^2] < \infty$ 的独立同分布随机序列。观测误差 η_k 不要求服从高斯分布。

Robbins-Monro 算法——收敛性

对三个条件的解释:

- **条件一**：对所有 w，$0 < c_1 \leq \nabla_w g(w) \leq c_2$
  - g 应当单调递增，这保证了 $g(w) = 0$ 的根存在且唯一。
  - 梯度有上界。
  - 该条件并不苛刻。考虑 $g(w) = \nabla_w J(w) = 0$ 的情形，该条件要求 $J(w)$ 是凸函数。

- **条件二**：$\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$
  - $\sum_{k=1}^{\infty} a_k^2 < \infty$ 保证当 $k \to \infty$ 时 a_k 收敛到零。
  - $\sum_{k=1}^{\infty} a_k = \infty$ 保证a_k 收敛到零的速度不能太快。

- **条件三**：$\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$
  - 一种特殊但常见的情形是，$\{\eta_k\}$ 是满足 $\mathbb{E}[\eta_k] = 0$ 和 $\mathbb{E}[\eta_k^2] < \infty$ 的独立同分布随机序列。观测误差 η_k 不要求服从高斯分布。

Robbins-Monro 算法——收敛性

对三个条件的解释:

- **条件一**：对所有 w，$0 < c_1 \leq \nabla_w g(w) \leq c_2$
  - g 应当单调递增，这保证了 $g(w) = 0$ 的根存在且唯一。
  - 梯度有上界。
  - 该条件并不苛刻。考虑 $g(w) = \nabla_w J(w) = 0$ 的情形，该条件要求 $J(w)$ 是凸函数。

- **条件二**：$\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$
  - $\sum_{k=1}^{\infty} a_k^2 < \infty$ 保证当 $k \to \infty$ 时 a_k 收敛到零。
  - $\sum_{k=1}^{\infty} a_k = \infty$ 保证a_k 收敛到零的速度不能太快。

- **条件三**：$\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$
  - 一种特殊但常见的情形是，$\{\eta_k\}$ 是满足 $\mathbb{E}[\eta_k] = 0$ 和 $\mathbb{E}[\eta_k^2] < \infty$ 的独立同分布随机序列。观测误差 η_k 不要求服从高斯分布。

Robbins-Monro 算法——收敛性

对三个条件的解释:

- **条件一**：对所有 w，$0 < c_1 \leq \nabla_w g(w) \leq c_2$
  - g 应当单调递增，这保证了 $g(w) = 0$ 的根存在且唯一。
  - 梯度有上界。
  - 该条件并不苛刻。考虑 $g(w) = \nabla_w J(w) = 0$ 的情形，该条件要求 $J(w)$ 是凸函数。

- **条件二**：$\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$
  - $\sum_{k=1}^{\infty} a_k^2 < \infty$ 保证当 $k \to \infty$ 时 a_k 收敛到零。
  - $\sum_{k=1}^{\infty} a_k = \infty$ 保证a_k 收敛到零的速度不能太快。

- **条件三**：$\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty$
  - 一种特殊但常见的情形是，$\{\eta_k\}$ 是满足 $\mathbb{E}[\eta_k] = 0$ 和 $\mathbb{E}[\eta_k^2] < \infty$ 的独立同分布随机序列。观测误差 η_k 不要求服从高斯分布。

Robbins-Monro 算法——收敛性

更仔细地分析条件二:

$$\sum_{k=1}^{\infty} a_k^2 < \infty \qquad \sum_{k=1}^{\infty} a_k = \infty$$

- 首先，$\sum_{k=1}^{\infty} a_k^2 < \infty$ 表明当 $k \to \infty$ 时 $a_k \to 0$。

为什么该条件重要?

由于

$$w_{k+1} - w_k = -a_k \tilde{g}(w_k, \eta_k),$$

- 若 $a_k \to 0$，则 $a_k \tilde{g}(w_k, \eta_k) \to 0$，从而$w_{k+1} - w_k \to 0$。
- 若 w_k 最终收敛，则需要 $w_{k+1} - w_k \to 0$。
- 若 $w_k \to w^*$，则 $g(w_k) \to 0$，$\tilde{g}(w_k, \eta_k)$ 主要由 η_k 主导。

更仔细地分析条件二:

$$\sum_{k=1}^{\infty} a_k^2 < \infty \qquad \sum_{k=1}^{\infty} a_k = \infty$$

- 首先，$\sum_{k=1}^{\infty} a_k^2 < \infty$ 表明当 $k \to \infty$ 时 $a_k \to 0$。

为什么该条件重要?
由于

$$w_{k+1} - w_k = -a_k \tilde{g}(w_k, \eta_k),$$

- 若 $a_k \to 0$，则 $a_k \tilde{g}(w_k, \eta_k) \to 0$，从而$w_{k+1} - w_k \to 0$。
- 若 w_k 最终收敛，则需要 $w_{k+1} - w_k \to 0$。
- 若 $w_k \to w^*$，则 $g(w_k) \to 0$，$\tilde{g}(w_k, \eta_k)$ 主要由 η_k 主导。

Robbins-Monro 算法——收敛性

更仔细地分析条件二：

$$\sum_{k=1}^{\infty} a_k^2 < \infty \qquad \sum_{k=1}^{\infty} a_k = \infty$$

- 其次，$\sum_{k=1}^{\infty} a_k = \infty$ 表明 a_k 收敛到零的速度不能太快。

为什么该条件重要?

将

$w_2 = w_1 - a_1\tilde{g}(w_1, \eta_1)$，$w_3 = w_2 - a_2\tilde{g}(w_2, \eta_2)$，$\ldots$，$w_{k+1} = w_k - a_k\tilde{g}(w_k, \eta_k)$

求和，得

$$w_1 - w_\infty = \sum_{k=1}^{\infty} a_k\tilde{g}(w_k, \eta_k).$$

设 $w_\infty = w^*$。若 $\sum_{k=1}^{\infty} a_k < \infty$，则 $\sum_{k=1}^{\infty} a_k\tilde{g}(w_k, \eta_k)$ 可能有界。此时，若初始猜测 w_1 距 w^* 任意远，则上述等式可能不成立。

更仔细地分析条件二:

$$\sum_{k=1}^{\infty} a_k^2 < \infty \qquad \sum_{k=1}^{\infty} a_k = \infty$$

- 其次，$\sum_{k=1}^{\infty} a_k = \infty$ 表明 a_k 收敛到零的速度不能太快。

为什么该条件重要?
将
$w_2 = w_1 - a_1\tilde{g}(w_1, \eta_1)$，$w_3 = w_2 - a_2\tilde{g}(w_2, \eta_2)$，$\ldots$，$w_{k+1} = w_k - a_k\tilde{g}(w_k, \eta_k)$
求和，得

$$w_1 - w_\infty = \sum_{k=1}^{\infty} a_k\tilde{g}(w_k, \eta_k).$$

设 $w_\infty = w^*$。若 $\sum_{k=1}^{\infty} a_k < \infty$，则 $\sum_{k=1}^{\infty} a_k\tilde{g}(w_k, \eta_k)$ 可能有界。此时，若初始猜测 w_1 距 w^* 任意远，则上述等式可能不成立。

Robbins-Monro 算法——收敛性

哪些 $\{a_k\}$ 满足两个条件? $\sum_{k=1}^{\infty} a_k^2 < \infty$, $\sum_{k=1}^{\infty} a_k = \infty$

一个典型的序列是

$$a_k = \frac{1}{k}$$

- 它满足$\sum_{k=1}^{\infty} a_k = \infty$，因为

$$\lim_{n\to\infty}\left(\sum_{k=1}^{n}\frac{1}{k} - \ln n\right) = \kappa,$$

  其中 $\kappa \approx 0.577$ 称为欧拉-马歇罗尼常数（也叫欧拉常数）。

- 它满足$\sum_{k=1}^{\infty} a_k^2 < \infty$，因为

$$\sum_{k=1}^{\infty}\frac{1}{k^2} = \frac{\pi^2}{6} < \infty.$$

  $\sum_{k=1}^{\infty} 1/k^2$ 的极限在数论中也有一个专门的名称：巴塞尔问题。

Robbins-Monro 算法——收敛性

哪些 $\{a_k\}$ 满足两个条件? $\sum_{k=1}^{\infty} a_k^2 < \infty$, $\sum_{k=1}^{\infty} a_k = \infty$

一个典型的序列是

$$a_k = \frac{1}{k}$$

- 它满足$\sum_{k=1}^{\infty} a_k = \infty$，因为

$$\lim_{n\to\infty}\left(\sum_{k=1}^{n}\frac{1}{k} - \ln n\right) = \kappa,$$

  其中 $\kappa \approx 0.577$ 称为欧拉-马歇罗尼常数（也叫欧拉常数）。

- 它满足$\sum_{k=1}^{\infty} a_k^2 < \infty$，因为

$$\sum_{k=1}^{\infty}\frac{1}{k^2} = \frac{\pi^2}{6} < \infty.$$

  $\sum_{k=1}^{\infty} 1/k^2$ 的极限在数论中也有一个专门的名称：巴塞尔问题。

Robbins-Monro 算法——收敛性

哪些 $\{a_k\}$ 满足两个条件? $\sum_{k=1}^{\infty} a_k^2 < \infty$, $\sum_{k=1}^{\infty} a_k = \infty$
一个典型的序列是

$$a_k = \frac{1}{k}$$

- 它满足$\sum_{k=1}^{\infty} a_k = \infty$，因为

$$\lim_{n\to\infty}\left(\sum_{k=1}^{n}\frac{1}{k} - \ln n\right) = \kappa,$$

其中 $\kappa \approx 0.577$ 称为欧拉-马歇罗尼常数（也叫欧拉常数）。

- 它满足$\sum_{k=1}^{\infty} a_k^2 < \infty$，因为

$$\sum_{k=1}^{\infty}\frac{1}{k^2} = \frac{\pi^2}{6} < \infty.$$

$\sum_{k=1}^{\infty} 1/k^2$ 的极限在数论中也有一个专门的名称：巴塞尔问题。

Robbins-Monro 算法——收敛性

哪些 $\{a_k\}$ 满足两个条件? $\sum_{k=1}^{\infty} a_k^2 < \infty$, $\sum_{k=1}^{\infty} a_k = \infty$
一个典型的序列是

$$a_k = \frac{1}{k}$$

- 它满足$\sum_{k=1}^{\infty} a_k = \infty$，因为

$$\lim_{n\to\infty}\left(\sum_{k=1}^{n}\frac{1}{k} - \ln n\right) = \kappa,$$

  其中 $\kappa \approx 0.577$ 称为欧拉-马歇罗尼常数（也叫欧拉常数）。

- 它满足$\sum_{k=1}^{\infty} a_k^2 < \infty$，因为

$$\sum_{k=1}^{\infty}\frac{1}{k^2} = \frac{\pi^2}{6} < \infty.$$

  $\sum_{k=1}^{\infty} 1/k^2$ 的极限在数论中也有一个专门的名称：巴塞尔问题。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

Robbins-Monro 算法——应用于均值估计

回顾，

$$w_{k+1} = w_k + \alpha_k(x_k - w_k).$$

是本讲开头介绍的均值估计算法。

- 若 $\alpha_k = 1/k$，则 $w_{k+1} = 1/k \sum_{i=1}^{k} x_i$。
- 若 α_k 不是 $1/k$，其收敛性尚未得到分析。

下面，我们证明该算法是RM算法的特例，从而其收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

回顾，

$$w_{k+1} = w_k + \alpha_k(x_k - w_k).$$

是本讲开头介绍的均值估计算法。

- 若 $\alpha_k = 1/k$，则 $w_{k+1} = 1/k \sum_{i=1}^{k} x_i$。
- 若 α_k 不是 $1/k$，其收敛性尚未得到分析。

下面，我们证明该算法是RM算法的特例，从而其收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

回顾，

$$w_{k+1} = w_k + \alpha_k(x_k - w_k).$$

是本讲开头介绍的均值估计算法。

- 若 $\alpha_k = 1/k$，则 $w_{k+1} = 1/k \sum_{i=1}^{k} x_i$。
- 若 α_k 不是 $1/k$，其收敛性尚未得到分析。

下面，我们证明该算法是RM算法的特例，从而其收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

1) 考虑函数：

$$g(w) \doteq w - \mathbb{E}[X].$$

我们的目标是求解 $g(w) = 0$。若能做到，则可得到 $\mathbb{E}[X]$。

- 均值估计（即求 $\mathbb{E}[X]$）被转化为求根问题（即求解 $g(w) = 0$）。
- **问题**：这里的 $g(w)$ 的表达式是否已知?

2) 我们能得到的观测为

$$\tilde{g}(w, x) \doteq w - x,$$

因为我们只能获得 X 的样本。 注意

$$\begin{aligned}\tilde{g}(w, \eta) = w - x &= w - x + \mathbb{E}[X] - \mathbb{E}[X] \\ &= (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \doteq g(w) + \eta,\end{aligned}$$

3) 求解 $g(w) = 0$ 的RM算法为

$$w_{k+1} = w_k - \alpha_k \tilde{g}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k),$$

这与均值估计算法完全一致。

收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

1) 考虑函数：

$$g(w) \doteq w - \mathbb{E}[X].$$

我们的目标是求解 $g(w) = 0$。若能做到，则可得到 $\mathbb{E}[X]$。

- 均值估计（即求 $\mathbb{E}[X]$）被转化为求根问题（即求解 $g(w) = 0$）。
- **问题**：这里的 $g(w)$ 的表达式是否已知?

2) 我们能得到的观测为

$$\tilde{g}(w, x) \doteq w - x,$$

因为我们只能获得 X 的样本。 注意

$$\begin{aligned}\tilde{g}(w, \eta) = w - x &= w - x + \mathbb{E}[X] - \mathbb{E}[X] \\ &= (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \doteq g(w) + \eta,\end{aligned}$$

3) 求解 $g(w) = 0$ 的RM算法为

$$w_{k+1} = w_k - \alpha_k \tilde{g}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k),$$

这与均值估计算法完全一致。

收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

1) 考虑函数：

$$g(w) \doteq w - \mathbb{E}[X].$$

我们的目标是求解 $g(w) = 0$。若能做到，则可得到 $\mathbb{E}[X]$。

- 均值估计（即求 $\mathbb{E}[X]$）被转化为求根问题（即求解 $g(w) = 0$）。
- **问题**：这里的 $g(w)$ 的表达式是否已知?

2) 我们能得到的观测为

$$\tilde{g}(w, x) \doteq w - x,$$

因为我们只能获得 X 的样本。 注意

$$\begin{aligned}\tilde{g}(w, \eta) = w - x &= w - x + \mathbb{E}[X] - \mathbb{E}[X] \\ &= (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \doteq g(w) + \eta,\end{aligned}$$

3) 求解 $g(w) = 0$ 的RM算法为

$$w_{k+1} = w_k - \alpha_k \tilde{g}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k),$$

这与均值估计算法完全一致。

收敛性自然成立。

Robbins-Monro 算法——应用于均值估计

1) 考虑函数:

$$g(w) \doteq w - \mathbb{E}[X].$$

我们的目标是求解 $g(w) = 0$。若能做到，则可得到 $\mathbb{E}[X]$。

- 均值估计（即求 $\mathbb{E}[X]$）被转化为求根问题（即求解 $g(w) = 0$）。
- **问题**：这里的 $g(w)$ 的表达式是否已知?

2) 我们能得到的观测为

$$\tilde{g}(w, x) \doteq w - x,$$

因为我们只能获得 X 的样本。 注意

$$\begin{aligned}\tilde{g}(w, \eta) = w - x &= w - x + \mathbb{E}[X] - \mathbb{E}[X] \\ &= (w - \mathbb{E}[X]) + (\mathbb{E}[X] - x) \doteq g(w) + \eta,\end{aligned}$$

3) 求解 $g(w) = 0$ 的RM算法为

$$w_{k+1} = w_k - \alpha_k \tilde{g}(w_k, \eta_k) = w_k - \alpha_k (w_k - x_k),$$

这与均值估计算法完全一致。

收敛性自然成立。

Dvoretzky 收敛定理（选读）

Theorem (Dvoretzky 定理)

考虑如下随机过程

$$w_{k+1} = (1 - \alpha_k)w_k + \beta_k \eta_k,$$

其中 $\{\alpha_k\}_{k=1}^{\infty}, \{\beta_k\}_{k=1}^{\infty}, \{\eta_k\}_{k=1}^{\infty}$ 为随机序列，且对所有 k 有 $\alpha_k \geq 0, \beta_k \geq 0$。若以下条件满足，则 w_k 以概率*1*收敛到零：

1) $\sum_{k=1}^{\infty} \alpha_k = \infty$，$\sum_{k=1}^{\infty} \alpha_k^2 < \infty$；$\sum_{k=1}^{\infty} \beta_k^2 < \infty$（以概率*1*一致成立）；

2) $\mathbb{E}[\eta_k | \mathcal{H}_k] = 0$ 且 $\mathbb{E}[\eta_k^2 | \mathcal{H}_k] \leq C$（以概率*1*成立）；

其中 $\mathcal{H}_k = \{w_k, w_{k-1}, \ldots, \eta_{k-1}, \ldots, \alpha_{k-1}, \ldots, \beta_{k-1}, \ldots\}$。

- 这是比RM定理更一般的结论。
  - 它可以用来证明RM定理。
  - 它可以用来分析均值估计问题。
  - 其推广形式可用于分析Q学习和TD学习算法。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

随机梯度下降

接下来，我们介绍随机梯度下降（SGD）算法:

- SGD在机器学习和强化学习领域被广泛使用。
  - SGD是RM算法的一种特例。
  - 均值估计算法是SGD的一种特例。

问题设置：假设我们的目标是求解如下优化问题:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)]$$

- w 是待优化的参数。
- X 是随机变量，期望关于 X 取得。
- w 和 X 可以是标量或向量，函数 $f(\cdot)$ 是标量。

随机梯度下降

接下来，我们介绍随机梯度下降（SGD）算法：

- SGD在机器学习和强化学习领域被广泛使用。
  - SGD是RM算法的一种特例。
  - 均值估计算法是SGD的一种特例。

问题设置：假设我们的目标是求解如下优化问题：

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)]$$

- w 是待优化的参数。
- X 是随机变量，期望关于 X 取得。
- w 和 X 可以是标量或向量，函数 $f(\cdot)$ 是标量。

随机梯度下降

方法一：梯度下降（GD）

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

缺点：计算期望需要知道 X 的分布。

方法二：批量梯度下降（BGD）

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

因此

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

缺点：每次迭代对每个 w_k 都需要大量样本。

随机梯度下降

方法一：梯度下降（GD）

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

缺点：计算期望需要知道 X 的分布。

方法二：批量梯度下降（BGD）

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

因此

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

缺点：每次迭代对每个 w_k 都需要大量样本。

随机梯度下降

方法一：梯度下降（GD）

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

缺点：计算期望需要知道 X 的分布。

方法二：批量梯度下降（BGD）

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

因此

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

缺点：每次迭代对每个 w_k 都需要大量样本。

随机梯度下降

方法一：梯度下降（GD）

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

缺点：计算期望需要知道 X 的分布。

方法二：批量梯度下降（BGD）

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

因此

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

缺点：每次迭代对每个 w_k 都需要大量样本。

随机梯度下降

方法一：梯度下降（GD）

$$w_{k+1} = w_k - \alpha_k \nabla_w \mathbb{E}[f(w_k, X)] = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

缺点：计算期望需要知道 X 的分布。

方法二：批量梯度下降（BGD）

$$\mathbb{E}[\nabla_w f(w_k, X)] \approx \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

因此

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

缺点：每次迭代对每个 w_k 都需要大量样本。

方法三：随机梯度下降（SGD）

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k),$$

- 与梯度下降法相比：
  - 用随机梯度 $\nabla_w f(w_k, x_k)$替代真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$。
- 与批量梯度下降法相比：
  - 令 $n = 1$。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

随机梯度下降——示例与应用

我们考虑如下示例:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

练习:

- 练习一: 证明最优解为 $w^* = \mathbb{E}[X]$。
- 练习二: 写出求解该问题的GD算法。
- 练习三: 写出求解该问题的SGD算法。

随机梯度下降——示例与应用

我们考虑如下示例:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

练习:

- 练习一: 证明最优解为 $w^* = \mathbb{E}[X]$。
- 练习二: 写出求解该问题的GD算法。
- 练习三: 写出求解该问题的SGD算法。

随机梯度下降——示例与应用

我们考虑如下示例:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

练习:

- 练习一: 证明最优解为 $w^* = \mathbb{E}[X]$。
- 练习二: 写出求解该问题的GD算法。
- 练习三: 写出求解该问题的SGD算法。

随机梯度下降——示例与应用

我们考虑如下示例：

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

- **练习一**：证明最优解为 $w^* = \mathbb{E}[X]$。
- **练习一答案**：最优解 w^* 必须满足

$$\nabla_w J(w) = 0$$

即

$$\nabla_w \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right] = \mathbb{E}\left[\nabla_w \frac{1}{2}\|w - X\|^2\right] = \mathbb{E}\left[w - X\right] = 0$$

因此，我们将均值估计问题（即求 $\mathbb{E}[X]$）转化为优化问题（即优化 $J(w)$）。

随机梯度下降——示例与应用

我们考虑如下示例:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

- **练习二**：写出求解该问题的GD算法。
- **练习二答案**：求解上述问题的GD算法为

$$\begin{aligned} w_{k+1} &= w_k - \alpha_k \nabla_w J(w_k) \\ &= w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)] \\ &= w_k - \alpha_k \mathbb{E}[w_k - X]. \end{aligned}$$

随机梯度下降——示例与应用

我们考虑如下示例:

$$\min_{w} \quad J(w) = \mathbb{E}[f(w, X)] = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right],$$

其中

$$f(w, X) = \|w - X\|^2/2 \qquad \nabla_w f(w, X) = w - X$$

- **练习三**：写出求解该问题的SGD算法。
- **练习三答案**： 求解上述问题的SGD算法为

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k) = w_k - \alpha_k (w_k - x_k)$$

  - 这与之前介绍的均值估计算法相同。
  - 因此，该均值估计算法是SGD的特例。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

随机梯度下降——收敛性

SGD的核心思想：

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

$$\Downarrow$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

其中真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$ 被随机梯度 $\nabla_w f(w_k, X)$ 替代。

问题： 由于

$$\nabla_w f(w_k, x_k) \neq \mathbb{E}[\nabla_w f(w, X)]$$

SGD 是否满足当 $k \to \infty$ 时 $w_k \to w^*$?

观察： 随机梯度是真实梯度的含噪测量：

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w, X)] + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}$$

其中 η 为噪声。

随机梯度下降——收敛性

SGD的核心思想：

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

$$\Downarrow$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

其中真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$ 被随机梯度 $\nabla_w f(w_k, X)$ 替代。

问题： 由于

$$\nabla_w f(w_k, x_k) \neq \mathbb{E}[\nabla_w f(w, X)]$$

SGD 是否满足当 $k \to \infty$ 时 $w_k \to w^*$?

观察： 随机梯度是真实梯度的含噪测量：

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w, X)] + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}$$

其中 η 为噪声。

随机梯度下降——收敛性

SGD的核心思想：

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

$$\Downarrow$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

其中真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$ 被随机梯度 $\nabla_w f(w_k, X)$ 替代。

问题：由于

$$\nabla_w f(w_k, x_k) \neq \mathbb{E}[\nabla_w f(w, X)]$$

SGD 是否满足当 $k \to \infty$ 时 $w_k \to w^*$?

观察：随机梯度是真实梯度的含噪测量：

$$\nabla_w f(w_k, x_k) = \mathbb{E}[\nabla_w f(w, X)] + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}$$

其中 η 为噪声。

随机梯度下降——收敛性

下面证明SGD是RM算法的特例，从而收敛性自然成立。

SGD的目标是最小化

$$J(w) = \mathbb{E}[f(w, X)]$$

该问题可转化为求根问题:

$$\nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0$$

令

$$g(w) = \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)]$$

则SGD的目标是求 $g(w) = 0$ 的根。

随机梯度下降——收敛性

下面证明SGD是RM算法的特例，从而收敛性自然成立。

SGD的目标是最小化

$$J(w) = \mathbb{E}[f(w, X)]$$

该问题可转化为求根问题:

$$\nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0$$

令

$$g(w) = \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)]$$

则SGD的目标是求 $g(w) = 0$ 的根。

随机梯度下降——收敛性

下面证明SGD是RM算法的特例，从而收敛性自然成立。

SGD的目标是最小化

$$J(w) = \mathbb{E}[f(w, X)]$$

该问题可转化为求根问题:

$$\nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0$$

令

$$g(w) = \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)]$$

则SGD的目标是求 $g(w) = 0$ 的根。

随机梯度下降——收敛性

下面证明SGD是RM算法的特例，从而收敛性自然成立。

SGD的目标是最小化

$$J(w) = \mathbb{E}[f(w, X)]$$

该问题可转化为求根问题:

$$\nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0$$

令

$$g(w) = \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)]$$

则SGD的目标是求 $g(w) = 0$ 的根。

随机梯度下降——收敛性

我们能测量的量为

$$\begin{aligned}\tilde{g}(w,\eta) &= \nabla_w f(w,x) \\ &= \underbrace{\mathbb{E}[\nabla_w f(w,X)]}_{g(w)} + \underbrace{\nabla_w f(w,x) - \mathbb{E}[\nabla_w f(w,X)]}_{\eta}.\end{aligned}$$

则求解 $g(w)=0$ 的RM算法为

$$w_{k+1} = w_k - a_k \tilde{g}(w_k,\eta_k) = w_k - a_k \nabla_w f(w_k,x_k).$$

- 这正是SGD算法。
- 因此，SGD是RM算法的特例。

随机梯度下降——收敛性

我们能测量的量为

$$\begin{aligned}\tilde{g}(w,\eta) &= \nabla_w f(w,x) \\ &= \underbrace{\mathbb{E}[\nabla_w f(w,X)]}_{g(w)} + \underbrace{\nabla_w f(w,x) - \mathbb{E}[\nabla_w f(w,X)]}_{\eta}.\end{aligned}$$

则求解 $g(w)=0$ 的RM算法为

$$w_{k+1} = w_k - a_k \tilde{g}(w_k,\eta_k) = w_k - a_k \nabla_w f(w_k,x_k).$$

- 这正是SGD算法。
- 因此，SGD是RM算法的特例。

随机梯度下降——收敛性

由于SGD是RM算法的特例，其收敛性自然成立。

Theorem (SGD收敛定理)

在*SGD*算法中，若

1) $0 < c_1 \leq \nabla_w^2 f(w, X) \leq c_2$;

2) $\sum_{k=1}^{\infty} a_k = \infty$ 且 $\sum_{k=1}^{\infty} a_k^2 < \infty$;

3) $\{x_k\}_{k=1}^{\infty}$ 是独立同分布的;

则 w_k 以概率*1*收敛到 $\nabla_w \mathbb{E}[f(w, X)] = 0$ 的根。

证明见教材。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

随机梯度下降——收敛规律

SGD的核心思想:

$$w_{k+1} = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)]$$

$$\Downarrow$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

其中真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$ 被随机梯度 $\nabla_w f(w_k, X)$ 替代。

问题: 由于随机梯度是随机的，SGD的收敛是否缓慢或具有随机性?

随机梯度下降——收敛规律

示例： $X \in \mathbb{R}^2$ 表示平面上的随机位置，其分布在以原点为中心、边长为20的正方形区域内均匀分布。真实均值为 $\mathbb{E}[X] = 0$。均值估计基于100个独立同分布样本 $\{x_i\}_{i=1}^{100}$。

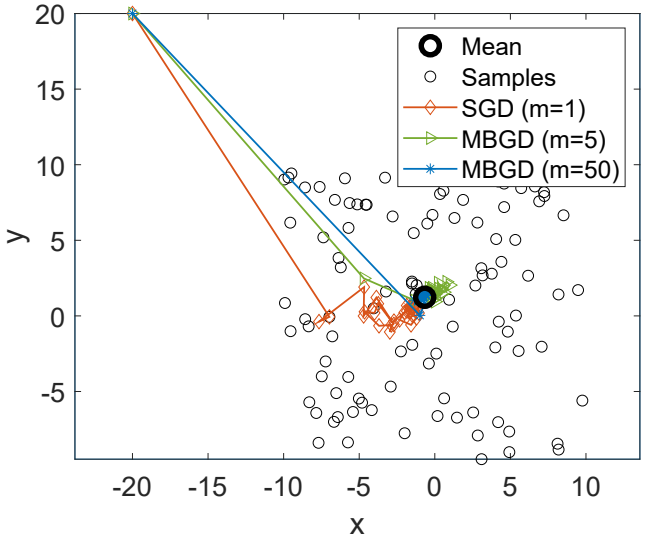

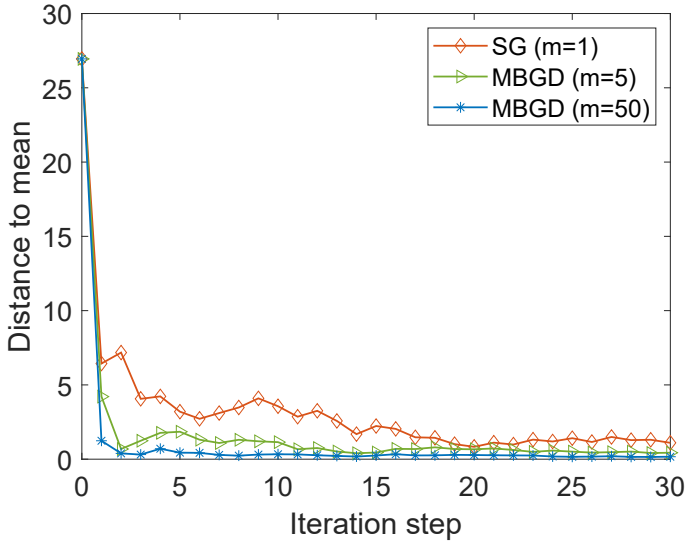

观察：

- 当估计值（如初始猜测）距真实值较远时，SGD估计能快速接近真实值的邻域。
- 当估计值接近真实值时，呈现一定随机性，但仍逐渐趋近真实值。

随机梯度下降——收敛规律

示例： $X \in \mathbb{R}^2$ 表示平面上的随机位置，其分布在以原点为中心、边长为20的正方形区域内均匀分布。真实均值为 $\mathbb{E}[X] = 0$。均值估计基于100个独立同分布样本 $\{x_i\}_{i=1}^{100}$。

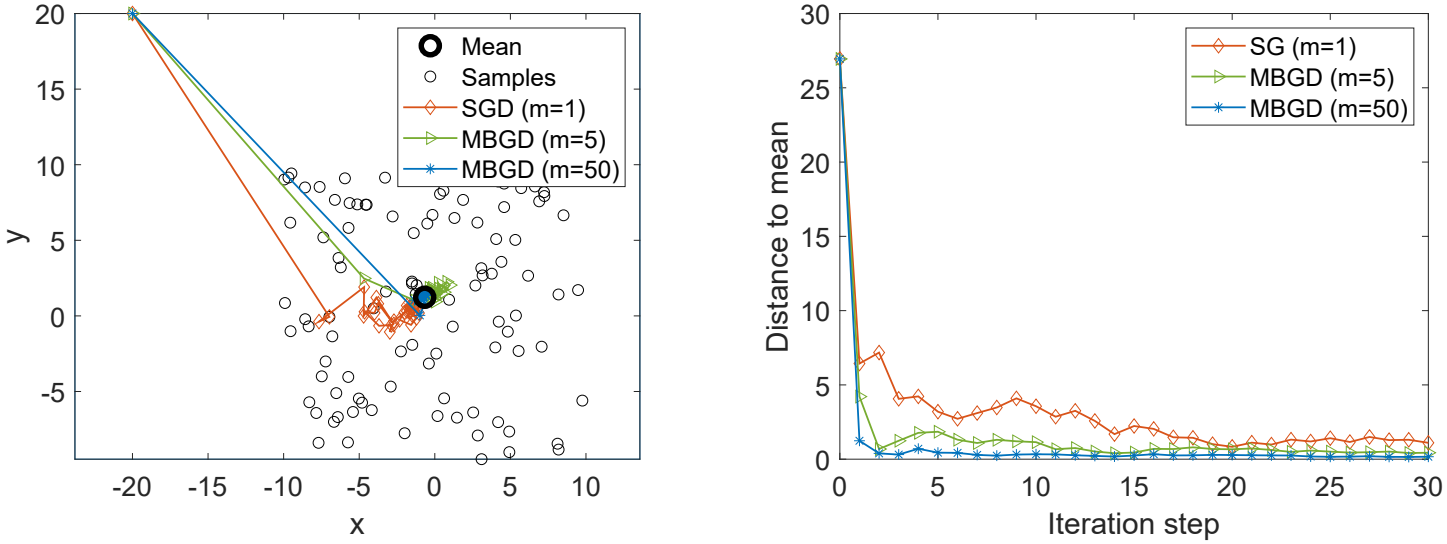

观察：

- 当估计值（如初始猜测）距真实值较远时，SGD估计能快速接近真实值的邻域。
- 当估计值接近真实值时，呈现一定随机性，但仍逐渐趋近真实值。

随机梯度下降——收敛规律

问题：为什么会出现这种规律?

答：我们通过考虑随机梯度与批量梯度之间的相对误差来回答这个问题:

$$\delta_k \doteq \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}.$$

可以证明

$$\delta_k \leq \frac{\left|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]\right|}{c|w_k - w^*|}.$$

证明见下一张幻灯片（选读）。

随机梯度下降——收敛规律

问题：为什么会出现这种规律?

答：我们通过考虑随机梯度与批量梯度之间的相对误差来回答这个问题:

$$\delta_k \doteq \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}.$$

可以证明

$$\delta_k \leq \frac{\left|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]\right|}{c|w_k - w^*|}.$$

证明见下一张幻灯片（选读）。

随机梯度下降——收敛规律（选读）

由于 $\mathbb{E}[\nabla_w f(w^*, X)] = 0$，我们有

$$\delta_k = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)] - \mathbb{E}[\nabla_w f(w^*, X)]|} = \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]|}$$

其中最后一个等号利用了均值定理，$\tilde{w}_k \in [w_k, w^*]$。

假设 f 是严格凸的，使得对所有 w, X，

$$\nabla_w^2 f \geq c > 0$$

其中 c 是一个正的下界。

则 δ_k 的分母为

$$\begin{aligned}\left|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]\right| &= \left|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)](w_k - w^*)\right| \\ &= \left|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)]\right|\left|(w_k - w^*)\right| \geq c|w_k - w^*|.\end{aligned}$$

将上述不等式代入 δ_k 得

$$\delta_k \leq \frac{\left|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]\right|}{c|w_k - w^*|}.$$

随机梯度下降——收敛规律

注意

$$\delta_k \leq \frac{|\overbrace{\nabla_w f(w_k, x_k)}^{\text{随机梯度}} - \overbrace{\mathbb{E}[\nabla_w f(w_k, X)]}^{\text{真实梯度}}|}{\underbrace{c|w_k - w^*|}_{\text{与最优解的距离}}}.$$

上式揭示了SGD一个有趣的收敛规律。

- 上界与 $|w_k - w^*|$ 成反比。
  - 当 $|w_k - w^*|$ 较大时，相对误差 δ_k 较小，SGD的行为类似GD。
  - 当 $|w_k - w^*|$ 较小时，相对误差 δ_k 可能较大（上界可能不紧），SGD在 w^* 附近表现出更多随机性。

随机梯度下降——收敛规律

注意

$$\delta_k \leq \frac{\left|\overbrace{\nabla_w f(w_k, x_k)}^{\text{随机梯度}} - \overbrace{\mathbb{E}[\nabla_w f(w_k, X)]}^{\text{真实梯度}}\right|}{\underbrace{c|w_k - w^*|}_{\text{与最优解的距离}}}.$$

上式揭示了SGD一个有趣的收敛规律。

- 上界与 $|w_k - w^*|$ 成反比。
  - 当 $|w_k - w^*|$ 较大时，相对误差 δ_k 较小，SGD的行为类似GD。
  - 当 $|w_k - w^*|$ 较小时，相对误差 δ_k 可能较大（上界可能不紧），SGD在 w^* 附近表现出更多随机性。

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

BGD、MBGD与SGD

假设我们希望在给定 X 的一组随机样本 $\{x_i\}_{i=1}^n$ 的条件下，最小化 $J(w) = \mathbb{E}[f(w, X)]$。

求解该问题的BGD、SGD、MBGD算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m} \sum_{j \in I_k} \nabla_w f(w_k, x_j), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k). \qquad \text{(SGD)}$$

- **BGD算法中**，每次迭代使用所有样本。当 n 较大时，$(1/n)\sum_{i=1}^n \nabla_w f(w_k, x_i)$ 接近真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$。
- **MBGD算法中**，I_k 是 $\{1, \ldots, n\}$ 的大小为 $|I_k| = m$ 的子集，由 m 次独立同分布采样得到。
- **SGD算法中**，x_k 在时刻 k 从 $\{x_i\}_{i=1}^n$ 中随机采样。

BGD、MBGD与SGD

假设我们希望在给定 X 的一组随机样本 $\{x_i\}_{i=1}^n$ 的条件下，最小化 $J(w) = \mathbb{E}[f(w, X)]$。

求解该问题的BGD、SGD、MBGD算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m} \sum_{j \in I_k} \nabla_w f(w_k, x_j), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k). \qquad \text{(SGD)}$$

- **BGD算法中**，每次迭代使用所有样本。当 n 较大时，$(1/n)\sum_{i=1}^n \nabla_w f(w_k, x_i)$ 接近真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$。
- **MBGD算法中**，I_k 是 $\{1, \ldots, n\}$ 的大小为 $|I_k| = m$ 的子集，由 m 次独立同分布采样得到。
- **SGD算法中**，x_k 在时刻 k 从 $\{x_i\}_{i=1}^n$ 中随机采样。

BGD、MBGD与SGD

假设我们希望在给定 X 的一组随机样本 $\{x_i\}_{i=1}^n$ 的条件下，最小化 $J(w) = \mathbb{E}[f(w, X)]$。

求解该问题的BGD、SGD、MBGD算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m} \sum_{j \in I_k} \nabla_w f(w_k, x_j), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k). \qquad \text{(SGD)}$$

- **BGD算法中**，每次迭代使用所有样本。当 n 较大时，$(1/n)\sum_{i=1}^n \nabla_w f(w_k, x_i)$ 接近真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$。
- **MBGD算法中**，I_k 是 $\{1, \ldots, n\}$ 的大小为 $|I_k| = m$ 的子集，由 m 次独立同分布采样得到。
- **SGD算法中**，x_k 在时刻 k 从 $\{x_i\}_{i=1}^n$ 中随机采样。

BGD、MBGD与SGD

假设我们希望在给定 X 的一组随机样本 $\{x_i\}_{i=1}^n$ 的条件下，最小化 $J(w) = \mathbb{E}[f(w, X)]$。

求解该问题的BGD、SGD、MBGD算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^{n} \nabla_w f(w_k, x_i), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m} \sum_{j \in I_k} \nabla_w f(w_k, x_j), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k). \qquad \text{(SGD)}$$

- **BGD算法中**，每次迭代使用所有样本。当 n 较大时，$(1/n)\sum_{i=1}^n \nabla_w f(w_k, x_i)$ 接近真实梯度 $\mathbb{E}[\nabla_w f(w_k, X)]$。
- **MBGD算法中**，I_k 是 $\{1, \ldots, n\}$ 的大小为 $|I_k| = m$ 的子集，由 m 次独立同分布采样得到。
- **SGD算法中**，x_k 在时刻 k 从 $\{x_i\}_{i=1}^n$ 中随机采样。

BGD、MBGD与SGD

将MBGD与BGD和SGD比较：

- 与SGD相比，MBGD的随机性更小，因为它使用了更多样本，而非像SGD那样只用一个。
- 与BGD相比，MBGD不需要在每次迭代中使用所有样本，更加灵活高效。
- 若 $m = 1$，MBGD退化为SGD。
- 若 $m = n$，MBGD并不严格等同于BGD，因为MBGD使用随机抽取的 n 个样本，而BGD使用全部 n 个数据。特别地，MBGD可能重复使用 $\{x_i\}_{i=1}^n$ 中的某个值，而BGD每个数据只用一次。

BGD、MBGD与SGD

将MBGD与BGD和SGD比较：

- 与SGD相比，MBGD的随机性更小，因为它使用了更多样本，而非像SGD那样只用一个。
- 与BGD相比，MBGD不需要在每次迭代中使用所有样本，更加灵活高效。

- 若 $m = 1$，MBGD退化为SGD。
- 若 $m = n$，MBGD并不严格等同于BGD，因为MBGD使用随机抽取的 n 个样本，而BGD使用全部 n 个数据。特别地，MBGD可能重复使用 $\{x_i\}_{i=1}^n$ 中的某个值，而BGD每个数据只用一次。

BGD、MBGD与SGD

将MBGD与BGD和SGD比较：

- 与SGD相比，MBGD的随机性更小，因为它使用了更多样本，而非像SGD那样只用一个。
- 与BGD相比，MBGD不需要在每次迭代中使用所有样本，更加灵活高效。

- 若 $m = 1$，MBGD退化为SGD。
- 若 $m = n$，MBGD并不严格等同于BGD，因为MBGD使用随机抽取的 n 个样本，而BGD使用全部 n 个数据。特别地，MBGD可能重复使用 $\{x_i\}_{i=1}^n$ 中的某个值，而BGD每个数据只用一次。

BGD、MBGD与SGD

将MBGD与BGD和SGD比较:

- 与SGD相比，MBGD的随机性更小，因为它使用了更多样本，而非像SGD那样只用一个。
- 与BGD相比，MBGD不需要在每次迭代中使用所有样本，更加灵活高效。

- 若 $m = 1$，MBGD退化为SGD。
- 若 $m = n$，MBGD并不严格等同于BGD，因为MBGD使用随机抽取的 n 个样本，而BGD使用全部 n 个数据。特别地，MBGD可能重复使用 $\{x_i\}_{i=1}^n$ 中的某个值，而BGD每个数据只用一次。

BGD、MBGD与SGD——示例演示

给定 $\{x_i\}_{i=1}^n$ 中的若干数，我们的目标是计算均值 $\bar{x} = \sum_{i=1}^n x_i/n$。该问题等价于以下优化问题：

$$\min_w \quad J(w) = \frac{1}{2n}\sum_{i=1}^n \|w - x_i\|^2$$

求解该问题的三种算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n}\sum_{i=1}^n (w_k - x_i) = w_k - \alpha_k(w_k - \bar{x}), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m}\sum_{j\in I_k} (w_k - x_j) = w_k - \alpha_k\left(w_k - \bar{x}_k^{(m)}\right), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k(w_k - x_k), \qquad \text{(SGD)}$$

其中 $\bar{x}_k^{(m)} = \sum_{j\in I_k} x_j/m$。

BGD、MBGD与SGD——示例演示

给定 $\{x_i\}_{i=1}^n$ 中的若干数，我们的目标是计算均值 $\bar{x} = \sum_{i=1}^n x_i/n$。该问题等价于以下优化问题：

$$\min_w \quad J(w) = \frac{1}{2n}\sum_{i=1}^n \|w - x_i\|^2$$

求解该问题的三种算法分别为：

$$w_{k+1} = w_k - \alpha_k \frac{1}{n}\sum_{i=1}^n (w_k - x_i) = w_k - \alpha_k(w_k - \bar{x}), \qquad \text{(BGD)}$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{m}\sum_{j\in I_k} (w_k - x_j) = w_k - \alpha_k\left(w_k - \bar{x}_k^{(m)}\right), \qquad \text{(MBGD)}$$

$$w_{k+1} = w_k - \alpha_k(w_k - x_k), \qquad \text{(SGD)}$$

其中 $\bar{x}_k^{(m)} = \sum_{j\in I_k} x_j/m$。

BGD、MBGD与SGD

令 $\alpha_k = 1/k$。给定100个数据点，使用不同的小批量大小会导致不同的收敛速度。

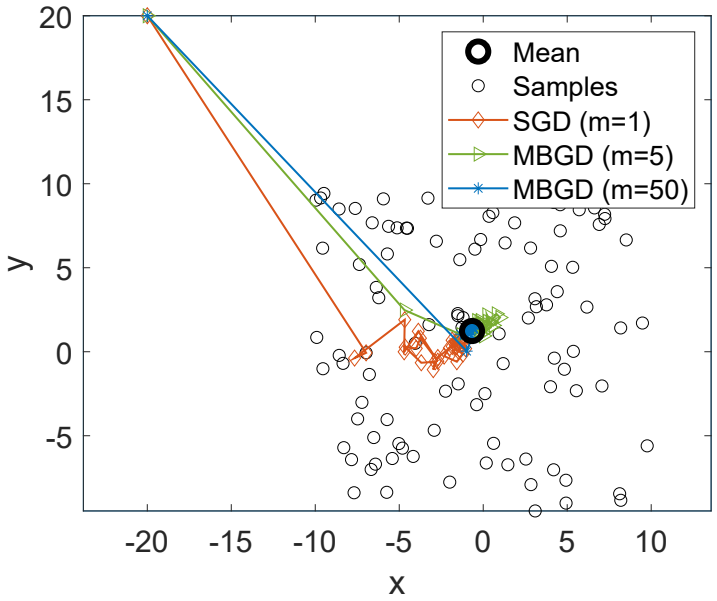

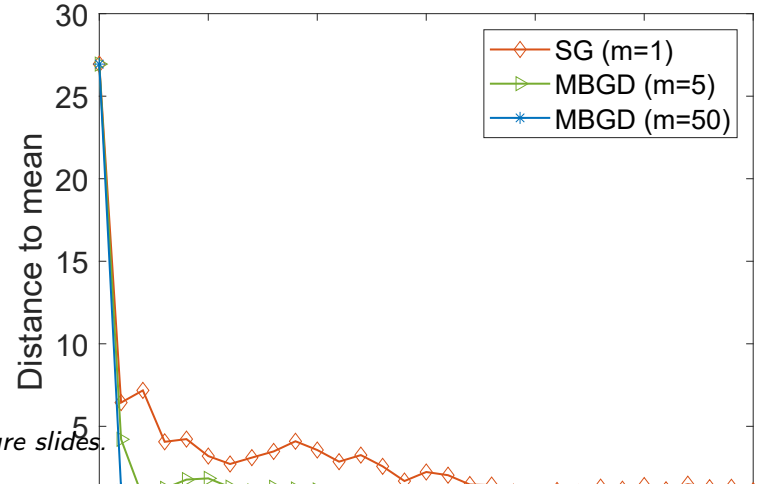

大纲

1 动机示例

2 Robbins-Monro 算法
- 算法描述
- 示例演示
- 收敛性分析
- 应用于均值估计

3 随机梯度下降
- 算法描述
- 示例与应用
- 收敛性分析
- 收敛规律
- BGD、MBGD与SGD

4 总结

总结

- 均值估计：利用 $\{x_k\}$ 计算 $\mathbb{E}[X]$

$$w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

- RM算法：利用 $\{\tilde{g}(w_k, \eta_k)\}$ 求解 $g(w) = 0$

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k)$$

- SGD算法：利用 $\{\nabla_w f(w_k, x_k)\}$ 最小化 $J(w) = \mathbb{E}[f(w, X)]$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k),$$

这些结论非常有用：

- 在下一章中，我们将看到时序差分学习算法可以被视为随机逼近算法，从而具有类似的表达形式。
- 它们是重要的优化技术，可应用于许多其他领域。