第九讲：策略梯度方法

April 11, 2026

大纲

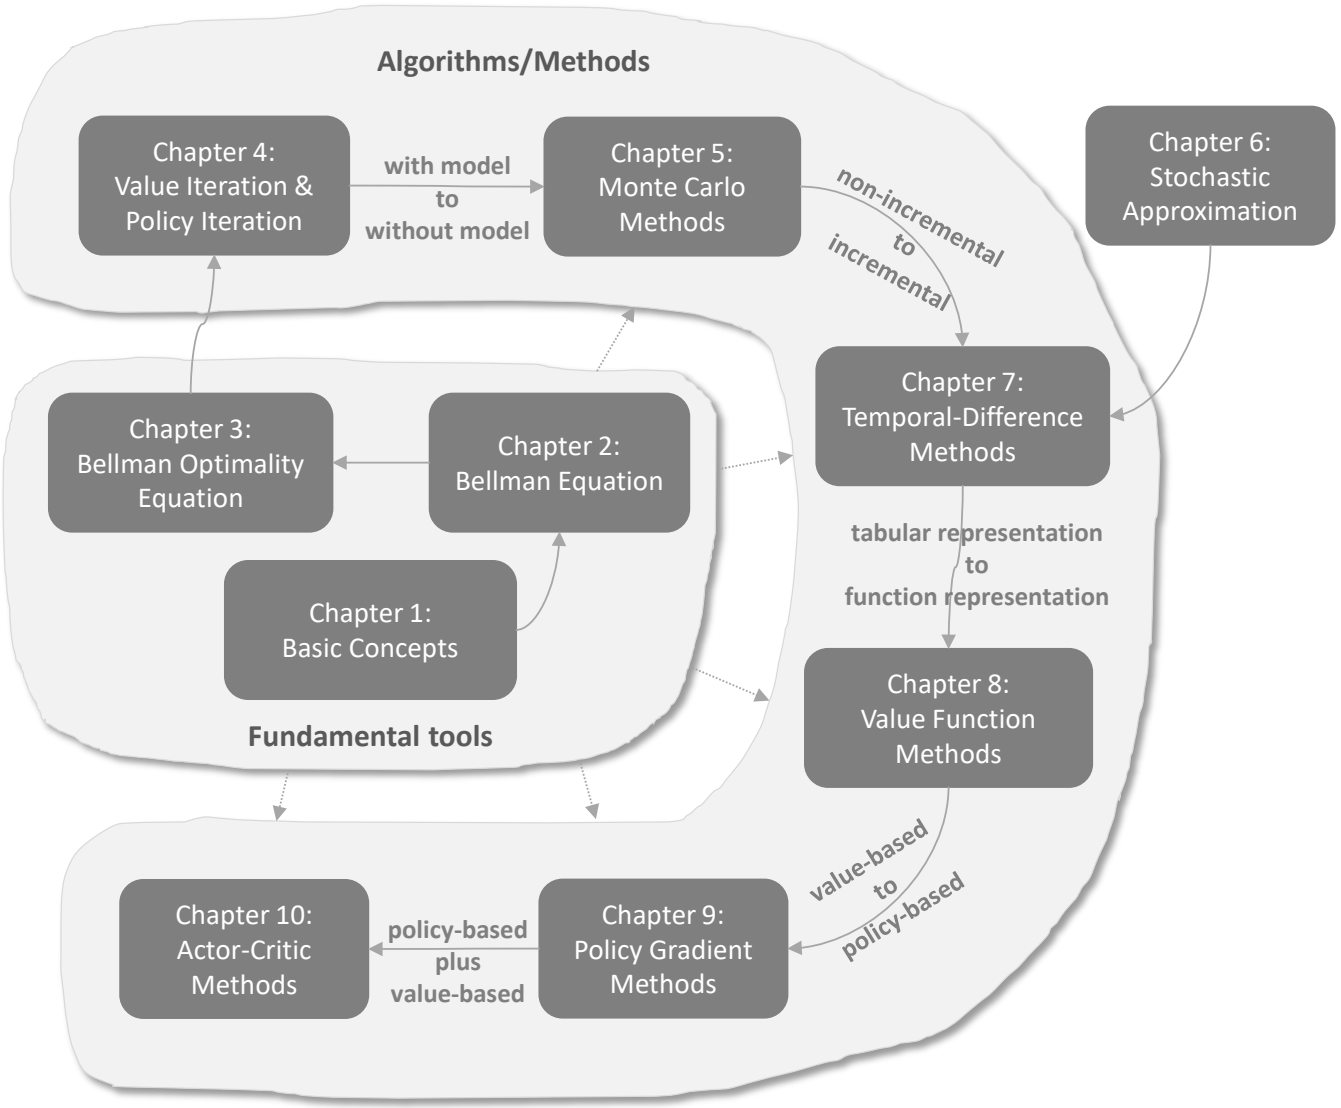
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

介绍

本讲将从

- 基于值的方法转向基于策略的方法
- 值函数方法转向策略函数方法（又称策略梯度方法）

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

策略梯度的基本思想

此前，策略以表格形式表示:

- 所有状态的动作概率存储在表格$\pi(a|s)$ 中，表中每个条目由状态和动作索引。

	a_1	a_2	a_3	a_4	a_5
s_1	$\pi(a_1\|s_1)$	$\pi(a_2\|s_1)$	$\pi(a_3\|s_1)$	$\pi(a_4\|s_1)$	$\pi(a_5\|s_1)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
s_9	$\pi(a_1\|s_9)$	$\pi(a_2\|s_9)$	$\pi(a_3\|s_9)$	$\pi(a_4\|s_9)$	$\pi(a_5\|s_9)$

策略梯度的基本思想

现在，策略可以用参数化函数表示：

$$\pi(a|s,\theta)$$

其中$\theta \in \mathbb{R}^m$ 为参数向量。

- 该函数例如可以是神经网络，输入为s，输出为选取各动作的概率，参数为θ。
- **优点：** 当状态空间很大时，表格表示在存储和泛化方面效率低下。
- 函数表示有时也写作$\pi(a,s,\theta)$、$\pi_\theta(a|s)$ 或$\pi_\theta(a,s)$。

策略梯度的基本思想

表格表示与函数表示的区别:

- 第一，如何定义最优策略?
  - 在表格情形中，策略π 是最优的，当且仅当它能最大化每个状态值。
  - 在函数情形中，策略π 是最优的，当且仅当它能最大化某个标量指标。

表格表示与函数表示的区别:

- 第二，如何获取某动作的概率?
  - 在表格情形中，在状态s 选取动作a 的概率可以直接通过查表获得。
  - 在函数情形中，需要根据函数结构和参数计算 $\pi(a|s,\theta)$ 的值。

策略梯度的基本思想

表格表示与函数表示的区别：

- 第三，如何更新策略?
  - 在表格情形中，策略π 可以通过直接修改表中的条目来更新。
  - 在函数情形中，策略π 无法以此方式更新，只能通过改变参数θ来更新。

策略梯度的基本思想

策略梯度的基本思想很简单:

- 第一，定义最优策略的指标（目标函数）： $J(\theta)$，用于定义最优策略。
- 第二，使用基于梯度的优化算法搜索最优策略:

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta J(\theta_t)$$

思想虽简单，但在回答以下问题时会遇到困难:

- 应使用哪些合适的指标?
- 如何计算指标的梯度?

这些问题将在本讲中详细解答。

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

指标一：平均值

第一个指标是平均状态值，简称平均值：

$$\bar{v}_\pi = \sum_{s \in \mathcal{S}} d(s) v_\pi(s)$$

- $\bar{v}_\pi$ 是状态值的加权平均。
- $d(s) \geq 0$ 是状态s 的权重。

由于$\sum_{s \in \mathcal{S}} d(s) = 1$，可以将$d(s)$ 理解为一个概率分布。从而该指标可以写为：

$$\bar{v}_\pi = \mathbb{E}_{S \sim d}[v_\pi(S)]$$

指标一：平均值

如何选择分布d? 有两种情形。

情形一：d 与策略π 无关。

- 该情形相对简单，因为指标的梯度更易计算：$\nabla_\theta \bar{v}_\pi = d^T \nabla_\theta v_\pi$
- 在此情形中，特别记d 为d_0，$\bar{v}_\pi$ 为$\bar{v}_\pi^0$。

如何选择d_0?

- 一种简单方式是将所有状态视为同等重要，设$d_0(s) = 1/|\mathcal{S}|$。
- 另一种重要情形是只关注特定状态 s_0。例如，某些任务中每个回合总是从同一状态s_0 出发，此时只关心从s_0 出发的长期回报。在此情形下：

$$d_0(s_0) = 1, \quad d_0(s \neq s_0) = 0$$

即$\bar{v}_\pi = v_\pi(s_0)$

指标一：平均值

如何选择分布d? 有两种情形。

情形二：d **依赖于**策略π。

- 一种常见方式是将d 选为$d_\pi(s)$，即策略π 下的稳态分布。稳态分布的详细内容见上一讲和教材。
- 选择d_π 的含义如下：
  - d_π 反映了给定策略π 下马尔可夫决策过程的长期行为。
  - 若某状态在长期运行中被频繁访问，则它更重要，应赋予更高权重。
  - 若某状态几乎不被访问，则赋予较低权重。

指标一：平均值

一个重要的等价表达式：

文献中常见如下指标：

$$J(\theta) = \lim_{n\to\infty} \mathbb{E}\left[\sum_{t=0}^{n} \gamma^t R_{t+1}\right] = \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t R_{t+1}\right].$$

问：它与上面介绍的指标有什么关系?

答：两者相同。 这是因为：

$$\begin{aligned} J(\theta) = \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t R_{t+1}\right] &= \sum_{s\in\mathcal{S}} d(s)\mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} | S_0 = s\right] \\ &= \sum_{s\in\mathcal{S}} d(s) v_\pi(s) \\ &= \bar{v}_\pi \end{aligned}$$

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

指标二：平均奖励

第二个指标是平均单步奖励，简称平均奖励：

$$\bar{r}_\pi \doteq \sum_{s\in\mathcal{S}} d_\pi(s) r_\pi(s) = \mathbb{E}[r_\pi(S)],$$

其中$S \sim d_\pi$，

$$r_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) r(s,a)$$

$$r(s,a) = \mathbb{E}[R|s,a] = \sum_r r p(r|s,a)$$

注：

- $\bar{r}_\pi$ 是即时奖励的加权平均。
- $r_\pi(s)$ 是从状态s 能获得的平均即时奖励。
- d_π 是稳态分布。

指标二：平均奖励

一个重要的等价表达式：

- 假设智能体遵循给定策略并生成一条轨迹，奖励序列为$(R_1, R_2, \dots)$。
- 沿该轨迹的平均单步奖励为：

$$\lim_{n\to\infty} \frac{1}{n}\mathbb{E}\Big[R_1 + R_2 + \cdots + R_n | S_0 = s_0\Big]$$
$$= \lim_{n\to\infty} \frac{1}{n}\mathbb{E}\left[\sum_{t=0}^{n-1} R_{t+1} | S_0 = s_0\right]$$

其中s_0 是轨迹的起始状态。

定义最优策略的指标——注

一个重要的事实是:

$$\lim_{n\to\infty}\frac{1}{n}\mathbb{E}\left[\sum_{t=0}^{n-1}R_{t+1}|S_0=s_0\right]=\lim_{n\to\infty}\frac{1}{n}\mathbb{E}\left[\sum_{t=0}^{n-1}R_{t+1}\right]$$
$$=\sum_{s}d_\pi(s)r_\pi(s)$$
$$=\bar{r}_\pi$$

注:

- 重点：起始状态s_0 不影响结果。
- 该等式的推导较为复杂，详见教材。

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

两个指标的总结

指标	表达式一	表达式二	表达式三
$\bar{v}_\pi$	$\sum_{s\in\mathcal{S}} d(s)v_\pi(s)$	$\mathbb{E}_{S\sim d}[v_\pi(S)]$	$\lim_{n\to\infty}\mathbb{E}\big[\sum_{t=0}^{n}\gamma^t R_{t+1}\big]$
$\bar{r}_\pi$	$\sum_{s\in\mathcal{S}} d_\pi(s)r_\pi(s)$	$\mathbb{E}_{S\sim d_\pi}[r_\pi(S)]$	$\lim_{n\to\infty}\frac{1}{n}\mathbb{E}\big[\sum_{t=0}^{n-1} R_{t+1}\big]$

Table: $\bar{v}_\pi$ 与$\bar{r}_\pi$ 不同但等价的表达式汇总。

两个指标的总结

关于指标的注一：

- 所有这些指标都是π 的函数。
- 由于π 由θ 参数化，这些指标也是θ 的函数。
- 换言之，不同的θ 值会产生不同的指标值。

因此，可以搜索最优的θ 值以最大化这些指标，这正是策略梯度方法的基本思想。

两个指标的总结

关于指标的注二：

- 一个复杂之处在于，这些指标可以在$\gamma \in (0,1)$ 的折扣情形或$\gamma = 1$ 的非折扣情形下定义。
- 非折扣情形较为复杂。
- 本书目前只考虑折扣情形。关于非折扣情形的详细内容，见教材。

两个指标的总结

关于指标的注三：

- $\bar{r}_\pi$ 与$\bar{v}_\pi$ 的关系是什么?
- 两个指标是等价的（并非相等）。具体地，在$\gamma < 1$ 的折扣情形下，有：

$$\bar{r}_\pi = (1-\gamma)\bar{v}_\pi.$$

因此，两者可以同时最大化。证明见教材。

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

指标的梯度

给定指标后，接下来需要：

- 推导其梯度
- 然后，应用基于梯度的方法对指标进行优化。

梯度计算是策略梯度方法中最复杂的部分之一！这是因为：

- 首先，需要区分不同指标$\bar{v}_\pi$、$\bar{r}_\pi$、$\bar{v}_\pi^0$；
- 其次，需要区分折扣情形和非折扣情形。

指标的梯度

以下直接给出梯度的表达式（不作证明）：

$$\nabla_\theta J(\theta) = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta) q_\pi(s,a)$$

上式是多种情形的统一表达：

- $J(\theta)$ 可以是$\bar{v}_\pi$、$\bar{r}_\pi$ 或$\bar{v}_\pi^0$。
- "=" 可以表示严格相等、近似或正比。
- η 是状态的分布或权重。

该表达式的推导**非常复杂**。
此处不展开细节，感兴趣的读者可参见教材。
对大多数读者而言，了解该表达式即可。

指标的梯度

梯度的紧凑重要表达式:

$$\nabla_\theta J(\theta) = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta) q_\pi(s,a)$$
$$= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right]$$

第一，为什么该表达式有用?

- 因为可以用样本近似梯度:

$$\nabla_\theta J \approx \nabla_\theta \ln \pi(a|s,\theta) q_\pi(s,a)$$

其中s, a 为样本。这正是随机梯度下降的思想。

指标的梯度

梯度的紧凑重要表达式:

$$\nabla_\theta J(\theta) = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta) q_\pi(s,a)$$
$$= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right]$$

第二，如何证明上式?

证明：考虑函数$\ln \pi$，其中ln 为自然对数。容易得到:

$$\nabla_\theta \ln \pi(a|s,\theta) = \frac{\nabla_\theta \pi(a|s,\theta)}{\pi(a|s,\theta)}$$

从而:

$$\nabla_\theta \pi(a|s,\theta) = \pi(a|s,\theta) \nabla_\theta \ln \pi(a|s,\theta).$$

指标的梯度

梯度的紧凑重要表达式:

$$\nabla_\theta J(\theta) = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta) q_\pi(s,a)$$
$$= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right]$$

证明（续）：则有:

$$\begin{aligned}
\nabla_\theta J &= \sum_s \eta(s) \sum_a \nabla_\theta \pi(a|s,\theta) q_\pi(s,a) \\
&= \sum_s \eta(s) \sum_a \pi(a|s,\theta) \nabla_\theta \ln \pi(a|s,\theta) q_\pi(s,a) \\
&= \mathbb{E}_{S\sim\eta}\left[\sum_a \pi(a|S,\theta) \nabla_\theta \ln \pi(a|S,\theta) q_\pi(S,a)\right] \\
&= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right]
\end{aligned}$$

指标的梯度

注： $\ln \pi(a|s,\theta)$ 要求对任意s,a,θ 满足$\pi(a|s,\theta) > 0$。

- 这可以通过使用Softmax 函数来实现，它能将向量中的元素从$(-\infty,+\infty)$ 归一化到$(0,1)$。
  - 例如，对任意向量$x = [x_1,\ldots,x_n]^T$：

$$z_i = \frac{e^{x_i}}{\sum_{j=1}^{n} e^{x_j}}$$

  其中$z_i \in (0,1)$ 且$\sum_{i=1}^{n} z_i = 1$。
- 具体地，策略函数的形式为：

$$\pi(a|s,\theta) = \frac{e^{h(s,a,\theta)}}{\sum_{a'\in\mathcal{A}} e^{h(s,a',\theta)}}$$

  其中$h(s,a,\theta)$ 是另一个待学习的函数。

指标的梯度

注（续）：

- 基于Softmax 函数的形式可以由神经网络实现：输入为s，参数为θ，网络有$|\mathcal{A}|$ 个输出，每个输出对应一个动作a 的$\pi(a|s,\theta)$，输出层的激活函数为Softmax。
- 由于对所有a 均有$\pi(a|s,\theta) > 0$，参数化策略是随机的，因此具有探索性。
  - 也存在确定性策略梯度（DPG）方法，将在下一讲中学习。

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

梯度上升算法

现在，我们介绍第一个策略梯度算法以寻找最优策略！

1) 最大化$J(\theta)$ 的梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\Big]\end{aligned}$$

2) 由于真实梯度未知，可以用随机梯度替代：

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_\pi(s_t,a_t)$$

3) 此外，由于q_π 未知，可用其估计值替代：

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)$$

梯度上升算法

- 若$q_\pi(s_t, a_t)$ 由蒙特卡洛估计得到，该算法有一个专有名称：REINFORCE。
- REINFORCE 是最早且最简单的策略梯度算法之一。
- 许多其他策略梯度算法（如演员-评论家方法）可以通过扩展REINFORCE得到（下一讲）。

伪代码：蒙特卡洛策略梯度（REINFORCE）

初始化： 初始参数θ；$\gamma \in (0,1)$；$\alpha > 0$。
目标： 学习最优策略以最大化$J(\theta)$。

对每个回合，执行：
　按策略$\pi(\theta)$ 生成回合$\{s_0, a_0, r_1, \ldots, s_{T-1}, a_{T-1}, r_T\}$。
　对$t = 0, 1, \ldots, T-1$：
　　值更新：$q_t(s_t, a_t) = \sum_{k=t+1}^{T} \gamma^{k-t-1} r_k$
　　策略更新：$\theta \leftarrow \theta + \alpha \nabla_\theta \ln \pi(a_t|s_t, \theta) q_t(s_t, a_t)$

注一：如何进行采样?

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\Big] \longrightarrow \nabla_\theta \ln \pi(a|s,\theta_t) q_\pi(s,a)$$

- 如何对S 采样?
  - $S \sim \eta$，其中分布η 反映策略π 下的长期行为。
  - 实践中通常不必特别关注。
- 如何对A 采样?
  - $A \sim \pi(A|S,\theta)$。因此，a_t 应在s_t 处按$\pi(\theta_t)$ 采样。
  - 所以，策略梯度方法是同策略的。

注二：如何理解该算法?

由于：

$$\nabla_\theta \ln \pi(a_t|s_t,\theta_t) = \frac{\nabla_\theta \pi(a_t|s_t,\theta_t)}{\pi(a_t|s_t,\theta_t)}$$

算法可以改写为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t) \\ &= \theta_t + \alpha \underbrace{\left(\frac{q_t(s_t,a_t)}{\pi(a_t|s_t,\theta_t)}\right)}_{\beta_t} \nabla_\theta \pi(a_t|s_t,\theta_t).\end{aligned}$$

因此，得到该算法的重要表达式：

$$\theta_{t+1} = \theta_t + \alpha \beta_t \nabla_\theta \pi(a_t|s_t,\theta_t)$$

梯度上升算法

对于:

$$\theta_{t+1} = \theta_t + \alpha\beta_t \nabla_\theta \pi(a_t|s_t, \theta_t)$$

的解释如下。假设α 足够小。

解释:

- 若$\beta_t > 0$，选择(s_t, a_t) 的概率增大:

$$\pi(a_t|s_t, \theta_{t+1}) > \pi(a_t|s_t, \theta_t)$$

- 若$\beta_t < 0$，选择(s_t, a_t) 的概率减小:

$$\pi(a_t|s_t, \theta_{t+1}) < \pi(a_t|s_t, \theta_t)$$

数学: 当$\theta_{t+1} - \theta_t$ 足够小时，由微分的定义可得:

$$\begin{aligned}
\pi(a_t|s_t, \theta_{t+1}) &\approx \pi(a_t|s_t, \theta_t) + (\nabla_\theta \pi(a_t|s_t, \theta_t))^T (\theta_{t+1} - \theta_t) \\
&= \pi(a_t|s_t, \theta_t) + \alpha\beta_t (\nabla_\theta \pi(a_t|s_t, \theta_t))^T (\nabla_\theta \pi(a_t|s_t, \theta_t)) \\
&= \pi(a_t|s_t, \theta_t) + \alpha\beta_t \|\nabla_\theta \pi(a_t|s_t, \theta_t)\|^2
\end{aligned}$$

梯度上升算法

$$\theta_{t+1} = \theta_t + \alpha \underbrace{\left(\frac{q_t(s_t, a_t)}{\pi(a_t|s_t, \theta_t)} \right)}_{\beta_t} \nabla_\theta \pi(a_t|s_t, \theta_t)$$

解释（续）：β_t 能平衡探索与利用。

原因如下：

- 第一，β_t 与$q_t(s_t, a_t)$ 成正比。

$$q_t(s_t, a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t, \theta_{t+1}) \text{ 越大}$$

  因此，算法倾向于利用值较大的动作。

- 第二，β_t 与$\pi(a_t|s_t, \theta_t)$ 成反比（当$q_t(s_t, a_t) > 0$ 时）。

$$\pi(a_t|s_t, \theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t, \theta_{t+1}) \text{ 越大}$$

  因此，算法倾向于探索概率较低的动作。

大纲

1 策略梯度的基本思想

2 定义最优策略的指标
- 指标一：平均值
- 指标二：平均奖励
- 两个指标的总结

3 指标的梯度

4 梯度上升算法

5 总结

总结

本讲内容：

- 最优性指标
- 指标的梯度
- 梯度上升算法
- 特殊情形：REINFORCE

下一讲：演员-评论家方法