第十讲：演员-评论家方法

April 11, 2026

大纲

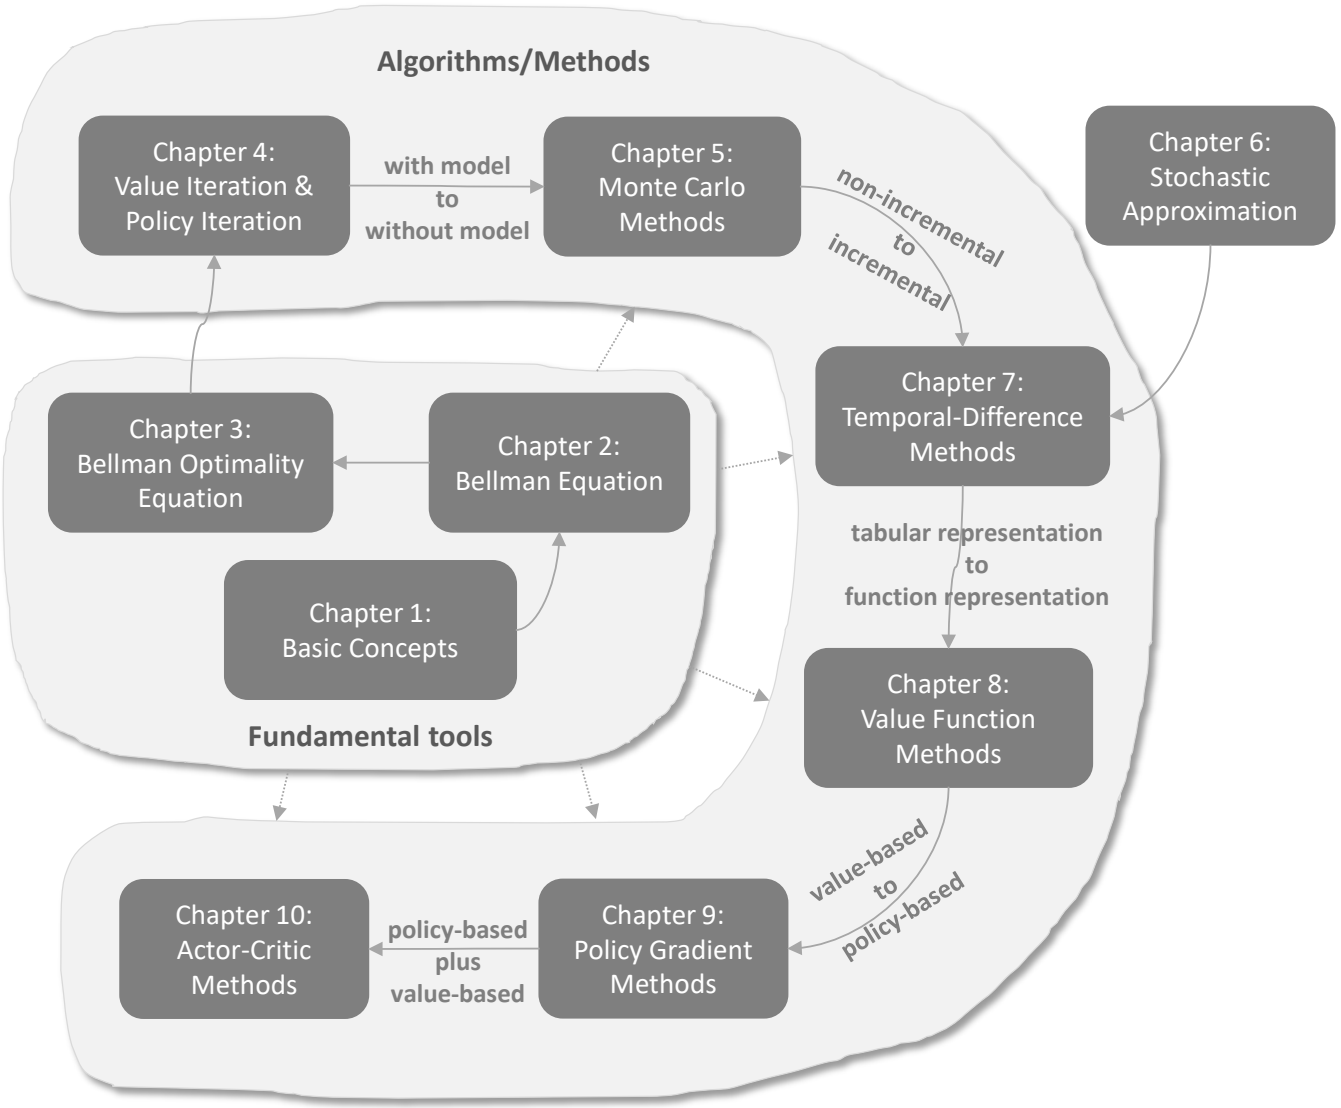
Algorithms/Methods
Chapter 4: Value Iteration & Policy Iteration
with model to without model
Chapter 5: Monte Carlo Methods
non-incremental to incremental
Chapter 6: Stochastic Approximation
Chapter 7: Temporal-Difference Methods
tabular representation to function representation
Chapter 8: Value Function Methods
value-based to policy-based
Chapter 9: Policy Gradient Methods
policy-based plus value-based
Chapter 10: Actor-Critic Methods
Chapter 3: Bellman Optimality Equation
Chapter 2: Bellman Equation
Chapter 1: Basic Concepts
Fundamental tools

介绍

演员-评论家方法仍属于策略梯度方法。

- 它们强调将策略梯度与基于值的方法相结合的结构。

"演员"与"评论家"分别指什么？

- 此处，"演员"指策略更新。之所以称为演员，是因为策略将被用于执行动作。
- 此处，"评论家"指策略评估或值估计。之所以称为评论家，是因为它通过评估策略来对其进行评判。

介绍

演员-评论家方法仍属于策略梯度方法。

- 它们强调将策略梯度与基于值的方法相结合的结构。

"演员"与"评论家"分别指什么？

- 此处，"演员"指策略更新。之所以称为演员，是因为策略将被用于执行动作。
- 此处，"评论家"指策略评估或值估计。之所以称为评论家，是因为它通过评估策略来对其进行评判。

介绍

演员-评论家方法仍属于策略梯度方法。

- 它们强调将策略梯度与基于值的方法相结合的结构。

"演员"与"评论家"分别指什么?

- 此处，"演员"指策略更新。之所以称为演员，是因为策略将被用于执行动作。
- 此处，"评论家"指策略评估或值估计。之所以称为评论家，是因为它通过评估策略来对其进行评判。

介绍

演员-评论家方法仍属于策略梯度方法。

- 它们强调将策略梯度与基于值的方法相结合的结构。

"演员"与"评论家"分别指什么?

- 此处，"演员"指策略更新。之所以称为演员，是因为策略将被用于执行动作。
- 此处，"评论家"指策略评估或值估计。之所以称为评论家，是因为它通过评估策略来对其进行评判。

大纲

1. 最简单的演员-评论家（QAC）
2. 优势演员-评论家（A2C）
   - 基线不变性
   - 优势演员-评论家算法
3. 离策略演员-评论家
   - 示例说明
   - 重要性采样
   - 离策略策略梯度定理
   - 离策略演员-评论家算法
4. 确定性演员-评论家（DPG）
   - 确定性策略梯度定理
   - 确定性演员-评论家算法

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

最简单的演员-评论家

回顾上一讲介绍的策略梯度思想。

1) 标量指标$J(\theta)$，可以是$\bar{v}_\pi$ 或$\bar{r}_\pi$。

2) 最大化$J(\theta)$ 的梯度上升算法为:

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right]\end{aligned}$$

3) 随机梯度上升算法为:

$$\boxed{\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)}$$

该表达式非常重要！从中可以直接看出"演员"与"评论家":

- 该表达式对应演员！
- 估计$q_t(s,a)$ 的算法对应评论家！

最简单的演员-评论家

回顾上一讲介绍的策略梯度思想。

1) 标量指标$J(\theta)$，可以是$\bar{v}_\pi$ 或$\bar{r}_\pi$。

2) 最大化$J(\theta)$ 的梯度上升算法为:

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right]\end{aligned}$$

3) 随机梯度上升算法为:

$$\boxed{\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)}$$

该表达式非常重要！从中可以直接看出"演员"与"评论家":

- 该表达式对应演员！
- 估计$q_t(s,a)$ 的算法对应评论家！

最简单的演员-评论家

回顾上一讲介绍的策略梯度思想。

1) 标量指标$J(\theta)$，可以是$\bar{v}_\pi$ 或$\bar{r}_\pi$。

2) 最大化$J(\theta)$ 的梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right]\end{aligned}$$

3) 随机梯度上升算法为：

$$\boxed{\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)}$$

该表达式非常重要！从中可以直接看出"演员"与"评论家"：

- 该表达式对应演员！
- 估计$q_t(s,a)$ 的算法对应评论家！

最简单的演员-评论家

回顾上一讲介绍的策略梯度思想。

1) 标量指标$J(\theta)$，可以是$\bar{v}_\pi$ 或$\bar{r}_\pi$。

2) 最大化$J(\theta)$ 的梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right]\end{aligned}$$

3) 随机梯度上升算法为：

$$\boxed{\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)}$$

该表达式非常重要！从中可以直接看出"演员"与"评论家"：

- 该表达式对应演员！
- 估计$q_t(s,a)$ 的算法对应评论家！

最简单的演员-评论家

回顾上一讲介绍的策略梯度思想。

1) 标量指标$J(\theta)$，可以是$\bar{v}_\pi$ 或$\bar{r}_\pi$。

2) 最大化$J(\theta)$ 的梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta J(\theta_t) \\ &= \theta_t + \alpha \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right]\end{aligned}$$

3) 随机梯度上升算法为：

$$\boxed{\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t) q_t(s_t,a_t)}$$

该表达式非常重要！从中可以直接看出"演员"与"评论家"：

- 该表达式对应演员！
- 估计$q_t(s,a)$ 的算法对应评论家！

最简单的演员-评论家

如何得到$q_t(s_t, a_t)$?

目前，我们已学习了两种估计动作值的方式：

- **蒙特卡洛学习：** 若使用MC，对应的算法称为REINFORCE 或蒙特卡洛策略梯度。
  - 已在上一讲中介绍。
- **时序差分学习：** 若使用TD，此类算法通常称为演员-评论家。
  - 将在本讲中介绍。

最简单的演员-评论家

如何得到$q_t(s_t, a_t)$?

目前，我们已学习了两种估计动作值的方式：

- **蒙特卡洛学习：** 若使用MC，对应的算法称为REINFORCE 或蒙特卡洛策略梯度。
  - 已在上一讲中介绍。
- **时序差分学习：** 若使用TD，此类算法通常称为演员-评论家。
  - 将在本讲中介绍。

最简单的演员-评论家

如何得到$q_t(s_t, a_t)$?

目前，我们已学习了两种估计动作值的方式：

- **蒙特卡洛学习：** 若使用MC，对应的算法称为REINFORCE 或蒙特卡洛策略梯度。
  - 已在上一讲中介绍。
- **时序差分学习：** 若使用TD，此类算法通常称为演员-评论家。
  - 将在本讲中介绍。

最简单的演员-评论家

最简单的演员-评论家算法（QAC）

初始化： 策略函数$\pi(a|s,\theta_0)$，θ_0 为初始参数。值函数$q(s,a,w_0)$，w_0 为初始参数。$\alpha_w,\alpha_\theta>0$。

目标： 学习最优策略以最大化$J(\theta)$。

对每个回合中的时刻t，执行：

按$\pi(a|s_t,\theta_t)$ 生成a_t，观测r_{t+1},s_{t+1}，再按$\pi(a|s_{t+1},\theta_t)$ 生成a_{t+1}。

演员（策略更新）：

$$\theta_{t+1}=\theta_t+\alpha_\theta\nabla_\theta\ln\pi(a_t|s_t,\theta_t)q(s_t,a_t,w_t)$$

评论家（值更新）：

$$w_{t+1}=w_t+\alpha_w\left[r_{t+1}+\gamma q(s_{t+1},a_{t+1},w_t)-q(s_t,a_t,w_t)\right]\nabla_w q(s_t,a_t,w_t)$$

最简单的演员-评论家

注：

- 评论家对应"Sarsa + 值函数"。
- 演员对应策略更新算法。
- 该特定演员-评论家算法有时称为Q 演员-评论家（QAC）。
- 虽然简单，但该算法揭示了演员-评论家方法的核心思想，可以扩展得到许多其他算法（如后文所示）。

最简单的演员-评论家

注：

- 评论家对应"Sarsa + 值函数"。
- 演员对应策略更新算法。
- 该特定演员-评论家算法有时称为Q 演员-评论家（QAC）。
- 虽然简单，但该算法揭示了演员-评论家方法的核心思想，可以扩展得到许多其他算法（如后文所示）。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

介绍

接下来，将QAC 扩展为优势演员-评论家（A2C）：

- 核心思想是引入基线以降低方差。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

基线不变性

性质：策略梯度对额外的基线具有不变性：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\Big]$$

基线不变性

性质：策略梯度对额外的基线具有不变性：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\Big]$$

基线不变性

性质：策略梯度对额外的基线具有不变性：

$$\begin{aligned}\nabla_\theta J(\theta) &= \mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\Big] \\ &= \mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)(q_\pi(S,A) - b(S))\Big]\end{aligned}$$

其中额外基线$b(S)$ 是关于S 的标量函数。

基线不变性

性质：策略梯度对额外的基线具有不变性：

$$\begin{aligned}\nabla_\theta J(\theta) &= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t) q_\pi(S,A)\right] \\ &= \mathbb{E}_{S\sim\eta, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta_t)(q_\pi(S,A) - b(S))\right]\end{aligned}$$

其中额外基线$b(S)$ 是关于S 的标量函数。

接下来回答两个问题：

- 为什么这是合法的?
- 为什么这是有用的?

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s)$$

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s)$$

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\begin{aligned}\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] &= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s) \\ &= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) b(s)\end{aligned}$$

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\begin{aligned}
\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] &= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t)
\end{aligned}$$

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\begin{aligned}
\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] &= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \nabla_\theta \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t)
\end{aligned}$$

基线不变性

第一，为什么这是合法的?

这是因为:

$$\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] = 0$$

详细推导:

$$\begin{aligned}
\mathbb{E}_{S\sim\eta, A\sim\pi}\Big[\nabla_\theta \ln \pi(A|S,\theta_t) b(S)\Big] &= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \nabla_\theta \ln \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) b(s) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \sum_{a\in\mathcal{A}} \nabla_\theta \pi(a|s,\theta_t) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \nabla_\theta \sum_{a\in\mathcal{A}} \pi(a|s,\theta_t) \\
&= \sum_{s\in\mathcal{S}} \eta(s) b(s) \nabla_\theta 1 = 0
\end{aligned}$$

基线不变性

第二，为什么基线是有用的?

梯度为$\nabla_\theta J(\theta) = \mathbb{E}[X]$，其中：

$$X(S, A) \doteq \nabla_\theta \ln \pi(A|S, \theta_t)[q_\pi(S, A) - b(S)]$$

我们有：

- $\mathbb{E}[X]$ 对$b(S)$ 不变。
- $\mathrm{var}(X)$ 对$b(S)$ 不是不变的。
  - 为什么？因为$\mathrm{tr}[\mathrm{var}(X)] = \mathbb{E}[X^T X] - \bar{x}^T \bar{x}$，且：

$$\begin{aligned}\mathbb{E}[X^T X] &= \mathbb{E}\left[(\nabla_\theta \ln \pi)^T (\nabla_\theta \ln \pi)(q_\pi(S, A) - b(S))^2\right] \\ &= \mathbb{E}\left[\|\nabla_\theta \ln \pi\|^2 (q_\pi(S, A) - b(S))^2\right]\end{aligned}$$

证明见教材。

基线不变性

第二，为什么基线是有用的?

梯度为$\nabla_\theta J(\theta) = \mathbb{E}[X]$，其中：

$$X(S, A) \doteq \nabla_\theta \ln \pi(A|S, \theta_t)[q_\pi(S, A) - b(S)]$$

我们有：

- $\mathbb{E}[X]$ 对$b(S)$ 不变。
- $\mathrm{var}(X)$ 对$b(S)$ 不是不变的。
  - 为什么？因为$\mathrm{tr}[\mathrm{var}(X)] = \mathbb{E}[X^T X] - \bar{x}^T \bar{x}$，且：

$$\begin{aligned}\mathbb{E}[X^T X] &= \mathbb{E}\left[(\nabla_\theta \ln \pi)^T (\nabla_\theta \ln \pi)(q_\pi(S, A) - b(S))^2\right] \\ &= \mathbb{E}\left[\|\nabla_\theta \ln \pi\|^2 (q_\pi(S, A) - b(S))^2\right]\end{aligned}$$

证明见教材。

基线不变性

第二，为什么基线是有用的?

梯度为$\nabla_\theta J(\theta) = \mathbb{E}[X]$，其中：

$$X(S, A) \doteq \nabla_\theta \ln \pi(A|S, \theta_t)[q_\pi(S, A) - b(S)]$$

我们有：

- $\mathbb{E}[X]$ 对$b(S)$ 不变。
- $\mathrm{var}(X)$ 对$b(S)$ 不是不变的。
  - 为什么？因为$\mathrm{tr}[\mathrm{var}(X)] = \mathbb{E}[X^T X] - \bar{x}^T \bar{x}$，且：

$$\begin{aligned}\mathbb{E}[X^T X] &= \mathbb{E}\left[(\nabla_\theta \ln \pi)^T (\nabla_\theta \ln \pi)(q_\pi(S, A) - b(S))^2\right] \\ &= \mathbb{E}\left[\|\nabla_\theta \ln \pi\|^2 (q_\pi(S, A) - b(S))^2\right]\end{aligned}$$

证明见教材。

基线不变性

第二，为什么基线是有用的?

梯度为$\nabla_\theta J(\theta) = \mathbb{E}[X]$，其中：

$$X(S, A) \doteq \nabla_\theta \ln \pi(A|S, \theta_t)[q_\pi(S, A) - b(S)]$$

我们有：

- $\mathbb{E}[X]$ 对$b(S)$ 不变。
- $\mathrm{var}(X)$ 对$b(S)$ 不是不变的。
  - 为什么？因为$\mathrm{tr}[\mathrm{var}(X)] = \mathbb{E}[X^T X] - \bar{x}^T \bar{x}$，且：

$$\begin{aligned}\mathbb{E}[X^T X] &= \mathbb{E}\left[(\nabla_\theta \ln \pi)^T (\nabla_\theta \ln \pi)(q_\pi(S, A) - b(S))^2\right] \\ &= \mathbb{E}\left[\|\nabla_\theta \ln \pi\|^2 (q_\pi(S, A) - b(S))^2\right]\end{aligned}$$

证明见教材。

基线不变性

第二，为什么基线是有用的?

梯度为$\nabla_\theta J(\theta) = \mathbb{E}[X]$，其中：

$$X(S, A) \doteq \nabla_\theta \ln \pi(A|S, \theta_t)[q_\pi(S, A) - b(S)]$$

我们有：

- $\mathbb{E}[X]$ 对$b(S)$ 不变。
- $\mathrm{var}(X)$ 对$b(S)$ 不是不变的。
  - 为什么？因为$\mathrm{tr}[\mathrm{var}(X)] = \mathbb{E}[X^T X] - \bar{x}^T \bar{x}$，且：

$$\begin{aligned}\mathbb{E}[X^T X] &= \mathbb{E}\left[(\nabla_\theta \ln \pi)^T (\nabla_\theta \ln \pi)(q_\pi(S, A) - b(S))^2\right] \\ &= \mathbb{E}\left[\|\nabla_\theta \ln \pi\|^2 (q_\pi(S, A) - b(S))^2\right]\end{aligned}$$

证明见教材。

基线不变性

我们的目标： 选择最优基线 b 以最小化$\mathrm{var}(X)$：

- 好处： 当用随机样本近似$\mathbb{E}[X]$ 时，估计方差也会较小。

在REINFORCE 和QAC 算法中：

- 没有基线。
- 或者说$b = 0$，这不一定是好的基线。

基线不变性

我们的目标： 选择最优基线 b 以最小化$\mathrm{var}(X)$：

- 好处： 当用随机样本近似$\mathbb{E}[X]$ 时，估计方差也会较小。

在REINFORCE 和QAC 算法中：

- 没有基线。
- 或者说$b = 0$，这不一定是好的基线。

基线不变性

- 能最小化$\mathrm{var}(X)$ 的最优基线为，对任意$s \in \mathcal{S}$:

$$b^*(s) = \frac{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2 q_\pi(s,A)]}{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2]}.$$

证明见教材。

- 虽然该基线是最优的，但形式复杂。
- 可以去掉权重$\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2$，选择次优基线:

$$b(s) = \mathbb{E}_{A\sim\pi}[q_\pi(s,A)] = v_\pi(s)$$

这正是状态s 的状态值！

基线不变性

- 能最小化$\mathrm{var}(X)$ 的最优基线为，对任意$s \in \mathcal{S}$:

$$b^*(s) = \frac{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2 q_\pi(s,A)]}{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2]}.$$

  证明见教材。

- 虽然该基线是最优的，但形式复杂。
- 可以去掉权重$\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2$，选择次优基线:

$$b(s) = \mathbb{E}_{A\sim\pi}[q_\pi(s,A)] = v_\pi(s)$$

  这正是状态s 的状态值！

基线不变性

- 能最小化$\mathrm{var}(X)$ 的最优基线为，对任意$s \in \mathcal{S}$:

$$b^*(s) = \frac{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2 q_\pi(s,A)]}{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2]}.$$

  证明见教材。

- 虽然该基线是最优的，但形式复杂。
- 可以去掉权重$\|\nabla_\theta \ln \pi(A|s,\theta_t)\|^2$，选择次优基线:

$$b(s) = \mathbb{E}_{A\sim\pi}[q_\pi(s,A)] = v_\pi(s)$$

  这正是状态s 的状态值！

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

优势演员-评论家算法

当$b(s) = v_\pi(s)$ 时：

- 梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)[q_\pi(S,A) - v_\pi(S)]\Big] \\ &\doteq \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)\delta_\pi(S,A)\Big]\end{aligned}$$

其中：

$$\delta_\pi(S,A) \doteq q_\pi(S,A) - v_\pi(S)$$

称为优势函数（为何称为优势？）。

- 随机版本为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)[q_t(s_t,a_t) - v_t(s_t)] \\ &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)\end{aligned}$$

优势演员-评论家算法

当$b(s) = v_\pi(s)$ 时：

- 梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)[q_\pi(S,A) - v_\pi(S)]\Big] \\ &\doteq \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)\delta_\pi(S,A)\Big]\end{aligned}$$

  其中：

$$\delta_\pi(S,A) \doteq q_\pi(S,A) - v_\pi(S)$$

  称为优势函数（为何称为优势？）。

- 随机版本为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)[q_t(s_t,a_t) - v_t(s_t)] \\ &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)\end{aligned}$$

优势演员-评论家算法

当$b(s) = v_\pi(s)$ 时：

- 梯度上升算法为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)[q_\pi(S,A) - v_\pi(S)]\Big] \\ &\doteq \theta_t + \alpha \mathbb{E}\Big[\nabla_\theta \ln \pi(A|S,\theta_t)\delta_\pi(S,A)\Big]\end{aligned}$$

  其中：

$$\delta_\pi(S,A) \doteq q_\pi(S,A) - v_\pi(S)$$

  称为优势函数（为何称为优势？）。

- 随机版本为：

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)[q_t(s_t,a_t) - v_t(s_t)] \\ &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)\end{aligned}$$

优势演员-评论家算法

此外，优势函数由TD 误差近似：

$$\delta_t = q_t(s_t, a_t) - v_t(s_t) \rightarrow r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t)$$

- 该近似是合理的，因为：

$$\mathbb{E}[q_\pi(S, A) - v_\pi(S) | S = s_t, A = a_t] = \mathbb{E}\Big[R + \gamma v_\pi(S') - v_\pi(S) | S = s_t, A = a_t\Big]$$

- **好处：** 只需一个网络来近似$v_\pi(s)$，而无需分别为$q_\pi(s, a)$ 和$v_\pi(s)$ 各用一个网络。

优势演员-评论家算法

此外，优势函数由TD 误差近似：

$$\delta_t = q_t(s_t, a_t) - v_t(s_t) \rightarrow r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t)$$

- 该近似是合理的，因为：

$$\mathbb{E}[q_\pi(S, A) - v_\pi(S)|S = s_t, A = a_t] = \mathbb{E}\Big[R + \gamma v_\pi(S') - v_\pi(S)|S = s_t, A = a_t\Big]$$

- **好处：** 只需一个网络来近似$v_\pi(s)$，而无需分别为$q_\pi(s, a)$ 和$v_\pi(s)$ 各用一个网络。

优势演员-评论家算法

此外，优势函数由TD 误差近似：

$$\delta_t = q_t(s_t, a_t) - v_t(s_t) \rightarrow r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t)$$

- 该近似是合理的，因为：

$$\mathbb{E}[q_\pi(S, A) - v_\pi(S) | S = s_t, A = a_t] = \mathbb{E}\Big[R + \gamma v_\pi(S') - v_\pi(S) | S = s_t, A = a_t\Big]$$

- **好处：** 只需一个网络来近似$v_\pi(s)$，而无需分别为$q_\pi(s, a)$ 和$v_\pi(s)$ 各用一个网络。

优势演员-评论家算法

A2C 算法的解释:

$$\theta_{t+1} = \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t, \theta_t) \delta_t(s_t, a_t)$$

因此，该算法能平衡探索与利用。

$$\delta_t(s_t, a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t, \theta_{t+1}) \text{ 越大}$$

$$\pi(a_t|s_t, \theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t, \theta_{t+1}) \text{ 越大}$$

类似情形的分析见上一讲。

- 此处关键在于相对值δ_t 而非绝对值q_t，这更为合理。

优势演员-评论家算法

A2C 算法的解释:

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t) \\ &= \theta_t + \alpha \frac{\nabla_\theta \pi(a_t|s_t,\theta_t)}{\pi(a_t|s_t,\theta_t)}\delta_t(s_t,a_t)\end{aligned}$$

因此，该算法能平衡探索与利用。

$$\delta_t(s_t,a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

$$\pi(a_t|s_t,\theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

类似情形的分析见上一讲。

- 此处关键在于相对值δ_t 而非绝对值q_t，这更为合理。

优势演员-评论家算法

A2C 算法的解释:

$$
\begin{aligned}
\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \frac{\nabla_\theta \pi(a_t|s_t,\theta_t)}{\pi(a_t|s_t,\theta_t)}\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \underbrace{\left(\frac{\delta_t(s_t,a_t)}{\pi(a_t|s_t,\theta_t)}\right)}_{\beta_t} \nabla_\theta \pi(a_t|s_t,\theta_t)
\end{aligned}
$$

因此，该算法能平衡探索与利用。

$$\delta_t(s_t,a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

$$\pi(a_t|s_t,\theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

类似情形的分析见上一讲。

- 此处关键在于相对值δ_t 而非绝对值q_t，这更为合理。

优势演员-评论家算法

A2C 算法的解释:

$$
\begin{aligned}
\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \frac{\nabla_\theta \pi(a_t|s_t,\theta_t)}{\pi(a_t|s_t,\theta_t)}\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \underbrace{\left(\frac{\delta_t(s_t,a_t)}{\pi(a_t|s_t,\theta_t)}\right)}_{\beta_t} \nabla_\theta \pi(a_t|s_t,\theta_t)
\end{aligned}
$$

因此，该算法能平衡探索与利用。

$$\delta_t(s_t,a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

$$\pi(a_t|s_t,\theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

类似情形的分析见上一讲。

- 此处关键在于相对值δ_t 而非绝对值q_t，这更为合理。

A2C 算法的解释:

$$
\begin{aligned}
\theta_{t+1} &= \theta_t + \alpha \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \frac{\nabla_\theta \pi(a_t|s_t,\theta_t)}{\pi(a_t|s_t,\theta_t)}\delta_t(s_t,a_t) \\
&= \theta_t + \alpha \underbrace{\left(\frac{\delta_t(s_t,a_t)}{\pi(a_t|s_t,\theta_t)}\right)}_{\beta_t} \nabla_\theta \pi(a_t|s_t,\theta_t)
\end{aligned}
$$

因此，该算法能平衡探索与利用。

$$\delta_t(s_t,a_t) \text{ 越大} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

$$\pi(a_t|s_t,\theta_t) \text{ 越小} \Longrightarrow \beta_t \text{ 越大} \Longrightarrow \pi(a_t|s_t,\theta_{t+1}) \text{ 越大}$$

类似情形的分析见上一讲。

- 此处关键在于相对值δ_t 而非绝对值q_t，这更为合理。

优势演员-评论家算法

优势演员-评论家（A2C）或TD 演员-评论家

初始化： 策略函数$\pi(a|s,\theta_0)$，θ_0 为初始参数。值函数$v(s,w_0)$，w_0 为初始参数。$\alpha_w,\alpha_\theta>0$。
目标： 学习最优策略以最大化$J(\theta)$。

对每个回合中的时刻t，执行：

按$\pi(a|s_t,\theta_t)$ 生成a_t，然后观测r_{t+1},s_{t+1}。

优势（TD 误差）：

$$\delta_t = r_{t+1}+\gamma v(s_{t+1},w_t)-v(s_t,w_t)$$

演员（策略更新）：

$$\theta_{t+1}=\theta_t+\alpha_\theta\delta_t\nabla_\theta\ln\pi(a_t|s_t,\theta_t)$$

评论家（值更新）：

$$w_{t+1}=w_t+\alpha_w\delta_t\nabla_w v(s_t,w_t)$$

- 该算法是同策略的。
- 由于策略$\pi(\theta_t)$ 是随机的，无需使用ε-贪心等技巧。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

介绍

- 策略梯度是同策略的。
  - 为什么？因为梯度为$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta, A\sim\pi}[*]$

- 能否将其转化为离策略?
  - 可以，通过重要性采样实现。
  - 重要性采样技术不限于演员-评论家，也适用于任何旨在估计期望的算法。

介绍

- 策略梯度是同策略的。
  - 为什么？因为梯度为$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta, A\sim\pi}[*]$

- 能否将其转化为离策略?
  - 可以，通过重要性采样实现。
  - 重要性采样技术不限于演员-评论家，也适用于任何旨在估计期望的算法。

介绍

- 策略梯度是同策略的。
  - 为什么？因为梯度为$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta, A\sim\pi}[*]$

- 能否将其转化为离策略?
  - 可以，通过重要性采样实现。
  - 重要性采样技术不限于演员-评论家，也适用于任何旨在估计期望的算法。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

示例说明

考虑随机变量$X \in \mathcal{X} = \{+1, -1\}$。

若X 的概率分布为p_0:

$$p_0(X = +1) = 0.5, \quad p_0(X = -1) = 0.5$$

则X 的期望为:

$$\mathbb{E}_{X \sim p_0}[X] = (+1) \cdot 0.5 + (-1) \cdot 0.5 = 0.$$

问：如何用样本$\{x_i\}$ 估计$\mathbb{E}[X]$?

示例说明

考虑随机变量$X \in \mathcal{X} = \{+1, -1\}$。

若X 的概率分布为p_0:

$$p_0(X = +1) = 0.5, \quad p_0(X = -1) = 0.5$$

则X 的期望为:

$$\mathbb{E}_{X \sim p_0}[X] = (+1) \cdot 0.5 + (-1) \cdot 0.5 = 0.$$

问：如何用样本$\{x_i\}$ 估计$\mathbb{E}[X]$?

示例说明

考虑随机变量$X \in \mathcal{X} = \{+1, -1\}$。

若X 的概率分布为p_0:

$$p_0(X = +1) = 0.5, \quad p_0(X = -1) = 0.5$$

则X 的期望为:

$$\mathbb{E}_{X \sim p_0}[X] = (+1) \cdot 0.5 + (-1) \cdot 0.5 = 0.$$

问：如何用样本$\{x_i\}$ 估计$\mathbb{E}[X]$?

示例说明

考虑随机变量$X \in \mathcal{X} = \{+1, -1\}$。

若X 的概率分布为p_0:

$$p_0(X = +1) = 0.5, \quad p_0(X = -1) = 0.5$$

则X 的期望为:

$$\mathbb{E}_{X \sim p_0}[X] = (+1) \cdot 0.5 + (-1) \cdot 0.5 = 0.$$

问：如何用样本$\{x_i\}$ 估计$\mathbb{E}[X]$?

示例说明

情形一（已熟悉）：

- 样本$\{x_i\}$ 按p_0 生成:

$$\mathbb{E}[x_i] = \mathbb{E}[X], \quad \mathrm{var}[x_i] = \mathrm{var}[X]$$

则样本均值收敛到期望:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \to \mathbb{E}[X], \quad 当 n \to \infty$$

见大数定律。

示例说明

情形一（已熟悉）：

- 样本$\{x_i\}$ 按p_0 生成:

$$\mathbb{E}[x_i] = \mathbb{E}[X], \quad \mathrm{var}[x_i] = \mathrm{var}[X]$$

则样本均值收敛到期望:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \to \mathbb{E}[X], \quad 当 n \to \infty$$

见大数定律。

示例说明

情形一（已熟悉）：

- 样本$\{x_i\}$ 按p_0 生成:

$$\mathbb{E}[x_i] = \mathbb{E}[X], \quad \mathrm{var}[x_i] = \mathrm{var}[X]$$

则样本均值收敛到期望:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \to \mathbb{E}[X], \quad 当 n \to \infty$$

见大数定律。

示例说明

图：样本及$\bar{x} \to \mathbb{E}[X]$

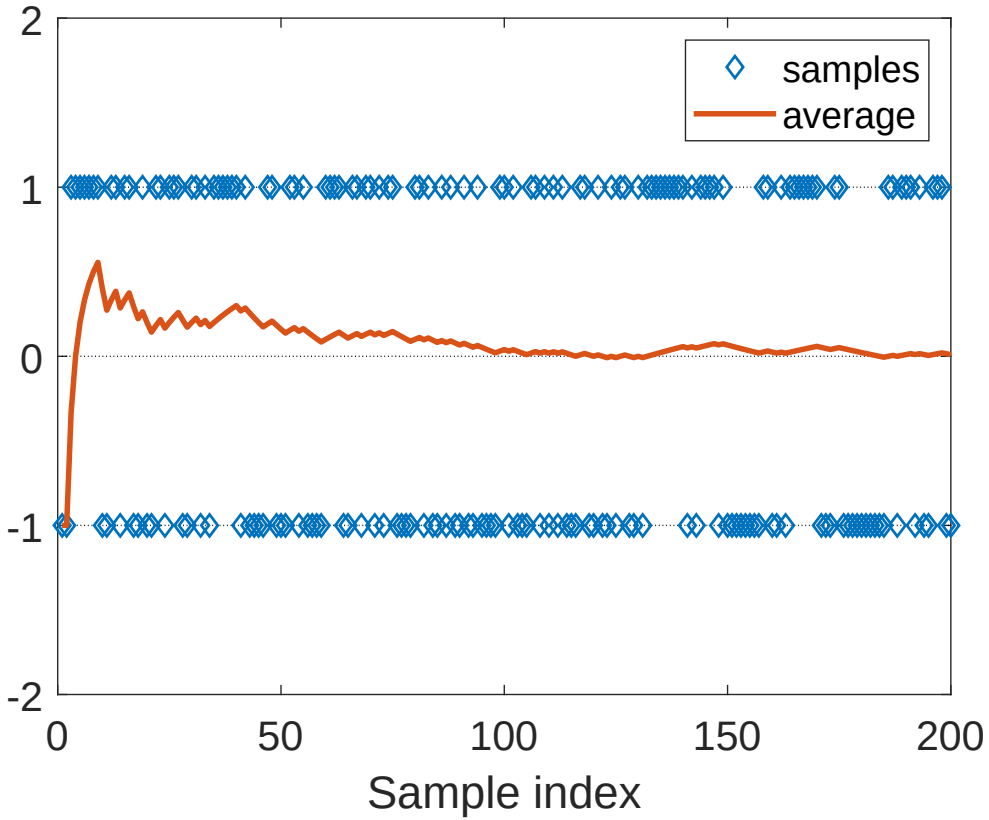

示例说明

情形二（新情形）：

- 样本$\{x_i\}$ 按另一分布p_1 生成:

$$p_1(X=+1)=0.8, \quad p_1(X=-1)=0.2$$

期望为:

$$\mathbb{E}_{X\sim p_1}[X]=(+1)\cdot 0.8+(-1)\cdot 0.2=0.6$$

若直接用样本均值，则毫不意外地有:

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i \to \mathbb{E}_{X\sim p_1}[X]=0.6\neq \mathbb{E}_{X\sim p_0}[X]=0$$

示例说明

情形二（新情形）：

- 样本$\{x_i\}$ 按另一分布p_1 生成：

$$p_1(X=+1)=0.8, \quad p_1(X=-1)=0.2$$

期望为：

$$\mathbb{E}_{X\sim p_1}[X]=(+1)\cdot 0.8+(-1)\cdot 0.2=0.6$$

若直接用样本均值，则毫不意外地有：

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i \to \mathbb{E}_{X\sim p_1}[X]=0.6\neq \mathbb{E}_{X\sim p_0}[X]=0$$

示例说明

情形二（新情形）：

- 样本$\{x_i\}$ 按另一分布p_1 生成：

$$p_1(X=+1)=0.8, \quad p_1(X=-1)=0.2$$

期望为：

$$\mathbb{E}_{X\sim p_1}[X]=(+1)\cdot 0.8+(-1)\cdot 0.2=0.6$$

若直接用样本均值，则毫不意外地有：

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i \to \mathbb{E}_{X\sim p_1}[X]=0.6\neq \mathbb{E}_{X\sim p_0}[X]=0$$

示例说明

情形二（新情形）：

- 样本$\{x_i\}$ 按另一分布p_1 生成：

$$p_1(X=+1)=0.8, \quad p_1(X=-1)=0.2$$

期望为：

$$\mathbb{E}_{X\sim p_1}[X]=(+1)\cdot 0.8+(-1)\cdot 0.2=0.6$$

若直接用样本均值，则毫不意外地有：

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i \to \mathbb{E}_{X\sim p_1}[X]=0.6\neq \mathbb{E}_{X\sim p_0}[X]=0$$

示例说明

问：能否用$\{x_i\} \sim p_1$ 来估计$\mathbb{E}_{X\sim p_0}[X]$?

- 为何要这样做?
  我们可能希望基于行为策略 β 的样本来估计$\mathbb{E}_{A\sim\pi}[*]$，其中π 为目标策略。

- 如何做到?
  - 直接使用$\bar{x}$ 无法实现:

$$\bar{x} \to \mathbb{E}_{X\sim p_1}[X] = 0.6 \neq \mathbb{E}_{X\sim p_0}[X] = 0$$

  - 可以通过重要性采样技术实现。

示例说明

问：能否用$\{x_i\} \sim p_1$ 来估计$\mathbb{E}_{X\sim p_0}[X]$?

- 为何要这样做?
  我们可能希望基于行为策略 β 的样本来估计$\mathbb{E}_{A\sim\pi}[*]$，其中π 为目标策略。

- 如何做到?
  - 直接使用$\bar{x}$ 无法实现:

$$\bar{x} \to \mathbb{E}_{X\sim p_1}[X] = 0.6 \neq \mathbb{E}_{X\sim p_0}[X] = 0$$

  - 可以通过重要性采样技术实现。

示例说明

问：能否用$\{x_i\} \sim p_1$ 来估计$\mathbb{E}_{X\sim p_0}[X]$?

- 为何要这样做?
  我们可能希望基于行为策略 β 的样本来估计$\mathbb{E}_{A\sim\pi}[*]$，其中π 为目标策略。

- 如何做到?
  - 直接使用$\bar{x}$ 无法实现:

$$\bar{x} \to \mathbb{E}_{X\sim p_1}[X] = 0.6 \neq \mathbb{E}_{X\sim p_0}[X] = 0$$

  - 可以通过重要性采样技术实现。

示例说明

问：能否用$\{x_i\} \sim p_1$ 来估计$\mathbb{E}_{X\sim p_0}[X]$?

- **为何要这样做?**
  我们可能希望基于行为策略 β 的样本来估计$\mathbb{E}_{A\sim\pi}[*]$，其中π 为目标策略。

- **如何做到?**
  - 直接使用$\bar{x}$ 无法实现:

$$\bar{x} \to \mathbb{E}_{X\sim p_1}[X] = 0.6 \neq \mathbb{E}_{X\sim p_0}[X] = 0$$

  - 可以通过重要性采样技术实现。

示例说明

图：样本及$\bar{x} \to \mathbb{E}_{X\sim p_1}[X]$（虚线）

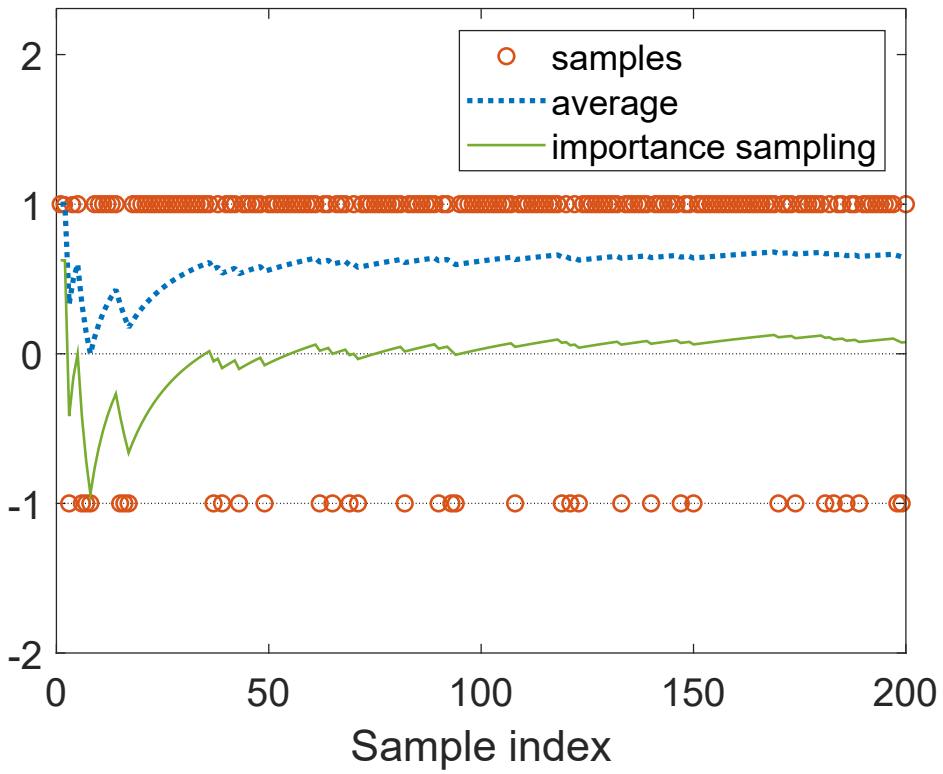

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X]$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad \text{其中} x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad \text{当} n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad \text{其中} x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad \text{当} n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x = \sum_x p_1(x)\underbrace{\frac{p_0(x)}{p_1(x)}x}_{f(x)}$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad 其中 x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad 当 n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x = \sum_x p_1(x)\underbrace{\frac{p_0(x)}{p_1(x)}x}_{f(x)} = \mathbb{E}_{X\sim p_1}[f(X)]$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad 其中 x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad 当 n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x = \sum_x p_1(x)\underbrace{\frac{p_0(x)}{p_1(x)}x}_{f(x)} = \mathbb{E}_{X\sim p_1}[f(X)]$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad 其中 x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad 当 n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x = \sum_x p_1(x)\underbrace{\frac{p_0(x)}{p_1(x)}x}_{f(x)} = \mathbb{E}_{X\sim p_1}[f(X)]$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad 其中 x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad 当 n \to \infty$$

重要性采样

注意到：

$$\mathbb{E}_{X\sim p_0}[X] = \sum_x p_0(x)x = \sum_x p_1(x)\underbrace{\frac{p_0(x)}{p_1(x)}x}_{f(x)} = \mathbb{E}_{X\sim p_1}[f(X)]$$

- 因此，可以通过估计$\mathbb{E}_{X\sim p_1}[f(X)]$ 来估计$\mathbb{E}_{X\sim p_0}[X]$。
- 如何估计$\mathbb{E}_{X\sim p_1}[f(X)]$？很简单。令：

$$\bar{f} \doteq \frac{1}{n}\sum_{i=1}^{n} f(x_i), \qquad \text{其中} x_i \sim p_1$$

则：

$$\bar{f} \to \mathbb{E}_{X\sim p_1}[f(X)], \quad \text{当} n \to \infty$$

重要性采样

因此，$\bar{f}$ 是$\mathbb{E}_{X\sim p_1}[f(X)] = \mathbb{E}_{X\sim p_0}[X]$ 的良好近似:

$$\boxed{\mathbb{E}_{X\sim p_0}[X] \approx \bar{f} = \frac{1}{n}\sum_{i=1}^{n} f(x_i) = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i}$$

- $\frac{p_0(x_i)}{p_1(x_i)}$ 称为重要性权重。
  - 若$p_1(x_i) = p_0(x_i)$，重要性权重为1，$\bar{f}$ 退化为$\bar{x}$。
  - 若$p_0(x_i) \geq p_1(x_i)$，x_i 在p_0 下比在p_1 下被采样的频率更高，重要性权重（> 1）可以强调该样本的重要性。

重要性采样

因此，$\bar{f}$ 是$\mathbb{E}_{X\sim p_1}[f(X)] = \mathbb{E}_{X\sim p_0}[X]$ 的良好近似:

$$\boxed{\mathbb{E}_{X\sim p_0}[X] \approx \bar{f} = \frac{1}{n}\sum_{i=1}^{n} f(x_i) = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i}$$

- $\dfrac{p_0(x_i)}{p_1(x_i)}$ 称为重要性权重。
  - 若$p_1(x_i) = p_0(x_i)$，重要性权重为$\mathbf{1}$，$\bar{f}$ 退化为$\bar{x}$。
  - 若$p_0(x_i) \geq p_1(x_i)$，x_i 在p_0 下比在p_1 下被采样的频率更高，重要性权重（> 1）可以强调该样本的重要性。

重要性采样

因此，$\bar{f}$ 是$\mathbb{E}_{X\sim p_1}[f(X)] = \mathbb{E}_{X\sim p_0}[X]$ 的良好近似:

$$\boxed{\mathbb{E}_{X\sim p_0}[X] \approx \bar{f} = \frac{1}{n}\sum_{i=1}^{n} f(x_i) = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i}$$

- $\dfrac{p_0(x_i)}{p_1(x_i)}$ 称为重要性权重。
  - 若$p_1(x_i) = p_0(x_i)$，重要性权重为1，$\bar{f}$ 退化为$\bar{x}$。
  - 若$p_0(x_i) \geq p_1(x_i)$，x_i 在p_0 下比在p_1 下被采样的频率更高，重要性权重（> 1）可以强调该样本的重要性。

重要性采样

你可能会问： 既然$\bar{f} = \frac{1}{n}\sum_{i=1}^{n}\frac{p_0(x_i)}{p_1(x_i)}x_i$ 需要知道$p_0(x)$，那么如果我知道$p_0(x)$，为何不直接计算期望?

回答： 我们可能只能对给定的x 计算$p_0(x)$，而无法对所有x 都计算。

- 例如，连续情形、p_0 的表达式复杂，或p_0 无解析表达式（如p_0 由神经网络表示）。

重要性采样

你可能会问： 既然$\bar{f} = \frac{1}{n}\sum_{i=1}^{n}\frac{p_0(x_i)}{p_1(x_i)}x_i$ 需要知道$p_0(x)$，那么如果我知道$p_0(x)$，为何不直接计算期望?

回答： 我们可能只能对给定的x 计算$p_0(x)$，而无法对所有x 都计算。

- 例如，连续情形、p_0 的表达式复杂，或p_0 无解析表达式（如p_0 由神经网络表示）。

重要性采样

你可能会问： 既然$\bar{f} = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i$ 需要知道$p_0(x)$，那么如果我知道$p_0(x)$，为何不直接计算期望?

回答： 我们可能只能对给定的x 计算$p_0(x)$，而无法对所有x 都计算。

- 例如，连续情形、p_0 的表达式复杂，或p_0 无解析表达式（如p_0 由神经网络表示）。

重要性采样

总结： 若$\{x_i\} \sim p_1$，则：

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \to \mathbb{E}_{X\sim p_1}[X]$$

$$\bar{f} = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i \to \mathbb{E}_{X\sim p_0}[X]$$

重要性采样

总结： 若$\{x_i\} \sim p_1$，则：

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \to \mathbb{E}_{X\sim p_1}[X]$$

$$\bar{f} = \frac{1}{n}\sum_{i=1}^{n} \frac{p_0(x_i)}{p_1(x_i)} x_i \to \mathbb{E}_{X\sim p_0}[X]$$

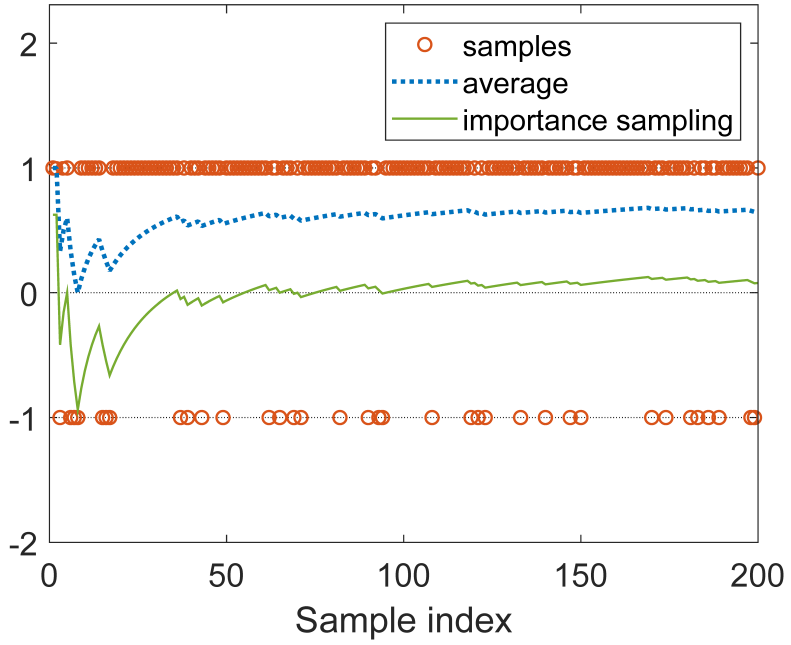

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

离策略策略梯度定理

与之前的同策略情形类似，需要推导离策略情形下的策略梯度。

- 假设β 为行为策略，用于生成经验样本。
- 我们的目标是利用这些样本更新目标策略$\pi(\theta)$，以优化指标:

$$J(\theta) = \sum_{s \in \mathcal{S}} d_\beta(s) v_\pi(s) = \mathbb{E}_{S \sim d_\beta}[v_\pi(S)]$$

其中d_β 是策略β 下的稳态分布。

离策略策略梯度定理

与之前的同策略情形类似，需要推导离策略情形下的策略梯度。

- 假设β 为行为策略，用于生成经验样本。
- 我们的目标是利用这些样本更新目标策略$\pi(\theta)$，以优化指标:

$$J(\theta) = \sum_{s \in \mathcal{S}} d_\beta(s) v_\pi(s) = \mathbb{E}_{S \sim d_\beta}[v_\pi(S)]$$

其中d_β 是策略β 下的稳态分布。

离策略策略梯度定理

与之前的同策略情形类似，需要推导离策略情形下的策略梯度。

- 假设β 为行为策略，用于生成经验样本。
- 我们的目标是利用这些样本更新目标策略$\pi(\theta)$，以优化指标:

$$J(\theta) = \sum_{s \in \mathcal{S}} d_\beta(s) v_\pi(s) = \mathbb{E}_{S \sim d_\beta}[v_\pi(S)]$$

其中d_β 是策略β 下的稳态分布。

离策略策略梯度定理

Theorem (离策略策略梯度定理)

在$\gamma \in (0,1)$ 的折扣情形下，$J(\theta)$ 的梯度为：

$$\begin{aligned}\nabla_\theta J(\theta) &= \mathbb{E}_{S\sim\rho, A\sim\pi}\left[\nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right] \\ &= \mathbb{E}_{S\sim\rho, A\sim\beta}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)} \nabla_\theta \ln \pi(A|S,\theta) q_\pi(S,A)\right]\end{aligned}$$

其中β 为行为策略，ρ 为状态分布。

详细内容及证明见教材。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

离策略演员-评论家算法

离策略策略梯度对基线$b(s)$ 同样具有不变性。

- 特别地，有：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\rho, A\sim\beta}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - b(S)\big)\right]$$

- 为降低估计方差，选择基线$b(S) = v_\pi(S)$，得到：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - v_\pi(S)\big)\right]$$

离策略演员-评论家算法

离策略策略梯度对基线$b(s)$ 同样具有不变性。

- 特别地，有：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\rho, A\sim\beta}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - b(S)\big)\right]$$

- 为降低估计方差，选择基线$b(S) = v_\pi(S)$，得到：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - v_\pi(S)\big)\right]$$

离策略演员-评论家算法

离策略策略梯度对基线$b(s)$ 同样具有不变性。

- 特别地，有：

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\rho, A\sim\beta}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - b(S)\big)\right]$$

- 为降低估计方差，选择基线$b(S) = v_\pi(S)$，得到：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\frac{\pi(A|S,\theta)}{\beta(A|S)}\nabla_\theta \ln \pi(A|S,\theta)\big(q_\pi(S,A) - v_\pi(S)\big)\right]$$

离策略演员-评论家算法

对应的随机梯度上升算法为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\big(q_t(s_t,a_t) - v_t(s_t)\big)$$

与同策略情形类似:

$$q_t(s_t,a_t) - v_t(s_t) \approx r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t) \doteq \delta_t(s_t,a_t)$$

则算法变为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)$$

其解释可从以下形式看出:

$$\theta_{t+1} = \theta_t + \alpha_\theta \left(\frac{\delta_t(s_t,a_t)}{\beta(a_t|s_t)}\right) \nabla_\theta \pi(a_t|s_t,\theta_t)$$

离策略演员-评论家算法

对应的随机梯度上升算法为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\big(q_t(s_t,a_t) - v_t(s_t)\big)$$

与同策略情形类似:

$$q_t(s_t,a_t) - v_t(s_t) \approx r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t) \doteq \delta_t(s_t,a_t)$$

则算法变为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)$$

其解释可从以下形式看出:

$$\theta_{t+1} = \theta_t + \alpha_\theta \left(\frac{\delta_t(s_t,a_t)}{\beta(a_t|s_t)}\right) \nabla_\theta \pi(a_t|s_t,\theta_t)$$

离策略演员-评论家算法

对应的随机梯度上升算法为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\big(q_t(s_t,a_t) - v_t(s_t)\big)$$

与同策略情形类似:

$$q_t(s_t,a_t) - v_t(s_t) \approx r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t) \doteq \delta_t(s_t,a_t)$$

则算法变为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)$$

其解释可从以下形式看出:

$$\theta_{t+1} = \theta_t + \alpha_\theta \left(\frac{\delta_t(s_t,a_t)}{\beta(a_t|s_t)}\right) \nabla_\theta \pi(a_t|s_t,\theta_t)$$

离策略演员-评论家算法

对应的随机梯度上升算法为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\big(q_t(s_t,a_t) - v_t(s_t)\big)$$

与同策略情形类似:

$$q_t(s_t,a_t) - v_t(s_t) \approx r_{t+1} + \gamma v_t(s_{t+1}) - v_t(s_t) \doteq \delta_t(s_t,a_t)$$

则算法变为:

$$\theta_{t+1} = \theta_t + \alpha_\theta \frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)} \nabla_\theta \ln \pi(a_t|s_t,\theta_t)\delta_t(s_t,a_t)$$

其解释可从以下形式看出:

$$\theta_{t+1} = \theta_t + \alpha_\theta \left(\frac{\delta_t(s_t,a_t)}{\beta(a_t|s_t)}\right) \nabla_\theta \pi(a_t|s_t,\theta_t)$$

离策略演员-评论家算法

基于重要性采样的离策略演员-评论家

初始化： 给定行为策略$\beta(a|s)$。目标策略$\pi(a|s,\theta_0)$，θ_0 为初始参数。值函数$v(s,w_0)$，w_0 为初始参数。$\alpha_w,\alpha_\theta>0$。
目标： 学习最优策略以最大化$J(\theta)$。

对每个回合中的时刻t，执行：

按$\beta(s_t)$ 生成a_t，然后观测r_{t+1},s_{t+1}。

优势（TD 误差）：

$$\delta_t = r_{t+1}+\gamma v(s_{t+1},w_t)-v(s_t,w_t)$$

演员（策略更新）：

$$\theta_{t+1}=\theta_t+\alpha_\theta\frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)}\delta_t\nabla_\theta\ln\pi(a_t|s_t,\theta_t)$$

评论家（值更新）：

$$w_{t+1}=w_t+\alpha_w\frac{\pi(a_t|s_t,\theta_t)}{\beta(a_t|s_t)}\delta_t\nabla_w v(s_t,w_t)$$

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

介绍

迄今为止，策略梯度方法中使用的策略均为随机策略，因为对所有(s, a) 均有$\pi(a|s, \theta) > 0$。

能否在策略梯度方法中使用确定性策略?

- 好处：可以处理连续动作空间。

介绍

迄今为止，策略梯度方法中使用的策略均为随机策略，因为对所有(s, a) 均有$\pi(a|s, \theta) > 0$。

能否在策略梯度方法中使用确定性策略?

- 好处：可以处理连续动作空间。

介绍

策略的表示方式:

- 迄今为止，一般策略记为$\pi(a|s,\theta) \in [0,1]$，可以是随机的或确定性的。
- 现在，确定性策略特别记为:

$$a = \mu(s,\theta) \doteq \mu(s)$$

  - μ 是从$\mathcal{S}$ 到$\mathcal{A}$ 的映射。
  - μ 可以由神经网络表示，输入为s，输出为a，参数为θ。
  - 有时将$\mu(s,\theta)$ 简写为$\mu(s)$。

介绍

策略的表示方式:

- 迄今为止，一般策略记为$\pi(a|s,\theta) \in [0,1]$，可以是随机的或确定性的。
- 现在，确定性策略特别记为:

$$a = \mu(s,\theta) \doteq \mu(s)$$

  - μ 是从$\mathcal{S}$ 到$\mathcal{A}$ 的映射。
  - μ 可以由神经网络表示，输入为s，输出为a，参数为θ。
  - 有时将$\mu(s,\theta)$ 简写为$\mu(s)$。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

确定性策略梯度定理

- 之前介绍的策略梯度定理仅对随机策略有效。
- 若策略必须是确定性的，则需推导新的策略梯度定理。
- 思路和步骤与之前类似。

确定性策略梯度定理

- 之前介绍的策略梯度定理仅对随机策略有效。
- 若策略必须是确定性的，则需推导新的策略梯度定理。
- 思路和步骤与之前类似。

确定性策略梯度定理

- 之前介绍的策略梯度定理仅对随机策略有效。
- 若策略必须是确定性的，则需推导新的策略梯度定理。
- 思路和步骤与之前类似。

确定性策略梯度定理

考虑折扣情形下的平均状态值指标:

$$J(\theta) = \mathbb{E}[v_\mu(s)] = \sum_{s \in \mathcal{S}} d_0(s) v_\mu(s)$$

其中$d_0(s)$ 是满足$\sum_{s \in \mathcal{S}} d_0(s) = 1$ 的概率分布。

- d_0 选为与μ 无关的分布，此时梯度更易计算。
- 选择d_0 有两种特别重要的情形:
  - 第一种特殊情形：$d_0(s_0) = 1$，$d_0(s \neq s_0) = 0$，其中s_0 为感兴趣的特定起始状态。
  - 第二种特殊情形：d_0 为与μ 不同的某行为策略的稳态分布。

确定性策略梯度定理

考虑折扣情形下的平均状态值指标:

$$J(\theta) = \mathbb{E}[v_\mu(s)] = \sum_{s \in \mathcal{S}} d_0(s) v_\mu(s)$$

其中$d_0(s)$ 是满足$\sum_{s \in \mathcal{S}} d_0(s) = 1$ 的概率分布。

- d_0 选为与μ 无关的分布，此时梯度更易计算。
- 选择d_0 有两种特别重要的情形:
  - 第一种特殊情形：$d_0(s_0) = 1$，$d_0(s \neq s_0) = 0$，其中s_0 为感兴趣的特定起始状态。
  - 第二种特殊情形：d_0 为与μ 不同的某行为策略的稳态分布。

确定性策略梯度定理

考虑折扣情形下的平均状态值指标:

$$J(\theta) = \mathbb{E}[v_\mu(s)] = \sum_{s \in \mathcal{S}} d_0(s) v_\mu(s)$$

其中$d_0(s)$ 是满足$\sum_{s \in \mathcal{S}} d_0(s) = 1$ 的概率分布。

- d_0 选为与μ 无关的分布，此时梯度更易计算。
- 选择d_0 有两种特别重要的情形:
  - 第一种特殊情形：$d_0(s_0) = 1$，$d_0(s \neq s_0) = 0$，其中s_0 为感兴趣的特定起始状态。
  - 第二种特殊情形：d_0 为与μ 不同的某行为策略的稳态分布。

确定性策略梯度定理

考虑折扣情形下的平均状态值指标:

$$J(\theta) = \mathbb{E}[v_\mu(s)] = \sum_{s\in\mathcal{S}} d_0(s) v_\mu(s)$$

其中$d_0(s)$ 是满足$\sum_{s\in\mathcal{S}} d_0(s) = 1$ 的概率分布。

- d_0 选为与μ 无关的分布，此时梯度更易计算。
- 选择d_0 有两种特别重要的情形:
  - 第一种特殊情形：$d_0(s_0) = 1$，$d_0(s \neq s_0) = 0$，其中s_0 为感兴趣的特定起始状态。
  - 第二种特殊情形：d_0 为与μ 不同的某行为策略的稳态分布。

确定性策略梯度定理

考虑折扣情形下的平均状态值指标:

$$J(\theta) = \mathbb{E}[v_\mu(s)] = \sum_{s \in \mathcal{S}} d_0(s) v_\mu(s)$$

其中$d_0(s)$ 是满足$\sum_{s \in \mathcal{S}} d_0(s) = 1$ 的概率分布。

- d_0 选为与μ 无关的分布，此时梯度更易计算。
- 选择d_0 有两种特别重要的情形:
  - 第一种特殊情形：$d_0(s_0) = 1$，$d_0(s \neq s_0) = 0$，其中s_0 为感兴趣的特定起始状态。
  - 第二种特殊情形：d_0 为与μ 不同的某行为策略的稳态分布。

确定性策略梯度定理

Theorem (折扣情形下的确定性策略梯度定理)

在$\gamma \in (0,1)$ 的折扣情形下，$J(\theta)$ 的梯度为：

$$\begin{aligned}\nabla_\theta J(\theta) &= \sum_{s\in\mathcal{S}} \rho_\mu(s)\nabla_\theta \mu(s)\big(\nabla_a q_\mu(s,a)\big)|_{a=\mu(s)} \\ &= \mathbb{E}_{S\sim\rho_\mu}\left[\nabla_\theta \mu(S)\big(\nabla_a q_\mu(S,a)\big)|_{a=\mu(S)}\right]\end{aligned}$$

其中ρ_μ 为状态分布。详细内容及证明见教材。

与随机情形的一个重要区别：

- 梯度不涉及动作A 的分布（为什么？）。
- 因此，确定性策略梯度方法是离策略的。

确定性策略梯度定理

Theorem (折扣情形下的确定性策略梯度定理)

在$\gamma \in (0,1)$ 的折扣情形下，$J(\theta)$ 的梯度为：

$$\begin{aligned}\nabla_\theta J(\theta) &= \sum_{s\in\mathcal{S}} \rho_\mu(s)\nabla_\theta \mu(s)\big(\nabla_a q_\mu(s,a)\big)|_{a=\mu(s)} \\ &= \mathbb{E}_{S\sim\rho_\mu}\left[\nabla_\theta \mu(S)\big(\nabla_a q_\mu(S,a)\big)|_{a=\mu(S)}\right]\end{aligned}$$

其中ρ_μ 为状态分布。详细内容及证明见教材。

与随机情形的一个重要区别：

- 梯度不涉及动作A 的分布（为什么？）。
- 因此，确定性策略梯度方法是离策略的。

确定性策略梯度定理

Theorem (折扣情形下的确定性策略梯度定理)

在$\gamma \in (0,1)$ 的折扣情形下，$J(\theta)$ 的梯度为：

$$\begin{aligned}\nabla_\theta J(\theta) &= \sum_{s\in\mathcal{S}} \rho_\mu(s)\nabla_\theta \mu(s)\big(\nabla_a q_\mu(s,a)\big)|_{a=\mu(s)} \\ &= \mathbb{E}_{S\sim\rho_\mu}\left[\nabla_\theta \mu(S)\big(\nabla_a q_\mu(S,a)\big)|_{a=\mu(S)}\right]\end{aligned}$$

其中ρ_μ 为状态分布。详细内容及证明见教材。

与随机情形的一个重要区别：

- 梯度不涉及动作A 的分布（为什么？）。
- 因此，确定性策略梯度方法是离策略的。

大纲

1 最简单的演员-评论家（QAC）

2 优势演员-评论家（A2C）
- 基线不变性
- 优势演员-评论家算法

3 离策略演员-评论家
- 示例说明
- 重要性采样
- 离策略策略梯度定理
- 离策略演员-评论家算法

4 确定性演员-评论家（DPG）
- 确定性策略梯度定理
- 确定性演员-评论家算法

确定性演员-评论家算法

基于策略梯度，最大化$J(\theta)$ 的梯度上升算法为：

$$\theta_{t+1} = \theta_t + \alpha_\theta \mathbb{E}_{S\sim\rho_\mu}\left[\nabla_\theta \mu(S)\big(\nabla_a q_\mu(S,a)\big)|_{a=\mu(S)}\right]$$

对应的随机梯度上升算法为：

$$\theta_{t+1} = \theta_t + \alpha_\theta \nabla_\theta \mu(s_t)\big(\nabla_a q_\mu(s_t,a)\big)|_{a=\mu(s_t)}$$

确定性演员-评论家算法

基于策略梯度，最大化$J(\theta)$ 的梯度上升算法为：

$$\theta_{t+1} = \theta_t + \alpha_\theta \mathbb{E}_{S\sim\rho_\mu}\left[\nabla_\theta \mu(S)\big(\nabla_a q_\mu(S,a)\big)|_{a=\mu(S)}\right]$$

对应的随机梯度上升算法为：

$$\theta_{t+1} = \theta_t + \alpha_\theta \nabla_\theta \mu(s_t)\big(\nabla_a q_\mu(s_t,a)\big)|_{a=\mu(s_t)}$$

确定性演员-评论家算法

确定性策略梯度或确定性演员-评论家

初始化： 给定行为策略$\beta(a|s)$。确定性目标策略$\mu(s,\theta_0)$，θ_0 为初始参数。值函数$q(s,a,w_0)$，w_0 为初始参数。$\alpha_w,\alpha_\theta>0$。
目标： 学习最优策略以最大化$J(\theta)$。

对每个回合中的时刻t，执行：

按β 生成a_t，然后观测r_{t+1},s_{t+1}。

TD 误差：

$$\delta_t = r_{t+1}+\gamma q(s_{t+1},\mu(s_{t+1},\theta_t),w_t)-q(s_t,a_t,w_t)$$

演员（策略更新）：

$$\theta_{t+1}=\theta_t+\alpha_\theta\nabla_\theta\mu(s_t,\theta_t)\big(\nabla_a q(s_t,a,w_t)\big)|_{a=\mu(s_t)}$$

评论家（值更新）：

$$w_{t+1}=w_t+\alpha_w\delta_t\nabla_w q(s_t,a_t,w_t)$$

确定性演员-评论家算法

注：

- 这是离策略实现，行为策略β 可以与μ 不同。
- β 也可以替换为μ+噪声。
- 如何选择表示$q(s, a, w)$ 的函数?
  - 线性函数：$q(s, a, w) = \phi^T(s, a)w$，其中$\phi(s, a)$ 为特征向量。详见DPG论文。
  - 神经网络：深度确定性策略梯度（DDPG）方法。

确定性演员-评论家算法

注：

- 这是离策略实现，行为策略β 可以与μ 不同。
- β 也可以替换为μ+噪声。
- 如何选择表示$q(s,a,w)$ 的函数?
  - 线性函数：$q(s,a,w)=\phi^T(s,a)w$，其中$\phi(s,a)$ 为特征向量。详见DPG论文。
  - 神经网络：深度确定性策略梯度（DDPG）方法。

确定性演员-评论家算法

注:

- 这是离策略实现，行为策略β 可以与μ 不同。
- β 也可以替换为μ+噪声。
- 如何选择表示$q(s,a,w)$ 的函数?
  - 线性函数：$q(s,a,w)=\phi^T(s,a)w$，其中$\phi(s,a)$ 为特征向量。详见DPG论文。
  - 神经网络：深度确定性策略梯度（DDPG）方法。

总结

- 最简单的演员-评论家
- 优势演员-评论家
- 离策略演员-评论家
- 确定性演员-评论家

结语

这是本课程的终点，也是你在强化学习领域旅程的起点！